p.303 해설 — 초록과 서론: 문제 설정

> 스캔본이라 수식 기호가 흐릿합니다. 그리스 문자 대응: 원문의 σ(시그마) = 활성화 함수, y_j = 가중치 벡터, θ_j = 편향, α_j = 출력 계수.

① **초록** — 고정된 일변수 함수와 **아핀 범함수**($y^\top x + \theta$)의 합성들의 **유한 선형결합**이 단위 초입방체 위의 임의의 n변수 연속함수를 **균등하게 근사**할 수 있음을 보인다. 단층 은닉층 신경망의 표현 가능성에 대한 **열린 문제를 해결**. 특히 **임의의 결정 영역**도 근사 가능. → 🔎 *uniformly approximate any continuous function* 에 밑줄.

② **식 (1)** ⭐ **이 논문의 주인공**

$$\sum_{j=1}^{N} \alpha_j \, \sigma\left(y_j^\top x + \theta_j\right)$$

$y_j \in \mathbb{R}^n$, $\alpha_j, \theta_j \in \mathbb{R}$ 는 고정. = **은닉층 하나짜리 신경망**의 출력.

③ **시그모이드의 정의**

$$\sigma(t) \to 1 \ (t \to +\infty), \qquad \sigma(t) \to 0 \ (t \to -\infty)$$

→ 단조 증가는 요구하지 않음에 주목!

④ **주 결과 예고** — σ가 **연속 시그모이드**이면 (1) 꼴의 합들은 단위 정육면체 위 연속함수 공간에서 **조밀(dense)** 하다.

⑤ **각주** — 1988년 10월 접수, 1989년 2월 수정. 저자 소속: 일리노이 대학 슈퍼컴퓨팅 연구개발센터.

p.304 해설 — 배경: 왜 이 문제가 중요한가

① **신경망 = 합성과 중첩** — 신경망은 단순한 비선형 함수 하나를 **합성(composition)** 하고 **중첩(superposition, 선형 결합)** 한 것. 가장 단순한 비자명한 경우가 은닉층 하나 = 식 (1).

② **응용과 질문** — 패턴 분류, 시계열 예측 등에서 원하는 응답을 내도록 합성을 고른다. 그렇다면 **신경망이 실현할 수 있는 함수의 집합은 무엇인가?**

③ **공학적 비유** ⭐ — 디지털 신호처리의 기본 결과: **단위 지연 + 상수 곱셈기**로 만든 디지털 필터는 임의의 연속 전달함수를 근사한다. 이 논문은 신경망도 **같은 종류의 보편성**을 가짐을 보인다.

④ **정확한 표현은 너무 큰 요구 — 콜모고로프 정리** — 힐베르트의 13번째 문제의 해결로, 콜모고로프는 모든 n변수 연속함수가 **일변수 함수들의 유한 합성·중첩으로 정확히 표현**됨을 보였다. 하지만 거기선 **서로 다른** 비선형 함수들이 쓰인다. → 🔎 *Kolmogorov* 와 *Hilbert's 13th problem* 에 밑줄. 신경망 이론의 숨은 뿌리!

⑤ **이 논문의 입장** — **같은** 일변수 함수만 쓰고, 정확한 표현 대신 **근사**에 만족. 이렇게 보면 (1)은 **유한 푸리에 급수 근사의 일반화**.

⑥ **증명 도구의 두 계열** — (a) 함수 대수 → **스톤-바이어슈트라스** 정리, (b) 평행이동 불변 부분공간 → **타우버 정리**. 이 논문은 둘 다 예시.

⑦ **결정 영역 문제** — Nilsson은 M개 점을 임의의 두 부분집합으로 나누는 단층망이 존재함을 보였다. 일반 이론은 없었다.

p.305 해설 — 관련 연구, 증명 전략, 2절 시작

① **결정 영역** — Makhoul 외는 단층으로 **정확히** 만들 수 있는 결정 영역을 기하학적으로 분석. 이 논문은 $\mathbb{R}^n$의 **서로소인 콤팩트 집합들을 임의 정밀도로 구별**할 수 있음을 보인다 (정리 3).

② **동시대 연구들**

연구	방법
Hornik, Stinchcombe, White	**단조** 시그모이드의 완비성
Carroll & Dickinson	**라돈 변환**으로 구성적 증명
Jones	유계 시그모이드의 구성적 증명
Funahashi	푸리에 해석, 페일리-위너 이론
Cybenko (이전)	은닉층 **2개**면 충분

③ **증명 전략 요약** ⭐ **이 문단이 논문의 지도**

1. (1) 꼴의 유한합들은 연속함수 공간의 **부분공간**을 이룬다.
2. **한-바나흐 + 리스 표현 정리** → 이 부분공간을 **소멸시키는 유한 측도**가 존재.
3. 그 측도는 (1)의 **모든 항**도 소멸시켜야 하고, 이것이 σ에 대한 조건이 된다. → 🔎 *Hahn-Banach and Riesz Representation Theorems* 에 밑줄.

④ **2절 기호**

- $I_n = [0,1]^n$, $C(I_n)$ = 연속함수 공간, $\|f\|$ = **상한(균등) 노름**
- $M(I_n)$ = 유한 **부호** 정칙 보렐 측도의 공간

⑤ **목표** — $G(x) = \sum_j \alpha_j \sigma(y_j^\top x + \theta_j)$ 가 상한 노름에 대해 $C(I_n)$에서 조밀할 조건.

p.306 해설 — 정의와 정리 1 ⭐ 가장 중요한 쪽

① **정의: 판별적(discriminatory)** — 측도 $\mu \in M(I_n)$ 에 대해

$$\int_{I_n} \sigma(y^\top x + \theta)\, d\mu(x) = 0 \quad \forall\, y \in \mathbb{R}^n,\ \theta \in \mathbb{R} \implies \mu = 0$$

이면 σ를 **판별적**이라 한다. → 직관: σ로 만든 "탐침"들로 **모든 측도를 구별**할 수 있다.

② **정리 1** — σ가 연속이고 판별적이면, $G(x)$ 꼴의 합들은 $C(I_n)$에서 조밀하다. 즉 $\forall f \in C(I_n),\ \forall \varepsilon > 0$, $\exists G$:

$$|G(x) - f(x)| < \varepsilon \quad \forall x \in I_n$$

③ **증명 ✍️ 한 줄씩 노트에 옮기기**

1. S = G 꼴 함수 전체 → $C(I_n)$의 **선형 부분공간**.
2. **귀류법**: S의 폐포 R이 전체가 아니라고 가정 → R은 닫힌 **진부분공간**.
3. **한-바나흐**: $L \neq 0$ 이지만 $L(R) = L(S) = 0$ 인 유계 선형범함수 L 존재.
4. **리스 표현**: 어떤 $\mu \in M(I_n)$ 로 $L(h) = \int_{I_n} h\, d\mu$.
5. $\sigma(y^\top x + \theta) \in R$ 이므로 모든 y, θ에 대해 $\int \sigma(y^\top x + \theta)\, d\mu = 0$.
6. σ가 판별적 → $\mu = 0$ → $L = 0$. **모순**. ∎

→ 🔎 3번과 4번이 핵심. "닫힌 진부분공간이면 그것을 죽이는 0 아닌 범함수가 있다"는 한-바나흐의 따름정리.

p.307 해설 — 보조정리 1: 시그모이드는 판별적이다

① **단조성 불필요** — 실제 신경망의 시그모이드는 보통 단조 증가이지만, 이 결과에는 **단조성이 필요 없다**.

② **보조정리 1** — 유계·가측 시그모이드 함수는 판별적이다. 특히 연속 시그모이드는 판별적.

③ **증명 1단계: 계단함수로의 극한** ⭐ $\sigma_\lambda(x) = \sigma\big(\lambda(y^\top x + \theta) + \varphi\big)$ 에서 $\lambda \to +\infty$ 이면

$$\sigma_\lambda(x) \to \gamma(x) = \begin{cases} 1 & y^\top x + \theta > 0 \\ 0 & y^\top x + \theta < 0 \\ \sigma(\varphi) & y^\top x + \theta = 0 \end{cases}$$

→ 시그모이드를 가파르게 하면 **반공간의 지시함수**가 된다! 그림을 그려 보세요.

④ **2단계: 유계 수렴 정리** — $\Pi_{y,\theta}$ = 초평면 $\{y^\top x + \theta = 0\}$, $H_{y,\theta}$ = 열린 반공간 $\{y^\top x + \theta > 0\}$. 르베그 유계 수렴 정리로

$$0 = \int \sigma_\lambda \, d\mu \to \int \gamma \, d\mu = \sigma(\varphi)\,\mu(\Pi_{y,\theta}) + \mu(H_{y,\theta})$$

⑤ **남은 과제** — "모든 반공간의 측도가 0 $\Rightarrow \mu = 0$" 을 보여야 한다. μ가 **양의 측도라면 자명**하지만, **부호 측도**라서 어렵다. → 🔎 *This would be trivial if μ were a positive measure but here it is not* 에 밑줄.

⑥ **3단계 준비** — y를 고정하고 유계 가측함수 h에 대해 $F(h) = \int_{I_n} h(y^\top x)\, d\mu(x)$ 정의 → $L^\infty(\mathbb{R})$ 위의 유계 선형범함수.

p.308 해설 — 푸리에 변환으로 마무리, 정리 2

① **3단계: 지시함수에서 단순함수로** — h = 구간 $[\theta, \infty)$의 지시함수 → $F(h) = \mu(\Pi) + \mu(H) = 0$. 열린 구간도 마찬가지 → 선형성으로 **모든 구간의 지시함수**, 따라서 모든 **단순함수**에 대해 $F = 0$. 단순함수는 L^∞에서 조밀 → $F = 0$.

② **4단계: 푸리에 변환** ⭐ **아름다운 마무리** $h = \cos(m\cdot), \sin(m\cdot)$ 를 넣으면

$$F(c + is) = \int_{I_n} \exp(i\, m^\top x)\, d\mu(x) = 0 \quad \forall m$$

→ μ의 **푸리에 변환이 0** → $\mu = 0$. 따라서 σ는 판별적. ∎ → 🔎 푸리에 변환의 **단사성**이 결정적. 이 증명은 "근사 이론 = 조화 해석"임을 보여줌.

③ **3절: 신경망에 적용** — 정리 1 + 보조정리 1 = **노드 수와 가중치 크기에 제한이 없다면**, 은닉층 하나 + 임의의 연속 시그모이드로 연속함수를 임의 정밀도로 근사. → 🔎 *no constraints are placed on the number of nodes or the size of the weights* — 이 단서가 정리의 한계.

④ **정리 2** ⭐ **(보편 근사 정리)** — σ가 연속 시그모이드이면 $G(x) = \sum_j \alpha_j \sigma(y_j^\top x + \theta_j)$ 들은 $C(I_n)$에서 조밀하다.

⑤ **결정 함수** — I_n을 k개의 서로소 가측 집합 $P_1, \ldots, P_k$로 분할하고 $f(x) = j \iff x \in P_j$ 로 정의 → **분류 문제**.

p.309 해설 — 정리 3: 분류 문제

① **정리 3** — 임의의 유한 가측 분할의 결정 함수 f와 $\varepsilon > 0$ 에 대해, G와 집합 $D \subset I_n$ 이 존재하여

$$m(D) > 1 - \varepsilon, \qquad |G(x) - f(x)| < \varepsilon \ \ (x \in D)$$

(m = 르베그 측도)

② **증명 — 루진 정리 활용** — 루진 정리: 가측 함수는 **거의 모든 곳에서 연속함수와 같다**. 즉 연속 h와 $m(D) > 1 - \varepsilon$ 인 D가 있어 D 위에서 $h = f$. 정리 2로 $|G - h| < \varepsilon$ 인 G를 찾으면 D 위에서 $|G - f| < \varepsilon$. ∎ → 🔎 *Lusin's theorem* 에 밑줄. 짧지만 강력한 증명.

③ **해석** — 연속 함수로 불연속 결정을 하므로 **어떤 점들은 반드시 틀린다**. 하지만 틀린 점들의 **전체 측도**는 원하는 만큼 작게 할 수 있다. → 이런 종류로는 가장 강한 결과.

④ **닫힌 집합 하나의 경우 (구성적 논의)** — $\Delta(x, D) = \min_{y \in D} |x - y|$ (거리 함수, 연속)로

$$f_\varepsilon(x) = \max\left(0,\ \frac{\varepsilon - \Delta(x, D)}{\varepsilon}\right)$$

를 만들면 D 위에서 1, D에서 ε보다 먼 곳에서 0인 연속함수. $|G - f_\varepsilon| < \frac{1}{2}$ 인 G로 판정하면, D **안의 점과 D에서 충분히 먼 점은 모두 정확히 분류**된다. → 정리 3은 "틀리는 양"을, 이 논의는 "틀리는 위치"(경계 근처)를 알려준다.

p.310 해설 — 4절: 다른 활성화 함수 (1)

---

① **불연속 시그모이드 — 계단 함수(hard limiter)**: $\sigma(x) = 1\ (x > 0), 0\ (x < 0)$. 좋은 학습 알고리즘이 없어 잘 쓰이지 않지만, 고전적 **퍼셉트론**과 관련 있어 이론적으로 중요. → 역전파는 미분이 필요하므로 계단 함수는 학습이 어렵다. 이것이 **연속** 시그모이드가 쓰이는 실용적 이유.

② **정리 4** — σ가 유계 가측 시그모이드이면 G 꼴의 합들은 $L^1(I_n)$에서 조밀:

$$\|G - f\|_{L^1} = \int_{I_n} |G(x) - f(x)|\, dx < \varepsilon$$

증명은 정리 1·2와 같은 틀. 차이점: 연속함수 → 적분가능 함수, L^∞**가** L^1**의 쌍대공간**임을 사용. → 🔎 균등 수렴 대신 L^1 **수렴** — 더 약한 의미의 근사.

③ **판별성의 변형** — $h \in L^\infty$ 에 대해 $\int \sigma(y^\top x + \theta) h(x)\, dx = 0\ \forall y, \theta \Rightarrow h = 0$ a.e. $h(x)dx$ 꼴 측도가 $M(I_n)$에 속하므로 보조정리 1이 그대로 적용.

④ **정리 5** — L^1 수렴은 **측도 수렴**을 함의하므로 정리 3의 유사 결과가 일반 시그모이드에도 성립.

⑤ **스톤-바이어슈트라스 예고** — 다른 활성화 함수들도 이 정리로 비슷한 성질을 보일 수 있다.

p.311 해설 — 4절: 다른 활성화 함수 (2)

① 스톤-바이어슈트라스로 되는 경우

- **사인·코사인**: $\sin(mt), \cos(mt)$의 선형결합 = 삼각다항식 → $C(I_n)$에서 완비.
- **지수함수** $\exp(mt)$: 마찬가지 (Palm의 연구). → 🔎 보조정리 1에서 푸리에 변환의 단사성을 쓴 것이 사실 **삼각다항식의 완비성을 암묵적으로 사용**한 것이라는 지적.

② 위너 타우버 정리로 되는 경우 ⭐ — $\sigma \in L^1(\mathbb{R})$ 이고 $\int \sigma(t)\,dt \neq 0$ 이면 (1) 꼴의 합들은 L^1에서 조밀. → 시그모이드가 아니어도 된다! 예: 가우시안 모양의 "범프" 함수.

③ 증명 스케치

1. $F(g) = \int_{I_n} g(y^\top x) h(x)\,dx$ 정의.
2. $g_{\theta,s}(t) = \sigma(st + \theta)$ — σ의 **평행이동과 확대축소**. 가정에 의해 $F(g_{\theta,s}) = 0$.
3. 푸리에 변환: $\hat{g}_{\theta,s}(z) = e^{iz\theta/s}\hat{\sigma}(z/s)/s$. 확대축소 때문에 모두가 동시에 0이 될 수 있는 곳은 $z = 0$뿐인데, $\hat{\sigma}(0) = \int \sigma \neq 0$.
4. **위너 타우버 정리** → $g_{\theta,s}$들이 $L^1(\mathbb{R})$에서 조밀 → $F = 0$ → h의 푸리에 변환이 0 → $h = 0$.

④ 신기한 예시 시작 — $\sigma(x)$ = 축에 평행한 고정 직사각형의 지시함수, U = 직교행렬 → $\sigma(Ux + y)$ = **임의로 회전·이동한 직사각형**.

p.312 해설 — 직사각형 예시, 5절 요약, Table 1

① **직사각형 활성화** — 크기 조정 없이 **강체 운동(회전+이동)만** 허용해도 $\sum_j \alpha_j \sigma(U_j x + y_j)$ 가 $L^1(\mathbb{R}^n)$에서 조밀. 이유: σ의 푸리에 변환이 원점을 포함하지 않는 **격자** 위에서만 0이고, 모든 회전의 격자들의 교집합은 **공집합**. → 🔎 고전적 **폼페이우 문제(Pompeiu problem)** 와 연결. 저자는 직사각형 대신 "모서리가 있는 임의의 볼록 집합"도 될 것이라 추측.

② **5절 요약** — 판별적 일변수 함수의 유한 중첩은 단위 초입방체 위 연속함수를 균등 근사. 연속 시그모이드는 판별적. 따라서 **은닉층 하나 + 연속 시그모이드**로 임의의 연속함수를 근사(정리 2), 결정 함수도 근사(정리 3).

③ **Table 1 ⭐ 한눈에 보는 결과 지도**

활성화 함수	함수 공간	출처
연속 시그모이드	$C(I_n)$	이 논문
단조 시그모이드	$C(I_n)$	Funahashi, Hornik 외
시그모이드	$C(I_n)$	Jones
L^1, 적분 ≠ 0	$L^1(I_n)$	이 논문
연속 시그모이드	$L^2(I_n)$	Carroll & Dickinson
회전 직사각형 지시함수	$L^1(I_n)$	이 논문
$L^1(\mathbb{R}^n)$, 적분 ≠ 0 (확대·이동)	$L^1(\mathbb{R}^n)$	위너 타우버 정리

p.313 해설 — 한계와 열린 문제 ⭐ 꼭 읽기

① **존재성만 증명했다** — 이 결과들은 **존재성**에 관한 것. 남은 중요한 질문은 **실현 가능성**:

- 주어진 정확도에 **몇 개의 항(뉴런)** 이 필요한가?
- 근사할 함수의 **어떤 성질**이 필요한 뉴런 수를 결정하는가?

② **저자의 예상** — 대부분의 근사 문제는 **천문학적인 수의 항**을 필요로 할 것이다. 근거: 다차원 근사 이론과 통계를 괴롭히는 **차원의 저주**. → 🔎 *astronomical numbers of terms* 와 *curse of dimensionality* 에 밑줄. → ✍️ 생각해볼 것: 그런데 실제 딥러닝은 고차원(이미지 수백만 차원)에서 잘 작동한다. 왜일까? (힌트: Barron 1993 — 함수의 푸리에 성질이 좋으면 뉴런 수가 차원에 덜 의존. 또 실제 데이터는 저차원 다양체 위에 있다.)

③ **관련 연구** — Baum & Haussler(일반화를 위한 망 크기), Blumer 외(**VC 차원**), Valiant(**PAC 학습**). → 표현력에서 **학습 가능성**으로 넘어가는 다리.

④ **참고문헌 시작** — [A] Ash『실해석과 확률』: 이 논문에 쓰인 함수해석 도구의 출처.

핵심 용어	뜻
existence vs feasibility	존재성 vs 실현 가능성
curse of dimensionality	차원의 저주

p.314 해설 — 참고문헌과 전체 정리

참고문헌 중 주목할 것

참고문헌	왜 볼까
[K] 콜모고로프 (1957)	연속함수의 일변수 함수 중첩 표현 — 신경망 표현론의 뿌리
[MP] 민스키 & 페퍼트 『퍼셉트론』(1969)	단층 퍼셉트론의 한계 → 첫 번째 AI 겨울
[R1], [R2] 루딘 『실해석과 복소해석』, 『함수해석』	이 논문의 수학을 공부할 교과서
[RHM] 럼멜하트, 힌턴, 맥클렐랜드 (1986)	병렬 분산 처리 — 역전파 시대의 시작
[V] 밸리언트 (1984)	PAC 학습 이론

✍️ 논문 전체 정리 질문

1. 정리 1의 증명에서 **한-바나흐, 리스 표현, 판별성**이 각각 어떤 역할을 했는지 한 문장씩 써 보자.
2. 보조정리 1에서 시그모이드를 가파르게 하면 반공간 지시함수가 되는 그림을 그려 보자.
3. 왜 "양의 측도라면 자명"한가? 부호 측도에서는 무엇이 어려운가?
4. ReLU $\max(0, t)$는 시그모이드가 아니다. 그래도 보편 근사가 성립할까? (힌트: $\sigma(t) = \mathrm{ReLU}(t) - \mathrm{ReLU}(t-1)$ 은 시그모이드!)
5. ai_life **01 선형회귀**는 $\alpha\sigma(yx+\theta)$ 없이 $wx+b$ 만 쓴다. 뉴런을 하나씩 추가하면 무엇을 표현할 수 있게 될까?