p.1 해설 — 초록: 학습도 커널로 설명된다

① **출발점** — 초기화 시점의 신경망은 **무한 폭 극한에서 가우시안 과정(GP)** 과 같다 → 커널 방법과 연결된다 (Neal 1996 등).

② **주장** ⭐ — 학습 **도중**의 신경망 변화도 커널로 설명된다. 파라미터에 대해 경사하강을 하면, 네트워크 함수 f_θ 는 함수 공간의 비용(**볼록**!)에 대해 새 커널 = **신경 탄젠트 커널(NTK)** 방향의 **커널 경사**를 따른다. → 🔎 *which is convex, in contrast to the parameter cost* 에 밑줄. 파라미터 공간에서는 비볼록, 함수 공간에서는 볼록!

③ **핵심 결과 요약**

- NTK는 초기화 때 무작위이고 학습 중에 변하지만, 무한 폭에서는 **명시적인 극한 커널로 수렴**하고 **학습 내내 일정**
- 학습의 수렴 ⟺ 극한 NTK의 **양정치성**. 데이터가 구 위에 있고 비선형 함수가 다항식이 아니면 양정치임을 증명
- 최소제곱 회귀: 무한 폭에서 f_θ 는 **선형 미분방정식**을 따른다. NTK에 대한 **커널 주성분** 방향일수록 빨리 수렴 → **조기 종료**의 이론적 동기
- 수치 실험으로 넓은 망이 극한에 가깝게 행동함을 확인

④ **서론 시작** — 충분한 은닉 뉴런이 있으면 신경망은 어떤 함수든 근사할 수 있다(**보편 근사**, 이번 주 Cybenko!). 하지만 **최적화가 무엇으로 수렴하는지**는 모른다. 손실 곡면은 매우 비볼록하고 안장점이 많다. 충분히 넓은 망에는 "나쁜" 국소 최솟값이 적다는 결과들이 있다.

⑤ **학회** — NeurIPS 2018, 몬트리올. 저자: EPFL(스위스 로잔 연방공대).

p.2 해설 — 동기와 기여, 2절 신경망 설정

① 일반화의 미스터리 — 신경망은 과대 파라미터화되어도 일반화를 잘한다. 무작위 레이블도 맞출 수 있으면서 진짜 데이터에서는 테스트 정확도가 좋다 — **이번 주 Zhang 외 논문** [23]. 커널 방법도 같은 성질을 가진다 — **Belkin 외** [1]. → 🔎 이번 주 논문 세 편(Cybenko, Zhang, Belkin)이 모두 이 논문에서 만난다!

② 네 가지 기여

1. 경사하강 중 f_θ 는 극한 커널에 대한 **커널 경사하강**을 따른다. 그 커널은 **깊이, 비선형 함수, 초기화 분산에만** 의존.
2. 수렴 성질은 무한 폭 NTK의 **양정치성**과 연결. 학습 집합 밖에서의 f_θ 값도 NTK가 결정 → **일반화** 이해의 열쇠.
3. 최소제곱에서 f_θ 는 **선형 미분방정식**, 야코비안의 고유함수 = 입력 데이터의 **커널 주성분**.
4. 단위원 위의 인공 데이터와 MNIST로 수치 확인.

③ 2절 설정 — 층 0(입력)부터 L(출력)까지, 뉴런 수 $n_0, \ldots, n_L$. 비선형 함수 σ 는 립시츠이고 두 번 미분 가능, 2계 도함수 유계.

④ 실현 함수 — $F^{(L)} : \mathbb{R}^P \to \mathcal{F}$, 파라미터 θ → 함수 f_θ. 파라미터 = 연결 행렬 $W^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell+1}}$, 편향 $b^{(\ell)}$. 모두 i.i.d. $N(0,1)$ 로 초기화.

⑤ 함수 공간의 내적 — 입력 분포 p^{in} 에 대해

$$\langle f, g \rangle_{p^{in}} = \mathbb{E}_{x \sim p^{in}} \left[f(x)^\top g(x) \right]$$

p.3 해설 — NTK 매개변수화와 3절 커널 경사

① **유한 데이터** — p^{in} = 데이터 $x_1, \dots, x_N$ 의 경험분포 $\frac{1}{N}\sum_i \delta_{x_i}$.

② **신경망 정의** ⭐ **NTK 매개변수화**

$$\tilde{\alpha}^{(\ell+1)}(x;\theta) = \frac{1}{\sqrt{n_\ell}} W^{(\ell)} \alpha^{(\ell)}(x;\theta) + \beta b^{(\ell)}, \qquad \alpha^{(\ell)} = \sigma\big(\tilde{\alpha}^{(\ell)}\big)$$

$\tilde{\alpha}$ = 전활성(preactivation), α = 활성.

③ **주의 1: 고전적 정의와의 차이** — 보통은 $\frac{1}{\sqrt{n_\ell}}$ 과 β 가 없고 대신 가중치를 분산 $1/n_\ell$ (LeCun 초기화)로 초기화. **표현 가능한 함수 집합은 같지만**, 파라미터에 대한 **미분의 크기**가 달라진다. $\frac{1}{\sqrt{n_\ell}}$ 인수가 폭 → ∞ 일 때 **일관된 극한**을 얻는 열쇠. 부작용으로 연결 가중치의 영향이 줄어들어 β 로 편향과 균형. 실험: $\beta = 0.1$, 학습률 1.0 (≈ 폭 100짜리 고전 망의 학습률 0.01).

④ **비볼록 vs 볼록** ⭐ — 함수 공간의 비용 C 가 볼록이어도 합성 비용 $C \circ F^{(L)}$ 은 파라미터 공간에서 매우 비볼록. 이 논문은 **함수 공간**에서 학습을 연구한다.

⑤ **3절: 커널** — 다차원 커널 $K : \mathbb{R}^{n_0} \times \mathbb{R}^{n_0} \to \mathbb{R}^{n_L \times n_L}$, $K(x,x') = K(x',x)^\top$. 쌍선형 형식 $\langle f, g\rangle_K = \mathbb{E}_{x,x'}[f(x)^\top K(x,x') g(x')]$. **양정치**: $\|f\|_{p^{in}} > 0 \Rightarrow \|f\|_K > 0$.

⑥ **쌍대 공간** — $\mathcal{F}^*$ = $\mu = \langle d, \cdot\rangle_{p^{in}}$ 꼴의 선형 형식들. 사상 $\Phi_K : \mathcal{F}^* \to \mathcal{F}$, $f_{\mu,i}(x) = \langle d, K_{i,\cdot}(x,\cdot)\rangle_{p^{in}}$. → 이번 주 Cybenko 논문의 **쌍대 공간** 개념이 여기서도 핵심 도구로 쓰인다.

p.4 해설 — 커널 경사하강과 3.1 무작위 함수 근사

① **커널 경사** — 비용의 함수 미분 $\partial_f^{in} C|_{f_0} \in \mathcal{F}^*$, 대응 원소 $d|_{f_0}$. **커널 경사** $\nabla_K C|_{f_0} = \Phi_K\left(\partial_f^{in} C|_{f_0}\right)$. → 🔎 비용은 데이터 위에서만 정의되지만, 커널 경사는 커널 덕분에 **데이터 밖의 x로 일반화**된다!

② **커널 경사하강** $-\partial_t f(t) = -\nabla_K C|_{f(t)}$. 비용의 변화:

$$\partial_t C|_{f(t)} = -\left\langle d|_{f(t)},\ \nabla_K C|_{f(t)} \right\rangle_{p^{in}} = -\|d|_{f(t)}\|_K^2$$

→ K 가 **양정치**이면 비용이 엄격히 감소 → 임계점 수렴 보장. 비용이 볼록이고 아래로 유계이면 **전역 최솟값**으로 수렴.

③ **3.1 무작위 함수 근사** ⭐ **직관을 주는 장난감 모델** (Rahimi & Recht의 무작위 특징에서 영감 — Belkin 논문의 RFF!) — 공분산이 K 인 분포에서 무작위 함수 $f^{(p)}$ 를 P개 뽑아 선형 매개변수화:

$$F^{lin}(\theta) = \frac{1}{\sqrt{P}} \sum_{p=1}^{P} \theta_p f^{(p)}$$

④ **경사하강 = 커널 경사하강** — 파라미터 경사하강은 함수 공간에서 **탄젠트 커널**

$$\tilde{K} = \sum_{p=1}^{P} \partial_{\theta_p} F^{lin}(\theta) \otimes \partial_{\theta_p} F^{lin}(\theta) = \frac{1}{P} \sum_{p} f^{(p)} \otimes f^{(p)}$$

에 대한 커널 경사하강과 같다. $P \to \infty$ 이면 **큰수의 법칙**으로 $\tilde{K} \to K$. → ✍️ 연쇄법칙으로 $\partial_t F^{lin}(\theta(t)) = -\nabla_{\tilde{K}} C$ 를 직접 유도해 보세요.

p.5 해설 — 4절 NTK 정의, 초기화 시 극한 ⭐

① NTK 정의 ⭐ 이 논문의 주인공

$$\partial_t f_{\theta(t)} = -\nabla_{\Theta^{(L)}} C|_{f_{\theta(t)}}, \qquad \Theta^{(L)}(\theta) = \sum_{p=1}^{P} \partial_{\theta_p} F^{(L)}(\theta) \otimes \partial_{\theta_p} F^{(L)}(\theta)$$

→ 🔎 NTK = **"출력의 파라미터 기울기들의 내적"**. 두 입력 x, x' 에서 기울기 벡터가 얼마나 같은 방향인가.

② 어려움 — F^{lin} 과 달리 $F^{(L)}$ 은 **비선형** → NTK가 θ 에 의존 → 초기화 때 무작위이고 학습 중 변한다.

③ 명제 1: 초기화 시 가우시안 과정 — 립시츠 σ, $n_1, \ldots, n_{L-1} \to \infty$ 이면 출력 $f_{\theta,k}$ 들은 공분산 $\Sigma^{(L)}$ 인 **i.i.d. 중심 가우시안 과정**으로 (분포) 수렴:

$$\Sigma^{(1)}(x, x') = \frac{1}{n_0} x^\top x' + \beta^2, \qquad \Sigma^{(L+1)}(x, x') = \mathbb{E}_{f \sim N(0, \Sigma^{(L)})}\left[\sigma(f(x))\sigma(f(x'))\right] + \beta^2$$

④ 정리 1 ⭐ 첫 번째 핵심 결과 — 같은 극한에서 NTK $\Theta^{(L)}$ 은 **결정적 극한** $\Theta_\infty^{(L)} \otimes \mathrm{Id}_{n_L}$ 로 확률 수렴:

$$\Theta_\infty^{(1)} = \Sigma^{(1)}, \qquad \Theta_\infty^{(L+1)}(x, x') = \Theta_\infty^{(L)}(x, x')\, \dot{\Sigma}^{(L+1)}(x, x') + \Sigma^{(L+1)}(x, x')$$

$$\dot{\Sigma}^{(L+1)}(x, x') = \mathbb{E}_{f \sim N(0, \Sigma^{(L)})}\left[\dot{\sigma}(f(x))\dot{\sigma}(f(x'))\right]$$

→ ✍️ 이 점화식을 노트에 옮겨 쓰세요. $\dot{\sigma}$ = σ 의 도함수.

⑤ 주의 3 — 라데마허 정리로 $\dot{\sigma}$ 는 측도 0인 집합 밖에서 정의됨. 극한 NTK는 σ, **깊이, 초기화 분산**에만 의존.

p.6 해설 — 정리 2: 학습 중 불변, 양정치성, 5절 시작

① **일반화된 학습** — 파라미터가 $\partial_t \theta_p = \langle \partial_{\theta_p} F^{(L)}, d_t \rangle_{p^{in}}$ 를 따른다. 경사하강이면 $d_t = -d|_{f_\theta(t)}$. (GAN처럼 방향이 다른 망에서 올 수도 있음.) 가정: $\int_0^T \|d_t\|_{p^{in}} dt$ 가 확률적으로 유계.

② **정리 2** ⭐ **두 번째 핵심 결과** — 폭 → ∞ 이면 $t \in [0, T]$ 에서 균등하게

$$\Theta^{(L)}(t) \to \Theta_\infty^{(L)} \otimes \mathrm{Id}_{n_L}$$

→ NTK가 학습 내내 **변하지 않는다**. 따라서

$$\partial_t f_{\theta(t)} = \Phi_{\Theta_\infty^{(L)} \otimes \mathrm{Id}}\left(\langle d_t, \cdot \rangle_{p^{in}}\right)$$

③ **주의 4** ⭐ **깊은 통찰** — 넓을수록 **개별** 은닉 활성의 변화는 줄어든다. 하지만 **집단적** 변화는 의미 있다 → 아래층 파라미터도 학습한다. 정리 1 공식에서 둘째 항 $\Sigma^{(L+1)}$ = 마지막 층의 학습, 첫째 항 = **아래층들의 학습**.

④ **양정치성** — 수렴은 양정치 커널에서 보장. 마지막 층 전활성들의 생성 공간이 $\mathcal{F}$ 에서 **조밀**해지면 양정치 — 보편 근사 정리(Hornik, Leshno 등)와 연결!

⑤ **명제 2** — **다항식이 아닌** 립시츠 σ 에 대해, 극한 NTK를 단위 구 $S^{n_0 - 1}$ 로 제한하면 **양정치** (증명: 부록 A.4). → 🔎 "다항식이 아니면" — Leshno 외(1993) 보편 근사 조건과 **같은 조건**!

⑥ **5절 최소제곱 회귀** — $C(f) = \frac{1}{2}\|f - f^*\|_{p^{in}}^2$. 학습 방향의 노름이 감소하므로 정리 1·2 적용 가능. 커널 경사하강: $\partial_t f_t = \Phi_K\left(\langle f^* - f_t, \cdot \rangle_{p^{in}}\right)$.

p.7 해설 — 선형 미분방정식의 해와 조기 종료 ⭐

① **해** — 사상 $\Pi : f \mapsto \Phi_K(\langle f, \cdot \rangle_{p^{in}})$ 를 쓰면

$$f_t = f^* + e^{-t\Pi}(f_0 - f^*), \qquad e^{-t\Pi} = \sum_{k=0}^{\infty} \frac{(-t)^k}{k!} \Pi^k$$

Π 가 고유함수 $f^{(i)}$, 고윳값 λ_i 로 대각화되면 $e^{-t\Pi}$ 의 고윳값은 $e^{-t\lambda_i}$. → ✍️ 행렬 지수함수를 2×2 대각 행렬로 계산해 보세요.

② **유한 데이터에서** — $\Pi(f)_k(x) = \frac{1}{N} \sum_i \sum_{k'} f_{k'}(x_i) K_{kk'}(x_i, x)$. 양의 고유함수는 최대 Nn_L 개 = 데이터의 **커널 주성분**, 고윳값 = 그 성분이 설명하는 분산.

③ **고유공간 분해**

$$f_t = f^* + \Delta_f^0 + \sum_{i=1}^{Nn_L} e^{-t\lambda_i} \Delta_f^i$$

④ **조기 종료의 이론적 근거** ⭐ — **큰 고윳값** 방향일수록 빨리 수렴. 조기 종료 = 가장 중요한 커널 주성분에 집중하고, 작은 고윳값 방향(보통 **잡음이 많은** 방향, 예: RBF 커널에서는 **고주파** 함수)은 맞추지 않는 것. → 🔎 *Early stopping hence focuses the convergence on the most relevant kernel principal components* 에 밑줄. Zhang 논문의 "암묵적 정규화"에 대한 하나의 답!

⑤ **극한** $t \to \infty$ — f_0 가 가우시안이면 f_t 도 항상 가우시안. 그람 행렬이 가역이면

$$f_{\infty,k}(x) = \kappa_{x,k}^\top \tilde{K}^{-1} y^* + \left(f_0(x) - \kappa_{x,k}^\top \tilde{K}^{-1} y_0 \right)$$

첫째 항(평균) = 가우시안 사전분포 아래 **MAP 추정** = 정규화 → 0인 **커널 릿지 회귀**. 둘째 항 = 데이터점에서 분산이 사라지는 중심 가우시안. → Belkin 논문의 **최소 노름 보간**과 같은 해!

⑥ **6절 수치 실험 설정** — 모든 은닉층 폭 n 동일, **ReLU**, $n_0 = 2$, 입력은 **단위원** 위 (고차원 데이터는 중심화하면 노름이 거의 같다 — 각주 2: $N(0, I)$ 에서 노름 ≈ $\sqrt{n_0}$), $n_L = 1$, $\beta = 0.1$.

p.8 해설 — Figure 1, 2: 실험으로 확인하기

① **Figure 1** ⭐ **NTK가 고정된 극한으로 수렴** — 깊이 $L = 4$, 폭 $n = 500$ vs 10000. $x_0 = (1, 0)$ 고정, $x = (\cos\gamma, \sin\gamma)$ 에 대해 $\Theta^{(4)}(x_0, x)$ 를 그림. 초기화 10번, $t = 0$ 과 200 스텝 후 (학습률 1.0, 목표 $f^*(x) = x_1 x_2$).

- 넓은 망: **분산이 작고 더 매끄러움**
- 두 폭의 NTK **기댓값은 매우 비슷**
- 200 스텝 후 NTK가 **"부풀어 오름"(inflate)** — 좁은 망($n = 500$)에서 뚜렷, 넓은 망($n = 10000$)에서는 거의 고정 → 🔎 정리 2를 눈으로 보는 그림.

② **Figure 2** — 폭 $n = 50, 1000$, 각 10번 초기화, 단위원 위 **4개 점**으로 1000 스텝 학습. 큰 폭 망($n = 10000$)으로 $\Theta_\infty^{(4)}$, $\Sigma^{(4)}$ 를 근사하여 $t \to \infty$ 극한 가우시안의 10, 50, 90 백분위수를 그림.

- 두 폭 모두 평균과 분산이 **극한 분포에 가까움**
- 폭 50처럼 **비교적 좁아도** NTK가 좋은 예측 → ✍️ 4개 학습점에서 모든 곡선이 **한 점으로 모이는지** 확인 (보간!).

③ **6.3 주성분 방향의 수렴 (MNIST)** — 28×28 이미지, $n_0 = 784$. $N = 512$ 개 숫자에 대해 폭 10000 망의 NTK로 첫 3개 주성분을 **거듭제곱 반복법**으로 계산: $\lambda_1 = 0.0457$, $\lambda_2 = 0.00108$, $\lambda_3 = 0.00078$. 중심화하지 않은 커널 PCA라 첫 성분은 거의 **상수 함수**.

p.9 해설 — Figure 3과 7절 결론

① **Figure 3** — (a) 2번째·3번째 주성분 좌표로 그린 MNIST 배치 → 숫자들이 의미 있게 **군집**. (b) 직선 경로에서의 이탈. (c) 2번째 주성분 방향의 수렴.

② **실험 설계** ⭐ — 목표를 $f^* = f_\theta(0) + 0.5 f^{(2)}$ 로 설정 → 초기 차이가 **정확히 2번째 주성분**. 무한 폭 이론의 예측:

$$\|g_t\|_{p^{in}} = 0.5\, e^{-\lambda_2 t}, \qquad h_t = 0$$

(g_t = $f^{(2)}$ 방향 성분, h_t = 직교 성분) → 함수 공간에서 **직선으로** 수렴.

③ **결과** — 폭이 클수록 직선에서 **덜 벗어남** (b), 2번째 주성분 방향 궤적이 이론 극한(파란선)에 수렴 (c).

④ **놀라운 관찰** — **작은 망이 더 빨리 수렴**하는 것처럼 보인다. NTK의 "부풀어 오름" 때문: NTK에 a 를 곱하는 것 = 학습률에 a 를 곱하는 것. 넓은 망은 NTK가 안정적이라 원리적으로 더 큰 학습률을 쓸 수 있다. 스텝 수로 비교할 때 주의!

⑤ **각주 3** — $\beta = 1.0$ 을 쓰면 1·2번째 주성분 사이 간격이 약 **10배** 커져 학습이 더 어려워진다 (조건수 악화).

⑥ **7절 결론** — NTK = 경사하강 중 신경망의 **국소 동역학**을 기술하는 새 도구. 무한 폭에서 신경망 경사하강 $\Longleftrightarrow \Theta_\infty^{(L)}$ 에 대한 커널 경사하강. 일반화 이해, 깊이·비선형 함수의 영향 연구, 수렴과 양정치성의 연결, 선호 방향(주성분) 특성화.

p.10 해설 — 참고문헌 [1]~[16]

참고문헌 중 주목할 것

번호	참고문헌	왜 볼까
[1]	**Belkin, Ma, Mandal (2018)** 딥러닝을 이해하려면 커널 학습을	이번 주 Belkin 논문의 자매 논문 ⭐
[2]	Cho & Saul (2009) 딥러닝을 위한 커널 방법	arc-cosine 커널 = ReLU의 극한 커널
[4]	Daniely, Frostig, Singer (2016)	**쌍대 활성화 함수** — 부록 A.4 증명에 사용
[5]	Dauphin 외 (2014)	고차원 비볼록 최적화의 **안장점** 문제
[6], [13]	Matthews 외, Lee 외 (2018)	**깊은** 신경망 = 가우시안 과정
[8]	Dragomir, 그론월형 부등식	정리 2 증명의 핵심 도구
[11]	Hornik, Stinchcombe, White (1989)	보편 근사 (Cybenko와 동시대)
[12]	Karakida, Akaho, **Amari** (2018)	피셔 정보의 평균장 분석
[14]	**Leshno 외 (1993)**	**다항식이 아닌** 활성화면 보편 근사 ⭐
[15]	Mei, Montanari, Nguyen (2018)	2층 망의 **평균장** 관점 — NTK와 대조되는 극한
[16]	**Neal (1996)**	무한 폭 신경망 = 가우시안 과정의 원조

p.11 해설 — 참고문헌 끝, 부록 A 시작

① **남은 참고문헌** — [17] Pascanu 외 (안장점), [18] Pennington & Bahri (무작위 행렬 이론으로 본 손실 곡면), [19] **Rahimi & Recht 무작위 특징** (3.1절, Belkin 논문의 RFF), [20] Sagun 외 (과대 파라미터 망의 헤시안), [21] Schölkopf 외 (**커널 PCA**), [22] Shawe-Taylor & Cristianini (커널 방법 교과서), [23] **Zhang 외 (이번 주 논문)**.

② **부록 A: 증명 개요** — 명제 1, 정리 1·2를 증명. 극한을 **순차적으로** 취한다: 먼저 $n_1 \to \infty$, 그다음 $n_2 \to \infty$, … → 증명이 훨씬 간단해짐. ($\min(n_1, \ldots, n_{L-1}) \to \infty$ 로 강화 가능할 것.)

③ **커널의 작용소 노름**

$$\|K\|_{op} = \max_{\|f\|_{p^{in}} \le 1} \left(\mathbb{E}_{x,x'} \left[f(x)^\top K(x,x') f(x') \right] \right)^{1/2}$$

유한 데이터에서는 $Nn_L \times Nn_L$ **그람 행렬의 최대 고윳값**. 따라서 작용소 노름 수렴 = 데이터 위 점별 수렴.

④ **A.1 초기화 시 점근 — 명제 1 증명 시작 — 귀납법**. $L = 1$ 이면 은닉층이 없고 f_θ 는 입력의 무작위 아핀 함수 → 공분산 $\Sigma^{(1)} = \frac{1}{n_0} x^\top x' + \beta^2$ 인 가우시안.

p.12 해설 — 명제 1 증명, 정리 1 증명 시작

① 명제 1 귀납 단계 ⭐ — $(L+1)$층 망 = L층 망 (입력 → 전활성 $\tilde{\alpha}^{(L)}$) + 비선형 σ + 무작위 아핀 사상.

1. 귀납 가정: $\tilde{\alpha}_i^{(L)}$ 는 공분산 $\Sigma^{(L)}$ 인 i.i.d. 가우시안 과정
2. $\alpha^{(L)}$ 이 주어지면 출력은 조건부로 공분산 $\tilde{\Sigma}^{(L+1)} = \frac{1}{n_L}\alpha^{(L)}(x)^\top \alpha^{(L)}(x') + \beta^2$ 인 i.i.d. 가우시안
3. **큰수의 법칙**: $n_L \to \infty$ 이면 $\tilde{\Sigma}^{(L+1)} \to \Sigma^{(L+1)} = \mathbb{E}[\sigma(f(x))\sigma(f(x'))] + \beta^2$
4. 극한 공분산이 **결정적**이라 $\alpha^{(L)}$ 과 독립 → 조건부 분포 = 무조건부 분포 ∎ → ✍️ "큰수의 법칙 + 조건부 가우시안" — 확률론의 기본 도구만으로 끝나는 우아한 증명.

② 정리 1 증명 시작 — 역시 귀납법. $L = 1$: NTK는 $W^{(0)}$, $b^{(0)}$ 성분들의 합

$$\Theta^{(1)}_{kk'}(x, x') = \frac{1}{n_0} x^\top x' \delta_{kk'} + \beta^2 \delta_{kk'} = \Sigma^{(1)}(x, x')\delta_{kk'}$$

→ 극한을 취할 필요 없음.

③ 귀납 단계 설정 — 파라미터를 처음 L층의 $\tilde{\theta}$ 와 마지막 층 $(W^{(L)}, b^{(L)})$ 로 나눈다.

p.13 해설 — 정리 1 증명 완료, A.2 학습 중 점근

① NTK를 두 부분으로 — 아래층 파라미터 $\tilde{\theta}$ 의 기여 + 마지막 층 $W^{(L)}, b^{(L)}$ 의 기여.

② 아래층 기여 (연쇄법칙)

$$\partial_{\tilde{\theta}_p} f_{\theta,k}(x) = \frac{1}{\sqrt{n_L}} \sum_{i=1}^{n_L} \partial_{\tilde{\theta}_p} \tilde{\alpha}_i^{(L)}(x;\theta)\, \dot{\sigma}\big(\tilde{\alpha}_i^{(L)}(x;\theta)\big) W_{ik}^{(L)}$$

귀납 가정으로 $\frac{1}{n_L}\sum_i \Theta_\infty^{(L)}(x,x')\dot{\sigma}(\tilde{\alpha}_i(x))\dot{\sigma}(\tilde{\alpha}_i(x'))W_{ik}^{(L)}W_{ik'}^{(L)}$ 로 수렴 → 큰수의 법칙으로 $\Theta_\infty^{(L)}(x,x')\dot{\Sigma}^{(L+1)}(x,x')\delta_{kk'}$.

③ 마지막 층 기여 → $\Sigma^{(L+1)}\delta_{kk'}$. 둘을 더하면 정리 1의 점화식 ∎ → 🔎 점화식의 두 항이 **어디서 오는지** 이제 명확: 곱셈 항 = 아래층 (연쇄법칙의 $\dot{\sigma}$ 두 개), 덧셈 항 = 마지막 층.

④ A.2 학습 중 — 학습 방향 $t \mapsto d_t$ 가 주어지면 파라미터는 i.i.d. $N(0,1)$ 로 시작해 $\partial_t \theta_p(t) = \langle \partial_{\theta_p} F^{(L)}(\theta(t)), d_t \rangle_{p^{in}}$ 를 따른다.

⑤ 정리 2 재진술과 증명 시작 — 귀납법. $L=1$ 이면 NTK가 파라미터에 의존하지 않으므로 **자명하게** 상수. 귀납 단계: $(L+1)$층 망을 L층 부분망 + 마지막 층으로 나누고, 부분망의 학습 방향이 확률적으로 유계임을 보여야 함 → $\|\frac{1}{\sqrt{n_L}} W^{(L)}(t)\|_{op}$ 를 유계로 해야 함.

p.14 해설 — 보조정리 1과 그론월 부등식

① **보조정리 1** ⭐ — 깊이 $L+1$ 망에서 모든 $\ell = 1, \dots, L$ 에 대해 확률 수렴:

$$\lim_{n_L \to \infty} \cdots \lim_{n_1 \to \infty} \sup_{t \in [0,T]} \frac{1}{\sqrt{n_\ell}} \left\| W^{(\ell)}(t) - W^{(\ell)}(0) \right\|_{op} = 0$$

→ 🔎 가중치 행렬이 (정규화된 크기로) **거의 움직이지 않는다** = **"게으른 학습(lazy training)"** 의 수학적 진술.

② **초기 가중치 유계** — 큰수의 법칙으로 $W^{(L)}(0)$ 의 각 행의 노름이 유계 → $\| \frac{1}{\sqrt{n_L}} W^{(L)}(0) \|_{op}$ 유계. 따라서 귀납 가정을 부분망에 적용 가능 → 부분망은 **상수 커널** $\Theta_\infty^{(L)}$ 로 학습.

③ **마지막 층 가중치의 변화** — 코시-슈바르츠로 열 $W_i^{(L)}(t)$ 의 변화와 활성 $\alpha_i^{(L)}(t)$ 의 변화를 함께 상한하는 양 $A(t)$ 를 정의.

④ **그론월 보조정리** ⭐ **미분방정식 부등식의 핵심 도구**

$$A(t) \le A(0) \exp\left(\frac{\text{상수}}{\sqrt{n_L}} \int_0^t \|d_s\|_{p^{in}} ds \right)$$

지수 안의 값이 $n_L \to \infty$ 이면 0으로 수렴 → $A(t) \to A(0)$. 활성과 가중치의 변화가 $O(1/\sqrt{n_L})$ 로 0에 수렴.
→ ✍️ 그론월 부등식: $u'(t) \le \beta(t) u(t)$ 이면 $u(t) \le u(0) \exp \int_0^t \beta$. 직접 증명해 보세요 ($\frac{d}{dt}[u e^{-\int \beta}] \le 0$).

p.15 해설 — 정리 2 증명 완료와 흥미로운 해석

① **NTK의 변화 통제** — 마지막 층 편향에 대한 미분은 상수 $\delta_{jj'}$. 연결 가중치에 대한 미분 $\frac{1}{\sqrt{n_L}}\alpha_i^{(L)}(x;\theta)\delta_{jj'}$ — 활성이 $O(1/\sqrt{n_L})$ 로 변하므로 이 기여는 $n_L^{-3/2}$ 속도로 변한다.

② **아래층 기여** — 귀납 가정으로 부분망 NTK는 $\Theta_\infty^{(L)}$ 로 수렴. 남은 것은 $\dot\sigma(\tilde\alpha_i)W_{ij}$ 들이 $1/\sqrt{n_L}$ 속도로 변한다는 것 → $\ddot\sigma$ 가 유계이므로 성립 ∎

③ **반직관적 결론** ⭐ **꼭 생각해 볼 문단** — 폭이 커지면 은닉층 활성 $\alpha^{(\ell)}$ 의 학습 중 변화가 **0으로 간다**. 보통 은닉층의 목적은 데이터의 **"좋은 표현"을 학습**하는 것이라고 여기는데! 하지만 개별 활성의 변화는 작아도 **뉴런 수가 늘어** 집단적 효과는 크다. → 🔎 *It is somewhat counterintuitive* 문단 전체에 표시. → ✍️ 비판적 질문: 그렇다면 NTK 영역에서는 **특징 학습(feature learning)** 이 일어나지 않는다. 실제 유한 폭 망이 커널 방법보다 나은 이유는? (힌트: 평균장 극한 [15], μP)

④ **각주 4** — 결과적으로 전활성은 학습 중에도 **같은 공분산 $\Sigma^{(\ell)}$ 의 가우시안**으로 남는다.

⑤ **A.3 사전 통제** — 보조정리 1의 증명.

p.16 해설 — 보조정리 1 증명 (1)

① **전략** — 모든 ℓ 에 대해 **동시에** 증명. 활성 $\alpha^{(\ell)}$ 의 변화를 아래층으로 **역전파된 학습 방향** $d^{(1)}, \dots, d^{(L)}$ 과 부분망의 NTK로 표현.

② **1단계: 층별 진화 방정식** — 전활성과 가중치의 시간 변화를 층별 학습 방향으로 쓴다. 층별 방향은 위층에서 아래층으로 점화식으로 정의 (= 역전파!). 부분망 NTK는

$$\Theta^{(\ell+1)} = \frac{1}{n_\ell}\dot\sigma(\cdot)W^{(\ell)\top}\Theta^{(\ell)}W^{(\ell)}\dot\sigma(\cdot) + \frac{1}{n_\ell}\alpha^{(\ell)}\otimes\alpha^{(\ell)} + \beta^2$$

꼴의 점화식을 만족.

③ **2단계: 재귀적 상한** — 활성 크기 $a^{(\ell)}(t)$, 가중치 크기 $w^{(\ell)}(t)$, 립시츠 상수 c 로

$$\|\Theta^{(1)}\|_{op} \le (a^{(0)}(t))^2 + \beta^2, \qquad \|\Theta^{(\ell+1)}\|_{op} \le c^2(w^{(\ell)}(t))^2\|\Theta^{(\ell)}\|_{op} + (a^{(\ell)}(t))^2 + \beta^2$$

→ 모든 부분망 NTK가 a, w 들의 **다항식** P 로 상한된다.

④ **3단계 준비** — 변화량들의 합

$$A(t) = \sum_k a^{(k)}(0) + w^{(k)}(0) + \tilde a^{(k)}(t) + \tilde w^{(k)}(t)$$

를 통제하면 모든 것을 통제할 수 있다.

p.17 해설 — 보조정리 1 증명 (2)과 A.4 시작

① 3단계: $A(t)$ 의 미분 상한

$$\partial_t A(t) \leq \frac{1}{\sqrt{\min\{n_1, \ldots, n_L\}}} Q\left(w^{(1)}(t), \ldots, a^{(L)}(t)\right) \left\| d_t \right\|_{p^{in}}$$

Q 는 양의 계수를 가진 다항식 → $A(t)$ 자신의 다항식으로 상한.

② 4단계: 비선형 그론월 — $A(0)$ 은 극한에서 확률적으로 유계 ($w^{(\ell)} \to 0$, $a^{(\ell)}$ 은 명제 1로 수렴). 비선형 그론월 보조정리 [8]로 $A(t)$ 는 $[0, \tau]$ 에서 균등 유계이고, 앞의 $\frac{1}{\sqrt{\min n}}$ 인수 덕분에 $\tau \to T$. 따라서 $\partial_t A \to 0$ 균등 수렴, $A(t) \to A(0)$ ∎ → 🔎 핵심 아이디어 한 줄: **"변화율이 $1/\sqrt{폭}$ 에 비례하므로 폭 → ∞ 이면 변화 없음."**

③ A.4 극한 NTK의 양정치성 — 명제 2 증명.

④ 보조정리 2 (Daniely 외 [4]) — 립시츠 함수 μ 의 **쌍대** $\hat{\mu}(\rho) = \mathbb{E}_{(X,Y)}[\mu(X)\mu(Y)]$, (X, Y) 는 분산 1, 공분산 ρ 인 중심 가우시안. μ 를 **에르미트 다항식** h_i 로 전개 $\mu = \sum_i a_i h_i$ 하면

$$\hat{\mu}(\rho) = \sum_{i=0}^{\infty} a_i^2 \rho^i$$

→ ✍️ 에르미트 다항식은 가우시안 가중치에 대한 **직교 다항식**. 확률론과 직교 함수의 만남.

p.18 해설 — 쇤베르크 정리와 명제 2 증명

① 정리 3 (쇤베르크 정리의 일반화, Gneiting [9]) — $f(\rho) = \sum_{n=0}^{\infty} b_n \rho^n$ ($b_n \geq 0$) 에 대해 커널 $K(x, x') = f(x^\top x')$ 가 **모든 차원** $n_0 \geq 1$ 의 구 위에서 양정치 $\Leftrightarrow$ b_n 이 **무한히 많은 짝수** n 과 **무한히 많은 홀수** n 에서 엄격히 양수. → 🔎 구 위의 양정치 함수를 **거듭제곱급수 계수**로 판정하는 고전 정리.

② 명제 2 증명

1. **분해**: $\Theta_\infty^{(L+1)} = \dot{\Sigma}^{(L+1)} \Theta_\infty^{(L)} + \Sigma^{(L+1)}$. 첫째 항은 두 양반정치 커널의 곱이라 **양반정치** → $\Sigma^{(L+1)}$ 이 양정치면 $\Theta_\infty^{(L+1)}$ 도 양정치.
2. **위로 전파**: 계수 c_i 와 서로 다른 점 x_i 에 대해

$$\sum_{i,j} c_i c_j \Sigma^{(L+1)}(x_i, x_j) = \mathbb{E}\Big[\Big(\sum_i c_i \sigma(f(x_i))\Big)^2\Big] + \beta^2 \Big(\sum_i c_i\Big)^2$$

   $\Sigma^{(L)}$ 이 양정치면 가우시안 $\big(f(x_i)\big)$ 가 비퇴화 → 좌변이 0이려면 모든 $c_i = 0$ (σ 가 상수가 아니므로). 귀납으로 $\Sigma^{(2)}$ 의 양정치성만 보이면 충분.
3. $\Sigma^{(2)}$ **로 환원**: 단위 구 위에서 변수변환하면 $\Sigma^{(2)}(x, x') = \hat{\mu}(x^\top x') + \beta^2$ 꼴 (보조정리 2의 쌍대).

p.19 해설 — 증명 마무리와 전체 정리

① **4단계** — μ 를 에르미트 다항식으로 전개. σ 가 **다항식이 아니므로** μ 도 다항식이 아니고, **무한히 많은** 0 아닌 계수 a_i 를 가진다.

② **5단계** — $\Sigma^{(2)}(x, x') = \nu(x^\top x')$, $\nu(\rho) = \beta^2 + \sum_i a_i^2 \rho^i$. ν 의 거듭제곱급수는 0 아닌 **짝수 항과 홀수 항을 무한히** 가진다 → 정리 3으로 $\Sigma^{(2)}$ 양정치 ∎

③ **주의 5 (역)** — σ 가 **다항식이면** 어떤 입력 차원에서 $\Theta^{(2)}$ 가 양정치가 **아니다**. → 🔎 "다항식 활성화는 왜 안 되는가?" — Cybenko·Leshno의 보편 근사 조건과 NTK의 수렴 조건이 **같은 이유**로 연결된다.

✍️ 논문 전체 정리 질문

1. 3.1절의 무작위 함수 모델에서 "파라미터 경사하강 = 커널 경사하강"을 연쇄법칙으로 유도해 보자. (p.4)
2. 정리 1의 점화식에서 두 항이 각각 어느 층의 학습을 나타내는가? (p.6, p.13)
3. $f_t = f^* + e^{-t\Pi}(f_0 - f^*)$ 에서 큰 고윳값 방향이 먼저 학습된다는 것이 조기 종료와 어떻게 연결되는가? (p.7)
4. $t \to \infty$ 해가 커널 릿지 회귀($\lambda \to 0$)이자 Belkin의 최소 노름 보간이라는 것을 확인해 보자.
5. 그론월 부등식을 증명해 보자. (p.14)
6. "개별 뉴런은 거의 안 변하지만 집단은 학습한다" — 이것은 특징 학습이 없다는 뜻인가? (p.15)
7. 이번 주 10편 중 이 논문이 연결하는 논문들을 모두 찾아 지도를 그려 보자.

핵심 용어	뜻
neural tangent kernel	신경 탄젠트 커널
kernel gradient	커널 경사
lazy training	게으른 학습
Grönwall's lemma	그론월 보조정리
Hermite polynomials	에르미트 다항식
positive definite	양정치