Adam: 확률적 최적화 방법

> 원제: *Adam: A Method for Stochastic Optimization*

항목	내용
저자	Diederik P. Kingma (University of Amsterdam), Jimmy Lei Ba (University of Toronto)
학회	ICLR 2015
분야	인공지능 수학 · 최적화 이론
난이도	★★★☆☆
링크	https://arxiv.org/abs/1412.6980
PDF 원문	arXiv PDF (무료)
ai_life 연결 단원	01 선형회귀(경사하강·학습률 슬라이더)

한 줄 요약

기울기의 1차 모멘트(평균)와 2차 모멘트(제곱 평균)를 지수이동평균으로 추정해, 파라미터마다 학습률을 자동으로 조절하는 최적화 알고리즘.

왜 중요한가

오늘날 거의 모든 딥러닝 모델(GPT 포함)이 Adam 또는 그 변형(AdamW)으로 학습됩니다. 알고리즘은 몇 줄이지만, 각 줄에 **통계적 추정**과 **스케일 불변성**이라는 수학적 이유가 숨어 있습니다.

핵심 내용

알고리즘 (논문 Algorithm 1)

기울기 $g_t = \nabla_\theta f_t(\theta_{t-1})$ 에 대해

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1-\beta_1)\, g_t && \text{(1차 모멘트: 모멘텀)} \\ v_t &= \beta_2 v_{t-1} + (1-\beta_2)\, g_t^2 && \text{(2차 모멘트: 크기)} \\ \hat{m}_t &= \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t} && \text{(편향 보정)} \\ \theta_t &= \theta_{t-1} - \alpha \frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon} \end{aligned}$$

기본값: $\alpha = 0.001,\ \beta_1 = 0.9,\ \beta_2 = 0.999,\ \epsilon = 10^{-8}$

각 단계의 수학적 의미

1. **편향 보정**: $m_0 = 0$으로 시작하므로 초기에는 0쪽으로 치우침. $\mathbb{E}[m_t] = \mathbb{E}[g](1-\beta_1^t)$ 이므로 $(1-\beta_1^t)$로 나누면 불편추정량이 됨. → **직접 유도해 보세요** (논문 3절).
2. **스케일 불변성**: 기울기를 c배 하면 $\hat{m}$도 c배, $\sqrt{\hat{v}}$도 c배 → 업데이트 크기는 그대로.
3. **유효 스텝 크기 상한**: 대략 $|\Delta\theta| \lesssim \alpha$ → α가 "신뢰 영역(trust region)" 역할.
4. **신호 대 잡음비(SNR)**: $\hat{m}/\sqrt{\hat{v}}$는 기울기 방향이 얼마나 확실한지를 나타냄. 불확실하면 작게 움직임.

수렴 분석 (4절)

온라인 볼록 최적화 틀에서 regret $R(T) = O(\sqrt{T})$ 를 주장.

> ⚠ 주의: 이 증명에는 오류가 있다는 것이 이후 밝혀짐 (Reddi et al., 2018, *On the Convergence of Adam and Beyond*). 논문을 비판적으로 읽는 좋은 연습 대상!

읽는 순서 가이드

1. **Algorithm 1** - 먼저 알고리즘을 손으로 써 보기 (15분)
2. **2절** - 각 하이퍼파라미터의 의미 (20분)
3. **3절 편향 보정** - 기댓값 계산 직접 따라가기 (30분)
4. **4절 수렴 분석** - 정리 진술만, 그리고 Reddi et al.의 반례와 비교 (20분)
5. **6절 실험** - 그래프만 훑기

사전 지식 체크

- □ 확률적 경사하강법(SGD)과 모멘텀
- □ 지수이동평균과 기댓값 계산
- □ 볼록함수와 regret 개념 (선택)

생각해볼 질문

1. β_2가 β_1보다 훨씬 1에 가까운 이유는 무엇일까?
2. Adam의 업데이트는 대각 헤시안 근사를 사용하는 2차 방법(뉴턴법)과 어떤 점이 닮았고 어떤 점이 다른가?
3. 가중치 감쇠(L2 정규화)를 Adam에 그대로 넣으면 왜 문제가 될까? (힌트: AdamW, Loshchilov & Hutter 2019)

용어 정리

영어	한국어
first/second moment	1차/2차 모멘트
bias correction	편향 보정
exponential moving average	지수이동평균
regret bound	후회 상한
adaptive learning rate	적응적 학습률

다음에 이어 읽을 논문

- Reddi, Kale, Kumar (2018), *On the Convergence of Adam and Beyond*
- Loshchilov & Hutter (2019), *Decoupled Weight Decay Regularization* (AdamW)

✍ 나의 메모