다층 순방향 신경망은 보편 근사기이다

> 원제: *Multilayer Feedforward Networks are Universal Approximators*

항목	내용
저자	Kurt Hornik (빈 공과대학, 오스트리아), Maxwell Stinchcombe, Halbert White (UC 샌디에이고 경제학과)
학술지	Neural Networks, Vol.2, No.5, pp.359-366 (1989)
분야	인공지능 수학 · 근사 이론 · 함수해석
난이도	★★★★☆
링크	https://doi.org/10.1016/0893-6080(89)90020-8
PDF 원문	CMU 강의(10-715) 읽기 자료 PDF — 스캔본, 첫 쪽은 텍스트 층 없음
ai_life 연결 단원	01 선형회귀 심화(뉴런을 더하면 무엇을 표현할 수 있나), 03 CNN(표현력의 근거)

한 줄 요약

은닉층이 하나뿐이어도, 어떤 '찌그러뜨리는 함수(squashing function)'를 쓰든, 은닉 뉴런만 충분하면 순방향 신경망은 거의 모든 함수(보렐 가측 함수)를 원하는 정확도로 근사할 수 있다.

왜 중요한가

지난주 Cybenko(1989)가 **한-바나흐 정리**(쌍대성)로 연속 시그모이드에 대한 보편 근사를 보였다면, Hornik 외는 같은 해 **스톤-바이어슈트라스 정리**(함수 대수)라는 전혀 다른 길로, 더 **넓은** 결과를 얻었습니다:

- 활성화 함수가 **불연속**이어도 됨 (계단함수 포함)
- 근사 대상이 연속함수뿐 아니라 **가측함수**(측도 의미)와 L^p 함수까지
- 다출력·다층으로 확장

그리고 결론의 한 문장 — "응용에서의 실패는 **학습 부족, 은닉 뉴런 부족, 혹은 입력-목표 관계가 결정적이지 않기 때문**" — 은 딥러닝 실패를 진단하는 틀로 지금도 쓰입니다.

핵심 내용

1. 대상이 되는 신경망 (정의 2.1-2.3)

아핀 함수 $A(x) = w \cdot x + b$ 와 찌그러뜨리는 함수 Ψ (비감소, $\Psi(-\infty) = 0$, $\Psi(+\infty) = 1$)로

$$f(x) = \sum_{j=1}^{q} \beta_j \, \Psi\big(A_j(x)\big) \qquad (\Sigma^r(\Psi))$$

= 은닉층 1개, 출력층은 선형. 예: 계단함수 $1\{\lambda \geq 0\}$, 램프 함수, 갈랑-화이트의 **코사인 찌그러뜨리개**.

2. ΣΠ 신경망과 정리 2.1 (스톤-바이어슈트라스)

곱을 허용한 망 $f(x) = \sum_j \beta_j \prod_k G(A_{jk}(x))$ 의 집합 $\Sigma\Pi^r(G)$는 **곱에 닫혀 있는 대수**입니다. 그래서

- 점을 분리하고 (서로 다른 x, y에서 다른 값)
- 어디서도 0이 아니면

스톤-바이어슈트라스 정리에 의해 콤팩트 집합 위 연속함수 공간에서 **균등 조밀**.

$$\text{정리 2.1: } G\text{가 연속}\backslash\text{cdotp비상수이면 } \Sigma\Pi^r(G)\text{는 } C^r\text{에서 콤팩트 위 균등 조밀.}$$

3. 핵심 트릭: 곱을 없애는 코사인 (부록 Lemma A.3-A.5)

1. 아무 찌그러뜨리개 Ψ로 코사인 찌그러뜨리개를 근사 → 이것들을 더하고 빼서 구간 $[-M, M]$ 위의 $\cos$ 를 근사.
2. 삼각함수 곱셈 공식 $\cos a \cos b = \frac{1}{2}[\cos(a+b) + \cos(a-b)]$ 로 **곱을 합으로** 바꿈.
3. 따라서 곱이 없는 보통 망 $\Sigma^r(\Psi)$도 조밀 → **정리 2.4**.

4. 거리의 선택: 균등 거리와 확률 거리

$$\rho_K(f,g) = \sup_{x\in K} |f(x) - g(x)|, \qquad \rho_\mu(f,g) = \inf\{\varepsilon > 0 :\ \mu\{x : |f-g| > \varepsilon\} < \varepsilon\}$$

ρ_μ는 "**입력 분포 μ에서 크게 다를 확률이 작다**"는 뜻 = 확률수렴. μ는 입력 패턴이 나타나는 빈도(입력 환경).

5. 따름정리들

- **2.2**: $L^p(\mu)$ 근사 · **2.5**: 모든 **불 함수**를 근사 · **정리 2.5**: 서로 다른 n개 점은 은닉 뉴런 n개로 **정확히 보간** · **2.6-2.7**: 다출력·다층으로 확장.

> 💡 핵심 통찰: 증명은 "망이 만들 수 있는 함수 집합이 **충분히 풍부한 대수**를 흉내 낼 수 있다"는 것을 보이는 것뿐. 푸리에 급수가 모든 함수를 근사하듯, 신경망도 그 급수를 **품고 있다**.

6. 이 논문이 답하지 않은 것

필요한 은닉 뉴런 **개수**(근사 속도)와 입력 차원 r이 커질 때의 **스케일링** — 후속 과제로 명시 (→ Barron 1993).

읽는 순서 가이드

1. **p.359-360 초록·서론** - 민스키·페퍼트, 콜모고로프와의 관계 (15분)
2. **p.360-361 정의 2.1-2.7, 정리 2.1** - 기호를 노트에 정리 (30분)
3. **p.362 정리 2.2-2.4** - 진술만 정확히 (20분)
4. **p.363 따름정리와 결론** - 정리 2.5(보간)는 직접 그림으로 (20분)

5. **p.364-365 부록** - 정리 2.1 증명(5줄!)과 Lemma A.5만 (30분)

사전 지식 체크

- [ ] Cybenko(1989) 보편 근사 정리 (지난주)
- [ ] 스톤-바이어슈트라스 정리 (해석학)
- [ ] 콤팩트 집합, 균등수렴, 조밀(dense)
- [ ] 측도와 확률수렴, L^p 공간 (기초만)
- [ ] 삼각함수 곱→합 공식

생각해볼 질문

1. Cybenko(한-바나흐)와 Hornik(스톤-바이어슈트라스)의 증명 전략은 각각 "**존재하지 않음을 반박**"과 "**직접 구성**" 중 어느 쪽에 가까운가?
2. 정리 2.5: 점 n개를 뉴런 n개로 정확히 맞출 수 있다면, Zhang 외(2017, 지난주)의 "무작위 레이블도 외운다"는 실험과 어떻게 연결되는가?
3. 은닉층 하나면 충분한데, 왜 실제로는 **깊은** 망을 쓸까? (힌트: 필요한 뉴런 수, Liu 외 2024 KAN과 비교)
4. ReLU는 찌그러뜨리는 함수가 아니다(상한 없음). 그래도 이 논문의 틀로 보편 근사를 보일 수 있을까?

용어 정리

영어	한국어
universal approximator	보편 근사기
squashing function	찌그러뜨리는(압축) 함수
affine function	아핀 함수
Borel measurable	보렐 가측
uniformly dense on compacta	콤팩트 집합 위에서 균등 조밀
algebra (of functions)	함수 대수
separates points	점을 분리한다
convergence in probability	확률수렴

다음에 이어 읽을 논문

- Barron (1993), *Universal approximation bounds for superpositions of a sigmoidal function* — 근사 **속도**와 차원
- Leshno, Lin, Pinkus, Schocken (1993), *Multilayer feedforward networks with a nonpolynomial activation function can approximate any function* — "다항식만 아니면 된다"

✍️ 나의 메모