넓은 신경망은 깊이와 상관없이 경사하강법 아래서 선형 모델처럼 진화한다

> 원제: *Wide Neural Networks of Any Depth Evolve as Linear Models Under Gradient Descent*

항목	내용
저자	Jaehoon Lee*, Lechao Xiao* (공동 1저자), Samuel S. Schoenholz, Yasaman Bahri, Roman Novak, Jascha Sohl-Dickstein, Jeffrey Pennington (Google Brain)
학회	NeurIPS 2019
분야	인공지능 수학 · 학습 이론 · 가우시안 과정 · 신경 탄젠트 커널
난이도	★★★★★
링크	https://arxiv.org/abs/1902.06720 · 코드 https://github.com/google/neural-tangents
PDF 원문	arXiv PDF (무료) — 28쪽 (본문 9 + 참고문헌 3 + 보충자료 16)
ai_life 연결 단원	01 선형회귀 심화 ("신경망도 결국 선형 회귀?"), 03 CNN (Wide ResNet 실험)

한 줄 요약

신경망이 충분히 넓으면, 학습 내내 매개변수가 초기값 근처에서 거의 움직이지 않아 신경망을 '초기값에서의 1차 테일러 전개' — 매개변수에 대한 선형 모델 — 로 바꿔도 학습 궤적이 똑같다. 제곱 손실이면 해가 닫힌 식으로 나오고, 예측은 특정 커널의 가우시안 과정을 따른다.

왜 중요한가

지난주 Jacot 외(2018)의 NTK는 **함수 공간**에서 "무한 폭 신경망 = 커널 경사하강"을 보였습니다. 이 논문은 실제로 갱신이 일어나는 **매개변수 공간**에서 같은 이야기를 완성합니다: (1) 임의 깊이·임의 손실에서 선형화가 정확해지는 **학습률 임계값** $\eta_{critical}$을 정리로 제시, (2) 학습 중 예측 분포를 **시간에 따른 가우시안 과정**으로 명시, (3) **유한 폭** 실제 신경망(Wide ResNet 포함)에서도 선형 모델과 놀랍도록 일치함을 실험으로 확인. "비볼록 신경망 학습이 왜 잘 되는가"에 대한 가장 깔끔한 수학적 답 중 하나이며, ai_life **01 선형회귀**가 딥러닝 이론의 출발점이 될 수 있는 이유를 보여 줍니다. (같은 해 Chizat 외는 이를 "게으른 학습(lazy training)"이라 부르며 한계도 지적)

핵심 내용

1. NTK 매개변수화 (식 1)

$$\mathbf{h}^{l+1} = \mathbf{x}^l W^{l+1} + \mathbf{b}^{l+1}, \quad W_{ij}^l = \frac{\sigma_\omega}{\sqrt{n_l}}\omega_{ij}^l, \quad b_j^l = \sigma_b \beta_j^l, \quad \omega, \beta \sim \mathcal{N}(0,1)$$

$1/\sqrt{n}$ 을 가중치 밖으로 빼서 **순전파와 역전파 모두** 정규화. (표준 매개변수화에서도 결과 성립 — 보충 F)

2. 학습 동역학과 탄젠트 커널 (식 2-4)

$$\dot{\theta}_t = -\eta \nabla_\theta f_t(\mathcal{X})^\top \nabla_{f_t(\mathcal{X})}\mathcal{L}, \qquad \dot{f}_t(\mathcal{X}) = -\eta\, \hat{\Theta}_t(\mathcal{X},\mathcal{X}) \nabla_{f_t(\mathcal{X})}\mathcal{L}$$
$$\hat{\Theta}_t = \nabla_\theta f_t(\mathcal{X}) \nabla_\theta f_t(\mathcal{X})^\top \quad (\text{경험적 탄젠트 커널})$$

3. 선형화된 신경망 (식 5) ⭐

$$f_t^{lin}(x) \equiv f_0(x) + \nabla_\theta f_0(x)\big|_{\theta=\theta_0}\omega_t, \qquad \omega_t = \theta_t - \theta_0$$

= 초기 출력 + (고정된 특징 $\nabla_\theta f_0$) × (매개변수 변화). **매개변수에 대해 선형**(입력에 대해선 비선형) → 기울기를 특징으로 쓰는 **랜덤 특징 모델**.

4. 제곱 손실이면 닫힌 해 (식 8-11) ⭐⭐

$$f_t^{lin}(\mathcal{X}) = \left(I - e^{-\eta\hat{\Theta}_0 t}\right)\mathcal{Y} + e^{-\eta\hat{\Theta}_0 t} f_0(\mathcal{X})$$
$$\mu_t(x) = \hat{\Theta}_0(x,\mathcal{X})\hat{\Theta}_0^{-1}\left(I - e^{-\eta\hat{\Theta}_0 t}\right)\mathcal{Y}$$

→ 경사하강을 **돌리지 않고도** 학습 중 모든 시점의 출력을 계산! ($t \to \infty$이면 커널 회귀 $\Theta(x,\mathcal{X})\Theta^{-1}\mathcal{Y}$)

5. 무한 폭 → 가우시안 과정

- 초기 출력: 중심극한정리로 $f_0(\mathcal{X}) \sim \mathcal{N}(0, K(\mathcal{X},\mathcal{X}))$ (**NNGP**)
- 마지막 층만 학습: $t \to \infty$에서 정확한 **베이즈 사후분포**(식 13) — "샘플 후 최적화"
- 전체 학습: 따름정리 1 — 평균 $\Theta(\mathcal{X}_T,\mathcal{X})\Theta^{-1}(I - e^{-\eta\Theta t})\mathcal{Y}$ 인 가우시안. 단 **어떤 확률 모델의 사후분포도 아니다**.

6. 정리 2.1·2.2: 언제 선형화가 정확한가

$$\eta < \eta_{critical} := \frac{2}{\lambda_{min}(\Theta) + \lambda_{max}(\Theta)}$$

이면 폭 $n \to \infty$에서

$$\sup_t \|f_t(x) - f_t^{lin}(x)\|, \ \sup_t \frac{\|\theta_t - \theta_0\|}{\sqrt{n}}, \ \sup_t \|\hat{\Theta}_t - \hat{\Theta}_0\|_F \ = \ O(n^{-1/2})$$

증명: (1) 과대 매개변수 신경망의 **전역 수렴**과 NTK **안정성** + (2) **그론월 부등식**.

> 💡 개별 가중치는 거의 안 움직이지만(그림 1: 입출력층 $1/\sqrt{n}$, 중간층 $1/n$), **수많은 가중치가 합심하여** 출력은 유한하게 바뀐다.

7. 실험

완전연결(그림 3), CNN(S2), MNIST 교차 엔트로피 + 모멘텀(S3), **Wide ResNet 전체 CIFAR-10**(그림 4)에서 원래 신경망과 선형 모델이 거의 일치. 유한 폭에선 해석적 커널 Θ보다 **경험적 커널** $\hat{\Theta}_0$ 이 더 정확 (변화량 $O(1/n)$ vs 편차 $O(1/\sqrt{n})$).

읽는 순서 가이드

1. **p.1-2 초록·기여 목록** - 6개 기여를 표로 (20분)
2. **p.3-4 식 (1)-(4)** - 동역학과 탄젠트 커널, Jacot 리뷰와 비교 (30분)
3. **p.4 식 (5)-(11)** - 선형화와 닫힌 해 ⭐ — 손으로 미분방정식 풀기 (40분)
4. **p.5 가우시안 과정, 따름정리 1** (30분)
5. **p.6 정리 2.1·2.2, 그림 1** (20분)
6. **p.7-9 실험·논의** - 그림 2-4 (20분)
7. 보충 **D(마지막 층만 학습)**, **E(커널 점화식)** (선택)

사전 지식 체크

- [ ] Jacot 외(2018) NTK (지난주) ⭐
- [ ] 테일러 전개, 야코비안, 행렬 지수 e^{-tA}
- [ ] 선형 상미분방정식 $\dot{\mathbf{g}} = -A\mathbf{g}$ 의 해
- [ ] 가우시안 과정 회귀: $\mu = K(x, X)K^{-1}Y$
- [ ] 중심극한정리, Neal(1994)의 "무한 폭 = GP"

생각해볼 질문

1. 선형화 모델은 "특징이 학습되지 않는" 모델이다. 그렇다면 실제 CNN이 커널 방법보다 잘하는 이유는? (힌트: 유한 폭, 큰 학습률, μP)
2. $\eta_{critical} = 2/(\lambda_{min} + \lambda_{max})$ 은 이상구 외(2023)의 "학습률이 크면 발산"과 어떤 관계인가? 2차 함수 $f = \frac{1}{2}\lambda x^2$ 에서 경사하강의 수렴 조건 $\eta < 2/\lambda$ 를 떠올려 보자.
3. 식 (9)에서 고유값이 큰 방향이 먼저 학습된다. 이것은 Nakkiran의 "에폭 방향 이중 하강"과 어떻게 연결될 수 있을까?
4. 경사하강으로 얻은 예측 분포가 "어떤 확률 모델의 사후분포도 아니다"라는 것은 무슨 뜻일까?

용어 정리

영어	한국어
linearized network	선형화된 신경망
first-order Taylor expansion	1차 테일러 전개
empirical / analytic tangent kernel	경험적 / 해석적 탄젠트 커널
NTK parameterization	NTK 매개변수화
Gaussian process (GP), NNGP	가우시안 과정, 신경망 가우시안 과정
posterior predictive	사후 예측 분포
sample-then-optimize	샘플 후 최적화
gradient flow	경사 흐름
Grönwall's inequality	그론월 부등식
lazy training	게으른 학습

다음에 이어 읽을 논문

- Chizat, Oyallon, Bach (2019), *On Lazy Training in Differentiable Programming* (NeurIPS 2019) — 선형화 영역의 한계
- Yang & Hu (2021), *Tensor Programs IV: Feature Learning in Infinite-Width Neural Networks* (ICML 2021) — μP, 무한 폭에서도 특징을 학습하는 매개변수화

✍️ 나의 메모