# p.1 해설 — 초록과 서론: 무한 폭이라는 극한

① **초록** ⭐ — 딥러닝 연구의 오랜 목표: 학습과 일반화를 **정확히** 기술하기. 복잡한 손실 지형 때문에 어려웠다. 이 논문: **넓은** 신경망에선 학습 동역학이 크게 단순해지고, **무한 폭 극한**에선 초기 매개변수 주변의 **1차 테일러 전개**로 얻은 **선형 모델**이 지배한다. → 🔎 *governed by a linear model obtained from the first-order Taylor expansion* 에 밑줄.

② **가우시안 과정 대응** — 넓은 베이즈 신경망 ↔ GP 대응처럼, 제곱 손실로 경사하강 학습한 넓은 신경망의 테스트 예측도 특정 **합성 커널**의 GP에서 뽑힌 것.

③ **유한 폭에서도** — 이론은 무한 폭에서만 정확하지만, 실제 크기 신경망에서도 원래 신경망과 선형화 버전이 **매우 잘 일치**. 구조·최적화 방법·손실에 걸쳐 견고.

④ **서론: 극한으로 단순화** — 물리학처럼 시스템의 **극한**을 보면 어려운 문제가 풀린다. 신경망의 극한 = **무한 폭**(완전연결층의 은닉 유닛 수, 합성곱층의 채널 수 → ∞).

⑤ **알려진 사실** — 무한 폭에서 초기 출력은 **GP에서 뽑힌 표본**, 제곱 손실의 정확한 베이즈 학습 후에도 GP [4-8]. 실용적으로도 넓은 신경망이 더 잘 일반화.

⑥ **이 논문** — 경사하강 아래 넓은 신경망의 학습 동역학: 가중치 공간 기술이 놀랍게 단순 — 폭이 커지면 신경망을 **초기값에서의 1차 테일러 전개**로 대체 가능 → 경사하강이 **해석적으로** 풀림.

→ ✍️ 지난주 Jacot 리뷰의 "lazy training" 💡 상자를 다시 읽고, 이 쪽의 주장과 같은 이야기임을 확인하자.

# p.2 해설 — 여섯 가지 기여와 관련 연구

① **닫힌 해와 GP** — 제곱 손실이면 학습 동역학이 닫힌 해 → 예측 분포의 진화를 GP로 기술. "샘플 후 최적화" 사후 샘플링[12]의 딥러닝 확장. 서로 다른 초기화의 유한 폭 **앙상블** 예측 변동을 정확히 모델링.

② **기여 목록** ⭐

| 기여 | 내용 |
|---|---|
| 매개변수 공간 동역학 | 넓은 신경망 학습 = 모든 매개변수에 대해 **아핀**인 모델의 학습. 손실 무관. 제곱 손실이면 시간의 닫힌 함수 |
| 선형화 충분조건 | 임계 학습률 $\eta_{critical}$보다 작으면 궤적이 선형화 궤적의 $O(n^{-1/2})$ 근방에 머묾 (정리 2.1) |
| 출력 분포 동역학 | 무한 폭에서 학습 내내 예측이 GP (정리 2.2), Jacot[13] 확장. 경사하강은 **어떤 확률 모델의 사후분포도 아님** |
| 대규모 실험 | Wide ResNet 등 실제 구조에서 정확 |
| 매개변수화 독립 | 표준·NTK 매개변수화 모두 → 효과는 **폭 증가** 때문 |
| 해석적 커널 | ReLU, erf의 NTK 계산 |
| → 🔎 *gradient descent does not generate samples from the posterior of any probabilistic model* 에 밑줄. | |

③ **코드** — Neural Tangents 라이브러리 + Colab 노트북 (가중치 공간·함수 공간 선형화). → ✍️ 각주의 Colab 노트북을 열어 실제로 돌려 보자 (무료).

④ **관련 연구** — Jacot 외[13]: 함수 공간의 **커널 경사하강**(NTK). 이 논문은 실제 갱신이 일어나는 **매개변수 공간**에서의 함의를 본다. Daniely 외: 초기화 시 유한 폭 커널과 무한 폭 커널 차이 $O(1/\sqrt{n})$. Saxe 외: **깊은 선형 신경망**(입력에 선형, 매개변수엔 비선형).

# p.3 해설 — 관련 연구(계속)와 설정

① **대조** ⭐ — Saxe의 깊은 선형망은 **입력**에 선형, 이 논문의 넓은 신경망은 **매개변수 갱신**에 선형(입력엔 보통 비선형). → 🔎 이 대조 문장에 밑줄. 헷갈리기 쉬운 포인트!

② **전역 수렴 연구** — Du 외, Allen-Zhu 외, Zou 외: 가우시안 초기화의 충분히 넓은 신경망은 SGD 중 매개변수가 초기값에서 **조금만** 움직인다 → 이 논문 효과의 핵심.

③ **평균장(mean field) 연구** — Mei 외, Chizat & Bach 등: 매개변수 분포를 **PDE**로. 은닉층 1개, 스케일 $1/n$ (이 논문은 $1/\sqrt{n}$, 현대 신경망의 관례). → ✍️ $1/n$ vs $1/\sqrt{n}$ 스케일의 차이가 "특징 학습 vs 게으른 학습"을 가른다 — 다음에 읽을 μP 논문의 주제.

④ **Chizat 외 [28]** — 무한 폭 신경망은 **"게으른 학습"** 영역이라 실제 신경망에 적용하기엔 너무 단순할 수 있다고 주장. 이 논문은 그래도 실험적으로 잘 맞음을 보인다.

⑤ **2.1 설정** — 학습 집합 $\mathcal{D}$, 입력 $\mathcal{X}$, 레이블 $\mathcal{Y}$. 은닉층 $L$개, 폭 $n_l$, 출력 $k$.

⑥ **식 (1) NTK 매개변수화** ⭐

$$\mathbf{h}^{l+1} = \mathbf{x}^l W^{l+1} + \mathbf{b}^{l+1}, \quad \mathbf{x}^{l+1} = \phi(\mathbf{h}^{l+1}), \quad W_{ij}^l = \frac{\sigma_\omega}{\sqrt{n_l}}\omega_{ij}^l, \quad b_j^l = \sigma_b \beta_j^l$$

$\omega, \beta \sim \mathcal{N}(0,1)$이 학습 변수. 표준 매개변수화는 순전파만, NTK는 **역전파도** 정규화. 둘은 층별 학습률 배율만 다르다.

⑦ **기호** — $\theta$ = 모든 매개변수 벡터, $f_t(x) \equiv \mathbf{h}^{L+1}(x)$ = 시각 $t$의 출력(로짓), 손실 $\mathcal{L} = \sum_{(x,y)\in\mathcal{D}} \ell(f_t(x,\theta), y)$ (평균 대신 **합**).

# p.4 해설 — 동역학, 선형화, 닫힌 해 ⭐⭐

**① 연속시간 경사하강 (식 2-3)**

$$\dot{\theta}_t = -\eta \nabla_\theta f_t(\mathcal{X})^\top \nabla_{f_t(\mathcal{X})} \mathcal{L}, \qquad \dot{f}_t(\mathcal{X}) = -\eta \hat{\Theta}_t \nabla_{f_t(\mathcal{X})} \mathcal{L}$$

**식 (4)** 탄젠트 커널 $\hat{\Theta}_t = \nabla_\theta f_t(\mathcal{X}) \nabla_\theta f_t(\mathcal{X})^\top = \sum_l \nabla_{\theta^l} f \, \nabla_{\theta^l} f^\top$ ($k|\mathcal{D}| \times k|\mathcal{D}|$). 유한 폭에선 초기화에 의존 → **경험적** 탄젠트 커널. 이산 경사하강은 $e^{-\eta \hat{\Theta}_0 t}$ 를 $(1 - \eta \hat{\Theta}_0)^i$ 로.

**② 식 (5) 선형화** ⭐

$$f_t^{lin}(x) \equiv f_0(x) + \nabla_\theta f_0(x)|_{\theta=\theta_0} \omega_t, \qquad \omega_t \equiv \theta_t - \theta_0$$

→ 🔎 크게 밑줄. (초기 출력, 변하지 않음) + (학습 중 변화).

**③ 식 (6)-(7)** — $\nabla_\theta f_0$ 가 **고정** → 동역학이 단순. 커널이 $\hat{\Theta}_0$ 로 고정.

**④ MSE의 닫힌 해 (식 8-11)** ⭐⭐

$$\omega_t = -\nabla_\theta f_0(\mathcal{X})^\top \hat{\Theta}_0^{-1} (I - e^{-\eta \hat{\Theta}_0 t})(f_0(\mathcal{X}) - \mathcal{Y})$$

$$f_t^{lin}(\mathcal{X}) = (I - e^{-\eta \hat{\Theta}_0 t}) \mathcal{Y} + e^{-\eta \hat{\Theta}_0 t} f_0(\mathcal{X})$$

임의의 점: $f_t^{lin}(x) = \mu_t(x) + \gamma_t(x)$, $\mu_t = \hat{\Theta}_0(x, \mathcal{X}) \hat{\Theta}_0^{-1} (I - e^{-\eta \hat{\Theta}_0 t}) \mathcal{Y}$. → **경사하강을 돌리지 않고** $\hat{\Theta}_0$, $f_0$만으로 전 과정 계산! → ✍️ 식 (9)를 유도하자: $\mathbf{g} = f_t^{lin}(\mathcal{X}) - \mathcal{Y}$ 라 두면 $\dot{\mathbf{g}} = -\eta \hat{\Theta}_0 \mathbf{g} \rightarrow \mathbf{g}(t) = e^{-\eta \hat{\Theta}_0 t} \mathbf{g}(0)$.

**⑤ 각주 7** — NTK 매개변수화에서 $\eta$는 관례보다 **폭 배** 큼 → 폭과 무관한 보편 학습률.

**⑥ 무한 폭 → GP 시작** — 중심극한정리로 초기 출력 $\{f_0(x)\}$가 다변량 가우시안으로 수렴.

# p.5 해설 — NNGP와 경사하강의 가우시안 과정

① **왜 가우시안?** — 각 층의 사전활성화 = 가우시안 변수(가중치·편향)의 **합** → 폭이 크면 가우시안 (CLT). 무작위 초기화 신경망 ↔ **NNGP**.

② **식 (12)-(13)** ⭐

$$K^{i,j}(x,x') = \lim_{\min n_l \to \infty} \mathbb{E}[f_0^i(x) f_0^j(x')], \qquad f_0(\mathcal{X}) \sim \mathcal{N}(0, K)$$

학습 데이터에 조건부:

$$\mu(x) = K(x,\mathcal{X})K^{-1}\mathcal{Y}, \quad \Sigma(x) = K(x,x) - K(x,\mathcal{X})K^{-1}K(x,\mathcal{X})^\top$$

= 무한 폭 신경망의 **정확한 베이즈 추론** 결과. → 🔎 식 (13)에 밑줄 — 가우시안 과정 회귀의 표준 공식.

③ **2.3.1 마지막 층만 학습** — $\theta^{\leq L}$을 고정하고 $\theta^{L+1}$만 최적화하면 원래 신경망 = 선형화. 무한 폭에서 $\hat{\Theta}_0 \to K$, $t \to \infty$에서 식 (10) → 식 (13) **사후분포**. = Matthews 외의 "샘플 후 최적화".

④ **전체 학습** — $\hat{\Theta}_0 \to \Theta$ (결정적 **해석적 커널**, 점화식으로 계산, ReLU·erf는 정확히). 식 (10)-(11)은 가우시안의 **아핀 변환** → 출력도 가우시안.

⑤ **따름정리 1** ⭐ — 무한 폭에서 $f_t^{lin}(x)$는

$$\mu(\mathcal{X}_T) = \Theta(\mathcal{X}_T,\mathcal{X})\Theta^{-1}(I - e^{-\eta\Theta t})\mathcal{Y}$$

와 식 (15)의 공분산을 갖는 가우시안. $t \to \infty$: 평균 $\Theta(\mathcal{X}_T,\mathcal{X})\Theta^{-1}\mathcal{Y}$ (식 16).

⑥ **해석** — 마지막 층만 학습할 때와 달리, 식 (14)-(15)는 **어떤 확률 모델의 사후분포로도 해석되지 않는다** (예외: NNGP 커널과 NTK가 상수배일 때, 예: 항등 활성화·편향 없음).

→ ✍️ NNGP($K$)와 NTK($\Theta$)를 한 줄씩 정의하고 차이를 적자: $K$=초기 출력의 공분산, $\Theta$=기울기의 내적.

# p.6 해설 — 그림 1과 정리 2.1·2.2

① **그림 1** ⭐ — 은닉층 3개 ReLU, $\eta = 1.0$, MNIST 부분집합($|\mathcal{D}| = 128$), $T = 2^{17}$ 스텝 후 상대 변화량 vs 폭 $n$ :

- 입력·출력층 가중치: $\propto 1/\sqrt{n}$ / 중간층 가중치: $\propto 1/n$ (입출력 차원은 $n$과 함께 안 커지므로)
- $\hat{\Theta}$, $\hat{K}$의 변화: 상한 $O(1/\sqrt{n})$, 실제로는 $O(1/n)$에 가까움 → 🔎 그림의 두 기울기 선($1/\sqrt{n}$, $1/n$)에 표시. "넓을수록 가중치가 덜 움직인다"의 증거.

② **정리 2.1 (비형식)** ⭐⭐ — $n_1 = \cdots = n_L = n$, $\lambda_{min}(\Theta) > 0$, 학습률

$$\eta < \eta_{critical} := \frac{2}{\lambda_{min}(\Theta) + \lambda_{max}(\Theta)}$$

이면 $\|x\| \leq 1$인 모든 $x$에 대해 높은 확률로

$$\sup_t \|f_t(x) - f_t^{lin}(x)\|_2,\ \sup_t \frac{\|\theta_t - \theta_0\|_2}{\sqrt{n}},\ \sup_t \|\hat{\Theta}_t - \hat{\Theta}_0\|_F = O(n^{-1/2}) \quad (17)$$

→ ✍️ 2차 함수 $\frac{1}{2}\lambda x^2$의 경사하강 수렴 조건 $\eta < 2/\lambda$와 비교. $\eta_{critical}$은 왜 $\lambda_{max}$만이 아니라 $\lambda_{min} + \lambda_{max}$일까? (모든 고유방향에서 수축률 $|1 - \eta\lambda|$를 균형 있게)

③ **정리 2.2** — $\eta < \eta_{critical}$이면 $f_t(x)$가 식 (14)-(15)의 가우시안으로 분포수렴.

④ **증명 두 단계** — (1) 과대 매개변수 신경망의 **전역 수렴** + NTK **안정성** (보충 G, Jacot보다 깔끔한 자체 증명), (2) **그론월형** 부등식으로 $f_t$와 $f_t^{lin}$의 차이를 $\|\hat{\Theta}_t - \hat{\Theta}_0\|_F$ 로 상계 (보충 H).

⑤ **핵심 통찰** ⭐ — 개별 가중치 갱신은 무한 폭에서 **사라지지만**, 그것들이 **합심하여** 출력에 유한한 변화를 만든다. → 🔎 *they collectively conspire to provide a finite change* 에 밑줄.

# p.7 해설 — 확장, 그림 2, 실험 시작

① **랜덤 특징 해석** — Jacot의 동역학 = **기울기를 특징으로 쓰는 랜덤 특징 방법**. (Nakkiran 부록 D의 랜덤 푸리에 특징과 비교!)

② **2.5 확장** — 보충 B: 다차원 출력, **교차 엔트로피**, **모멘텀**. 평균장 이론이 ResNet, CNN, RNN, 배치 정규화로 자연스럽게 확장된다는 문헌들 → 이론 대신 **실험**으로 다양한 구조 검증.

③ **그림 2** ⭐ — 학습 중 출력의 평균·분산이 선형화의 해석적 동역학을 따른다.

- **검은 선**: 학습된 신경망 **100개** 앙상블의 예측 분포
- **파란 영역**: 해석적 예측 (식 14, 15) = NTK-GP
- **빨간 영역**: 마지막 층만 학습 = NNGP (베이즈 사후)
- 은닉층 3개, 폭 8192, tanh, $\sigma_w^2 = 1.5$, 편향 없음, $\eta = 0.5$, $|\mathcal{D}| = 128$. 두 학습점 사이 보간 입력 $x(\alpha) = \alpha x^{(1)} + (1-\alpha)x^{(2)}$, ±2 표준편차. → ✍️ $t = 0, 16, 256, 65536$ 네 칸에서 검은 선이 파란 영역과 빨간 영역 중 어디에 더 잘 맞는지 확인하자.

④ **3절 실험 설정** — 완전연결, 합성곱, Wide ResNet. 전체·미니배치 경사하강, 연속시간 근사가 성립할 만큼 작은 학습률. CIFAR-10 이진(말 vs 비행기), MNIST·CIFAR-10 10클래스. MSE에선 이진 분류를 $\pm 1$ 회귀로. JAX와 TensorFlow, Neural Tangents 공개.

# p.8 해설 — 그림 3: 유한 폭에서도 선형 모델과 일치

① **그림 3** ⭐ — 이진 CIFAR, MSE, ReLU 완전연결 은닉층 5개, 폭 $n = 2048$, $\eta = 0.01$, $|\mathcal{D}| = 256$. 네 칸: (1) 출력 동역학 (2) **개별 가중치** 동역학 (3) 학습·테스트 손실 (4) 두 모델의 테스트 RMSE. 경험적 커널 $\hat{\Theta}$가 더 정확. → 🔎 둘째 칸(개별 가중치까지 일치!)에 밑줄.

② **예측 분포** — 앙상블의 평균·분산이 식 (14)-(15)를 잘 따름. NNGP(정확한 베이즈)는 비슷하지만 경사하강 학습 끝의 분포와 **눈에 띄게 다름**.

③ **왜 경험적 커널이 더 정확한가** ⭐

$$\|\hat{\Theta}_T^{(n)} - \hat{\Theta}_0^{(n)}\|_F = O(1/n) \;\leq\; O(1/\sqrt{n}) = \|\hat{\Theta}_0^{(n)} - \Theta\|_F$$

학습 중 커널 **변화**보다 초기 커널의 무한 폭 커널로부터의 **편차**가 더 크다.

④ **선형 모델을 직접 최적화** — ODE를 푸는 대신 $f^{lin}$의 매개변수를 직접 학습: 미니배치, 가중치 감쇠, 데이터 증강 그대로 적용 가능. 전체 MNIST(5만), 교차 엔트로피, 모멘텀(그림 S3).

⑤ **교차 엔트로피 주의** — 소프트맥스 로짓은 후반에 **무한히 커짐**(MSE는 목표값에 수렴) → 초반에 두 모델이 많이 벌어지면 후반 오차가 커짐(그림 S4).

⑥ **Wide ResNet** — 합성곱·배치 정규화·건너뛰기 연결·평균 풀링. 블록 구조를 약간 바꿔 채널 수를 **1024**로 일정하게, MSE + SGD 모멘텀, 전체 CIFAR-10 → 강한 일치 (그림 4).

# p.9 해설 — 그림 4, 데이터 크기, 논의

① **그림 4** ⭐ — Wide ResNet과 선형화가 SGD+모멘텀, MSE, CIFAR-10에서 비슷하게 행동. $N = 1$, 채널 1024, $\eta = 1.0$, $\beta = 0.9$, $k = 10$, 배치 8, **전체 5만 장**. 출력, 손실, **정확도 곡선**까지 일치. → ai_life **03 CNN**: 실제 CNN도 "넓으면 선형 회귀처럼" 학습된다!

② **데이터 크기 효과** — 폭이 무한하고 데이터가 **유한**할 때 일치. 폭↑ → 오차↓, 데이터↑ → 오차↑ (그림 S5). 데이터가 늘면 모델도 키워 상쇄 가능.

③ **4절 논의** ⭐ — 무한 폭에서 깊은 비선형 신경망의 매개변수 공간 동역학이 선형 모델로 **정확히** 기술됨. 완전연결·합성곱·Wide ResNet, 경사하강·모멘텀·미니배치, MSE·교차 엔트로피에서 실험과 일치. "놀랍도록 많은 실제 신경망이 이 영역에서 작동할지도". (층을 **재초기화**엔 강하지만 **재무작위화**엔 약하다는 Zhang 외[43]와 일치)

④ **미래 방향** — 동역학이 커널 $\hat{\Theta}$와 목표 신호로 완전히 결정되므로, $\hat{\Theta}$의 성질로 **학습 가능성과 일반화**를 연구. $K$와 $\Theta$로 경사하강의 **귀납적 편향** 이해.

⑤ **한계** ⭐ — 현대 신경망의 어떤 층은 선형화 영역에서 **멀리** 있을 수 있다. 유한 vs 무한 폭 성능 비교는 **구조 의존적**: 완전연결은 무한 폭이 비슷하거나 더 좋지만, **풀링 없는 CNN**은 반대. 무엇이 격차를 결정하는지는 열린 문제. → 🔎 *Some layers of modern neural networks may be operating far from the linearized regime* 에 밑줄.

# p.10 해설 — 참고문헌 [1]-[16]

**주목할 참고문헌**

| 번호 | 참고문헌 | 왜 볼까 |
|---|---|---|
| [2] | **He 외 (2016) ResNet** | 지난주 읽은 논문 |
| [4] | **Neal (1994)** *Priors for infinite networks* | "무한 폭 = 가우시안 과정"의 원조 ⭐ |
| [5] | **Lee 외 (2018)** *Deep neural networks as Gaussian processes* | 같은 저자의 NNGP 논문, 커널 점화식 |
| [6] | Matthews 외 (2018) | 넓은 깊은 신경망의 GP 행동 |
| [7] | Novak 외 (2019) | 채널이 많은 베이즈 CNN = GP |
| [12] | Matthews 외 (2017) | "샘플 후 최적화" 사후 샘플링 |
| [13] | **Jacot 외 (2018) NTK** | 지난주 읽은 논문 ⭐ |
| [14] | Zagoruyko & Komodakis (2016) | **Wide ResNet** — 그림 4의 구조 |
| [15] | Novak 외 (2019) **Neural Tangents** | 공개 라이브러리 |
| [16] | Daniely 외 (2016) | 초기화 커널, $O(1/\sqrt{n})$ 수렴 |

→ ✍️ [4] Neal의 아이디어를 한 문장으로: 은닉 유닛이 무한히 많은 1층 신경망에 무작위 가중치를 주면, 출력은 중심극한정리에 의해 가우시안 과정이 된다.

# p.11 해설 — 참고문헌 [17]-[34]

**주목할 참고문헌**

| 번호 | 참고문헌 | 왜 볼까 |
|---|---|---|
| [18] | Saxe, McClelland, Ganguli (2014) | 깊은 **선형** 신경망의 정확한 동역학 |
| [19] | **Du 외 (2019)** *GD finds global minima of deep NNs* | 과대 매개변수 → 전역 최소점 ⭐ |
| [20] | Allen-Zhu, Li, Song (2019) | 과대 매개변수화 수렴 이론 |
| [22] | Zou 외 (2019) | SGD가 과대 매개변수 ReLU망 최적화 |
| [23] | Mei, Montanari, Nguyen (2018, PNAS) | **평균장** 관점의 2층 신경망 |
| [24] | Chizat & Bach (2018) | 최적 수송으로 본 전역 수렴 |
| [27] | Glorot & Bengio (2010) | $1/\sqrt{n}$ 초기화의 출처 (자비에 초기화) |
| [28] | **Chizat, Oyallon, Bach (2018)** *Lazy training* | 이 논문의 한계를 지적한 동시대 연구 ⭐ |
| [31] | Park 외 (2019) | 폭과 SGD·일반화 |
| [32]-[34] | Poole·Schoenholz·Xiao 외 | 평균장 신호 전파, "10,000층 CNN 학습" |

→ ✍ [27] Glorot 초기화($\mathrm{Var}(W) \propto 1/n$)와 식 (1)의 $\sigma_\omega/\sqrt{n_l}$가 같은 아이디어임을 확인하자. 왜 분산을 $1/n$으로 줄여야 깊은 망에서 신호가 폭발/소멸하지 않을까?

# p.12 해설 — 참고문헌 [35]-[48]

### 주목할 참고문헌

| 번호 | 참고문헌 | 왜 볼까 |
|---|---|---|
| [35] | Yang & Schoenholz (2017) | 평균장 ResNet, "혼돈의 가장자리" |
| [37] | **Yang (2019)** *Scaling limits of wide NNs* | NTK 수렴의 엄밀한 증명 (Tensor Programs의 시작) |
| [38] | Dragomir (2003) | **그론월형 부등식** — 정리 2.1 증명 도구 |
| [41] | JAX (2018) | 자동 미분 — 선형화·NTK 계산이 쉬워짐 |
| [43] | Zhang, Bengio, Singer (2019) *Are all layers created equal?* | 재초기화 vs 재무작위화 |
| [44] | Qian (1999) | 모멘텀의 연속시간 극한 (보충 B.1) |
| [45] | Su, Boyd, Candès (2014) | 네스테로프 가속의 미분방정식 |
| [46] | **Cho & Saul (2009)** | ReLU 커널(arc-cosine 커널) — 보충 C |
| [47] | Williams (1997) | erf 무한 신경망 커널 — 보충 C |
| [48] | Vershynin (2010) | 무작위 행렬 비점근 분석 — 보충 G.3 |

### ✍️ 본문 정리 질문 (보충자료 들어가기 전에)

1. 식 (5)의 선형화를 그림으로: 매개변수 공간에서 곡면 $f(\theta)$를 $\theta_0$에서의 **접평면**으로 대체.
2. 식 (9)에서 $t \to \infty$ 이면 학습 데이터에서 $f = \mathcal{Y}$ (완벽 보간). 테스트 점에선 $\Theta(x, \mathcal{X})\Theta^{-1}\mathcal{Y}$ — ai_life **01 선형회귀**의 정규방정식과 비교해 보자.
3. 정리 2.1의 세 양이 모두 $O(n^{-1/2})$ 라는 것을 한 문장으로 요약.

# p.13 해설 — 보충 A: 그림 S1, S2

① **그림 S1** — 그림 2와 같은 설정에서 **개별** 초기화 100개의 학습된 함수들. 앙상블 평균·분산만이 아니라 개별 함수 궤적도 확인 가능. → ✍️ $t = 0$에서 함수들이 넓게 퍼져 있다가 학습점(검은 점)에서 모두 모이는 모습을 확인하자 — "보간".

② **그림 S2** ⭐ — **합성곱 신경망**과 그 선형화가 전체 배치 경사하강 + **모멘텀**에서 비슷하게 행동.

- 이진 CIFAR, MSE, tanh CNN 은닉층 3개, 채널 $n = 512$, 3×3 필터, 마지막 합성곱 뒤 평균 풀링
- $\eta = 0.1$, $\beta = 0.9$, $|\mathcal{D}| = 128$, $\sigma_w^2 = 2.0$, $\sigma_b^2 = 0.1$
- 선형 모델은 ODE를 적분하지 않고 모멘텀 경사하강으로 **직접** 학습 → 🔎 *trained directly by full batch gradient descent with momentum* 에 밑줄.

→ ai_life **03 CNN**: 채널 512의 3층 CNN도 선형화와 일치 — "CNN의 학습도 일종의 커널 회귀"라는 관점을 수업에 소개할 수 있을까?

# p.14 해설 — 그림 S3, S4: 교차 엔트로피

① **그림 S3** ⭐ — 신경망과 선형화가 **교차 엔트로피 + SGD 모멘텀**, **MNIST 10클래스**에서 비슷하게 행동.

- ReLU 완전연결 은닉층 2개, 폭 2048, $\eta = 1.0$, $\beta = 0.9$, $|\mathcal{D}| = 50{,}000$, $k = 10$, 배치 64
- 위 행: 무작위 데이터 하나의 **10개 로짓** 전부 → 전체 데이터, 확률적 미니배치, 비MSE 손실에서도 일치.

② **그림 S4** ⭐ — 교차 엔트로피에서 **로짓 편차**:

- 로짓은 후반에 **발산**(계속 커짐)
- 좁은 신경망($n = 32..256$, 첫 행): 초반 편차가 크면 후반 로짓 편차가 **매우 커짐**
- 넓은 신경망($n = 512..4096$, 둘째 행): 편차가 **더 늦게** 생김
- tanh 완전연결 $L = 4$, 이진 CIFAR → 🔎 *Logits ⋯ diverge at late times* 에 밑줄.

→ ✍️ 왜 교차 엔트로피에선 로짓이 무한히 커질까? 정답 클래스 확률 $\sigma(f_y) \to 1$을 위해 $f_y - f_j \to \infty$ 가 필요하기 때문. 이상구 외(2023)의 로지스틱 회귀 예제와 연결해 보자.

# p.15 해설 — 그림 S5, S6, 보충 B.1 모멘텀

① **그림 S5** ⭐ — 깊이·폭·데이터 크기에 따른 최종 RMSE(원래 vs 선형화):

- 완전연결: 깊이 1→16 (첫 칸), 데이터 32→4096 (마지막 칸)
- CNN: 깊이 1→32 / Wide ResNet: 깊이 10, 16 ($N = 1, 2$)
- 임계 초기화 $\sigma_w^2 = 2.0$, $\sigma_b^2 = 0.1$, MSE 경사하강 → 넓을수록 오차↓, 데이터가 많을수록 오차↑ (본문 p.9).

② **그림 S6** — 상대 프로베니우스 노름 변화: (위) 은닉층 1개 ReLU, 2클래스 CIFAR, $T = 2^{16}$ (아래) 3층 tanh. 그림 1과 같은 결론.

**③ 보충 B.1 모멘텀**

$$\theta_{i+1} = \theta_i + \beta(\theta_i - \theta_{i-1}) - \eta \nabla_\theta \mathcal{L}|_{\theta=\theta_i} \quad (S1)$$

$$f_{i+1}^{lin}(x) = f_i^{lin}(x) - \eta \hat{\Theta}_0(x, \mathcal{X}) \nabla_{f_i^{lin}(\mathcal{X})} \mathcal{L} + \beta(f_i^{lin}(x) - f_{i-1}^{lin}(x)) \quad (S2)$$

→ 🔎 (S2): 선형 모델에선 **출력 공간에서도** 모멘텀이 그대로 성립.

→ ✍️ Reddi 외(이번 주)의 Adam $m_t$와 여기 모멘텀 $\beta(\theta_i - \theta_{i-1})$의 차이를 비교하자 (지수이동평균 vs 직전 이동량).

# p.16 해설 — 보충 B: 모멘텀의 연속 극한, 교차 엔트로피, C: ReLU 커널

**① 연속시간 모멘텀 (S3-S4)** — Qian, Su 외처럼 $t = i\sqrt{\eta}$, $\tilde{\beta} = (\beta - 1)/\sqrt{\eta}$ 로 연속 극한 → **2계** 미분방정식. MSE면 해석적 처리 가능.

**② B.2 다차원 출력·교차 엔트로피** — 닫힌 해는 없지만 **초기값 문제**로 ODE 풀이 가능.

$$\ell(f, y) = -\sum_i y^i \log \sigma(f^i), \quad \sigma(f^i) = \frac{e^{f^i}}{\sum_j e^{f^j}}, \quad \frac{\partial \ell}{\partial \hat{y}^i} = \sigma(\hat{y}^i) - y^i$$

$$\dot{f}_t(\mathcal{X}) = -\eta \hat{\Theta}_t(\mathcal{X}, \mathcal{X})\big(\sigma(f_t(\mathcal{X})) - \mathcal{Y}\big) \quad (S8)$$

선형화는 $\hat{\Theta}_t \to \hat{\Theta}_0$ (S10-S11). dopri5 적분기 사용. → ✍️ 소프트맥스 교차 엔트로피의 기울기가 "예측 확률 – 정답"으로 깔끔하다는 것을 직접 유도해 보자.

**③ 보충 C: ReLU의 NTK** ⭐ — Cho & Saul의 공식:

$$k_n(x, y) = \frac{1}{\pi}\|x\|^n \|y\|^n J_n(\theta), \quad \theta = \arccos \frac{x \cdot y}{\|x\|\|y\|}$$

$$J_0(\theta) = \pi - \theta, \qquad J_1(\theta) = \sin\theta + (\pi - \theta)\cos\theta$$

→ 🔎 $J_0$, $J_1$에 밑줄 — "arc-cosine 커널". 두 입력 사이 **각도**만으로 커널이 결정됨.

# p.17 해설 — ReLU·erf 커널, 보충 D: 마지막 층만 학습

① **ReLU (S14-S15)** — $u = (x \cdot w, y \cdot w)$가 공분산 $\Sigma$의 가우시안일 때

$$\mathcal{T}(\Sigma) = \frac{1}{2\pi}\|x\|\|y\|J_1(\theta), \qquad \dot{\mathcal{T}}(\Sigma) = \frac{1}{2\pi}J_0(\theta)$$

(원문 식의 상수 계수를 직접 확인하자.)

② **erf (S16-S17)** — Williams(1997):

$$\mathcal{T}(\Sigma) = \frac{2}{\pi}\sin^{-1}\frac{2x \cdot y}{\sqrt{(1+2x \cdot x)(1+2y \cdot y)}}, \qquad \dot{\mathcal{T}}(\Sigma) = \frac{4}{\pi}\det(I+2\Sigma)^{-1/2}$$

③ **보충 D** ⭐ — 마지막 층만 학습하면 앙상블에 대해 출력이 학습 내내 GP이고, **GP 사전분포와 사후분포 사이의 보간**.

$$\mathbb{E}[f_t(x^*)] = K(x^*, \mathcal{X})K^{-1}(I - e^{-\eta K t})\mathcal{Y} \quad (S22)$$

$$\mathrm{Var}[f_t(x^*)] = K(x^*, x^*) - K(x^*, \mathcal{X})K^{-1}(I - e^{-2\eta K t})K(x^*, \mathcal{X})^\top \quad (S23)$$

$t \to \infty$: NNGP **사후분포**(식 13)와 **동일** → 마지막 층만 학습하면 **사후 샘플링**을 하는 셈. → 🔎 *the optimized neural network is performing posterior sampling* 에 밑줄. → ✍️ (S23)에서 $t = 0$이면 분산이 $K(x^*, x^*)$ (사전), $t \to \infty$이면 식 (13)의 $\Sigma$ (사후)임을 확인하자.

④ **보충 E 시작** — NNGP·탄젠트 커널의 점화식 (Lee 외 [5], Jacot 외 [13]).

# p.18 해설 — 보충 E: 커널 점화식, F: 표준 매개변수화

**① 핵심 함수 (S24)** — $(u, v) \sim \mathcal{N}(0, \Sigma)$:

$$\mathcal{T}(\Sigma) = \mathbb{E}[\phi(u)\phi(v)], \qquad \dot{\mathcal{T}}(\Sigma) = \mathbb{E}[\phi'(u)\phi'(v)]$$

**② NNGP 점화식 ⭐ (S26-S27)**

$$\mathcal{K}^l(x, x') = \sigma_\omega^2 \, \mathcal{T}\begin{pmatrix} \mathcal{K}^{l-1}(x,x) & \mathcal{K}^{l-1}(x,x') \\ \mathcal{K}^{l-1}(x,x') & \mathcal{K}^{l-1}(x',x') \end{pmatrix} + \sigma_b^2, \qquad \mathcal{K}^1 = \frac{\sigma_\omega^2}{n_0} x^\top x' + \sigma_b^2$$

**③ NTK 점화식 ⭐⭐ (S29)**

$$\Theta^l(x, x') = \mathcal{K}^l(x, x') + \sigma_\omega^2 \, \Theta^{l-1}(x, x') \, \dot{\mathcal{T}}(\cdots), \qquad \Theta^1 = \mathcal{K}^1$$

→ 🔎 "NTK = (이번 층의 NNGP) + (이전 층 NTK) × (활성화 도함수의 상관)" — 지난주 Jacot 논문의 핵심 공식.

**④ 증명 아이디어 (S30-S35)** — $J^l(x) = \nabla_{\theta^{\le l}} h_0^l(x)$를 이번 층과 이전 층으로 쪼갬 → 첫 항은 NNGP로, 둘째 항은 **연쇄법칙** + 귀납 가정으로.

**⑤ 보충 F** — 표준 매개변수화: $W_{ij}^l \sim \mathcal{N}(0, \sigma_\omega^2 / n_l)$ (S36). 함수 공간 결과가 표준 매개변수화에도 전이되는 이유 스케치.

→ ✍️ ReLU, 은닉층 1개, $\sigma_b = 0$일 때 $\Theta^2$를 $\mathcal{K}^1$, $\mathcal{T}$, $\dot{\mathcal{T}}$로 직접 써 보자.

# p.19 해설 — NTK vs 표준 매개변수화, 보충 G 가정

① **그림 S7** — MNIST·CIFAR, ReLU/tanh, 교차 엔트로피/MSE 조합에서 **NTK(원)** 와 **표준(삼각형)** 매개변수화가 정규화된 학습률 $\eta_{std} = \eta_{NTK}/n$에서 비슷한 정확도.

② **두 매개변수화의 관계** ⭐ — 표현하는 함수는 같지만 경사하강 동역학은 다름. 그러나 층별 학습률을

$$\eta^l_{NTK,w} = \frac{n_l}{n_{max}}\eta_0, \qquad \eta^l_{NTK,b} = \frac{1}{n_{max}}\eta_0 \quad (S37)$$

로 고르면 **동일**. 표준 신경망은 폭에 따라 학습률을 $1/n$로 줄여야 함. → 🔎 *learning dynamics are identical for networks with NTK and standard parameterizations* 에 밑줄.

③ **보충 G** — NTK로 경사하강의 **전역 수렴**과 NTK **안정성**을 간단히 증명 (표준 매개변수화 기준).

④ **가정 1-4** ⭐

1. 은닉층 폭 동일 $n_1 = \cdots = n_L = n$
2. 해석적 NTK $\Theta$가 **최대 계수**: $0 < \lambda_{min} \leq \lambda_{max} < \infty$, $\eta_{critical} = 2(\lambda_{min} + \lambda_{max})^{-1}$
3. 학습 집합이 콤팩트 집합 안, 입력이 서로 다름
4. 활성화: $|\phi(0)|$, $\|\phi'\|_\infty$, $\phi'$의 립시츠 상수 유한

→ ✍️ 가정 2가 성립하지 않으면(어떤 고유값이 0) 무슨 일이? 그 방향으로는 학습이 일어나지 않는다 — $e^{-\eta\Theta t}$에서 고유값 0인 성분은 줄지 않음.

# p.20 해설 — 그림 S8, 기호와 MSE 설정

① **그림 S8** ⭐ — **표준 매개변수화**에서도 원래 신경망과 선형화의 동역학이 거의 동일 (출력), 가중치도 비슷. MSE, ReLU 은닉층 5개, 폭 2048, $\eta = 0.005/2048$, $|\mathcal{D}| = 256$. 첫 행: 출력·가중치 동역학, 둘째 행: 손실·정확도·RMSE. → 🔎 학습률이 $0.005/2048$ — 폭으로 나눈 값임에 주목 (표준 매개변수화의 $1/n$ 스케일).

② **가정 2는 언제 성립?** — $\mathcal{X} \subseteq \{\|x\|_2 = 1\}$이고 $\phi$가 **비다항식**으로 자라면 (Jacot 외). 지난주 Leshno 외(1993) "다항식만 아니면 보편 근사"와 같은 조건!

③ **기호 (S39-S42)**

$$f(\theta_t) = f(\mathcal{X}, \theta_t), \quad g(\theta_t) = f(\mathcal{X}, \theta_t) - \mathcal{Y}, \quad J(\theta_t) = \nabla_\theta f(\theta_t)$$

$$\hat{\Theta}_t = \frac{1}{n} J(\theta_t) J(\theta_t)^\top, \qquad \Theta = \lim_{n\to\infty} \hat{\Theta}_0 \ (\text{확률수렴}, \text{Yang } [37])$$

④ **MSE (S43)** — $\mathcal{L}(t) = \frac{1}{2}\|g(\theta_t)\|_2^2$.

→ ✍️ $g$는 "잔차(residual)" 벡터다. ai_life **01 선형회귀**의 잔차 $y_i - \hat{y}_i$와 같다. 학습 = 잔차를 0으로 보내는 것.

# p.21 해설 — 보조정리 1과 정리 G.1·G.2

① **초기 잔차 유계 (S44)** — $f(\theta_0)$가 공분산 $K$의 가우시안으로 수렴하므로, 확률 $1-\delta_0$ 이상으로 $\|g(\theta_0)\|_2 < R_0$.

② **갱신식** — 경사하강 $\theta_{t+1} = \theta_t - \eta J(\theta_t)^\top g(\theta_t)$ (S45), 경사 흐름 $\dot\theta_t = -\eta J^\top g$ (S46).

③ **보조정리 1** ⭐ **(야코비안의 국소 립시츠성)** — 초기값 근방 $B(\theta_0, Cn^{-1/2})$에서

$$\frac{1}{\sqrt{n}}\|J(\theta)-J(\tilde\theta)\|_F \le K\|\theta-\tilde\theta\|_2, \qquad \frac{1}{\sqrt{n}}\|J(\theta)\|_F \le K \quad (S47)$$

→ 🔎 증명의 **유일한 기술적 열쇠**. "근방에서 기울기가 천천히 변한다".

④ **정리 G.1 (경사하강)** ⭐ — $\eta_0 < \eta_{critical}$이면 높은 확률로

$$\|g(\theta_t)\|_2 \le \left(1-\frac{\eta_0\lambda_{min}}{3}\right)^t R_0, \qquad \sum_j \|\theta_j-\theta_{j-1}\|_2 \le \frac{3KR_0}{\lambda_{min}} n^{-1/2}$$

→ 잔차는 **지수적으로** 0, 매개변수의 총 이동거리는 $O(n^{-1/2})$.

⑤ **정리 G.2 (경사 흐름)** — $\|g(\theta_t)\|_2 \le e^{-\eta_0\lambda_{min}t/3}R_0$, 이동거리도 $O(n^{-1/2})$.

⑥ **일반화 (비고 1)** — (1) 경험적 NTK가 양정치 극한으로 수렴, (2) 야코비안 국소 립시츠 — 이 둘만 성립하면 다른 구조에도 적용.

→ ✍️ $\lambda_{min}/3$의 "3"은 어디서? 경험적 커널이 해석적 커널과 $\lambda_{min}/3$ 이내라서 생기는 여유분이다 (다음 쪽).

# p.22 해설 — 정리 G.1의 증명: 귀납법

① **출발** — 높은 확률로 $\|g(\theta_0)\|_2 < R_0$ (S53), 보조정리 1 성립.

② **귀납 가정** — $t$까지 (S49) 성립한다고 가정.

③ **이동량 (S54)** — $\|\theta_{t+1} - \theta_t\|_2 \le \eta \|J(\theta_t)\|_{op} \|g(\theta_t)\|_2 \le K\eta_0 (1 - \frac{\eta_0 \lambda_{min}}{3})^t R_0\, n^{-1/2}$ → 기하급수 합으로 $\|\theta_j - \theta_0\| \le \frac{3KR_0}{\lambda_{min}} n^{-1/2}$.

④ **잔차 감소 (S55-S59)** ⭐ — **평균값 정리**:

$$g(\theta_{t+1}) = g(\theta_t) + J(\tilde{\theta}_t)(\theta_{t+1} - \theta_t) = \left(1 - \eta J(\tilde{\theta}_t) J(\theta_t)^\top\right) g(\theta_t)$$

$$\|g(\theta_{t+1})\|_2 \le \|1 - \eta J(\tilde{\theta}_t) J(\theta_t)^\top\|_{op} \, \|g(\theta_t)\|_2$$

→ 🔎 이 한 줄이 "선형 회귀의 경사하강"과 똑같은 구조!

⑤ **남은 일 (S60)** — $\|1 - \eta J(\tilde{\theta}_t) J(\theta_t)^\top\|_{op} \le 1 - \frac{\eta_0 \lambda_{min}}{3}$.

- $\eta_0 < \frac{2}{\lambda_{min} + \lambda_{max}} \Rightarrow \|1 - \eta_0 \Theta\|_{op} \le 1 - \eta_0 \lambda_{min}$ (S62)
- 삼각부등식: (해석적 커널 오차 $\le \frac{\eta_0 \lambda_{min}}{3}$) + (경험적 초기 커널 오차) + (근방에서 야코비안 변화 $\le$ 보조정리 1)
- 세 오차의 합을 $\frac{2\eta_0 \lambda_{min}}{3}$ 이하로 → $1 - \eta_0 \lambda_{min} + \frac{2\eta_0 \lambda_{min}}{3} = 1 - \frac{\eta_0 \lambda_{min}}{3}$ ✓

→ ✍️ (S62)를 직접 확인하자: $\Theta$의 고유값 $\lambda \in [\lambda_{min}, \lambda_{max}]$에 대해 $|1 - \eta_0 \lambda| \le \max(|1 - \eta_0 \lambda_{min}|, |1 - \eta_0 \lambda_{max}|)$, 그리고 $\eta_0 < \frac{2}{\lambda_{min} + \lambda_{max}}$ 이면 이 최댓값이 $1 - \eta_0 \lambda_{min}$.

# p.23 해설 — 커널 안정성, 정리 G.2 증명, 무작위 행렬

**① (S50) 커널 안정성 (S69-S72)** —

$$\frac{1}{n}\|J(\theta_0)J(\theta_0)^\top - J(\theta_t)J(\theta_t)^\top\|_F \le 2K^2\|\theta_0-\theta_t\|_2 \le \frac{6K^3R_0}{\lambda_{min}}n^{-1/2}$$

→ 학습 내내 **경험적 NTK가 $O(n^{-1/2})$ 이내로 고정**. 매개변수가 거의 안 움직이니 커널도 안 변한다.

**② G.2 경사 흐름 증명** ⭐ — **"처음 벗어나는 시각"** 논법:

$$t_1 = \inf\{t : \|\theta_t-\theta_0\|_2 \ge \frac{3KR_0}{\lambda_{min}}n^{-1/2}\}$$

$t \le t_1$ 동안 $\hat\Theta_t \succ \frac{1}{3}\lambda_{min}I$ 이므로

$$\frac{d}{dt}\|g(t)\|_2^2 = -2\eta_0 g^\top\hat\Theta_t g \le -\frac{2}{3}\eta_0\lambda_{min}\|g\|_2^2 \quad (S77)$$

→ $\|g(t)\|_2 \le e^{-\eta_0\lambda_{min}t/3}R_0$ → 이동거리가 경계에 **도달하지 못함** → 모순 → $t_1=\infty$. → 🔎 (S77)에 밑줄 — 잔차 제곱이 지수적으로 감소하는 미분부등식.

**③ G.3 보조정리 1의 증명 도구** — 정리 G.3 (Vershynin): $N\times n$ 표준정규 무작위 행렬 $A$는 확률 $1-2e^{-t^2/2}$ 이상으로

$$\sqrt{N}-\sqrt{n}-t \le \lambda_{min}(A) \le \lambda_{max}(A) \le \sqrt{N}+\sqrt{n}+t$$

→ 무작위 가중치 행렬의 연산자 노름이 $O(\sqrt{n})$ → 정규화하면 $O(1)$.

→ ✍️ "처음 벗어나는 시각" 논법을 그림으로: 반경 $r$인 공 안에서 출발한 점이 공 안에 있는 동안은 속도가 지수적으로 줄어 총 이동이 $r$보다 작다 → 영원히 공 안에 머문다.

# p.24 해설 — 보조정리 1의 증명, NTK 매개변수화판

**① 역전파 신호 (S82-S83)** — $\delta^l(\theta,x) = \nabla_{h^l} f^{L+1}(\theta,x)$ — 층 $l$의 사전활성화에 대한 출력의 기울기.

**② 가중치 노름 (S84)** — 근방 $B(\theta_0, C/\sqrt{n})$의 두 점 모두 높은 확률로 $\|W^1\|_{op} \le 3\sigma_\omega \frac{\sqrt{n}}{\sqrt{n_0}}$, $\|W^l\|_{op} \le 3\sigma_\omega$ (정리 G.3 + 삼각부등식).

**③ 두 추정 (S85-S86)** — 활성화 가정(S38)으로 귀납적으로

$$\frac{1}{\sqrt{n}}\|x^l(\theta,\mathcal{X})\|_2,\ \|\delta^l(\theta,\mathcal{X})\|_2 \le K_1, \qquad \text{차이는 } \le K_1\|\tilde{\theta}-\theta\|_2$$

(각주 13: $x^l$은 $l=1$부터 앞으로, $\delta^l$은 $l=L$부터 뒤로 귀납 — **순전파와 역전파**!)

**④ 야코비안 노름 (S87-S92)** ⭐ — 가중치에 대한 기울기 = (이전 층 활성화) × (역전파 신호)$^\top$:

$$\|J(\theta)\|_F^2 = \sum_l \left(\|J(W^l)\|_F^2 + \|J(b^l)\|_F^2\right) \le 2(L+1)K_1^4 n$$

→ $\frac{1}{\sqrt{n}}\|J\|_F \le K$. 차이도 같은 방식 (S93-S96). → 🔎 $x^{l-1}\delta^{lT}$ 구조에 밑줄 — 역전파 공식 "$\partial L/\partial W$ = 입력 × 오차신호"와 같다.

**⑤ G.4 NTK 매개변수화** — 정리 G.4: 같은 결론 (이동거리 $\le \frac{3KR_0}{\lambda_{min}} - n^{-1/2}$ 인자 없이, 매개변수화가 다르므로).

# p.25 해설 — 보조정리 2, 보충 H: 선형화와의 차이

① **보조정리 2 (NTK 매개변수화)** — 근방 $B(\theta_0, C)$에서 $\|J(\theta) - J(\tilde{\theta})\|_F \le \frac{K}{\sqrt{n}}\|\theta - \tilde{\theta}\|$, $\|J\|_F \le K$.

② **보충 H 목표** ⭐ — 원래 신경망과 선형화의 차이를 상계 (경사 흐름). $g^{lin}(t) = f_t^{lin}(\mathcal{X}) - \mathcal{Y}$, $g(t) = f_t(\mathcal{X}) - \mathcal{Y}$.

③ **정리 H.1** — 높은 확률로

$$\sup_t \|g^{lin}(t) - g(t)\|_2, \ \ \sup_t \|g^{lin}(t,x) - g(t,x)\|_2 \ \lesssim \ n^{-1/2} R_0^2$$

④ **핵심 계산 (S101-S105)** ⭐ — 적분 인자 $e^{\eta_0 \hat{\Theta}_0 t}$ 를 곱해 미분:

$$\frac{d}{dt}\left[e^{\eta_0 \hat{\Theta}_0 t}(g^{lin} - g)\right] = \eta_0 e^{\eta_0 \hat{\Theta}_0 t}(\hat{\Theta}_t - \hat{\Theta}_0) g(t)$$

적분하고 $g^{lin}(0) = g(0)$ 사용:

$$g^{lin}(t) - g(t) = -\int_0^t \eta_0 e^{\eta_0 \hat{\Theta}_0 (s-t)}(\hat{\Theta}_s - \hat{\Theta}_0)\left[(g^{lin} - g)(s) - g^{lin}(s)\right] ds$$

→ 🔎 차이의 원천은 오직 $(\hat{\Theta}_s - \hat{\Theta}_0)$ — 커널의 변화!

⑤ **노름 잡기 (S106-S112)** — $\hat{\Theta}_0$의 최소 고유값 $\lambda_0 > \frac{1}{3}\lambda_{min}$, $u(t) = e^{\lambda_0 \eta_0 t}\|g^{lin} - g\|$ 로 두면 적분부등식으로.

→ ✍️ 1차원 버전으로 연습: $\dot{y} = -ay + \epsilon(t)$ 의 해를 적분 인자 $e^{at}$로 구해 보자.

# p.26 해설 — 그론월 부등식으로 마무리

① **적분부등식 (S113)** — $u(t) \le \alpha(t) + \int_0^t \beta(s)u(s)ds$, $\alpha$ 비감소.

② **그론월 부등식** ⭐ **(S114)** —

$$u(t) \le \alpha(t) \exp\left( \int_0^t \beta(s)ds \right)$$

→ 🔎 크게 밑줄. "자기 자신에 비례해 커질 수 있는 양은 많아야 지수적으로 커진다".

③ **선형 모델의 잔차** — $\|g^{lin}(t)\|_2 \le e^{-\lambda_0\eta_0 t}\|g^{lin}(0)\|_2$ (식 9에서 바로).

④ **결합 (S118)** — $\sigma_t = \sup_{s\le t}\|\hat{\Theta}_s - \hat{\Theta}_0\|_{op}$ 로 두면

$$\|g^{lin}(t) - g(t)\|_2 \lesssim \eta_0 t\, \sigma_t\, e^{-\lambda_0\eta_0 t + \sigma_t\eta_0 t}\|g^{lin}(0)\|_2$$

⑤ **결론** ⭐ — 정리 G.1에서 $\sigma_t \lesssim n^{-1/2}R_0 \to 0$ (S119). 그러면 $e^{-\lambda_0\eta_0 t+\sigma_t\eta_0 t}\eta_0 t = O(1)$ (S120, 지수 감소가 이김) → $\|g^{lin} - g\|_2 \lesssim n^{-1/2}R_0^2 \to 0$ (S121).

⑥ **테스트 점** — 같은 방식: 차이의 미분 = (커널 변화) × (선형 잔차) + (커널) × (훈련 차이).

→ ✍️ 이 증명의 논리를 세 줄로: (1) 커널이 거의 안 변한다(보충 G) → (2) 두 ODE의 차이는 커널 변화에 비례 → (3) 그론월로 차이가 $O(n^{-1/2})$.

# p.27 해설 — 그림 S9, 보충 I·J

**① 테스트 점 마무리 (S127-S129)** — 보조정리 1로 $\|\hat{\Theta}_0(x,\mathcal{X}) - \hat{\Theta}_t(x,\mathcal{X})\|_2 \lesssim n^{-1/2}R_0$ → 테스트 점에서도 차이 $\lesssim n^{-1/2}$.

**② 그림 S9** ⭐ **(커널 수렴)** — 은닉층 1개·3개 ReLU, 무작위 초기화의 경험적 커널이 폭 $n$과 몬테카를로 표본 수 $M$이 늘수록 해석적 커널로 수렴. NNGP와 NTK 모두

$$\|\hat{\Theta}^{(n)} - \Theta\|_F = O(1/\sqrt{n}), \qquad \|\hat{K}^{(n)} - K\|_F = O(1/\sqrt{n})$$

— Daniely 외의 **중심극한정리** 예측대로. 입력 $\mathcal{N}(0,1)$, $n_0 = 1024$. → 🔎 $O(1/\sqrt{n})$ 에 밑줄 — 표본평균의 오차가 $1/\sqrt{n}$으로 주는 것과 같은 이유.

**③ 보충 J: Wide ResNet 구조 (표 S1)** — 배치정규화-ReLU-합성곱 순서.

| 그룹 | 출력 크기 | 블록 |
|---|---|---|
| conv1 | 32×32 | [3×3, 채널] |
| conv2 | 32×32 | [3×3, 3×3] × N |
| conv3 | 16×16 | [3×3, 3×3] × N |
| conv4 | 8×8 | [3×3, 3×3] × N |
| avg-pool | 1×1 | [8×8] |
| → ai_life **03 CNN**: 해상도가 32→16→8로 줄며 특징을 추출하는 전형적 CNN 구조. | | |

# p.28 해설 — 그림 S10, 전체 정리

① **그림 S10** — 은닉층 1개 ReLU의 커널이 몬테카를로 표본 수 $M$과 폭 $n$에 따라 해석적 커널로 수렴하는 2차원 지도 ($\log_2 n \times \log_2 M$). 오른쪽 위(넓고 표본 많음)로 갈수록 오차↓.

✍️ **논문 전체 정리 질문**

1. 식 (5)의 선형화 $f_t^{lin} = f_0 + \nabla_\theta f_0\, \omega_t$ 가 "매개변수에 선형, 입력에 비선형"인 이유를 설명하자.
2. MSE에서 식 (9)를 미분방정식으로부터 유도하고, $t \to \infty$일 때 학습점/테스트점의 예측을 쓰자.
3. NNGP($K$, 마지막 층만 학습 = 베이즈 사후) vs NTK-GP($\Theta$, 전체 학습 = 사후 아님) 비교표.
4. 정리 2.1의 학습률 조건 $\eta < 2/(\lambda_{min} + \lambda_{max})$를 2×2 대각 행렬 $\mathrm{diag}(\lambda_1, \lambda_2)$의 경사하강으로 직접 확인하자.
5. 증명의 뼈대 3단계(야코비안 립시츠 → 지수 수렴·작은 이동 → 그론월)를 지난주 Jacot 리뷰와 연결해 한 장에 그리자.
6. "넓은 신경망 = 선형 회귀"라면, ai_life **01 선형회귀** 단원 끝에 "신경망으로 가는 다리" 페이지를 어떻게 쓸까?