p.467 해설 — 초록과 서론: AI 이해는 기본 소양

① **초록** — 인공지능 알고리즘에서 많이 쓰이는 **경사하강법**을 대학수학 강좌의 AI 활용 사례로 쓸 수 있게 만든 교수·학습 기초자료. 미적분학 수준의 개념 설명 + 파이썬 기반 **SageMath 코드** + **선형회귀의 최소제곱문제**를 경사하강법으로 푸는 예시. → 🔎 "대학 미적분학 수준에서도 가르칠 수 있도록" 에 밑줄.

② **서론 첫 문단** — AI가 생활 속으로 들어오며 AI 이해는 **기본 소양**이 되고 있다. AI 알고리즘은 수학적 사고로 설계되었으므로 선형대수, 미적분, 확률/통계, 이산수학, 수치해석 지식이 동시에 필요.

③ **두 가지 전략** — (a) AI에 필요한 수학만 모은 **별도 강좌**(이상구 외 2020a), (b) 기존 대학수학 강좌 안에 **AI 응용 예시**를 넣기. 이 논문은 (b). 이유: 별도 강좌 개설이 어려운 대학도 있고, 배우는 수학이 현실에 쓰인다는 **학습 동기**. → 🔎 "구체적인 학습 동기를 부여" 에 밑줄 — ai_life 사이트의 목적과 같다!

④ **경사하강법이란** — 미분가능한 함수의 **극솟값**을 계산하는 대표적인 **수치적 방법**. 미적분 수업용과 상위 수학 수업용으로 수준을 나눠 개발.

⑤ **각주** — 2023.8 접수, 9.26 게재 확정. MSC 97U50-70(교육용 소프트웨어). 한국연구재단 지원. 주제어: 극값, 임계점, 경사하강법, 최소제곱.

→ ✍️ 내가 고등학교·대학교에서 배운 수학 중 "AI에 쓰인다"고 들은 적 있는 단원을 세 개 적어 보자.

p.468 해설 — 왜 미적분 수업에 경사하강법이 없나

① **현재 교재의 문제** — 경사하강법(gradient / steepest descent method)은 수치해석·계산과학에서 **간간이** 소개될 뿐.

- Burden & Faires: 연립방정식·비선형방정식의 반복 해법에서 **부분적으로**만 → **최적화**라는 본질이 안 보임
- Chapra & Canale: 방대한 방법 목록 중 하나 → 교수자에 따라 **빠질 수도** → 학생이 대학 내내 수학을 듣고도 경사하강법을 **한 번도 못 볼 수 있다**.

② **그런데도 중요한 이유** — 형식이 단순해서 **선형회귀, 로지스틱 회귀, 서포트 벡터 머신** 등에 두루 쓰인다.

③ **미적분 교재의 한계** ⭐ — 최적화 문제는 보통 (1) 임계점 계산 → (2) 이계도함수/헤시안으로 판정. 그런데 함수가 복잡하면 임계점 방정식 자체를 **손으로 못 푼다** → 교재엔 손으로 풀리는 단순한 문제만. → 🔎 "지필로 계산하기 어려운 복잡한 함수" 에 밑줄.

④ **논문 구성** — 경사하강법 소개 → SageMath 코드 → 최소제곱 예시.

⑤ **Ⅱ. 이론적 배경** — 데이터 기반 AI는 **예측값과 관측값의 오차 함수를 최소화**하는 문제. 예: 최소제곱문제

$$\min_{\mathbf{x}\in\mathbb{R}^n} \|A\mathbf{x}-\mathbf{b}\|^2 \qquad (A\in\mathbb{R}^{m\times n},\ \mathbf{b}\in\mathbb{R}^m)$$

⑥ **최솟값 vs 극솟값** — 제약이 없으면 극솟값 중 가장 작은 것이 **최솟값(global minimum)**. 하지만 **비볼록** 다변수 함수는 극솟값이 몇 개인지 몰라 찾은 극솟값이 최솟값인지 알기 어렵다 — 지금도 활발한 연구 분야.

→ ✍️ ai_life **01 선형회귀**에서 A, $\mathbf{x}$, $\mathbf{b}$는 각각 무엇에 해당하나? (A: 1과 x_i로 된 행렬, $\mathbf{x}=(a,b)$, $\mathbf{b}$: y_i)

p.469 해설 — 극솟값 판정법 총정리 (표 Ⅱ-2)

① **범위 한정** — 이 논문은 **제약 없는 극솟값** 문제만 다룬다.

② **본질은 하나** ⭐ — 변수 개수와 상관없이:

1. **페르마의 임계점 정리**: 극소점 후보는 $\nabla f(\mathbf{a}) = \mathbf{0}$
2. 임계점에서 **헤시안**의 고윳값이 모두 양수 (또는 선행 주 소행렬식이 모두 양수) → 극소

③ **1변수** — [1단계] $f'(a) = 0$, [2단계] $f''(a) > 0$ 이면 극소. 이때 헤시안은 1×1 행렬 $[f''(a)]$이므로 f''의 부호 = 고윳값의 부호 = 소행렬식의 부호.

④ **2변수** — 헤시안

$$\nabla^2 f = \begin{bmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{bmatrix}$$

$f_{xx} > 0$ 이고 $f_{xx} f_{yy} - f_{xy}^2 > 0$ 이면 극소. 또는 두 고윳값 $\lambda_1, \lambda_2 > 0$.

⑤ **n변수** — 선행 주 소행렬식 $D_1, \ldots, D_n$ 모두 양수, 또는 고윳값 $\lambda_1, \ldots, \lambda_n$ 모두 양수. → 🔎 "본질은 모두 같다" 에 밑줄.

→ ✍️ $f(x, y) = x^2 + xy + y^2$ 의 원점에서 헤시안의 고윳값을 구하고 극소인지 판정해 보자. (헤시안 $\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$, 고윳값 1, 3) → ✍️ 지난주 Jacot(NTK)의 "커널 행렬이 양정치" 조건과 여기 "헤시안이 양정치" 조건을 비교해 보자.

p.470 해설 — 연구 방법과 코시의 발견

① 수치적 방법이 필요한 이유 — 임계점 방정식 $f'(x) = 0$ 또는 $\nabla f(\mathbf{x}) = \mathbf{0}$ 이 복잡하면 손으로 못 푼다 → 수치 계산법을 **함께** 가르쳐야.

② 연구 절차 ①~⑤ ⭐

1. 다양한 전공 학생을 위한 쉬운 개념 + 간단한 예제 + **시각화**
2. 복잡한 계산 부담을 덜어 **수학적 사고와 논의**에 집중 — SageMath 코드
3. **최소제곱문제** 예시
4. 실제 AI는 **SGD**를 쓰므로 경사하강법의 **한계**도 소개
5. 필요시 전문가 검토로 보완 → 🔎 ②번 "복잡한 계산에 대한 부담을 덜어준다" 에 밑줄.

③ 역사: 코시 (1847) — 천체 궤도 계산을 위해 대수방정식을 풀려 했는데, **소거법 대신** 함수의 최솟값 문제로 바꿔 풀었다. 항상 ≥ 0인 연속함수 $u = f(x, y, z, \dots)$를 만들고, 점 $(x_0, y_0, z_0, \dots)$에서의 값을 u_0, 편도함수를 $X, Y, Z, \dots$라 둔다.

④ 각주 1 — 연립방정식을 **제곱합 함수의 최소화**로 바꾸는 예. 해가 있으면 최솟값이 0. → ✍️ 연립방정식 $x + y = 3,\ x - y = 1$ 을 $g(x, y) = (x + y - 3)^2 + (x - y - 1)^2$ 의 최소화로 바꿔 보자. 최솟값과 그 점은?

p.471 해설 — 코시의 논증과 1변수 알고리즘

① 1차 근사

$$f(x_0+\alpha,\, y_0+\beta,\, z_0+\gamma, \dots) \approx u_0 + X\alpha + Y\beta + Z\gamma + \cdots$$

② 핵심 한 줄 ⭐⭐ — 작은 $\theta > 0$로 $\alpha = -\theta X,\ \beta = -\theta Y,\ \gamma = -\theta Z$:

$$u_1 = f(x_0 - \theta X,\, y_0 - \theta Y, \dots) = u_0 - \theta\left(X^2 + Y^2 + Z^2 + \cdots\right) < u_0$$

→ 🔎 이 식에 크게 밑줄. 제곱합은 항상 양수 → **반드시 감소**. 이를 반복하면 최솟값으로 간다고 코시는 주장 (Lemaréchal 2012).

③ 1변수 문제 — $\min f(x)$, f = 목적함수 = 비용함수 = **손실함수**(이 논문은 AI 용어에 맞춰 '손실함수').

④ 반복법 — 초기 근사해 x_1 → $x_2, x_3, \dots$ → 목표: $f'(x^*) = 0$.

⑤ 표 III-1 알고리즘 ⭐

단계	내용
1	초기 근사해 x_1, 허용오차 $0 \le \epsilon \ll 1$, 학습률 $\eta > 0$, $k := 1$
2	$g_k = f'(x_k)$. $\lvert g_k \rvert \le \epsilon$ 이면 멈추고 x_k 반환
3	$x_{k+1} = x_k - \eta g_k$, $k := k + 1$, 단계 2로

⑥ 부호로 이해하기 — $g_k < 0$ (내리막이 오른쪽) → $-g_k > 0$ 이므로 **오른쪽**으로. $g_k > 0$ → **왼쪽**으로. → ✍️ ai_life **01 선형회귀**의 "기울기 슬라이더" 애니메이션을 이 표의 3단계로 설명하는 교사용 말풍선을 써 보자.

p.472 해설 — 학습률과 예제 1

① **목표의 재해석** — 경사하강법은 $f(x_1) > f(x_2) > f(x_3) > \cdots$ 가 되도록 점을 찾는 것. η = **학습률**: $-g_k$ 방향으로 **얼마나** 갈지.

② **각주 2 — 학습률 선택** ⭐ — η가 너무 크면 함숫값이 **증가해 발산**할 수 있고, 너무 작으면 **느리다**. (원문은 흔히 쓰는 범위와 초기값도 소개) → 🔎 이 각주에 밑줄. 지난주 Adam, 이번 주 Reddi 논문 모두 "학습률을 어떻게 조절할까"의 이야기.

③ **그림 Ⅲ-1** — $g_k < 0$이면 오른쪽, $g_k > 0$이면 왼쪽으로 이동하는 그림.

④ **예제 1** — $f(x) = 2x^2 - 3x + 2$ 의 최솟값 ($x_1 = 0,\ \eta = 0.1,\ \epsilon = 10^{-6}$). 해석적으로: $f'(x) = 4x - 3 = 0 \Rightarrow x = \frac{3}{4}$, 아래로 볼록이므로 최솟값 $f(\frac{3}{4}) = \frac{7}{8}$.

⑤ **각주 3** — 코드를 https://sagecell.sagemath.org/ 에 붙여 넣고 **Evaluate** 클릭 → 바로 실행.

→ ✍️ 손으로 처음 세 단계를 계산해 보자: $x_1 = 0$, $g_1 = -3$, $x_2 = 0.3$; $g_2 = -1.8$, $x_3 = 0.48$; $x_4 = ?$ (0.588) → ✍️ 오차 $e_k = x_k - 0.75$ 는 매 단계 $(1 - 4\eta) = 0.6$ 배가 된다. 왜? e_k가 10^{-6} 수준이 되려면 대략 몇 번?

p.473 해설 — 예제 1 코드와 다변수 확장

① 표 Ⅲ-2 코드 읽기

```
f(x) = 2*x^2 - 3*x + 2        # 함수
df(x) = diff(f(x), x)         # 도함수 자동 계산
x0 = 0.0; tol = 1e-6; eta = 0.1
x0 = x0 - eta*g0              # 경사하강법 반복단계
```

→🔎 `x0 = x0 - eta*g0` 한 줄에 밑줄 — 알고리즘의 심장.

② 실행 결과 — 알고리즘 성공! $x^* = 0.749999834\ldots$, $|g^*| \approx 6.6 \times 10^{-7}$, $f(x^*) = 0.875000\ldots$, 반복 **31회**.

③ 다변수 (표 Ⅲ-3)

$$\mathbf{g}_k = \nabla f(\mathbf{x}_k), \quad \|\mathbf{g}_k\| \le \epsilon \text{ 이면 멈춤}, \quad \mathbf{x}_{k+1} = \mathbf{x}_k - \eta\,\mathbf{g}_k$$

스칼라 → 벡터, 절댓값 → **노름**, 도함수 → **그레이디언트**. 구성은 1변수와 **완전히 동일**.

④ 또 다른 설명 — 방향도함수와 **코시-슈바르츠 부등식**으로부터 $-\nabla f(\mathbf{x}_k)$가 **가장 빠르게 감소하는 방향**.

→✍️ 코드에서 `eta = 0.5`로 바꾸면? `eta = 0.6`이면? 실제로 돌려 보고 각주 2와 비교. ($|1 - 4\eta| < 1$ 이어야 수렴)

p.474 해설 — 가장 가파른 방향과 예제 2

① 증명 한 줄 ⭐

$$\lim_{h\to 0}\frac{f(\mathbf{x}_k+h\mathbf{d})-f(\mathbf{x}_k)}{h}=\mathbf{d}\cdot\nabla f(\mathbf{x}_k),\qquad |\mathbf{d}\cdot\nabla f|\le\|\mathbf{d}\|\,\|\nabla f\|$$

단위벡터 $\mathbf{d}$ 중 $\mathbf{d}\cdot\nabla f$ 가 가장 작은(가장 음수인) 것은 $\mathbf{d}=-\nabla f/\|\nabla f\|$. → 🔎 코시-슈바르츠 부등식에 밑줄. 등호 조건이 바로 "같은 방향"!

② 예제 2 (Dennis & Schnabel 1996)

$$f(x,y)=(x-2)^4+(x-2)^2y^2+(y+1)^2,\quad \mathbf{x}_1=(1,1),\ \eta=0.1,\ \epsilon=10^{-6}$$

식을 보면 $(2,-1)$에서 최솟값 0 (첫 두 항은 $x=2$에서 0, 마지막 항은 $y=-1$에서 0).

③ 표 III-4 코드 — `f.gradient()` 로 그레이디언트 자동 계산, `contour_plot` 으로 **등고선** 위에 경로를 그린다.

④ 결과 — $\mathbf{x}^*\approx(1.99999965,\ -0.99999967)$, $\|\mathbf{g}^*\|\approx 9.6\times10^{-7}$, $f\approx 2.3\times10^{-13}$, 반복 **72회**.

→ ✍️ ∇f를 직접 구해 보자: $f_x=4(x-2)^3+2(x-2)y^2$, $f_y=2(x-2)^2y+2(y+1)$. 시작점 $(1,1)$에서의 값은? ($(-6,6)$) → 첫 이동 후 점은? ($(1.6,0.4)$) → ✍️ 등고선 그림에서 경로가 등고선과 **수직**으로 움직이는 이유를 설명해 보자.

p.475 해설 — 경사하강법의 한계와 유한합 최적화

① 한계 세 가지 ⭐

1. **비볼록** 함수(그림 III-2)면 시작점에 따라 다른 극솟값, 또는 극대도 극소도 아닌 **임계점**으로 수렴 → 보장되는 건 "임계점"뿐
2. 뉴턴법·준뉴턴법보다 이론적 **수렴 속도가 느림**
3. 고정 학습률 → 문제마다 적절한 η 선택 필요 → 🔎 "임계점이라는 것 이외에는 보장하지 못한다" 에 밑줄.

② 참고 문헌 — Bottou 외 2018, Boyd & Vandenberghe 2004, Nocedal & Wright 2006 등.

③ 유한합 최적화 ⭐

$$\min_{\mathbf{x}\in\mathbb{R}^n} F(\mathbf{x}) = \frac{1}{m}\sum_{i=1}^{m} f_i(\mathbf{x})$$

f_i = **성분함수** (데이터 하나에 대한 손실).

④ 최소제곱도 유한합 — A의 i번째 행을 $\mathbf{a}_i^\top$라 하면

$$\frac{1}{2m}\|A\mathbf{x}-\mathbf{b}\|^2 = \frac{1}{m}\sum_{i=1}^{m}\tfrac{1}{2}(\mathbf{a}_i^\top\mathbf{x}-b_i)^2$$

⑤ 문제점 — 전체 그레이디언트 $\nabla F = \frac{1}{m}\sum \nabla f_i$ 를 매번 계산·저장하기엔 m이 너무 크다. 실제 데이터엔 **중복**도 많아 매 단계 전부 쓰는 것이 비효율.

→ ✍️ 이미지 100만 장으로 학습한다면 한 번의 경사하강 단계에 그레이디언트를 몇 번 계산해야 하나? SGD는?

p.476 해설 — SGD 알고리즘과 예제 3

① **SGD의 아이디어** — 매 단계 **무작위로 하나**의 성분함수를 골라 $\nabla f_{i_t}(\mathbf{x}_t)$로 $\nabla F(\mathbf{x}_t)$를 대신. 계산 비용이 적고 특히 **초반에 매우 효과적**.

② **표 Ⅲ-5 SGD** ⭐

단계	내용
1	$\tilde{\mathbf{x}}_1$, ϵ, η 설정, $k := 1$
2	$\mathbf{x}_1 := \tilde{\mathbf{x}}_k$; $t = 1..m$ 동안 $\{1, .., m\}$에서 무작위 i_t, $\mathbf{x}_{t+1} = \mathbf{x}_t - \eta \nabla f_{i_t}(\mathbf{x}_t)$; $\tilde{\mathbf{x}}_{k+1} := \mathbf{x}_{m+1}$
3	$\|\tilde{\mathbf{x}}_{k+1} - \tilde{\mathbf{x}}_k\| \le \epsilon$ 이면 멈춤, 아니면 $k := k + 1$
→ 🔎 $\mathbf{x}_{t+1} = \mathbf{x}_t - \eta \nabla f_{i_t}(\mathbf{x}_t)$ 에 밑줄. 단계 2의 m번 반복 = 딥러닝의 "**1 에폭**".	

③ **예제 3** ⭐ — 점 $(1.2, 3.0), (2.0, 4.5), (3.1, 5.1), (4.6, 6.0), (7.2, 9.8)$의 최소제곱 직선 $y = a + bx$. $\hat{y}_i = a + bx_i$ 라 두고

$$E(a, b) = \tfrac{1}{2}\{(a + 1.2b - 3.0)^2 + (a + 2.0b - 4.5)^2 + (a + 3.1b - 5.1)^2 + (a + 4.6b - 6.0)^2 + \cdots$$

④ **결과** — 시작 $(0, 0)$, $\eta = 0.01$, $\epsilon = 10^{-6}$, 최대 2,000회 → $a = 1.86,\ b = 1.05$, 즉 $y = 1.86 + 1.05x$.

→ ✍️ 정규방정식으로 검산해 보자: $\sum x_i = 18.1$, $\sum y_i = 28.4$, $\sum x_i^2 = 88.05$, $\sum x_i y_i = 126.57$ → $b = \frac{5(126.57) - 18.1(28.4)}{5(88.05) - 18.1^2} \approx 1.055$, $a = \bar{y} - b\bar{x} \approx 1.862$ — 논문 결과와 일치!

p.477 해설 — 예제 3 코드와 로지스틱 회귀 도입

① **표 III-6 코드** — `E(a,b) = 0.5*((a + 1.2*b - 3.0)^2 + ...)`, `eta = 0.01`, `range(2000)`.

② **결과** — $(a^*, b^*) = (1.8617\ldots,\ 1.0548\ldots)$, $\|\mathbf{g}^*\| \approx 9.9 \times 10^{-7}$, $E \approx 0.4622$, 반복 **1176회**. → 🔎 "반복 횟수 = 1176" 에 동그라미. 예제 1(31회)보다 훨씬 많다 — 왜일까? (힌트: 헤시안의 고윳값 비, 즉 **조건수**가 크면 지그재그)

③ **그림** — 데이터 5개와 최소제곱 직선.

④ **손실함수 선택의 중요성** — 이제 **로지스틱 회귀**로. 성공/실패 같은 **이진 분류**, 사건 확률 추정. 종속변수는 0 또는 1, 예측은 0과 1 사이 확률.

⑤ **시그모이드 함수**

$$f(x) = \frac{1}{1 + e^{-x}}$$

→ 지난주 Cybenko, 이번 주 Hornik의 "시그모이드/찌그러뜨리는 함수"와 같은 함수!

→ ✍️ ai_life **01 선형회귀**의 데이터를 그대로 넣어 SageMath 코드를 돌려 보고, 사이트 슬라이더로 찾은 값과 비교하자.

p.478 해설 — 제곱오차 vs 교차 엔트로피

① 시그모이드의 성질

1. 모든 x에 대해 $0 < f(x) < 1$
2. $x > 0$이면 $f > 0.5$, $x < 0$이면 $f < 0.5$
3. $f'(x) = \dfrac{e^{-x}}{(1+e^{-x})^2} = f(x)\big(1 - f(x)\big)$ — **자기 자신으로 미분** ⭐

② 로지스틱 모형 $y = f(a+bx) = \dfrac{1}{1+e^{-(a+bx)}}$

③ 두 손실함수 ⭐⭐

$$E(a,b) = \sum_{i=1}^{n} \big[y_i - f(a+bx_i)\big]^2$$

$$CE(a,b) = -\sum_{i=1}^{n} \big[y_i \log f(a+bx_i) + (1-y_i)\log\big(1 - f(a+bx_i)\big)\big]$$

일반적으로는 **교차 엔트로피**를 쓴다. 이유: 제곱오차는 **비볼록**이라 초깃값 설정이 어렵다. → 🔎 "오차를 최소화하는 문제에서는 손실함수가 비볼록" 에 밑줄.

④ 예제 4 — 데이터 10개:
$(-1,0), (-0.6,0), (-0.1,1), (0.3,1), (0.8,1), (1.2,1), (1.6,0), (2.1,0), (2.5,1), (3,1)$.

⑤ 모수 하나로 단순화 — $f(bx) = \dfrac{1}{1+e^{-bx}}$:

$$CE(b) = -y\log f(bx) - (1-y)\log(1 - f(bx)) = \log(1+e^{bx}) - bxy$$

→ ✍️ 이 정리 과정을 직접 따라가 보자. (힌트: $1 - f(bx) = \dfrac{e^{-bx}}{1+e^{-bx}}$, $\log(1+e^{-bx}) + bx = \log(1+e^{bx})$)

p.479 해설 — 볼록성의 증명과 실험 결과

① 이계도함수 ⭐

$$\frac{d^2CE}{db^2} = \frac{x^2 e^{-bx}}{(1+e^{-bx})^2} \geq 0$$

→ CE는 **볼록함수**. 모수가 여러 개이거나 데이터가 고차원·대량이어도 같은 방식으로 볼록. → 어떤 초깃값에서도 수렴 조건 만족. → ✍️ $CE'(b) = xf(bx) - xy$ 임을 먼저 보이고, 한 번 더 미분해 위 식을 얻자. 이 결과가 $x^2 f(1-f)$ 와 같음도 확인.

② 그림 Ⅲ-3 vs Ⅲ-4 — 제곱오차 곡면은 **평평한 영역**이 넓고 구불구불(비볼록), 교차 엔트로피 곡면은 대부분 **가파른 그릇** 모양(볼록). → 🔎 두 그림을 나란히 형광펜으로 표시.

③ 실험 ⭐ — 시작 $(10, 0)$, $\eta = 0.1$, $\epsilon = 10^{-6}$, 최대 3,000회:

손실	결과
제곱오차	3,000회 후 약 $(9.88, -0.07)$, 허용오차 미달, 시작점마다 다른 답
교차 엔트로피	**652회** 후 약 $(-0.04,\ 0.50)$, 시작점을 바꿔도 같은 답

④ 신경망과의 연결 — 로지스틱 회귀의 출력 노드를 여러 개 = **단층 퍼셉트론(SLP)**, 은닉층 추가 = **다층 퍼셉트론(MLP)** → 심층학습. 제곱오차를 쓰면 기울기가 0 근처인 영역이 많아 학습이 느려진다. **평균제곱오차**는 1980-90년대에 유행, 이후 **교차 엔트로피**가 대체. → ai_life **03 CNN**의 분류 손실이 왜 교차 엔트로피인지 이 쪽으로 설명 가능!

p.480 해설 — 결론과 수업 제언

① **교차 엔트로피로 AI 성능이 비약적으로 개선** (Goodfellow 외 2016).

② **학습 효과** — 학습자는 자신이 배우는 수학이 현실에 쓰인다는 것을 느끼고, AI에 관심 있는 학생에게는 탄탄한 기초. 코드는 복잡한 함수의 수치 해법에도 적용 가능.

③ **Ⅳ. 결론** — 도함수(그레이디언트)가 **왜 중요한지** 보여 주는 좋은 사례. 특히 다변수 함수의 그레이디언트가 AI를 **구동**하는 방식.

④ **수업 제언** ⭐⭐

1. 이후 AI 공부에 도움이 되도록 — 실제로는 **SGD**를 쓰므로 경사하강법의 **한계와 극복 조치**도 간단히 소개
2. **모델링의 관점**으로 — "무엇을 손실함수로 생각할 것인가? 근본적인 제약조건은 무엇인가?" 학생이 질문하고 고민하게 → 🔎 2번의 두 질문에 밑줄 — ai_life 수업의 **발문**으로 바로 쓸 수 있다.

⑤ **마무리** — 컴퓨터공학 용어 없이도, 로지스틱 회귀의 단순한 예제와 그림으로 어떤 손실함수가 더 효율적인지 직관적으로 설명할 수 있었다.

→ ✍️ 제언 2를 따라, ai_life **05 음성인식**(예: "켜/꺼" 두 단어 분류)에 맞는 손실함수를 학생과 토론하는 수업 장면을 세 줄로 써 보자.

p.481 해설 — 참고문헌

국내 자료 (무료 공개본 많음)

참고문헌	왜 볼까
이상구·이재화 (2019) 『[빅북] 인공지능을 위한 기초수학』	**무료 PDF** (matrix.skku.ac.kr/math4ai) — ai_life 수학 배경 교재로 최적
이상구 외 (2020a) 『인공지능과 대학수학교육』	같은 팀의 AI 수학 강좌 운영 사례
이상구 외 (2020b) 『인공지능을 위한 기초수학 입문』	1변수 경사하강법 설명의 출처
이상구 외 (2022) 『다변수 미적분학 & 코딩』	헤시안·극값 판정

해외 자료

참고문헌	왜 볼까
Cauchy (1847)	경사하강법의 원조 (3쪽짜리 프랑스어 논문)
Lemaréchal (2012) *Cauchy and the gradient method*	코시 논문의 역사적 해설
Bottou, Curtis, Nocedal (2018)	SGD 이론의 표준 리뷰
Boyd & Vandenberghe (2004)	볼록 최적화 교과서 (저자 무료 공개)
Goodfellow 외 (2016) *Deep Learning*	교차 엔트로피, 무료 웹판

→ ✍️ 빅북 PDF에서 경사하강법 장을 찾아 이 논문의 예제와 비교해 보자.

p.482 해설 — 영문 초록과 전체 정리

① **영문 초록** — 대학수학용 경사하강법 교수·학습자료, 미적분 수준의 설명, SageMath 코드, 최소제곱문제. 미적분학·공학수학·수치해석·응용수학 교수자에게 도움.

② **저자** — 이상구(성균관대 수학과), 남윤(기초과학연구소), 이재화(기초과학연구소, 교신).

✍ 논문 전체 정리 질문

1. 코시의 한 줄 $u_1 = u_0 - \theta(X^2 + Y^2 + \cdots) < u_0$ 를 고등학생에게 설명하는 세 문장을 써 보자.
2. 예제 1(31회), 2(72회), 3(1176회)의 반복 횟수 차이를 **헤시안의 고윳값**으로 설명해 보자.
3. 경사하강법의 한계 3가지와, 이번 주 Reddi 외(2018)·지난주 Adam이 각각 어떤 한계를 고치려 했는지 연결하자.
4. 교차 엔트로피의 볼록성 증명($d^2CE/db^2 \geq 0$)을 처음부터 끝까지 손으로 써 보자.
5. ai_life **01 선형회귀** 단원에 이 논문의 예제 3과 "무엇을 손실함수로?" 발문을 넣은 15분 활동을 설계해 보자.