현대 기계학습과 편향-분산 트레이드오프의 화해 (이중 하강)

> 원제: *Reconciling Modern Machine-Learning Practice and the Classical Bias-Variance Trade-off*

항목	내용
저자	Mikhail Belkin, Daniel Hsu, Siyuan Ma, Soumik Mandal (Ohio State University, Columbia University)
학술지	*PNAS* Vol. 116, No. 32, 2019
분야	기계학습 · 통계적 학습 이론
난이도	★★★☆☆
링크	https://arxiv.org/abs/1812.11118
PDF 원문	arXiv PDF (무료) · PNAS 오픈액세스
ai_life 연결 단원	01 선형회귀(모델 복잡도·과적합)

한 줄 요약

모델 크기를 키우면 테스트 오차는 U자 모양으로 올라갔다가, 훈련 데이터를 완벽히 맞추는 지점(보간 임계점)을 지나면 다시 내려간다 — "이중 하강(double descent)".

왜 중요한가

교과서의 "모델이 너무 크면 과적합한다"(U자 곡선)와 실무의 "모델은 클수록 좋다"(GPT 등)가 **모순이 아님**을 하나의 곡선으로 통합했습니다. 이번 주 먼저 읽는 Zhang et al.(2017)의 질문에 대한 중요한 부분적 답입니다.

핵심 내용

1. 고전적 관점: 편향-분산 분해

$$\mathbb{E}\left[(y - \hat{f}(x))^2\right] = \underbrace{\text{Bias}^2}_{\text{모델이 단순해서 생기는 오차}} + \underbrace{\text{Variance}}_{\text{데이터에 민감해서 생기는 오차}} + \sigma^2$$

→ 복잡도가 커지면 편향↓ 분산↑ → U자 곡선.

2. 이중 하강 곡선 (Figure 1)

- **과소 파라미터 영역** (파라미터 수 $N <$ 데이터 수 n): 고전적 U자
- **보간 임계점** ($N \approx n$): 테스트 오차가 **급격히 치솟음**
- **과대 파라미터 영역** ($N > n$): 오차가 **다시 감소**, 종종 고전적 최적점보다 더 낮아짐

3. 왜 다시 내려가는가? — 최소 노름 귀납적 편향

$N > n$이면 훈련 데이터를 완벽히 맞추는 해가 무수히 많음. 그중 **노름이 가장 작은(가장 매끄러운) 해**를 고르면

$$\hat{w} = \arg\min_{w} \|w\| \quad \text{s.t.} \quad \Phi w = y$$

N이 커질수록 선택지가 많아져 더 매끄러운 해를 찾을 수 있음 → 일반화 향상. (임계점 $N \approx n$에서는 해가 거의 유일해서 노름이 폭발 → 오차 급증)

4. 실험

- 랜덤 푸리에 특징(RFF) + MNIST
- 2층 신경망, 결정 트리/랜덤 포레스트에서도 같은 현상 관찰

읽는 순서 가이드

1. **Figure 1** - 이 그림 하나가 논문의 전부. 먼저 이해 (10분)
2. **서론** - 고전 vs 현대 관점 정리 (15분)
3. **랜덤 푸리에 특징 실험** - RFF 정의와 최소 노름 해 유도 (40분)
4. **신경망/트리 실험** - 그래프 위주로 (15분)
5. **Discussion** - 저자들의 해석 (10분)

사전 지식 체크

- [ ] 편향-분산 분해 증명
- [ ] 최소 노름 해 / 의사역행렬 (Zhang 2017 리뷰 참고)
- [ ] 랜덤 푸리에 특징 (Rahimi & Recht 2007) — 커널 근사

직접 해보기 (추천 🧪)

Python으로 다항식 또는 랜덤 특징 회귀를 하며 특징 수 N을 1부터 $3n$까지 늘려 테스트 오차를 그려 보세요.
`np.linalg.pinv`로 최소 노름 해를 구하면 이중 하강이 직접 보입니다.

생각해볼 질문

1. 보간 임계점에서 오차가 폭발하는 것을 행렬 Φ의 **최소 특이값**으로 설명할 수 있을까?
2. 릿지 정규화를 적절히 넣으면 봉우리가 사라진다고 한다. 왜일까?
3. 데이터 수 n을 늘리는 것이 오히려 성능을 떨어뜨리는 "샘플 단위 이중 하강"도 가능할까? (힌트: Nakkiran et al. 2019)

용어 정리

영어	한국어
double descent	이중 하강
interpolation threshold	보간 임계점
over-parameterized	과대 파라미터화된
inductive bias	귀납적 편향
random Fourier features	랜덤 푸리에 특징

다음에 이어 읽을 논문

- Nakkiran et al. (2019), *Deep Double Descent: Where Bigger Models and More Data Hurt*
- Hastie, Montanari, Rosset, Tibshirani (2019), *Surprises in High-Dimensional Ridgeless Least Squares Interpolation*

✍️ 나의 메모