# p.1 해설 — 초록: 고전 이론과 현대 실무의 모순

① **문제 제기** — 기계학습의 중심 원리인 **편향-분산 트레이드오프**가 현대 실무와 **모순**되어 보인다.

- 고전: 모델은 과소적합과 과적합 사이에서 균형을 잡아야 한다 — 데이터 구조를 표현할 만큼 풍부하되, 가짜 패턴을 맞추지 않을 만큼 단순하게.
- 현대: 신경망 같은 매우 풍부한 모델을 데이터에 **정확히 맞추도록(보간, interpolate)** 학습하는데도 테스트 정확도가 높다. → 🔎 *interpolate* 에 밑줄. 이 논문의 핵심 단어 = "훈련 데이터를 오차 0으로 통과".

② **이 논문의 답** ⭐ — 고전 이해와 현대 실무를 **하나의 성능 곡선**으로 통합: **"이중 하강(double descent)"**. 교과서의 U자 곡선을 포함하면서, **보간점을 넘어 용량을 더 키우면 성능이 다시 좋아짐**을 보인다.

③ **기여** — (a) 다양한 모델과 데이터셋에서 이중 하강의 **존재와 보편성**에 대한 증거, (b) 그 **발생 메커니즘** 제시, (c) 고전 분석의 **한계**를 밝힘.

④ **저자** — 오하이오 주립대(Belkin, Ma, Mandal), 컬럼비아 대(Hsu). 이 PDF는 PNAS 게재 버전의 arXiv v2 (2019년 9월).

# p.2 해설 — 고전적 관점: U자 곡선

① **문제 설정** — 표본 $(x_1, y_1), \ldots, (x_n, y_n) \in \mathbb{R}^d \times \mathbb{R}$ 로 예측기 $h_n : \mathbb{R}^d \to \mathbb{R}$ 학습. **경험적 위험 최소화 (ERM)**:

$$\min_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^{n} \ell(h(x_i), y_i)$$

손실: 제곱 $\ell(y', y) = (y' - y)^2$ 또는 0-1 손실.

② **일반화의 핵심 긴장** — ERM의 목표(경험적 위험 최소화 = **최적화**)와 기계학습의 목표(**진짜 위험** $\mathbb{E}_{(x,y)\sim P}[\ell(h(x), y)]$ 최소화)의 **불일치**.

③ **편향-분산의 통념**

1. $\mathcal{H}$가 너무 작으면 → **과소적합**: 경험적 위험이 크고 새 데이터에서도 나쁨
2. $\mathcal{H}$가 너무 크면 → **과적합**: 가짜 패턴까지 맞춤 (경험적 위험 작음, 진짜 위험 큼) → "스위트 스팟"을 찾아야 한다. 이것이 Figure 1(a)의 **U자 곡선**.

④ **교과서의 따름정리** — "훈련 오차가 0인 모델은 과적합된 것이고 보통 일반화가 나쁘다" (Hastie 외, 『통계적 학습의 요소』 221쪽). → 🔎 이 인용문에 밑줄. 이 논문이 반박하는 대상!

⑤ **현대 실무의 반례** — 큰 신경망은 훈련 위험 0에 가까워도 정확하다. 딥러닝의 모범 관행: 망은 **손쉽게 손실 0을 달성할 만큼 커야** 한다. 더구나 레이블에 **잡음이 많아도** 보간하는 신경망과 커널 기계가 거의 최적의 테스트 성능 (이번 주 Zhang 외 논문 인용 [42]).

⑥ **주 발견** — Figure 1(b)의 이중 하강 곡선이 U자 곡선을 **보간점 너머로 확장**한다.

# p.3 해설 — Figure 1과 메커니즘 ⭐ 가장 중요한 쪽

① **Figure 1⭐ 논문의 전부가 이 그림에**

- 점선 = 훈련 위험, 실선 = 테스트 위험
- **(a)** 고전적 U자 곡선
- **(b)** 이중 하강: "고전" 영역(U자) + **보간 임계점** + "현대" 보간 영역 → ✍️ 두 그림을 노트에 직접 그려 보세요.

② **용량의 정의** — 이 논문에서 함수 클래스의 용량 = 함수를 지정하는 데 필요한 **파라미터 수**.

③ **곡선 해석** — 보간 임계점 아래: 고전적 U자. 용량을 충분히 키우면 학습된 예측기가 훈련 데이터를 (거의) 완벽히 맞춤 = 보간. 임계점에서는 위험이 높지만, **그 너머로 용량을 늘리면 위험이 감소**하여 보통 고전 영역의 스위트 스팟보다 **낮아진다**.

④ **왜? — 귀납적 편향⭐** — 임계점 오른쪽의 모든 예측기는 훈련 위험 0. 그런데 왜 더 풍부한 클래스가 더 좋은가? 클래스의 용량이 문제에 맞는 **귀납적 편향**을 반영하지 않기 때문. 적절한 귀납적 편향 = 어떤 함수 공간 노름으로 잰 **정칙성(매끄러움)**.

- 데이터를 완벽히 맞추는 함수 중 **가장 매끄러운 것**을 고르기 = **오컴의 면도날**
- 클래스가 클수록 후보가 많아져 **노름이 더 작은("더 단순한")** 보간 함수를 찾을 수 있다 → 🔎 *Occam's razor* 에 밑줄.

⑤ **관련 이론** — **마진 이론**: 큰 클래스가 더 큰 마진의 분류기를 허용. 하지만 회귀에는 적용 안 되고 두 번째 하강을 예측하지 못함. ERM 기반이 아닌 일부 보간 예측기는 통계적으로 (거의) 최적임이 증명됨.

# p.4 해설 — 무작위 푸리에 특징(RFF) 실험

① **RFF 모델** — 첫 층 가중치가 **고정된 2층 신경망**으로 볼 수 있는 모델 클래스. $N$개 (복소) 파라미터:

$$h(x) = \sum_{k=1}^{N} a_k \, \phi(x; v_k), \qquad \phi(x; v) = e^{\sqrt{-1}\langle v, x \rangle}$$

$v_1, \ldots, v_N$ 은 표준 정규분포에서 독립 추출. $N \to \infty$ 이면 **가우시안 커널의 RKHS** $\mathcal{H}_\infty$ 에 점점 가까워진다. → 🔎 *Reproducing Kernel Hilbert Space* 에 밑줄. 커널 방법과 신경망의 연결고리.

② **학습 절차** — 제곱 손실 ERM. 해가 유일하지 않을 때($N > n$ 이면 항상) 계수 $(a_1, \ldots, a_N)$ 의 $\ell_2$ **노름이 최소인 해**를 선택 (RKHS 노름 $\|h\|_{\mathcal{H}_\infty}$ 의 근사).

③ **Figure 2 결과 (다음 쪽)** — MNIST 부분집합에서 작은 $N$일 때 고전적 U자, **보간 임계점** $N = n$ **에서 정점**. 통계 분석은 $N \propto \sqrt{n} \log n$ 을 권장.

④ **보간 영역 ($N \geq n$)** — 가장 적은 파라미터로 보간하는 $N = n$ 이 **가장 부정확** (분류에서는 예측력이 없을 정도). $N$을 더 늘리면 정확도가 **극적으로 개선**되어 U자 바닥을 넘어선다. 커널 기계 $h_{n,\infty}$ 가 모든 유한 $N$보다 좋다.

⑤ **메커니즘 (시작)** — $N \ll n$ 이면 고전 통계 논리로 훈련 위험 ≈ 테스트 위험 → 특징 추가가 둘 다 개선. $N$이 $n$에 가까워지면...

# p.5 해설 — Figure 2: MNIST에서의 이중 하강

**① Figure 2 ⭐ 세 그래프를 위아래로 비교하세요**

- **위**: 테스트 위험 (로그 스케일, 0-1 손실과 제곱 손실)
- **가운데**: 계수의 $\ell_2$ 노름 (로그 스케일)
- **아래**: 훈련 위험
- 설정: MNIST 부분집합 $n = 10^4$, 10 클래스. **보간 임계점** $N = 10^4$.

**② 읽는 법**

1. 아래 그래프에서 훈련 위험이 **0이 되는 지점** = 보간 임계점을 찾는다.
2. 같은 $N$에서 위 그래프의 테스트 위험이 **정점**인지 확인한다.
3. 가운데 그래프에서 노름도 **같은 곳에서 정점**이고, 오른쪽으로 갈수록 **감소**하는지 확인한다. → 🔎 "노름의 정점 = 테스트 위험의 정점" — 이것이 메커니즘의 증거.

**③ 수평선** — 커널 기계 $h_{n,\infty}$ (무한 특징)의 성능. 모든 유한 $N$의 곡선이 이 선 위에 있다 → 무한 폭 극한이 최선. → 이번 주 **NTK 논문**과 연결: 무한 폭 신경망 = 커널 기계!

✍️ **직접 해보기** — Python으로 `np.linalg.pinv` (최소 노름 해)를 써서 특징 수 $N$을 $1$부터 $3n$까지 늘려 보세요. 이 그림을 재현할 수 있습니다.

# p.6 해설 — Figure 3과 두 번째 하강의 메커니즘

① **Figure 3** ⭐ **직관적인 1차원 예** — 데이터 10개(빨간 원)를 무작위 ReLU 특징 $\phi(x;(v_1,v_2)) = \max(v_1x + v_2, 0)$ 으로 맞춤.

- $N = 40$ (파란 점선): 계수 노름 ≈ **695**, 구불구불
- $N = 4000$ (검은 실선): 계수 노름 ≈ **159**, 훨씬 매끄러움 → 🔎 둘 다 10개 점을 **정확히 통과**하지만, 특징이 많을수록 더 매끄럽다.

② **임계점의 정점 설명** — 임계점에 가까워지면 데이터에 없거나 약하게만 있는 특징들이 훈련 데이터를 **억지로** 거의 완벽히 맞추게 된다 → 고전적 과적합, 정점에서 가장 두드러짐.

③ **두 번째 하강 설명** ⭐ — 임계점 오른쪽은 모두 훈련 위험 0. 가장 정칙적인 최소 노름 보간 함수 $h_{n,\infty}$ 가 유한 $\mathcal{H}_N$ 에 들어 있다는 보장은 없지만, $N$을 늘리면 그것에 **점점 더 가까운 근사**를 만들 수 있다. 따라서 노름은 임계점에서 최대이고 $N$과 함께 **단조 감소** → 두 번째 하강. → 수학적 직관: 임계점 $N = n$ 에서는 특징 행렬이 정사각에 가까워 **최소 특이값이 0에 가깝고**, 의사역행렬의 노름이 폭발한다.

④ **추가 증거** — 부록 C.1(다른 데이터셋), 무작위 ReLU 특징, C.4(1차원 합성 모델) 모두 같은 이중 하강.

⑤ **신경망과 역전파** — 일반 다층망에서는 SGD+역전파로 **모든 가중치**를 조정. 표현력은 커지지만 ERM이 더 어려워진다.

# p.7 해설 — 신경망에서의 이중 하강, 3절 트리 시작

① **2층 신경망 (Figure 4)** — 완전연결 2층망의 파라미터를 늘리면 RFF와 질적으로 비슷한 곡선. 임계점 너머의 개선은 신경망 학습 알고리즘의 **"작은 노름" 귀납적 편향** 추측과 부합. 이전에도 관찰됨 — 특히 [37]은 입자계의 **"재밍 (jamming)" 상전이**와 연결.

② **신경망에서 관찰이 어려운 이유** — 과소 파라미터 영역($N \ll n$)에서는 ERM이 **비볼록**이라 SGD가 **초기화에 민감**. 최적이 아닌 해만 찾으면 망을 키워도 훈련 위험이 줄지 않을 수 있고, 이 변동성이 이중 하강을 **가린다**.

③ **보간에 필요한 파라미터 수** ⭐ — 출력 하나면 최소 데이터 수만큼, 출력이 $K$개면 $n \times K$ 개. 예: ImageNet ($\sim 10^6$ 표본, $\sim 10^3$ 클래스) → $\sim 10^9$ **파라미터**가 있어야 보간 → 당시 많은 ImageNet 모델보다 큼. 그런 경우엔 **고전 U자 영역**이 일반화를 이해하는 데 더 적절. 작은 데이터셋에서는 큰 망이 확실히 과대 파라미터 영역. → 🔎 *~10^9 parameters* 에 밑줄. 이후 GPT 시대에 이 규모가 현실이 되었다!

④ **3절: 결정 트리와 앙상블** — 이중 하강은 신경망 외에도 나타날까? **부스팅**과 **랜덤 포레스트**도 비슷한 행동. Wyner 외: 최대 크기(보간) 트리를 쓰는 AdaBoost와 랜덤 포레스트가 얕은 트리보다 **잡음에 강건**. 보간 트리들을 **평균**하면 개별 트리보다 훨씬 매끄러운 함수.

# p.8 해설 — Figure 4: 완전연결 신경망

① **Figure 4** ⭐ — MNIST 부분집합 ($n = 4 \cdot 10^3$, $d = 784$, $K = 10$), 은닉층 하나에 $H$개 유닛.

- 파라미터 수: $(d+1) \cdot H + (H+1) \cdot K$
- **보간 임계점** (검은 점선): $n \cdot K = 4 \times 10^4$
- 위: 테스트 위험(0-1, 제곱 손실), 아래: 훈련 위험

② **계산 연습** ✍️ — $d = 784$, $K = 10$ 일 때 파라미터가 $n \cdot K = 40{,}000$ 이 되는 $H$는?

$$785H + 10(H+1) = 40000 \Rightarrow H \approx 50$$

→ 은닉 유닛 약 50개에서 정점. 그래프에서 확인해 보세요.

③ **읽는 법** — RFF(Figure 2)와 모양을 비교하세요. 신경망은 모든 층을 학습하므로 더 복잡하지만, **같은 이중 하강 패턴**이 나타난다. 이것이 "보편성" 주장의 근거.

④ **실험 세부 (부록 C.3)** — 과소 파라미터 영역에서는 **가중치 재사용**(작은 망의 가중치로 큰 망 초기화)으로 SGD의 초기화 민감성을 완화. 과대 파라미터 영역에서는 일반 무작위 초기화.

# p.9 해설 — Figure 5: 랜덤 포레스트

① **Figure 5** ⭐ — MNIST 부분집합 ($n = 10^4$, 10 클래스)에서 랜덤 포레스트의 이중 하강. 복잡도를 두 단계로 조절:

- **1단계 (임계점 전)**: 트리 하나의 **최대 잎 수** $N_{\text{leaf}}^{\max}$ 를 늘림
- **2단계 (임계점 후)**: 보간하는 트리의 **개수** $N_{\text{tree}}$ 를 늘림

② **x축 읽는 법** — 왼쪽 절반은 "잎 수 / 트리 1개", 오른쪽 절반은 "잎 수 최대 / 트리 여러 개". 두 종류의 용량을 하나의 축에 이어 붙인 **하이브리드 용량 척도**.

③ **관찰** — 잎 수가 늘어나면 고전적 U자, 트리 하나가 데이터를 보간하는 지점에서 정점, 이후 트리를 더 많이 평균할수록 테스트 위험 **감소**. → 🔎 신경망이 아닌 모델에서도 같은 현상 → 이중 하강은 신경망만의 특성이 아니라 **기계학습 일반의 현상**.

④ **귀납적 편향의 차이** — 신경망·RFF: **최소 노름**. 랜덤 포레스트: **평균화**. 다른 메커니즘이지만 둘 다 "보간하는 해 중 매끄러운 것"을 고른다.

# p.10 해설 — 트리의 용량, 4절 결론: 왜 지금까지 몰랐나

① **트리의 용량** — 잎이 2개인 트리 = 축에 평행한 경계의 2조각 상수 함수, 잎이 $n$개 = $n$개 표본 보간 가능. 그 너머는 보간 트리 여러 개의 **앙상블(평균)** 로 용량을 늘림 (부트스트랩 재표본 없이 — PERT 방법과 유사). $L_2$ 부스팅에서도 같은 현상 (부록 E).

② **결론** — 이중 하강 곡선은 편향-분산의 U자 곡선과 현대 실무를 **화해**시킨다. 메커니즘은 공통 귀납적 편향에 기반하므로 기계학습 전반에 **보편적**일 것이다.

③ **역사적 부재: 왜 지금까지 못 봤나?** ⭐ **과학사적으로 흥미로운 문단**

1. **고전 통계**: 작은 고정 특징 집합 → 용량 고정
2. **비모수 통계**: 풍부한 함수 클래스를 쓰지만 거의 항상 **평활화와 정규화** → 보간을 막고 정점을 가림
3. **RFF**: 원래 커널 기계의 **계산 대안**으로 제안 → 계산 이점은 $N \ll n$ 에서만 → 임계점 근처는 보통 안 봄
4. **신경망**: 정점이 **좁은 범위**에서만 나타나 놓치기 쉽고, **조기 종료**의 강한 정규화 효과가 정점을 가림 → 🔎 *early stopping has a strong regularizing effect* 에 밑줄.

④ **귀납적 편향 시작** — RFF·무작위 ReLU 특징은 특징 공간에서 **최소 노름 선형 회귀**로 해를 명시적으로 구성.

# p.11 해설 — 귀납적 편향과 최적화

① **RKHS의 최소 노름 해** — 특징 수 → ∞ 이면 RKHS의 **최소 함수 노름 해**에 접근: 보간 제약 아래 **함수의 매끄러움을 최대화**하는 해.

② **신경망의 귀납적 편향** — 학습 절차(보통 SGD)에서 비롯. 마지막 층만 학습하면(RFF처럼) **0에서 시작한 SGD는 최소 노름 해로 수렴**. 일반 신경망은 완전히 이해되지 않았지만 비슷한 편향의 경험적·이론적 증거가 있음 ([20] 행렬 분해의 암묵적 정규화).

③ **세 방법이 같은 해로** ⭐ **아름다운 사실** — 커널 기계에서는 다음 세 방법이 모두 **같은 최소 노름 해** $h_{n,\infty}$ 를 준다:

1. 명시적 노름 최소화 (선형 연립방정식 풀기)
2. SGD
3. 가우시안 과정 궤적의 평균 (사후 평균) → 🔎 최적화·확률·선형대수의 세 관점이 한 점에서 만난다.

④ **최적화 관점** — 적절한 "현대" 모델이 보통 최적의 "고전" 모델보다 낫다. 게다가 과대 파라미터 모델은 **최적화도 쉽다**: SGD 같은 국소 방법이 훈련 위험의 **전역 최솟값**으로 수렴. 임계점 왼쪽과 오른쪽의 모델은 최적화 성질도 질적으로 다를 것.

⑤ **전망** — 고전 U자 곡선은 모델 선택에 대한 우리의 시각을 형성해 왔다. 이 연구는 고전 분석의 한계를 보이고, 고전·현대 영역의 계산·통계·수학적 성질을 비교하는 새 연구 방향을 연다.

⑥ **참고문헌 시작** — [1] Advani & Saxe (2017): 신경망 일반화 오차의 고차원 동역학, [2] Bartlett (1998).

# p.12 해설 — 참고문헌 [3]~[19]

### 참고문헌 중 주목할 것

| 번호 | 참고문헌 | 왜 볼까 |
|---|---|---|
| [3] | Belkin, Hsu, Mitra (2018) *과적합인가 완벽한 적합인가?* | 보간 규칙의 위험 상한 — 이론적 배경 |
| [4] | Belkin, Ma, Mandal (2018) *딥러닝을 이해하려면 커널 학습을 이해해야* | 커널과 딥러닝의 연결 ⭐ |
| [6] | Blumer 외 (1987) *오컴의 면도날* | 단순성과 학습 가능성 |
| [8] | Boser, Guyon, Vapnik (1992) | 최적 마진 분류기 (SVM의 시작) |
| [9] | Breiman (2001) 랜덤 포레스트 | 3절의 모델 |
| [12] | Cho & Saul (2009) 딥러닝을 위한 커널 방법 | 무작위 ReLU 특징의 출처 |
| [17] | Geman, Bienenstock, Doursat (1992) ⭐ | **신경망과 편향/분산 딜레마** — 이 논문이 화해시키려는 고전 |
| [18] | Gigerenzer & Brighton (2009) | 편향-분산이 인간 의사결정도 설명한다는 인지과학 연구 |
| [19] | Glorot & Bengio (2010) | 초기화 (부록 C.3에서 사용) |

# p.13 해설 — 참고문헌 [20]~[33]

### 참고문헌 중 주목할 것

| 번호 | 참고문헌 | 왜 볼까 |
|---|---|---|
| [20] | Gunasekar 외 (2017) 행렬 분해의 암묵적 정규화 | SGD의 최소 노름 편향 근거 ⭐ |
| [21] | Hastie, Tibshirani, Friedman『통계적 학습의 요소』 | p.2에서 인용한 교과서 (참고도서 목록에 무료 PDF) |
| [24] | LeCun 외 (1998) | MNIST 데이터셋 |
| [25] | Li, Ma, Zhang (2018) | 과대 파라미터 모델의 알고리즘적 정규화 |
| [26] | Ma, Bassily, Belkin (2018) *보간의 힘* | 과대 파라미터에서 SGD가 효과적인 이유 |
| [27] | Neal 외 (2018) | 신경망의 편향-분산 트레이드오프 재고 |
| [29] | Pennington 외 (2014) GloVe | 20-Newsgroups 실험의 단어 임베딩 |
| [30] | Rahimi & Recht (2008) 무작위 특징 ⭐ | RFF의 원 논문 |
| [31] | Rasmussen (2004) 가우시안 과정 | p.11의 사후 평균 |
| [32] | Rudi & Rosasco (2017) | 무작위 특징의 일반화 성질 ($N \propto \sqrt{n}\log n$) |

# p.14 해설 — 참고문헌 끝, 부록 A: 정리 1

**① 남은 참고문헌** — [36] Soltanolkotabi 외: 과대 파라미터 얕은 망의 최적화 지형, [37] Spigler 외: **재밍 전이**, [38] Vapnik, [40] Wendland 『산재 데이터 근사』(정리 증명에 사용), [41] Wyner 외: AdaBoost와 랜덤 포레스트를 보간 분류기로 설명, [42] **Zhang 외** (이번 주 함께 읽는 논문).

**② 부록 A: 잡음 없는 경우의 정리** ⭐ — 설정: $x_i$ 를 콤팩트 영역에서 균등 추출, $y_i = h^*(x_i)$, $h^* \in \mathcal{H}_\infty$ (잡음 없음).

> **정리 1.** 절대 상수 $A, B > 0$ 가 있어, 데이터를 보간하는 임의의 $h \in \mathcal{H}_\infty$ 에 대해 높은 확률로
>
> $$|h(x) - h^*(x)| < A\, e^{-B(n/\log n)^{1/d}} \left( \|h^*\|_{\mathcal{H}_\infty} + \|h\|_{\mathcal{H}_\infty} \right)$$

→ 🔎 오차 상한이 $\|h\|$ **에 비례**한다! 그러므로 보간 함수 중 **노름이 작은 것**이 더 좋다. → 지수 $1/d$ 에 주목: 차원 $d$가 크면 수렴이 느려진다 (차원의 저주 — Cybenko 논문 p.313과 연결).

**③ 증명 스케치 시작** — 점들 $x_1, \ldots, x_n$ 의 **채움 거리(fill)**:

$$\kappa_n = \max_{x \in \Omega} \min_j \|x - x_j\|$$

= 점들이 영역을 얼마나 잘 덮는가.

# p.15 해설 — 증명 마무리, 부록 B: 실험 설정

① **증명 마무리** — 격자 분할과 합집합 상한으로 높은 확률로 $\kappa_n = O\big((\log n/n)^{1/d}\big)$. $f = h - h^*$ 로 두면 $f(x_i) = 0$ 이고 삼각부등식으로 $\|f\| \le \|h^*\| + \|h\|$. Wendland의 정리 11.22를 적용하면 결과. ∎

② **해석** ⭐ — 최소 노름 보간 함수 $h_{n,\infty}$ 는 정의상 노름이 $\|h^*\|$ 이하이므로 **정리 1의 가장 작은 상한**을 달성한다. 잡음 없는 경우에만 적용되지만, **작은 노름을 고르는 귀납적 편향**의 정당화가 된다. 실험적으로는 레이블 잡음이 많아도 최소 노름 보간 해가 잘 일반화.

③ **부록 B: 데이터셋**

| 데이터 | 종류 | 전처리 |
|---|---|---|
| MNIST, CIFAR-10, SVHN | 이미지 | 흑백 변환, $[0, 1]$ 스케일 |
| TIMIT | 음성 | z-점수 정규화 |
| 20-Newsgroups | 텍스트 | BoW → GloVe 임베딩 합 |
| 다중 클래스는 **원-핫 인코딩**(일대다). | | |

④ **학습** — 모두 **제곱 손실** 최소화. 정규화 없이 용량이 임계점을 넘으면 보간. 신경망·앙상블은 5회 반복 평균, RFF·무작위 ReLU는 결과가 안정적이라 1회. → ai_life **05 음성인식** 단원과 연결: TIMIT은 대표적인 음성 데이터셋.

# p.16 해설 — Figure 6: CIFAR-10과 20-Newsgroups의 RFF

① **Figure 6** — RFF 모델의 이중 하강. CIFAR-10 (이미지)과 20-Newsgroups (텍스트) 부분집합, $n = 10^4$, 보간 임계점 $N = 10^4$.

- 위: 테스트 위험 (로그)
- 가운데: 계수 $\ell_2$ 노름 (로그)
- 아래: 훈련 위험

② **읽는 법** — p.5의 MNIST 그림과 **같은 방법**으로 읽으세요.

1. 훈련 위험이 0이 되는 $N$ 찾기
2. 그곳에서 테스트 위험과 노름이 모두 정점인지 확인
3. 오른쪽에서 둘 다 감소하는지 확인

③ **의미** — 이미지와 **텍스트**라는 전혀 다른 종류의 데이터에서도 같은 모양 → 데이터 종류에 무관한 현상.

✍️ **비교 질문** — CIFAR-10의 테스트 위험이 MNIST보다 전반적으로 높은 이유는? (힌트: 과제의 난이도 vs 이중 하강의 모양은 별개)

# p.17 해설 — Figure 7: TIMIT과 SVHN의 RFF

① **Figure 7** — RFF 모델의 이중 하강. **TIMIT** (음성)과 **SVHN** (거리 번지수 사진) 부분집합, $n = 10^4$, 임계점 $N = 10^4$. 이 그림은 **0-1 손실**(분류 오류율) 위주.

② **RFF 설정 (부록 C.1)** — 무작위 특징 벡터 $v_k$ 는 평균 0, 공분산 $\sigma^{-2}I$ 인 정규분포에서 추출. 대역폭 $\sigma$:

| 데이터 | $\sigma$ |
|---|---|
| MNIST, SVHN, CIFAR-10 | 5 |
| 20-Newsgroups | 0.1 |
| TIMIT | 16 |
| → $\sigma$는 가우시안 커널의 폭. 데이터의 스케일에 맞춰 조정. | |

③ **관찰** — 4가지 데이터셋(이미지 3 + 음성 1 + 텍스트 1) 모두에서 이중 하강 → **보편성**의 증거.

# p.18 해설 — Figure 8: 무작위 ReLU 특징, 부록 C 시작

① **Figure 8 — 무작위 ReLU 특징** 모델의 이중 하강. MNIST, SVHN ($n = 10^4$), 임계점 $N = 10^4$. SVHN에는 임계점 근처 수치 안정성을 위해 아주 작은 정규화 $4 \cdot 10^{-6}$ 추가.

② **왜 ReLU 특징인가** — RFF는 $e^{i\langle v,x\rangle}$ 를 쓰지만, 실제 신경망은 **ReLU**를 쓴다. 무작위 ReLU 특징 = **첫 층을 무작위로 고정한 ReLU 신경망**. 따라서 실제 신경망에 한 걸음 더 가까운 실험.

③ **부록 C.1 요약** — Figure 6: CIFAR-10, 20-Newsgroups / Figure 7: TIMIT, SVHN (0-1 손실).

④ **C.2 무작위 ReLU 특징 시작** — 무작위 ReLU 특징 신경망 [12]도 이중 하강을 보인다. RFF와 같고 활성화 함수만 ReLU.

# p.19 해설 — C.2 ReLU 특징, C.3 완전연결 신경망

**① C.2 모델**

$$h(x) = \sum_{k=1}^{N} a_k \, \phi(x; v_k), \qquad \phi(x; v) = \max(\langle v, x \rangle, \, 0)$$

$v_k$ 는 **단위 구면 위의 균등분포**에서 추출, $a_k$ 는 선형 회귀로 학습. 결과 곡선과 노름 곡선이 RFF와 매우 비슷.

**② C.3 완전연결 신경망** — 은닉층 하나, **은닉 유닛 수**로 용량 조절, SGD로 ERM. RFF보다 어려운 이유: **해석적 해가 없고 비볼록** → SGD가 초기화에 민감.

**③ 가중치 재사용 기법** ⭐ — 과소 파라미터 영역($N < n$)에서: 은닉 유닛 $H_1$개인 작은 망을 먼저 학습 → $H_2 > H_1$ 인 큰 망의 **처음 $H_1$개 유닛을 그 가중치로 초기화**, 나머지는 평균 0·분산 0.01 정규분포. → 파라미터가 늘 때 훈련 위험이 **단조 감소**하도록 보장. 과대 파라미터 영역에서는 일반 무작위 초기화. → 🔎 이번 주 ResNet 논문의 "깊은 망 = 얕은 망 + 항등 층" 사고 실험과 비슷한 발상!

**④ 학습 세부** — 모멘텀 0.95 SGD (Keras). 가장 작은 망은 Glorot 균등 초기화. 임계점 아래: 500 에폭마다 스텝 10% 감소, 분류 오류 0 또는 6000 에폭에서 멈춤. 임계점 위: 고정 스텝, 6000 에폭.

**⑤ 가중치 재사용 없이 (Figure 9c)** — 분산이 훨씬 크고 훈련 손실이 단조 감소하지 않지만 이중 하강은 **여전히 분명**.

# p.20 해설 — Figure 9, C.4 합성 모델

① **Figure 9** — 은닉층 하나인 완전연결망. 파라미터 수 $(d+1)H + (H+1)K$, 임계점 $n \cdot K$ (검은 점선).

- **(a)** MNIST ($n = 4 \cdot 10^3$, $d = 784$, $K = 10$): 임계점 전 가중치 재사용, 후 무작위 초기화
- **(b)** CIFAR-10 부분집합 (고양이 vs 개 2클래스, 8×8로 축소, $n = 960$, $d = 64$, $K = 2$)
- **(c)** MNIST, 가중치 재사용 없음

② **C.4 1차원 합성 모델** ⭐ **수학적으로 가장 깔끔한 예** — 원 위의 RFF 버전. $[0, 2\pi]$ 위의 주기 함수, 기저 $e_k(x) = e^{\sqrt{-1}kx}$.

- 양의 정수 위의 확률분포 $p$에서 서로 다른 지표 $k_1, \ldots, k_N$ 을 뽑아 $\mathcal{H}_N = \mathrm{span}(e_{k_1}, \ldots, e_{k_N})$
- 데이터: $y_i = h^*(x_i) + \varepsilon_i$, $\varepsilon_i \sim N(0, \sigma^2)$, $x_i$ 는 $\{2\pi j/M\}$ ($M = 4096$)에서 균등 추출
- $p_k \propto 1/k^2$ (낮은 진동수를 더 자주 뽑음)
- ERM = $N$차원 최소제곱. $N \geq n$ 이면 **최소 노름** 보간 함수 선택

③ **결과 예고** — $n = 256$ 에서 20회 반복 평균: 정점이 $N = n$, 오른쪽 끝이 U자 바닥보다 **낮음**, 노름도 $N = n$ 에서 정점 후 감소. → ✍️ 이 모델은 푸리에 급수 근사 그 자체입니다. Cybenko 논문 p.304의 "푸리에 급수의 일반화"와 비교해 보세요.

# p.21 해설 — Figure 10, 11: 합성 모델과 랜덤 포레스트

① **Figure 10** ⭐ — 합성 모델의 결과, $n = 256$, 임계점 $N = 256$.

- 왼쪽: **SNR = ∞** (잡음 없음), 오른쪽: **SNR = 20** (잡음 있음)
- 위: 제곱 손실의 **초과 테스트 위험**
- 아래: 학습된 함수의 노름 $\|h\|_{\mathcal{H}_\infty}$ → 🔎 잡음이 있을 때 임계점의 정점이 **더 뾰족**해지는지 비교해 보세요. 잡음까지 억지로 맞추기 때문.

② **Figure 11** — 회귀 과제에서 랜덤 포레스트의 이중 하강. 복잡도 = 트리 수 $N_{\text{tree}}$ 와 트리당 최대 잎 수 $N_{\text{leaf}}^{\max}$.

- **(a)** 부트스트랩 재표본 **없이**: 트리 하나가 데이터를 보간 가능
- **(b)** 부트스트랩 **있이**: 보간하려면 여러 트리 필요

✍️ **생각해볼 것** — SNR(신호 대 잡음비)은 이번 주 Adam 논문에도 나왔습니다 ($\hat{m}/\sqrt{\hat{v}}$). 같은 개념이 서로 다른 맥락에서 어떻게 쓰이는지 비교해 보세요.

# p.22 해설 — Figure 12, 부록 D·E: 앙상블

① **Figure 12** — $L_2$-부스팅 트리의 이중 하강. 먼저 부스팅 트리 수 $N_{\text{tree}}$ 를 늘려 숲을 만들고, 그다음 그런 숲 여러 개 $N_{\text{forest}}$ 를 평균. 각 트리는 잎 **10개 이하**.

② **부록 D: 랜덤 포레스트** — Breiman의 표준 랜덤 포레스트(회귀). 노드 분할 시 전체 특징 수의 **제곱근**만큼 무작위 선택. 트리 깊이 제한 없음. 보간을 위해 부트스트랩 끄기 (= Cutler 외의 "완벽한 무작위 트리 앙상블"). 제곱 손실과 0-1 손실 모두 이중 하강 (0-1 손실에서는 U자가 덜 뚜렷). 부트스트랩을 켜도 비슷.

③ **부록 E: $L_2$-부스팅** — Friedman의 기울기 부스팅. 트리 수가 늘면 점차 보간, 낮은 축소율(0.85)로 빠르게 보간. 임계점을 넘기 위해 같은 하이퍼파라미터로 만든 **여러 숲의 예측을 평균**.

→ 🔎 "평균하기"가 노름 최소화와 같은 역할 — 매끄러운 해를 만든다.

# p.23 해설 — 부록 E 마무리와 전체 정리

① **부록 E 결론** — 모델 용량 = 숲의 수와 숲당 트리 수. 제곱·0-1 손실 모두 이중 하강. 제곱 손실에서는 임계점 전 **강한 과적합**. 축소율을 0.1로 높이면 **정규화 효과** 때문에 이중 하강이 덜 뚜렷. → p.10의 "정규화가 정점을 가린다"는 주장의 또 다른 증거.

### ✍️ 논문 전체 정리 질문

1. Figure 1의 (a)와 (b)를 그리고, "고전 영역", "보간 임계점", "현대 영역"을 표시해 보자.
2. 임계점에서 테스트 위험이 폭발하는 이유를 **특징 행렬의 최소 특이값**으로 설명해 보자.
3. 정리 1(p.14)에서 상한이 $\|h\|$ 에 비례한다는 것이 왜 "최소 노름 귀납적 편향"을 정당화하는가?
4. "명시적 노름 최소화 = SGD = 가우시안 과정 평균" (p.11) — 세 관점을 각각 설명해 보자.
5. Zhang(2017)의 질문 "왜 암기할 수 있는 모델이 일반화하는가?"에 이 논문은 어떻게 답하는가?
6. ai_life **01 선형회귀**에서 다항식 차수를 늘리는 실험으로 이중 하강을 보여줄 수 있을까?

| 핵심 용어 | 뜻 |
|---|---|
| interpolation threshold | 보간 임계점 |
| inductive bias | 귀납적 편향 |
| RKHS | 재생 커널 힐베르트 공간 |
| fill distance | 채움 거리 |