p.1 해설 — 초록과 서론: 무엇이 어려운가

① **핵심 질문** — 연속 잠재변수의 **사후분포를 계산할 수 없고(intractable)**, 데이터가 **큰** 상황에서, 유향 확률 모델의 추론과 학습을 어떻게 효율적으로 할까?

② **두 가지 기여** ⭐

1. 변분 하한을 **재매개변수화**하면 표준 확률적 경사법으로 바로 최적화할 수 있는 하한 추정량이 나온다.
2. i.i.d. 데이터에서 데이터점마다 연속 잠재변수가 있으면, 계산 불가능한 사후분포에 **근사 추론 모델(인식 모델)**을 맞춰 사후 추론을 특히 효율적으로 할 수 있다. → 🔎 *reparameterization of the variational lower bound*에 밑줄.

③ **서론** — 변분 베이즈(VB)는 계산 불가능한 사후분포의 **근사**를 최적화한다. 하지만 흔한 평균장(mean-field) 방법은 근사 사후분포에 대한 기댓값을 **해석적으로** 풀어야 해서 일반적으로는 불가능. → 이 논문의 **SGVB** (확률적 경사 변분 베이즈) 추정량은 미분 가능한 **불편 추정량**이라 거의 모든 연속 잠재변수 모델에 쓸 수 있다.

④ **AEVB와 VAE** — 데이터점마다 연속 잠재변수가 있는 경우의 알고리즘이 **AEVB** (자동 인코딩 VB). 데이터점마다 비싼 반복 추론(MCMC)이 필요 없다. 인식 모델로 **신경망**을 쓰면 = **변분 오토인코더(VAE)**.

⑤ **2절 방법 시작** — i.i.d. 데이터, (전역) 파라미터는 최대우도(ML)·최대사후(MAP), 잠재변수는 변분 추론.

p.2 해설 — Figure 1과 2.1 문제 상황

① **Figure 1** ⭐ — 실선: 생성 모델 $p_\theta(z)\,p_\theta(x|z)$. 점선: 계산 불가능한 사후분포 $p_\theta(z|x)$ 의 **변분 근사** $q_\phi(z|x)$. 변분 파라미터 ϕ 와 생성 파라미터 θ 를 **함께** 학습. → ✍️ 이 그림을 그리고 "$z \to x$ = 생성(디코더)", "$x \to z$ = 추론(인코더)" 라고 적어 두세요.

② **데이터 생성 과정** — 관측 안 된 연속 확률변수 z:

1. 사전분포 $p_{\theta^*}(z)$ 에서 $z^{(i)}$ 생성
2. 조건부분포 $p_{\theta^*}(x|z)$ 에서 $x^{(i)}$ 생성 진짜 파라미터 θ^* 와 잠재변수 $z^{(i)}$ 는 **모른다**.

③ **어려움 1: 계산 불가능성** ⭐

- 주변 우도 $p_\theta(x) = \int p_\theta(z)\,p_\theta(x|z)\,dz$ 계산 불가
- 사후분포 $p_\theta(z|x) = p_\theta(x|z)p_\theta(z)/p_\theta(x)$ 계산 불가 → **EM 알고리즘 사용 불가**
- 평균장 VB의 적분도 불가 → 예: $p_\theta(x|z)$ 가 비선형 은닉층이 있는 신경망이면 흔히 생기는 일.

④ **어려움 2: 큰 데이터** — 배치 최적화는 너무 비싸다. 미니배치로 업데이트하고 싶다. 몬테카를로 EM은 데이터점마다 샘플링 루프가 있어 너무 느리다.

⑤ **풀고 싶은 세 문제**

1. 파라미터 θ 의 효율적 근사 ML/MAP 추정 → 가짜 데이터 **생성**
2. 주어진 x에 대한 잠재변수 z 의 근사 사후 추론 → **표현·부호화**
3. x 의 근사 주변 추론 → 잡음 제거, 복원, 초해상도

p.3 해설 — 2.2 변분 하한, 2.3 SGVB ⭐ 가장 중요한 쪽

① **인식 모델** — $q_\phi(z|x)$: 진짜 사후분포의 근사. 평균장과 달리 **인수분해될 필요 없고**, 파라미터 ϕ 를 닫힌 형식 기댓값으로 계산하지 않고 θ 와 **함께 학습**.

② **부호화 이론 관점** — z = 잠재 **코드**. $q_\phi(z|x)$ = **확률적 인코더** (x → 코드의 분포), $p_\theta(x|z)$ = **확률적 디코더** (코드 → x의 분포).

③ **변분 하한 유도** ⭐ **반드시 손으로**

$$\log p_\theta(x^{(i)}) = D_{KL}\big(q_\phi(z|x^{(i)}) \,\|\, p_\theta(z|x^{(i)})\big) + \mathcal{L}(\theta, \phi; x^{(i)}) \tag{1}$$

KL ≥ 0 이므로 $\mathcal{L}$ 은 **하한**:

$$\log p_\theta(x^{(i)}) \geq \mathcal{L} = \mathbb{E}_{q_\phi(z|x)}\big[-\log q_\phi(z|x) + \log p_\theta(x, z)\big] \tag{2}$$

$$\mathcal{L} = -D_{KL}\big(q_\phi(z|x^{(i)}) \,\|\, p_\theta(z)\big) + \mathbb{E}_{q_\phi(z|x^{(i)})}\big[\log p_\theta(x^{(i)}|z)\big] \tag{3}$$

→ ✍️ (1)은 $\log p(x) = \mathbb{E}_q[\log p(x)]$ 에 $\frac{p(x,z)}{p(z|x)}$ 를 넣고 q 를 곱하고 나눠서 유도됩니다.

④ **순진한 경사 추정의 문제** — $\nabla_\phi \mathbb{E}_{q_\phi}[f(z)] = \mathbb{E}_{q_\phi}[f(z)\nabla_\phi \log q_\phi(z)]$ (점수 함수 추정량)는 **분산이 매우 커서** 실용성이 없다. → 🔎 *exhibits very high variance* 에 밑줄. 이것이 재매개변수화가 필요한 이유.

⑤ **2.3 SGVB 추정량** — $z \sim q_\phi(z|x)$ 를 보조 잡음 ϵ 의 **미분 가능한 변환**으로:

$$z = g_\phi(\epsilon, x), \quad \epsilon \sim p(\epsilon) \tag{4}$$

$$\mathbb{E}_{q_\phi(z|x)}[f(z)] = \mathbb{E}_{p(\epsilon)}[f(g_\phi(\epsilon, x))] \simeq \frac{1}{L}\sum_{l=1}^{L} f(g_\phi(\epsilon^{(l)}, x)) \tag{5}$$

식 (2)에 적용한 것이 일반 SGVB 추정량 $\tilde{\mathcal{L}}^A$ (식 6).

p.4 해설 — Algorithm 1, 오토인코더와의 연결, 재매개변수화

① **Algorithm 1 (미니배치 AEVB)** — 반복: 미니배치 M개 추출 → 잡음 ϵ 추출 → 추정량의 경사 계산 → SGD나 AdaGrad로 θ, ϕ 업데이트. 실험 설정 $M = 100$, $L = 1$.

② **두 번째 추정량 $\tilde{\mathcal{L}}^B$ (식 7)** — 식 (3)의 KL 항은 보통 **해석적으로 적분 가능**(부록 B) → 재구성 오차만 샘플링:

$$\tilde{\mathcal{L}}^B = -D_{KL}\big(q_\phi(z|x^{(i)}) \| p_\theta(z)\big) + \frac{1}{L}\sum_{l=1}^{L} \log p_\theta(x^{(i)}|z^{(i,l)})$$

보통 일반 추정량보다 **분산이 작다**. KL 항은 근사 사후분포를 사전분포 쪽으로 끌어당기는 **정규화**.

③ **미니배치 추정 (식 8)** — 전체 N개에 대해 $\mathcal{L}(X) \simeq \frac{N}{M}\sum_{i=1}^{M} \tilde{\mathcal{L}}(x^{(i)})$. M이 충분히 크면(예: 100) 데이터점당 샘플 $L = 1$ 이면 충분.

④ **오토인코더와의 연결** ⭐

- 첫째 항 (KL) = **정규화**
- 둘째 항 = **음의 재구성 오차**: x → (인코더) → z 샘플 → (디코더) → x 의 확률 → 🔎 *negative reconstruction error in auto-encoder parlance* 에 밑줄. 확률 모델이 그대로 오토인코더가 된다!

⑤ **2.4 재매개변수화 트릭** — 연속 확률변수 $z \sim q_\phi(z|x)$ 를 결정적 변수 $z = g_\phi(\epsilon, x)$ 로 표현 (ϵ 은 독립 보조 변수). 그러면 기댓값의 몬테카를로 추정이 ϕ **에 대해 미분 가능**. **증명**: 변수변환 $q_\phi(z|x)\prod_i dz_i = p(\epsilon)\prod_i d\epsilon_i$ 이므로

$$\int q_\phi(z|x) f(z)\, dz = \int p(\epsilon) f(g_\phi(\epsilon, x))\, d\epsilon$$

p.5 해설 — 가우시안 예시와 3절 VAE

① 1변수 가우시안 예 ⭐ **가장 쉬운 이해** $z \sim N(\mu, \sigma^2)$ 이면 $z = \mu + \sigma\epsilon$, $\epsilon \sim N(0,1)$:

$$\mathbb{E}_{N(z;\mu,\sigma^2)}[f(z)] = \mathbb{E}_{N(\epsilon;0,1)}[f(\mu+\sigma\epsilon)] \simeq \frac{1}{L}\sum_{l} f(\mu + \sigma\epsilon^{(l)})$$

→ ✍️ 이제 $\frac{\partial}{\partial\mu}$, $\frac{\partial}{\partial\sigma}$ 를 **연쇄법칙**으로 바로 계산할 수 있습니다. 무작위성이 ϵ 으로 빠졌기 때문!

② 재매개변수화가 가능한 분포들

방법	원리	예
역누적분포함수	$\epsilon \sim U(0,1)$, $g = F^{-1}$	지수, 코시, 로지스틱, 굼벨 등
위치-척도족	$g =$ 위치 $+$ 척도 $\cdot\epsilon$	가우시안, 라플라스, 스튜던트 t 등
합성	보조 변수들의 변환	로그정규, 감마, 디리클레, 베타, 카이제곱

③ 3절: 변분 오토인코더 ⭐

- 사전분포: $p_\theta(z) = N(z; 0, I)$ — 파라미터 없음
- 디코더 $p_\theta(x|z)$: 가우시안(실수 데이터) 또는 **베르누이**(이진 데이터), 파라미터는 MLP가 계산
- 인코더: 대각 공분산 가우시안

$$\log q_\phi(z|x^{(i)}) = \log N\left(z;\ \mu^{(i)},\ \sigma^{2(i)}I\right)$$

  $\mu^{(i)}, \sigma^{(i)}$ 는 인코딩 MLP의 출력.

④ 샘플링과 최종 추정량 (식 10) — $z^{(i,l)} = \mu^{(i)} + \sigma^{(i)} \odot \epsilon^{(l)}$, $\epsilon^{(l)} \sim N(0, I)$:

$$\mathcal{L} \simeq \frac{1}{2}\sum_{j=1}^{J}\left(1 + \log((\sigma_j^{(i)})^2) - (\mu_j^{(i)})^2 - (\sigma_j^{(i)})^2\right) + \frac{1}{L}\sum_{l=1}^{L}\log p_\theta(x^{(i)}|z^{(i,l)})$$

→ 🔎 이 식이 오늘날 VAE 코드의 **손실 함수 그 자체**입니다.

p.6 해설 — 4절 관련 연구, 5절 실험 시작

① **웨이크-슬립 알고리즘** — 같은 종류의 연속 잠재변수 모델에 쓸 수 있는 유일한 다른 온라인 방법. 인식 모델을 쓰는 점은 같지만, **두 목적함수를 동시에** 최적화해야 하고 그 조합이 주변 우도(의 하한)에 대응하지 않는다. 장점: 이산 잠재변수에도 적용 가능.

② **확률적 변분 추론** — 순진한 경사 추정량의 분산을 줄이는 **제어 변량(control variate)** 기법들, 비슷한 재매개변수화를 쓴 연구 [SK13].

③ **PCA와의 연결** ⭐ — 선형 오토인코더와 선형-가우시안 생성 모델의 관계는 오래 알려졌다. [Row98]: **PCA** = 사전분포 $p(z) = N(0, I)$, $p(x|z) = N(x; Wz, \epsilon I)$ 에서 $\epsilon \to 0$ 인 경우의 최대우도 해. → 🔎 VAE는 **비선형 확률적 PCA**로 볼 수 있다.

④ **오토인코더 연구** — 정규화 없는 오토인코더의 학습 기준 = 입력과 잠재 표현 사이 **상호정보량**의 하한 최대화 (infomax). 하지만 재구성 기준만으로는 유용한 표현을 배우기에 **부족** → 잡음 제거·수축·희소 오토인코더 같은 정규화가 제안됨. SGVB는 변분 하한이 **정규화 항을 자동으로** 정해 주므로 별도의 정규화 하이퍼파라미터가 필요 없다.

⑤ **독립적인 동시 연구** — [RMW14] Rezende, Mohamed, Wierstra도 같은 재매개변수화로 오토인코더와 변분 추론을 연결 (독립적으로 개발).

⑥ **5절 실험** — MNIST와 Frey Face 데이터로 이미지 생성 모델 학습, 변분 하한과 추정 주변 우도로 비교. Frey Face는 연속값이라 가우시안 디코더 (평균은 시그모이드로 $(0, 1)$ 제한).

p.7 해설 — Figure 2와 실험 세부

① **Figure 2** ⭐ — AEVB vs 웨이크-슬립, 잠재 공간 차원 N_z 별로 하한 최적화 비교. 세로축: 데이터점당 평균 변분 하한, 가로축: 평가한 학습 데이터 수.

- AEVB가 **훨씬 빨리 수렴**하고 **더 좋은 해**에 도달
- 흥미롭게도 잠재변수가 **많아도 과적합이 더 생기지 않음** → 하한의 **정규화 효과** → 🔎 *more latent variables does not result in more overfitting* 에 밑줄.

② **계산 비용** — 인텔 제온 CPU 하나로 학습 데이터 100만 개당 약 20~40분.

③ **학습 설정**

- 확률적 경사 **상승** (하한을 최대화하므로) + 작은 가중치 감쇠 = 사전분포 $p(\theta) = N(0, I)$ → 근사 MAP
- 모든 파라미터 $N(0, 0.01)$ 로 초기화
- 스텝 크기는 **AdaGrad** (전역 스텝 0.01, 0.02, 0.1 중 선택)
- $M = 100$, $L = 1$ → 이 논문은 Adam 이전이라 AdaGrad를 썼다. 1년 뒤 같은 저자가 **Adam**을 만들어 VAE로 실험한다 (Adam 논문 Figure 4).

④ **하한 실험** — 은닉 유닛: MNIST 500개, Frey Face 200개 (작은 데이터라 과적합 방지).

⑤ **주변 우도 실험** — 잠재 차원이 아주 낮으면 MCMC로 주변 우도 추정 가능. 은닉 100개, 잠재변수 **3개**. AEVB, 웨이크-슬립, 몬테카를로 EM(MCEM, 해밀토니안 몬테카를로 샘플러) 비교.

p.8 해설 — Figure 3, 6절 결론, 7절 향후 연구

① **Figure 3** — 추정 주변 우도 비교, 학습 데이터 수가 작을 때와 클 때. MCEM은 **온라인 알고리즘이 아니라** 전체 MNIST에 효율적으로 적용할 수 없다 (AEVB와 웨이크-슬립은 가능). → 🔎 학습 데이터가 많을 때 AEVB가 가장 빠르게 좋은 값에 도달하는지 확인.

② **고차원 데이터 시각화** — 잠재 공간을 **2차원**으로 하면 학습된 인코더로 고차원 데이터를 저차원 **다양체**에 사영할 수 있다 (부록 A, p.10).

③ **6절 결론** — 변분 하한의 새 추정량 **SGVB**: 표준 확률적 경사법으로 바로 미분·최적화. i.i.d. 데이터와 데이터점별 연속 잠재변수에 대해 **AEVB** 알고리즘.

④ **7절 향후 연구** ⭐ **모두 실현되었다**

1. 인코더·디코더에 **깊은 신경망(합성곱 망 등)** 을 쓴 계층적 생성 구조
2. 시계열 모델 (동적 베이즈 네트워크)
3. 전역 파라미터에 SGVB 적용
4. 잠재변수가 있는 지도학습 모델 → 🔎 1번은 이후 **잠재 확산 모델(Stable Diffusion)** 의 VAE 인코더로 이어진다.

p.9 해설 — 참고문헌과 부록 A

참고문헌 중 주목할 것

참고문헌	왜 볼까
[BCV13] Bengio, Courville, Vincent『표현 학습 리뷰』	표현 학습의 큰 그림
[BJP12] Blei, Jordan, Paisley	확률적 탐색 변분 추론 — 순진한 경사의 분산 문제
[DHS10] Duchi 외 **AdaGrad**	이 논문이 쓴 최적화기 (Adam 논문과 연결)
[DKPR87] Duane 외 하이브리드 몬테카를로	MCMC 비교 실험
[HBWP13] Hoffman 외 확률적 변분 추론	대규모 변분 추론
[HDFN95] Hinton 외 **웨이크-슬립**	비교 대상
[RMW14] Rezende, Mohamed, Wierstra ⭐	같은 아이디어의 독립적 동시 연구
[Row98] Roweis, PCA의 EM	PCA와 확률 모델의 연결
[VLL+10] Vincent 외 잡음 제거 오토인코더	오토인코더 정규화

부록 A 시작 — 그림 4, 5에서 AEVB로 학습한 모델의 잠재 공간과 관측 공간 시각화.

p.10 해설 — Figure 4, 5와 부록 B: KL의 닫힌 형식 ⭐

---

① **Figure 4** ⭐ **유명한 그림** — 2차원 잠재 공간으로 학습한 (a) Frey Face, (b) MNIST 다양체. 사전분포가 가우시안이므로 단위 정사각형 위의 **등간격 좌표**를 가우시안의 **역누적분포함수**로 변환해 z 값을 만들고, 각 z에 대한 $p_\theta(x|z)$를 그렸다. → 🔎 숫자가 한 모양에서 다른 모양으로 **연속적으로** 변하는 것 — 잠재 공간이 의미 있는 **연속 구조**를 가진다는 증거.

② **Figure 5** — 잠재 차원 2, 5, 10, 20 에서 학습한 MNIST 모델의 무작위 샘플. 차원이 커질수록 샘플이 더 다양하고 선명.

③ **부록 B: $-D_{KL}$ 의 가우시안 해** ⭐ **직접 계산하기** — 사전분포 $N(0, I)$, 근사 사후분포 $N(\mu, \sigma^2)$, z의 차원 J:

$$\int q(z) \log p(z)\, dz = -\frac{J}{2}\log(2\pi) - \frac{1}{2}\sum_{j=1}^{J}(\mu_j^2 + \sigma_j^2)$$

→ ✍️ 가우시안의 2차 모멘트 $\mathbb{E}[z^2] = \mu^2 + \sigma^2$ 만 알면 유도됩니다.

p.11 해설 — 부록 B 마무리, C: MLP 인코더·디코더, D 시작

① 부록 B 계속

$$\int q(z)\log q(z)\,dz = -\frac{J}{2}\log(2\pi) - \frac{1}{2}\sum_{j=1}^{J}(1+\log\sigma_j^2)$$

두 식을 빼면

$$-D_{KL}\big(q\|p\big) = \frac{1}{2}\sum_{j=1}^{J}\big(1+\log\sigma_j^2-\mu_j^2-\sigma_j^2\big)$$

→ 🔎 이 결과가 p.5 식 (10)의 첫 항. **샘플링 없이 정확히** 계산된다.

② C.1 베르누이 MLP 디코더 — 이진 데이터용, 은닉층 하나:

$$\log p(x|z) = \sum_{i=1}^{D} x_i\log y_i + (1-x_i)\log(1-y_i), \quad y = f_\sigma\big(W_2\tanh(W_1 z+b_1)+b_2\big)$$

→ = **이진 교차 엔트로피**. 로지스틱 회귀의 손실과 같다.

③ C.2 가우시안 MLP — 대각 공분산:

$$\log p(x|z) = \log N(x;\ \mu,\ \sigma^2 I), \quad \mu = W_4 h + b_4,\ \log\sigma^2 = W_5 h + b_5,\ h = \tanh(W_3 z + b_3)$$

인코더로 쓸 때는 z와 x를 **바꾸고**, 가중치가 변분 파라미터 ϕ 가 됨. → 🔎 분산 대신 $\log\sigma^2$ 를 출력하는 이유: 항상 양수가 되도록.

④ 부록 D: 주변 우도 추정량 — 표본 공간 차원이 낮을 때(5 미만) 좋은 추정.

p.12 해설 — 부록 D, E: MCEM, F: 완전 변분 베이즈 시작

① 부록 D 주변 우도 추정 3단계

1. 기울기 기반 MCMC(하이브리드 몬테카를로)로 사후분포에서 $z^{(l)}$ 샘플: $\nabla_z \log p_\theta(z|x) = \nabla_z \log p_\theta(z) + \nabla_z \log p_\theta(x|z)$
2. 샘플들에 밀도 추정량 $q(z)$ 를 맞춤
3. 새 샘플로 다음 추정량 계산:

$$p_\theta(x^{(i)}) \simeq \left(\frac{1}{L} \sum_{l=1}^{L} \frac{q(z^{(l)})}{p_\theta(z)\, p_\theta(x^{(i)}|z^{(l)})} \right)^{-1}$$

→ 조화 평균형 추정량. 왜 성립하는지 기댓값으로 확인해 보세요.

② 부록 E: 몬테카를로 EM — 인코더 없이 사후분포에서 직접 샘플링: HMC 도약(leapfrog) 10단계 (채택률 90%로 자동 조정) + 가중치 업데이트 5단계. 주변 우도는 학습·테스트 각 처음 1000개 데이터로, 데이터점마다 50개 샘플.

③ 부록 F: 완전 변분 베이즈 — 잠재변수 z 뿐 아니라 **파라미터 θ 에도** 변분 추론. 초사전분포 $p_\alpha(\theta)$:

$$\log p_\alpha(X) = D_{KL}\big(q_\phi(\theta) \| p_\alpha(\theta|X)\big) + \mathcal{L}(\phi; X) \tag{13}$$

$$\mathcal{L}(\phi; X) = \int q_\phi(\theta) \big(\log p_\theta(X) + \log p_\alpha(\theta) - \log q_\phi(\theta) \big)\, d\theta \tag{14}$$

→ 🔎 식 (1)과 **똑같은 구조**가 한 층 위에서 반복된다.

p.13 해설 — 부록 F 계속: 두 층의 재매개변수화

① 데이터점별 하한 (식 16)

$$\mathcal{L}(\theta, \phi; x^{(i)}) = \int q_\phi(z|x)\big(\log p_\theta(x^{(i)}|z) + \log p_\theta(z) - \log q_\phi(z|x)\big)\, dz$$

세 개의 기댓값으로 나뉘고, 둘째·셋째는 가우시안이면 해석적으로 풀린다.

② 두 가지 재매개변수화

- 잠재변수: $z = g_\phi(\epsilon, x)$, $\epsilon \sim p(\epsilon)$ (식 17-18)
- 파라미터: $\theta = h_\phi(\zeta)$, $\zeta \sim p(\zeta)$ (식 19-20)

③ 통합 함수 (식 21)

$$f_\phi(x, z, \theta) = N \cdot \big(\log p_\theta(x|z) + \log p_\theta(z) - \log q_\phi(z|x)\big) + \log p_\alpha(\theta) - \log q_\phi(\theta)$$

④ 몬테카를로 추정 — $\mathcal{L}(\phi; X) \simeq \frac{1}{L}\sum_l f_\phi\big(x^{(l)}, g_\phi(\epsilon^{(l)}, x^{(l)}), h_\phi(\zeta^{(l)})\big)$. 추정량이 ϕ 와 무관한 $p(\epsilon)$, $p(\zeta)$ 의 샘플에만 의존하므로 **ϕ 에 대해 미분 가능**. → 🔎 재매개변수화의 핵심을 다시 한번: "무작위성을 파라미터와 **분리**한다."

⑤ 가우시안 예 시작 — $p_\alpha(\theta) = N(0, I)$, $p_\theta(z) = N(0, I)$, 근사 사후분포는 대각 공분산 가우시안.

p.14 해설 — Algorithm 2와 전체 정리

① **Algorithm 2** — 확률적 경사 계산: 데이터에서 x 추출 → $\epsilon \sim p(\epsilon)$, $\zeta \sim p(\zeta)$ 추출 → $g \leftarrow \nabla_\phi f_\phi(x, g_\phi(\epsilon, x), h_\phi(\zeta))$.

② 가우시안 재매개변수화

$$\theta = \mu_\theta + \sigma_\theta \odot \zeta, \qquad z = \mu_z + \sigma_z \odot \epsilon, \qquad \zeta, \epsilon \sim N(0, I)$$

네 분포가 모두 가우시안이라 f_ϕ 의 **네 항을 해석적으로** 풀 수 있어 분산이 더 작은 추정량을 만들 수 있다 (p.11의 KL 공식이 두 번 쓰임).

✍️ 논문 전체 정리 질문

1. 식 (1)을 처음부터 유도하고, 왜 $\mathcal{L}$ 이 "하한"인지 설명해 보자. (p.3)
2. 순진한 점수 함수 경사 vs 재매개변수화 경사 — 왜 후자가 분산이 작을까?
3. $-D_{KL} = \frac{1}{2}\sum(1 + \log\sigma^2 - \mu^2 - \sigma^2)$ 를 직접 계산해 보자. (p.10-11)
4. VAE 손실 = "재구성 오차 + KL 정규화". 각각이 너무 강하면 어떤 일이 생길까?
5. 이번 주 Adam 논문 Figure 4가 왜 VAE로 실험했는지 이제 이해되는가?
6. ai_life **02 컴퓨터비전** 심화로, Figure 4 같은 "숫자 변형" 시각화를 학생 활동으로 만들 수 있을까?

핵심 용어	뜻
intractable	계산 불가능한
recognition model	인식 모델 (인코더)
reparameterization trick	재매개변수화 트릭
marginal likelihood	주변 우도
manifold	다양체