p.1 해설 — 초록과 서론: 무엇이 일반화를 결정하는가?

① **초록** — 거대한 신경망이 **훈련 성능과 테스트 성능의 차이가 놀랍게 작다**. 기존 설명은 (a) 모델족의 성질, (b) 정규화 기법. 체계적인 실험으로 이 둘이 **설명에 실패함**을 보인다:

- 최신 CNN은 SGD로 **무작위 레이블도 쉽게 맞춘다**
- 명시적 정규화를 해도 질적으로 같음
- 이미지를 **완전한 무작위 잡음**으로 바꿔도 맞춘다
- 이론: 파라미터 수가 데이터 수를 넘자마자 **깊이 2 신경망도 완벽한 유한 표본 표현력**을 가짐 → 🔎 *easily fit a random labeling of the training data* 에 밑줄. 논문의 핵심 한 줄.

② **서론 첫 문단** — 신경망은 학습 표본보다 파라미터가 **훨씬 많은데도** 일반화 오차(훈련 오차와 테스트 오차의 차이)가 작다. 동시에 일반화를 못 하는 구조도 쉽게 만들 수 있다. **무엇이 둘을 가르는가?**

③ **통계적 학습 이론의 도구들** — 일반화 오차를 통제하는 복잡도 척도:

척도	출처
VC 차원	Vapnik (1998)
라데마허 복잡도	Bartlett & Mendelson (2003)
균등 안정성	Bousquet & Elisseeff (2002) 등
파라미터가 많으면 이론상 **정규화가 필요**. 조기 종료처럼 **암묵적** 정규화도 있음.	

④ **문제 제기** — 기존 관점은 일반화 성능이 **극적으로 다른** 신경망들을 구별하지 못한다.

p.2 해설 — 핵심 발견 요약

① **무작위화 검정** ⭐ — 비모수 통계의 **무작위화 검정**(randomization test)을 변형. 진짜 레이블을 무작위 레이블로 바꾼 데이터로 표준 구조들을 학습.

> **심층 신경망은 무작위 레이블을 쉽게 맞춘다.**

→ 훈련 오차 0, 테스트 오차는 우연 수준. 모델·크기·하이퍼파라미터·최적화기를 **하나도 바꾸지 않고** 레이블만 섞어서 일반화 오차를 크게 만들 수 있다.

② **세 가지 함의**

1. 신경망의 **유효 용량**은 데이터 전체를 **암기**하기에 충분하다.
2. 무작위 레이블에서도 최적화는 **여전히 쉽다** — 학습 시간이 진짜 레이블보다 **작은 상수배**만 늘어난다.
3. 레이블 무작위화는 **데이터 변환일 뿐**, 학습 문제의 다른 성질은 그대로.

③ **무작위 픽셀** — 이미지 자체를 가우시안 잡음으로 바꿔도 CNN은 훈련 오차 0. 잡음 정도를 0에서 1까지 바꾸면 일반화 오차가 **꾸준히 나빠짐** → 신경망은 남은 **신호**를 잡으면서 **잡음 부분은 무차별적으로 외운다**.

④ **명시적 정규화의 역할** ⭐

> **명시적 정규화는 일반화를 개선할 수 있지만, 필요하지도 충분하지도 않다.**

볼록 경험적 위험 최소화에서는 정규화가 자명한 해를 막는 **필수** 장치이지만, 딥러닝에서는 **조정용 매개변수**에 가깝다.

⑤ **유한 표본 표현력** — 파라미터 $p = 2n + d$ 인 **2층 ReLU 망**이 d차원 표본 n개의 **어떤 레이블도** 표현. 이전 결과(Livni 외)는 $O(dn)$. 깊이 k로 하면 층당 $O(n/k)$.

p.3 해설 — 암묵적 정규화, 관련 연구, 2절 시작

① **암묵적 정규화** — 신경망은 거의 항상 **SGD의 출력**으로 모델을 고른다. 선형 모델에서 SGD는 항상 **작은 노름의 해**로 수렴 → **알고리즘 자체가 정규화**. 작은 데이터셋에서는 정규화 없는 가우시안 커널 방법도 잘 일반화.

② **균등 안정성의 한계** — Hardt 외(2016)는 SGD 단계 수로 일반화 오차를 상한. 하지만 균등 안정성은 **레이블과 무관한** 알고리즘의 성질 → 진짜 레이블(일반화 잘 됨)과 무작위 레이블(안 됨)을 **구별할 수 없다**. → 🔎 *independent of the labeling of the training data* 에 밑줄.

③ **표현력 연구와의 차이** — Cybenko(1989)부터 이어진 보편 근사 정리들은 **모집단 수준**(전체 정의역에서 어떤 함수를 표현하는가). 이 논문은 **유한 표본 n개**에 대한 표현력. → 이번 주 Cybenko 논문과 연결!

④ **크기와 무관한 상한** — Bartlett(1998): 시그모이드 망의 fat-shattering 차원을 가중치의 ℓ_1 노름으로 상한 → **망 크기와 무관한** 일반화 상한. 하지만 ReLU에서는 ℓ_1 노름이 정보를 주지 못함. Neyshabur 외(2014): **망 크기는 주된 용량 통제가 아니다**.

⑤ **2절 유효 용량** — 후보 구조를 진짜 데이터와 무작위 레이블 데이터 **둘 다로** 학습. 무작위 레이블에서는 학습이 불가능하므로 학습이 수렴하지 않거나 크게 느려질 것이라 예상했지만 — **놀랍게도 거의 영향이 없었다**.

p.4 해설 — Figure 1과 무작위화 실험 설계

① Figure 1 ⭐ 논문에서 가장 중요한 그림

- **(a)** 여러 설정의 훈련 손실 곡선: 진짜 레이블, 무작위 레이블, 섞인 픽셀, 무작위 픽셀, 가우시안 — **모두 0으로 감소**
- **(b)** 레이블 오염 비율에 따른 상대 수렴 시간: 오염이 클수록 조금 느려짐
- **(c)** 레이블 오염에 따른 테스트 오차(= 일반화 오차, 훈련 오차가 0이므로) → 🔎 (a)에서 모든 곡선이 결국 0에 도달하는 것을 확인하세요.

② 데이터와 모델 — CIFAR10(Inception 축소판, AlexNet, MLP), ImageNet(Inception V3).

③ 2.1 여섯 가지 변형

변형	내용
진짜 레이블	원본
부분 오염	확률 p로 레이블을 무작위 클래스로
무작위 레이블	모든 레이블을 무작위로
섞인 픽셀	**하나의** 픽셀 순열을 모든 이미지에 적용
무작위 픽셀	이미지마다 **다른** 순열
가우시안	원본과 평균·분산이 같은 가우시안으로 픽셀 생성

④ 관찰 ⭐ — 무작위 레이블에서 (a) **학습률 스케줄을 바꿀 필요 없음**, (b) 일단 맞추기 시작하면 **빠르게 수렴**, (c) 훈련 집합을 **완벽하게 (과)적합**. 무작위 픽셀·가우시안이 무작위 레이블보다 **더 빨리** 수렴 시작.

p.5 해설 — 결과와 기존 이론의 한계

① **왜 무작위 픽셀이 더 빠른가** — 무작위 픽셀 입력들은 같은 클래스의 자연 이미지들보다 **서로 더 떨어져 있어서** 임의의 레이블 할당이 더 쉽다.

② **ImageNet** — 무작위 레이블 100만 개(1000 클래스)에서 top-1 훈련 정확도 **95.20%**. 하이퍼파라미터 조정 없이! 명시적 정규화를 켜도 약 90%.

③ **부분 오염** — 모든 오염 수준에서 훈련 집합을 완벽히 맞춤. 오염이 1에 가까워지면 일반화 오차 → **90%** (CIFAR10 무작위 추측 수준).

④ **라데마허 복잡도와 VC 차원** ⭐ **수학적 핵심**

$$\hat{\mathfrak{R}}_n(\mathcal{H}) = \mathbb{E}_\sigma\left[\sup_{h\in\mathcal{H}} \frac{1}{n}\sum_{i=1}^{n} \sigma_i\, h(x_i)\right], \quad \sigma_i \in \{\pm 1\} \text{ 균등 무작위}$$

→ 이 정의는 **무작위** ± 1 **레이블을 맞추는 능력** = 바로 이 논문의 무작위화 검정! 신경망이 무작위 레이블을 완벽히 맞추므로 $\hat{\mathfrak{R}}_n(\mathcal{H}) \approx 1$ → **자명한 상한**이라 쓸모없는 일반화 한계. → 🔎 *This definition closely resembles our randomization test* 에 밑줄.

⑤ **VC 차원, fat-shattering 차원** — 같은 논리. Bartlett의 ℓ_1 노름 상한은 ReLU에 적용 불가, Neyshabur 외의 다른 노름 일반화도 관찰을 설명하지 못함.

⑥ **균등 안정성** — 표본 하나를 바꿨을 때 알고리즘이 얼마나 민감한가. 알고리즘만의 성질이라 **데이터·레이블 분포를 고려하지 않음**. 더 약한 안정성 개념은 일반화 오차 상한과 동치이지만 활용이 어렵다.

p.6 해설 — Table 1과 3절: 정규화의 역할

① **Table 1** ⭐ — CIFAR10에서 모델별 훈련/테스트 정확도, 무작위 자르기(데이터 증강)와 가중치 감쇠 켜고 끄기.

모델	파라미터	정규화 없이 테스트 정확도	무작위 레이블 훈련 정확도
Inception	약 165만	80%대	100%
AlexNet	약 139만	70%대	99.82%
MLP 3×512	약 174만	50%대	100%
MLP 1×512	약 121만	50%대	99.34%
→ 🔎 회색 줄(무작위 레이블)의 **테스트 정확도 ≈ 10%** 와 **훈련 정확도 ≈ 100%** 를 비교.			

② **3절: 정규화의 고전적 역할** — 파라미터가 데이터보다 많을 때 과적합을 완화하는 표준 도구. 원래 가설 공간이 너무 크지만, 정규화가 학습을 **관리 가능한 복잡도의 부분집합**으로 제한. 노름에 벌점을 주면 유효 라데마허 복잡도가 극적으로 줄어든다.

③ **딥러닝에서는 다르다** — 드롭아웃과 가중치 감쇠를 켜도 InceptionV3는 무작위 훈련 집합을 거의 완벽히 맞춤. 단 **AlexNet은 가중치 감쇠를 켜면 무작위 레이블에서 수렴 실패**.

④ **비교한 정규화 기법**

- **데이터 증강**: 무작위 자르기, 밝기·채도·색상·대비 변화
- **가중치 감쇠**: ℓ_2 정규화 = 가중치를 유클리드 공 안으로 제한하는 것과 동치
- **드롭아웃**: 층 출력을 무작위로 0으로 (ImageNet의 Inception V3만 사용)

p.7 해설 — Figure 2와 암묵적 정규화

① **Figure 2** — 암묵적 정규화의 효과. 회색 영역 = 누적 최고 테스트 정확도(조기 종료의 잠재적 이득).

- **(a) ImageNet**: 다른 정규화가 없을 때 조기 종료가 일반화를 개선할 **가능성**이 있음
- **(b) CIFAR10**: 조기 종료가 꼭 도움이 되지는 않음. 배치 정규화는 학습을 안정화하고 성능을 개선. 하지만 **모든 정규화를 꺼도 모든 모델이 여전히 잘 일반화**.

② **ImageNet 수치** ⭐

- 모든 정규화를 끄면 top-1 정확도 **18%p 하락**: 59.80% (무작위 추측은 0.1%)
- 데이터 증강만 켜면 **72.95%** → 알려진 대칭성을 이용한 증강이 가중치 감쇠보다 훨씬 강력
- 정규화 없이 top-5 **80.38%** vs ILSVRC 2012 우승(AlexNet) 83.6% → 🔎 *bigger gains can be achieved by simply changing the model architecture* 에 밑줄. 정규화보다 **구조**가 더 중요하다!

③ **3.1 암묵적 정규화: 조기 종료** — 일부 볼록 문제에서 조기 종료가 암묵적 정규화임이 알려짐. ImageNet에서는 잠재적 개선 확인, CIFAR10에서는 이득 없음. → 각주: "잠재적"이라 쓴 이유 — 엄밀하려면 조기 종료 시점을 고른 테스트 집합과 **다른 별도의 테스트 집합**이 필요.

④ **배치 정규화** — 미니배치 안에서 층 응답을 정규화. 정규화용으로 설계되진 않았지만 보통 일반화를 개선. BN을 모두 뺀 "Inception w/o BatchNorm"으로 실험.

p.8 해설 — 4절 유한 표본 표현력, 5절 선형 모델

① **BN 결과** — 학습 동역학은 안정화하지만 일반화 효과는 **3~4%** 뿐.

② **정규화 요약** — 잘 조정하면 일반화를 도울 수 있지만, **일반화의 근본 원인은 아닐 것**. 모든 정규화를 빼도 잘 작동하므로.

③ **4절: 유한 표본 표현력** — 기존 결과(Cybenko 등)는 거의 모두 **모집단 수준**: 같은 파라미터 수로 전체 정의역에서 어떤 함수를 표현할 수 있는가. 예: 깊이 k가 $k-1$보다 일반적으로 강력.

④ **저자들의 관점** — 실제로 중요한 것은 **크기 n인 유한 표본** 위의 표현력. 모집단 결과를 균등 수렴으로 옮기면 표본 수가 입력 차원에 다항적, 깊이에 **지수적**으로 커야 해서 비현실적.

⑤ **정의와 정리 1** ⭐ 신경망 C가 "크기 n 표본의 임의의 함수를 표현한다" $\iff$ 모든 $S \subseteq \mathbb{R}^d$ ($|S| = n$)와 모든 $f : S \to \mathbb{R}$ 에 대해 $C(x) = f(x)\ \forall x \in S$ 인 가중치가 존재.

> **정리 1.** ReLU 활성화와 $2n + d$ 개 가중치를 가진 2층 신경망이 존재하여 d차원 표본 n개 위의 임의의 함수를 표현한다. 증명은 부록 C (p.13-14).

⑥ **5절: 선형 모델로 돌아가기** — 선형 모델도 일반화의 원천을 이해하기 쉽지 않다. 경험적 위험 최소화 $\min_w \frac{1}{n}\sum_i \text{loss}(w^\top x_i, y_i)$. $d \geq n$ 이고 데이터 행렬 X ($n \times d$)의 랭크가 n 이면 $Xw = y$ 의 해가 **무한히 많다**. 그렇다면 모든 전역 최솟값이 똑같이 일반화하는가?

p.9 해설 — SGD가 고르는 해: 최소 노름 ⭐

① **곡률로는 구별 불가** — 선형 모델에서 제곱 손실의 헤시안은 $\frac{1}{n}X^\top X$ 로 w**와 무관** → 모든 최적해의 곡률이 같다. 게다가 모든 전역 최적해에서 헤시안이 **퇴화**. → "평평한 최솟값이 일반화를 잘한다"는 설명이 선형에서는 통하지 않음.

② **SGD의 해** ⭐ **직접 유도하기** — SGD 업데이트 $w_{t+1} = w_t - \eta_t e_t x_{i_t}$. $w_0 = 0$ 이면

$$w = \sum_{i=1}^{n} \alpha_i x_i = X^\top \alpha \quad (\text{데이터의 생성 공간 안})$$

여기에 $Xw = y$ 를 더하면 $XX^\top \alpha = y$ — **유일한 해**. 내적만 쓰므로 = **커널 트릭**!

③ **커널 실험** — 그람 행렬 $K = XX^\top$ 를 만들고 $K\alpha = y$ 를 풀면 끝.

데이터	전처리	테스트 오차
MNIST	없음	**1.2%**
MNIST	가보 웨이블릿	**0.6%**
CIFAR10	가우시안 커널	46%
CIFAR10	무작위 합성곱망(필터 32,000개)	17% ($\ell 2$ 추가 시 15%)
→ MNIST는 정규화를 추가해도 **개선 없음**!		

④ **최소 노름 해석** — 이 커널 해는 $Xw = y$ 의 **최소** ℓ_2 **노름 해**와 동치: $w = X^\top (XX^\top)^{-1} y$. 일반화 못 하는 해는 쉽게 만들 수 있다(예: 무작위 중심의 가우시안 커널) — 그런 해들은 노름이 훨씬 크다.

⑤ **하지만 최소 노름도 예측력이 없다** ⭐ — MNIST 전처리 없음: 노름 ≈ 220, 웨이블릿: 노름 ≈ **390**인데 테스트 오차는 **절반**. → 최소 노름은 일반화 이야기의 **아주 작은 조각**일 뿐. → 🔎 *only a very small piece of the generalization story* 에 밑줄.

⑥ **6절 결론 시작** — 유효 용량을 정의하고 이해하는 단순한 실험 틀을 제시.

p.10 해설 — 결론과 참고문헌

① 결론 ⭐

- 성공한 신경망 구조들의 유효 용량은 훈련 데이터를 **산산이 부술(shatter)** 만큼 크다 → 원리적으로 **암기** 가능.
- 전통적 복잡도 척도로는 거대 신경망의 일반화를 설명하기 어렵다.
- "이 거대한 모델이 **어떤 정밀한 척도에서 단순한지**" 아직 발견하지 못했다.
- 결과 모델이 일반화하지 못해도 **최적화는 여전히 쉽다** → 최적화가 쉬운 이유와 일반화의 진짜 원인은 **다르다**. → 🔎 마지막 문장에 밑줄. 최적화와 일반화를 분리해서 생각해야 함.

② 참고문헌 중 주목할 것

참고문헌	왜 볼까
Bartlett (1998) *가중치 크기가 망 크기보다 중요*	노름 기반 일반화의 시작
Bartlett & Mendelson (2003)	라데마허 복잡도
Bousquet & Elisseeff (2002)	안정성과 일반화
Choromanska 외 (2015)	다층망의 손실 곡면
Cybenko (1989)	이번 주 함께 읽는 논문
Hardt, Recht, Singer (2016)	SGD의 안정성
He 외 (2016) ResNet	이번 주 함께 읽는 논문

p.11 해설 — 참고문헌 (계속)

참고문헌 중 주목할 것

참고문헌	왜 볼까
Lin, Camoriano, Rosasco (2016)	여러 번 통과하는 SGD의 암묵적 정규화
Livni, Shalev-Shwartz, Shamir (2014)	신경망 학습의 계산 효율 — 정리 1의 이전 결과
Mhaskar & Poggio (2016)	깊은 망 vs 얕은 망의 근사 이론
Neyshabur, Tomioka, Srebro (2014) ⭐	*진짜 귀납적 편향을 찾아서* — 암묵적 정규화의 핵심 문헌
Neyshabur 외 (2015)	노름 기반 용량 통제
Schölkopf 외	일반화된 표현자 정리 — p.9 커널 트릭의 근거
Shalev-Shwartz 외 (2010)	학습 가능성, 안정성, 균등 수렴
Telgarsky (2016)	깊이의 이점
Vapnik (1998)	통계적 학습 이론의 고전
Yao, Rosasco, Caponnetto (2007)	조기 종료의 정규화 효과

✍️ 본문 정리 질문

1. "라데마허 복잡도 ≈ 1"이 왜 쓸모없는 상한인지 일반화 상한 식으로 설명해 보자.
2. 최적화가 쉬운 이유와 일반화가 잘 되는 이유가 다르다는 결론은 무엇을 의미할까?

p.12 해설 — 부록 A: 실험 설정 (CIFAR10)

① **Figure 3: 작은 Inception 모델** — 왼쪽: Conv 모듈, Inception 모듈(1×1과 3×3 합성곱 경로 병렬), Downsample 모듈. 오른쪽: 이들로 만든 전체 구조.

② **CIFAR10 데이터** — 학습 50,000장, 검증 10,000장, 10 클래스, 32×32 컬러. 픽셀을 255로 나눠 $[0, 1]$로, 중앙 28×28 자르기, **이미지별 백색화**(평균 빼고 표준편차로 나눔).

③ **모델**

- **작은 Inception**: 1×1과 3×3 합성곱 경로 조합
- **작은 AlexNet**: (5×5 합성곱 → 3×3 최대 풀링 → 국소 응답 정규화) × 2 + 완전연결 384, 192 + 10-way 선형층
- **MLP**: "1×512" = 은닉층 1개, 512 유닛
- 모두 **ReLU**

④ **학습 설정** — SGD + 모멘텀 0.9. 초기 학습률 0.1(Inception) / 0.01(AlexNet, MLP), 에폭마다 0.95배 감소. 무작위 레이블·픽셀 실험은 **가중치 감쇠·드롭아웃 등 명시적 정규화 없이**. → 이번 주 ResNet 논문의 학습 설정과 비교해 보세요.

p.13 해설 — 부록 B: ImageNet 결과, 부록 C: 정리 1 증명

① **ImageNet 설정** — 학습 1,281,167장, 검증 50,000장, 1000 클래스, 299×299. Inception V3, 50개 워커의 **분산 비동기 SGD**.

② **Table 2** ⭐

증강	드롭아웃	감쇠	top-1 테스트
○	○	○	77.84%
○	×	×	72.95%
×	×	○	67.18%
×	×	×	59.80%
무작위 레이블 (정규화 없음)			훈련 95.20% / 테스트 0.11%

③ **보조정리 1** ⭐ **선형대수 연습** — 번갈아 놓인 수열 $b_1 < x_1 < b_2 < x_2 < \cdots < b_n < x_n$ 에 대해

$$A = \left[\max\{x_i - b_j,\ 0\}\right]_{ij}$$

는 **최대 랭크**이고 최소 고윳값은 $\min_i(x_i - b_i)$. **증명**: $i < j$ 이면 $x_i < b_j$ 라서 성분이 0 → **하삼각 행렬**. 대각 성분 $x_i - b_i > 0$ → 가역. 하삼각 행렬의 고윳값은 대각 성분. ∎

④ **정리 1 증명 시작** — 함수

$$c(x) = \sum_{j=1}^{n} w_j \max\{\langle a, x\rangle - b_j,\ 0\}$$

는 깊이 2 ReLU 망 ($a \in \mathbb{R}^d$, $b, w \in \mathbb{R}^n$ → 파라미터 $2n + d$). 표본 z_i가 서로 다르므로 $x_i = \langle a, z_i\rangle$ 가 b들과 **번갈아 놓이도록** a, b를 고를 수 있다.

p.14 해설 — 증명 마무리, 깊이와 폭의 교환, 부록 D·E

① **정리 1 증명 완료** — $c(z_i) = (Aw)_i$ 이고 보조정리 1에 의해 A가 가역 → $w = A^{-1}y$ 로 풀면 $c(z_i) = y_i$. ∎ → ✍️ $n = 3, d = 1$ 인 작은 예를 직접 만들어 A를 써 보세요.

② **깊이와 폭의 교환** — 깊이 2는 폭이 클 수밖에 없지만, $[0, 1]$을 b개 구간으로 나눠 층 j가 구간 I_j의 점들만 담당하게 하면 층당 $O(n/b)$ 노드. 마지막에 입력이 어느 구간에 속하는지 고르는 **멀티플렉서**(근사 지시함수의 합)를 붙임.

> **따름정리 1.** 모든 $k \geq 2$ 에 대해 깊이 k, 폭 $O(n/k)$, 가중치 $O(n + d)$ 인 ReLU 망이 크기 n 표본 위의 임의의 함수를 표현한다.

③ **부록 D, Table 3** — 5절 커널 실험의 결과 정리 (MNIST 1.2% / 0.6%, CIFAR10 46% / 17%).

④ **부록 E, Table 4: 명시적 정규화와 무작위 레이블** — 가중치 감쇠를 켜면 AlexNet은 **수렴 실패**, Inception·MLP는 여전히 맞춤. Inception + 무작위 자르기: 99.93%.

p.15 해설 — 부록 E 마무리와 전체 정리

① **부록 E 결론** — 기본 가중치 감쇠 계수에서 AlexNet을 제외한 모든 모델이 무작위 레이블을 맞춘다. 데이터 증강을 쓰면 학습 집합이 사실상 폭발적으로 커지므로(더 이상 독립 동일 분포도 아님) 수렴이 오래 걸리지만, 학습률 감소를 0.95 → 0.999로 바꾸고 더 오래 돌리면 결국 무작위 레이블에 과적합.

② **각주** — 증강 실험에서는 에폭마다 새로 변형된 이미지를 쓰지만 (무작위로 정한) 레이블은 일관되게 유지. "훈련 정확도" = 증강된 미니배치들의 온라인 정확도 평균.

✍️ 논문 전체 정리 질문

1. "모델·알고리즘·데이터" 중 일반화를 결정하는 것은 무엇인가? 이 논문의 실험이 각각에 대해 무엇을 보여주는가?
2. 보조정리 1의 하삼각 행렬 증명을 $n = 3$으로 직접 확인해 보자.
3. 최소 노름 해 $w = X^\top (XX^\top)^{-1} y$ 를 SGD에서 유도해 보자. (p.9)
4. 이번 주 Belkin(이중 하강) 논문은 이 논문의 질문에 어떤 답을 주는가?
5. ai_life **01 선형회귀** 시뮬레이터에서 데이터 수보다 특징 수가 많으면 무슨 일이 생길까?

핵심 용어	뜻
effective capacity	유효 용량
shatter	산산이 부수다 (모든 레이블링을 실현)
randomization test	무작위화 검정
implicit regularization	암묵적 정규화