심층 이중 하강: 더 큰 모델과 더 많은 데이터가 해가 될 때

> 원제: *Deep Double Descent: Where Bigger Models and More Data Hurt*

항목	내용
저자	Preetum Nakkiran, Gal Kaplun, Yamini Bansal, Tristan Yang, Boaz Barak (하버드대), Ilya Sutskever (OpenAI)
학회	ICLR 2020 (arXiv 2019.12; 이후 *J. Stat. Mech.* 2021 게재)
분야	기계학습 · 일반화 이론 · 실험적 딥러닝
난이도	★★★☆☆
링크	https://arxiv.org/abs/1912.02292 · https://openreview.net/forum?id=B1g5sA4twr
PDF 원문	arXiv PDF (무료) — 24쪽 (본문 10 + 참고문헌 2 + 부록 12)
ai_life 연결 단원	01 선형회귀(과적합·모델 복잡도), 03 CNN(ResNet·CNN 크기), 04 자연어처리(트랜스포머)

한 줄 요약

지난주 Belkin(2019)의 '이중 하강'이 ResNet·CNN·트랜스포머 같은 현대 딥러닝에서도 강하게 나타나며, 모델 크기뿐 아니라 '학습 에폭'과 '데이터 수'에 대해서도 생긴다 — 그 정점은 모델이 학습 데이터를 겨우 다 맞출 수 있는 지점(EMC ≈ n)이다.

왜 중요한가

지난주 Zhang 외(2017)는 "신경망은 무작위 레이블도 외운다", Belkin 외(2019)는 "보간 임계점을 넘으면 테스트 오차가 다시 줄어든다"를 보였습니다. 이 논문은 그 아이디어를 (1) **실제 딥러닝 모델 전반**으로 확인하고, (2) **유효 모델 복잡도(EMC)** 라는 하나의 개념으로 "모델 크기·학습 시간·정규화·데이터 수"를 통합합니다. "더 오래 학습하면 과적합이 **다시 회복**될 수 있다", "**데이터를 4.5배 늘렸더니 성능이 나빠졌다**"는 직관에 반하는 결과로, 조기 종료와 모델 선택에 대한 실무적 사고를 바꿨습니다.

핵심 내용

1. 두 개의 통념

- 고전 통계: 편향-분산 절충 → 어느 지점을 넘으면 **"큰 모델이 나쁘다"**
- 딥러닝 실무: **"큰 모델이 좋다"**, 그리고 둘 다 동의하는 **"데이터는 많을수록 좋다"** → 이 논문은 셋 모두를 조건부로 수정합니다.

2. 유효 모델 복잡도 (정의 1)

$$\mathrm{EMC}_{\mathcal{D},\epsilon}(\mathcal{T}) = \max\{\, n \mid \mathbb{E}_{S\sim\mathcal{D}^n}[\mathrm{Error}_S(\mathcal{T}(S))] \le \epsilon \,\}$$

= 학습 절차 $\mathcal{T}$가 **학습 오차 ≈ 0** 을 달성할 수 있는 최대 표본 수. 구조뿐 아니라 **학습 시간·데이터 증강·정규화**에 따라 달라진다 ($\epsilon = 0.1$ 사용).

3. 일반화된 이중 하강 가설 (가설 1)

영역	조건	복잡도를 늘리면
과소 매개변수	EMC ≪ n	테스트 오차 **감소**
임계	EMC ≈ n	증가할 수도 감소할 수도
과대 매개변수	EMC ≫ n	테스트 오차 **감소**

4. 세 가지 이중 하강

- **모델 방향**: ResNet18 폭 k (표준은 $k = 64$), CNN, 트랜스포머 d_{model} → 정점은 **보간 임계점**. 레이블 잡음·데이터 증강·표본 수가 늘면 정점이 **오른쪽**(더 큰 모델)으로 이동.
- **에폭 방향**: 큰 모델은 학습 중 테스트 오차가 **감소 → 증가 → 다시 감소**. "오래 학습하면 과적합을 바로잡을 수 있다". 조기 종료는 **임계 크기** 모델에서만 확실히 도움.
- **표본 방향**: 표본을 늘리면 곡선 아래 면적은 줄지만 곡선이 **오른쪽으로 이동** → 임계 영역에서 **더 많은 데이터가 해롭다** (IWSLT'14 트랜스포머: 4k → 18k 표본에서 더 나쁜 모델 크기 존재).

5. 왜 정점이 생기나 (직관)

임계점에선 학습 데이터를 맞추는 모델이 **사실상 하나**뿐이라 잡음에 매우 민감 → 전역 구조가 망가짐. 과대 매개변수 영역에선 맞추는 모델이 **많아서** SGD가 잡음을 "흡수"하면서도 잘 일반화하는 것을 찾는다. (부록: 임계 영역에서 **앙상블**이 가장 큰 도움 → 분산이 원인이라는 증거)

6. 레이블 잡음 = 모델 오지정의 대리

잡음이 있을 때 가장 뚜렷하지만 본질은 **모델 오지정(mis-specification)**. 라데마허 복잡도·VC 차원은 레이블 분포와 학습 절차에 무관하므로 정점 위치를 설명할 수 없다.

읽는 순서 가이드

1. **p.1-2 초록·그림 1·2·서론** - 세 통념과 기여 (20분)
2. **p.3 정의 1과 가설 1** ⭐ - 표로 정리 (20분)
3. **p.5-7 모델 방향** - 그림 4-8 (20분)
4. **p.7-8 에폭 방향** - 그림 9 (15분)
5. **p.8-9 표본 방향** - 그림 11-12, "더 많은 데이터가 해롭다" (15분)
6. **p.9-10 결론** + **p.17 랜덤 특징 사례** (15분)

사전 지식 체크

- [ ] Belkin 외(2019) 이중 하강, Zhang 외(2017) 일반화 재고찰 (지난주)
- [ ] 편향-분산 분해
- [ ] 보간(interpolation), 학습 오차 vs 테스트 오차
- [ ] 레이블 잡음, 데이터 증강, 조기 종료

생각해볼 질문

1. ai_life **01 선형회귀**에서 다항식 차수를 데이터 개수 근처로 올리면 어떤 일이 생길까? 이것이 "임계 영역"과 어떻게 연결되나?
2. 에폭 방향 이중 하강이 있다면, "검증 오차가 오르기 시작하면 멈춰라"는 조기 종료 규칙은 언제 틀릴 수 있나?
3. EMC는 학습 절차에 의존한다. 그렇다면 Adam과 AMSGrad(Reddi 외 2018)는 같은 모델이라도 EMC가 다를 수 있을까?
4. Hornik(1989)의 "뉴런 n개로 점 n개 보간"(정리 2.5)은 EMC 관점에서 무엇을 말해 주는가?

용어 정리

영어	한국어
double descent	이중 하강
bias-variance trade-off	편향-분산 절충
interpolation threshold	보간 임계점
effective model complexity (EMC)	유효 모델 복잡도
under-/over-parameterized	과소/과대 매개변수화
critical regime	임계 영역
label noise	레이블 잡음
model mis-specification	모델 오지정
early stopping	조기 종료
ensembling	앙상블

다음에 이어 읽을 논문

- Hastie, Montanari, Rosset, Tibshirani (2022), *Surprises in High-Dimensional Ridgeless Least Squares Interpolation* (Annals of Statistics) — 선형 모델에서의 이중 하강 이론
- Bartlett, Long, Lugosi, Tsigler (2020), *Benign Overfitting in Linear Regression* (PNAS) — "해롭지 않은 과적합"

✍️ 나의 메모