p.1 해설 — 초록과 서론: "큰 모델은 나쁘다"?

① **초록** ⭐ — 다양한 현대 딥러닝 과제에서 **이중 하강**이 나타난다: 모델 크기를 키우면 성능이 **먼저 나빠졌다가 다시 좋아진다**. 모델 크기뿐 아니라 **학습 에폭 수**에 대해서도. 이를 **유효 모델 복잡도(EMC)** 로 통합하고 일반화된 이중 하강을 추측. 또 학습 표본을 늘리면(심지어 **4배**) 테스트 성능이 **나빠지는** 영역을 찾았다. → 🔎 *increasing (even quadrupling) the number of train samples actually hurts* 에 밑줄.

② **그림 1** — 왼쪽: CIFAR-10 + **15% 레이블 잡음**, ResNet18의 폭을 바꿀 때 학습/테스트 오차. 오른쪽: 에폭별 테스트 오차. Adam, 4K 에폭. 폭 64 = 표준 ResNet18. → ✍️ 그림 1 왼쪽에서 학습 오차가 0이 되는 폭과 테스트 오차 정점의 폭이 같은지 확인하자.

③ **편향-분산 절충** — 고전 통계(Hastie 외): 복잡한 모델은 편향↓ 분산↑. 임계를 넘으면 분산이 지배해 **"큰 모델이 나쁘다"**.

④ **현대 신경망은 다르다** — 수백만 매개변수로 **무작위 레이블도 외우는데**(Zhang 외, 지난주) 작은 모델보다 훨씬 잘한다. 실무 통념은 **"큰 모델이 좋다"**. → 🔎 *more than enough to fit even random labels* 에 밑줄 — 지난주와 연결!

⑤ **각주** — Nakkiran은 OpenAI 인턴 중 Sutskever와 연구. **Mikhail Belkin**과 Chris Olah에게 감사 → 지난주 Belkin 논문의 직접적 후속.

p.2 해설 — 두 영역과 주요 기여

① **그림 2** ⭐ — 왼쪽: (모델 크기 × 에폭) 평면의 테스트 오차. **가로선** = 모델 방향 이중 하강, **세로선** = 에폭 방향 이중 하강. 오른쪽: 학습 오차. ResNet18, CIFAR-10, 15% 잡음, 데이터 증강, Adam 최대 4K 에폭. → ✍️ 그림 2 왼쪽에서 "밝은 띠(높은 오차)"가 어디를 따라 놓여 있는지 형광펜으로 그려 보자.

② **학습 시간 논쟁, 그리고 유일한 합의** — 조기 종료가 좋은 경우도, 학습 오차 0까지 가는 게 좋은 경우도. 모두 동의하는 단 하나: **"데이터는 많을수록 좋다"**.

③ **두 영역** — **과소 매개변수**(복잡도 < 표본 수): 고전적 **U자**. 복잡도가 **보간**(학습 오차 ≈ 0)할 만큼 크면: 복잡도를 늘릴수록 테스트 오차 **감소**. Belkin 외(2018)가 처음 일반적으로 제기하고 **"이중 하강"** 이라 명명.

④ **기여 1** — 이중 하강은 과제·구조·최적화 방법에 걸쳐 **견고한** 현상.

⑤ **기여 2: EMC** ⭐ — 학습 절차가 학습 오차 ≈ 0을 달성하는 **최대 표본 수**. 데이터 분포·구조뿐 아니라 **학습 절차**에 의존, 특히 학습 시간을 늘리면 EMC가 증가 → **에폭 방향 이중 하강**. 따름결과: 조기 종료는 **임계 매개변수화** 모델이라는 좁은 영역에서만 도움. → 🔎 *early stopping only helps in the relatively narrow parameter regime* 에 밑줄.

⑥ **기여 3: 표본 비단조성** — 정점은 EMC = 표본 수 근처 → 표본을 늘리면 정점이 **오른쪽 이동** → 때로 **더 많은 데이터가 더 나쁘다** (그림 3: 표본 **4.5배**).

p.3 해설 — EMC의 정의와 일반화된 가설

① **그림 3** — IWSLT'14 독→영 번역, 트랜스포머 크기(d_{model})별 테스트 손실(토큰당 perplexity). 18k 표본 곡선은 대체로 4k보다 낮지만 **오른쪽으로 이동** → 어떤 크기에서는 18k가 **더 나쁨**.

② **학습 절차** $\mathcal{T}$ — 표본 집합 $S = \{(x_1, y_1), \ldots, (x_n, y_n)\}$ → 분류기 $\mathcal{T}(S)$.

③ **정의 1** ⭐⭐

$$\mathrm{EMC}_{\mathcal{D},\epsilon}(\mathcal{T}) := \max\{n \mid \mathbb{E}_{S\sim\mathcal{D}^n}[\mathrm{Error}_S(\mathcal{T}(S))] \leq \epsilon\}$$

→ 🔎 이 식에 크게 밑줄. "평균 학습 오차가 ϵ 이하가 되는 가장 큰 n".

④ **가설 1 (비형식적)** ⭐

영역	조건	유효 복잡도↑ 하면
과소	EMC $\ll n$	테스트 오차 ↓
과대	EMC $\gg n$	테스트 오차 ↓
임계	EMC $\approx n$	↓ 일 수도 ↑ 일 수도

⑤ **비형식성 인정** — ϵ을 원리적으로 고를 방법 없음(휴리스틱 **0.1**), "충분히 작다/크다"의 정식화도 없음. 보간 임계점 주변에 **임계 구간**이 있고 그 폭은 분포·절차에 의존 — 아직 완전히 이해 못 함.

⑥ **검증 방법** — 보간 임계점을 **매개변수 수, 학습 길이, 레이블 잡음 양, 표본 수**로 이동시키며 실험.

→ ✍️ ai_life **01 선형회귀**에서 점 5개에 대해 "4차 다항식"의 EMC는? (5 — 점 5개를 정확히 지나는 다항식이 있다)

p.4 해설 — 세 결과 요약, 관련 연구, 실험 설정

① 모델 방향 (5절) — CIFAR-10/100, IWSLT'14, CNN·ResNet·트랜스포머, SGD·Adam, 증강·정규화 모두에서. **정점은 체계적으로 보간 임계점**. "큰 모델이 더 나쁜" 현실적 설정 제시.

② 에폭 방향 (6절) — 큰 모델의 테스트 오차: 감소 → (임계 부근) 증가 → 학습 끝에서 **다시 감소**. "**더 오래 학습하면 과적합을 바로잡을 수 있다**". → 🔎 *training longer can correct overfitting* 에 밑줄.

③ 표본 방향 (7절) — 임계 영역에서 긴 **고원**(데이터를 늘려도 안 좋아짐, CIFAR-10 CNN) 또는 **정점**(IWSLT'14 트랜스포머: 더 많은 데이터가 해롭다).

④ 레이블 잡음에 대해 — 잡음이 있을 때 가장 뚜렷하지만, 잡음 없이도 정점: CIFAR-100 ResNet(그림 4a), CNN(그림 20), IWSLT'14 트랜스포머(그림 8). 무잡음에선 **고원**, 잡음을 넣으면 **정점**으로 발전.

⑤ 관련 연구 — Belkin 외(2018)가 일반 현상으로 제안. 선형 최소제곱 이론: Hastie 외, Bartlett 외, Mei & Montanari 등. 이 논문의 차별점: (1) 매개변수 수를 넘어 **학습 절차**까지 EMC로 통합, (2) 현대 관행 전반에 대한 광범위한 실증.

⑥ 실험 설정 (4절)

계열	크기 조절
ResNet18	층 폭 $[k, 2k, 4k, 8k]$, 표준 $k = 64$
5층 CNN	합성곱 4층 $[k, 2k, 4k, 8k]$ + 완전연결, $k = 64$면 증강 시 90% 이상
트랜스포머	6층 인코더-디코더, d_{model}, $d_{ff} = 4d_{model}$
→ ai_life **03 CNN**: "폭 k"가 무엇인지(필터 수) 그림으로 그려 보자.	

p.5 해설 — 최적화 설정과 모델 방향 이중 하강

① **최적화** — ResNet·CNN: 교차 엔트로피, (1) Adam 학습률 0.0001로 4K 에폭, (2) SGD 학습률 $\propto 1/\sqrt{T}$로 50만 스텝. 트랜스포머: 8만 스텝, 레이블 스무딩 10%, 드롭아웃 없음.

② **레이블 잡음** p — 확률 $1-p$로 정답, 아니면 **균등 무작위 오답**. 잡음은 **한 번만** 샘플(에폭마다 바뀌지 않음). 그림 1은 잡음 분포의 테스트 오차, 나머지는 깨끗한 분포 기준(서로 선형 변환 관계).

③ **그림 4** ⭐ — (a) CIFAR-100: 잡음 **없이도** 정점. (b) CIFAR-10: 잡음 없으면 보간점 근처 **고원**, 잡음을 넣으면 **정점**으로. → 🔎 그림 4(b)의 잡음 0%, 10%, 20% 곡선을 비교해 정점 위치가 어디로 가는지 화살표로 표시.

④ **5절 요지** — 끝까지 학습(고정된 큰 스텝 수)할 때 모델 크기를 키우면, 임계 영역에서 독특한 행동, 종종 잡음과 함께 두드러지는 **정점**.

⑤ **보간 임계점을 오른쪽으로 미는 것들** ⭐ — 레이블 잡음 추가, **데이터 증강**, 표본 수 증가 → 정점도 **더 큰 모델 쪽**으로 이동. (적대적 학습에서도 강건 오차의 정점 — 부록 그림 26)

⑥ **논의** — 메커니즘의 완전한 이해는 열린 문제. 하지만 **선형 모델**에서도 유사 현상이 이론적으로 분석됨 → 비슷한 메커니즘일 것.

⑦ **직관 시작** — 보간 임계점 크기에서는 학습 데이터를 맞추는 모델이 **사실상 하나**뿐이고, 그 모델은 잡음에 매우 **민감**…

p.6 해설 — 데이터 증강, SGD vs Adam, 그리고 직관

① **그림 5** — 5층 CNN, CIFAR-10, (a) 증강 없음 (b) 증강 있음. 증강은 보간 임계점을 **오른쪽**으로 → 정점도 이동. SGD 50만 스텝. → ✍️ 데이터 증강은 왜 EMC를 바꾸는가? (같은 모델이 "외워야 할" 데이터가 사실상 많아진다)

② **그림 6** — SGD vs Adam (CIFAR-10, 잡음·증강 없음). 둘 다 이중 하강, 정점 위치는 최적화기에 따라 다를 수 있음 → EMC가 **학습 절차에 의존**한다는 증거.

③ **그림 7** — 잡음 없는 CIFAR-100 CNN에서도 **정점**.

④ **직관 완성** ⭐⭐ — 임계점: 모델이 학습 데이터를 **겨우** 맞추므로, 약간의 잡음·오지정 레이블까지 맞추도록 강제하면 **전역 구조가 파괴**되어 테스트 오차가 크다. (부록 그림 28: 임계 영역에서 **앙상블**이 크게 도움 → 잡음 민감성의 증거) 과대 매개변수: 학습 데이터를 맞추는 모델이 **많아서**, SGD가 잡음을 **"외우면서(흡수하면서)"** 도 분포에서 잘 작동하는 모델을 찾는다. → 🔎 *"memorizes" (or "absorbs") the noise while still performing well* 에 밑줄.

⑤ **선형 모델에서는 이론적으로 정당화** — 잡음 없이도(Mei & Montanari 2019) 일어나며, 참 분포 구조와 모델 계열 사이에 **오지정**이 있을 때마다…

→ ✍️ 지난주 Jacot(NTK)의 "무한 폭에서는 커널 회귀" 관점으로, 과대 매개변수 영역에서 SGD가 고르는 해는 어떤 성질(최소 노름?)을 가질지 생각해 보자.

p.7 해설 — 트랜스포머와 에폭 방향 이중 하강

① **그림 8** — 다중 헤드 어텐션 인코더-디코더 트랜스포머, 8만 스텝, 레이블 스무딩 교차 엔트로피. IWSLT'14 독→영(16만 문장), WMT'14 영→불(20만 문장으로 축소). 테스트 손실 = 토큰당 perplexity. → 잡음 없이도 모델 방향 정점. → ai_life **04 자연어처리**: 지난주 Vaswani(트랜스포머)와 연결.

② **6절 에폭 방향 이중 하강** ⭐ — 학습 시간을 늘리면 **EMC가 증가** → 충분히 큰 모델은 학습 도중 과소 → 과대 매개변수로 **넘어간다**.

③ **그림 9** ⭐⭐ — ResNet18, CIFAR-10, 20% 잡음, Adam, 증강. 세 영역:

모델 크기	에폭에 따른 테스트 오차
작은 모델	단조 감소 (끝까지 과소)
중간 모델	고전적 **U자** — 조기 종료가 유리
큰 모델	**감소 → 증가 → 다시 감소**
→ 🔎 그림 9 왼쪽의 세 곡선에 각각 "작음/중간/큼"을 적어 두자.	

④ **견고성** — 데이터셋·구조·최적화기·학습률 스케줄에 걸쳐 (부록 E.1). 잡음이 정점을 강조.

⑤ **통념 수정** — 통념: (1) 일반화 격차가 작은 함수 학습 → (2) 과적합으로 테스트 오차 증가. 실제로는 어떤 영역에서 테스트 오차가 **다시 감소**하여 첫 최솟값보다 **더 낮아질** 수도 (그림 10, 10% 잡음).

p.8 해설 — 에폭 방향 결과와 표본 비단조성

① **그림 10** — 에폭 방향 이중 하강: (a) ResNet18 CIFAR-10 (b) ResNet18 CIFAR-100 (c) 5층 CNN CIFAR-10 (폭 128). ResNet은 Adam 0.0001, CNN은 SGD + 역제곱근 학습률. → ✍️ (a)에서 잡음 10% 곡선의 최종값이 첫 최솟값보다 낮은지 확인하자.

② **7절 표본 비단조성** — 모델·절차 고정, 표본 수 n을 바꿈. 앞에서는 EMC를 바꿔 임계 영역을 탐색했다면, 이번엔 n을 바꿔서. n을 늘리면 같은 절차가 **과대** → **과소 매개변수**로 바뀔 수 있다.

③ **두 효과** ⭐ — 표본을 늘리면 (테스트 오차 vs 복잡도 그래프에서)

1. 곡선 아래 **면적 감소** (예상대로)
2. 곡선이 **오른쪽으로 이동** — 정점이 더 큰 복잡도로 → 🔎 *"shifting the curve to the right"* 에 밑줄.

④ **그림 11(a)** — 5층 CNN, CIFAR-10: 위) 표본 **2배**가 테스트 오차를 개선하지 못하는 모델 크기 범위(초록), 아래) **4배**도 개선 못 하는 범위(빨강). **그림 11(b)** — IWSLT'14 트랜스포머 두 크기: 표본을 늘리면 **손실이 커지는** 구간이 존재 (그림 3과 같은 설정).

→ ✍️ "곡선이 아래로 내려가면서 동시에 오른쪽으로 이동"하는 두 효과를 직접 그려 보고, 두 곡선이 **교차**하는 곳이 "더 많은 데이터가 해로운" 지점임을 표시해 보자.

p.9 해설 — 표본 방향 정리와 결론

① **두 효과의 상쇄** — 어떤 모델 크기 범위에선 효과가 **상쇄**되어 표본 **4배**가 도움이 안 됨(끝까지 학습 시). 충분히 작거나 큰 모델에선 표본이 도움.

② **그림 12** ⭐ — 왼쪽: 5층 CNN, CIFAR-10 + 20% 잡음, (모델 크기 × 표본 수) 평면의 테스트 오차. **높은 오차의 능선**이 다시 **보간 임계점**을 따라 놓임. 오른쪽: 세 단면 — 작은/큰 모델은 데이터가 도움, **임계 근처**(초록)는 도움 안 됨. → 🔎 *the ridge of high test error again lies along the interpolation threshold* 에 밑줄.

③ **더 많은 데이터가 해롭다** — 두 효과가 결합해 그런 영역이 생김 (그림 3, 11b). DNN만의 현상이 아님 — **선형 모델**에서도 (부록 D).

④ **8절 결론** ⭐ — 일반화된 이중 하강 가설: EMC가 학습 표본 수와 **비슷할 때** 비정형적 행동. 현대 딥러닝에서 광범위한 증거. 모델 방향(큰 모델이 나쁜 영역 특정), **에폭 방향**(저자들이 아는 한 **최초 제안**), 더 많은 데이터가 해로운 영역. 정규화 양에 대해서도 이중 하강(그림 22).

⑤ **실무자를 위한 사고법** — 모델과 절차가 학습 데이터를 **겨우** 맞출 수 있다면, 작은 변화(모델 약간 키우기/줄이기, 정규화 변경)가 **예상 밖의 행동**을 낳을 수 있다.

⑥ **조기 종료** — 많은 현상이 **최적 조기 종료**에선 안 나타남 — 이는 가설과 일치(학습 오차 0에 도달하지 않으면 EMC가 n에 못 미침).

→ ✍️ ai_life 수업에서 "데이터를 더 모았는데 성능이 떨어졌다"는 학생 질문에 이 쪽을 근거로 답해 보자.

p.10 해설 — 레이블 잡음, 다른 복잡도 개념

① **조기 종료 (계속)** — 최적 조기 종료에서도 모델 방향 이중 하강이 일어나는 설정이 적어도 하나 있다(ResNet, CIFAR-100, 무잡음, 그림 19). 최적 조기 종료에서 "더 많은 데이터가 해로운" 경우는 관찰 못 했지만 불가능하다는 이유도 모름 → **열린 문제**.

② **레이블 잡음 ≠ 본질** ⭐ — 본질은 **모델 오지정**. 사고 실험: 잡음이 진짜 무작위가 아니라 (분류기 계열에 대해) **의사 난수**라면, 베이즈 최적 분류기 성능은 그대로(결정적·가역)인데 이중 하강은 똑같이 관찰될 것. → 잡음 추가는 분포를 **"더 어렵게"** 만드는 대리 수단. → 🔎 *merely a proxy for making distributions "harder"* 에 밑줄.

③ **다른 복잡도와의 차이** ⭐ — EMC는 라데마허 복잡도와 관련되지만: (1) **실제 레이블**에 의존, (2) **학습 절차**에 의존.

- 라데마허·VC 차원은 레이블 분포에 무관 → 잡음이 정점을 옮기는 현상 설명 불가
- 모델 계열과 데이터 분포에만 의존 → **에폭 방향**, 데이터 증강 효과 설명 불가 → ✍️ 지난주 Zhang 외(2017)가 "전통적 복잡도로는 일반화를 설명 못 한다"고 한 주장과 이 단락을 연결해 보자.

④ **감사의 글** — Belkin과의 초기 논의, Chris Olah의 **(모델 크기 × 에폭)** 시각화 제안이 에폭 방향 이중 하강 발견으로 이어짐.

⑤ **참고문헌 시작** — Advani & Saxe (2017), **Bartlett 외 (2019) "양성 과적합"**, **Belkin 외 (2018)** (지난주 논문의 arXiv판).

p.11 해설 — 참고문헌 (1)

참고문헌 중 주목할 것

참고문헌	왜 볼까
Belkin, Hsu, Xu (2019) *Two models of double descent for weak features*	이중 하강의 해석 가능한 선형 모델
Geiger 외 (2019a, b)	"막힘(jamming) 전이" — 물리학 관점의 임계점 (Jacot 도 공저)
Hastie, Montanari, Rosset, Tibshirani (2019)	고차원 무릿지 최소제곱 보간의 "놀라움" ⭐
He 외 (2016) *Identity mappings*	사전 활성화 ResNet — 이 논문의 ResNet18
Mei & Montanari (2019)	랜덤 특징 회귀의 정밀 점근 분석
Muthukumar 외 (2019)	잡음 데이터의 "해롭지 않은 보간"
Nakkiran 외 (2019) *SGD learns functions of increasing complexity*	"학습 시간 = 복잡도 증가" 아이디어의 출처
Opper (1995, 2001)	통계역학에서 본 학습 — 이중 하강의 아주 오래된 뿌리
Madry 외 (2017)	적대적 학습 (부록 그림 26)

→ ✍️ Hastie 외(2019)의 제목 *ridgeless*(릿지 없는)가 무슨 뜻인지, 릿지 회귀의 $\lambda \to 0$ 극한과 연결해 설명해 보자.

p.12 해설 — 참고문헌 (2)

참고문헌	왜 볼까
Ott 외 (2019) fairseq	트랜스포머 실험 구현체
Page (2018) *How to train your ResNet*	5층 CNN "백본"의 출처
Radford 외 (2019) GPT-2	"큰 모델이 좋다"의 대표 사례
Rahimi & Recht (2008)	랜덤 특징 — 부록 D 사례 연구의 모델
Sennrich 외 (2015)	BPE(바이트 쌍 인코딩) 토큰화
Spigler 외 (2018)	과소→과대 매개변수 막힘 전이
Szegedy 외 (2015)	GoogLeNet — "더 깊게"
Vaswani 외 (2017)	트랜스포머 (지난주)
Zhang 외 (2016/2017)	일반화 재고찰 (지난주)

✍️ 본문 정리 질문 (부록 들어가기 전에)

1. 정의 1(EMC)을 한국어 한 문장으로.
2. 세 가지 이중 하강(모델·에폭·표본)을 각각 "무엇을 바꾸고, 무엇을 고정했는가"로 표 정리.
3. 임계 영역에서 정점이 생기는 직관을 "정답이 하나뿐인 퍼즐 vs 정답이 많은 퍼즐"로 설명해 보자.
4. 라데마허 복잡도가 정점 위치를 설명하지 못하는 두 가지 이유는?

p.13 해설 — 부록 A 실험 요약표, B.1 모델

① **표 A** — **실험 요약** — 데이터셋 × 구조 × 최적화기 × 증강 × 잡음 % × (모델/에폭 이중 하강 관찰 여부) × 그림 번호.

- CIFAR-10 CNN(SGD) 잡음 0/10/20%: 모델·에폭 모두
- CIFAR-10 ResNet(Adam) 잡음 0-20%: 그림 2, 4, 9, 10
- CIFAR-100 ResNet(Adam), CNN(SGD)
- IWSLT'14, WMT'14 트랜스포머(Adam)
- 적대적 학습 ResNet: **강건 오차**에서 → ✍️ 이 표에서 "잡음 0%인데도 모델 방향 이중 하강이 관찰된" 행을 모두 찾아 동그라미.

② **B.1 ResNet** — **사전 활성화 ResNet18**(He 외 2016b): ResNet 블록 4개, 각 블록은 BatchNorm-ReLU-Conv 2개. 폭 $[k, 2k, 4k, 8k]$, 스트라이드 $[1, 2, 2, 2]$. 표준 = $k = 64$.

③ **표준 CNN** — Conv-BatchNorm-ReLU-MaxPool 4층 + 완전연결 출력. 폭 $[k, 2k, 4k, 8k]$, MaxPool $[1, 2, 2, 8]$, 커널 3, 스트라이드 1, 패딩 1. $k = 64$이면 **1,558,026개** 매개변수, 증강 시 CIFAR-10 90% 이상. → 🔎 매개변수 수에 밑줄. ai_life **03 CNN**에서 "모델 크기"를 체감시킬 숫자.

④ **트랜스포머** — Vaswani 외 6층, 층당 어텐션 헤드 8개, fairseq 구현. d_{model}로 크기 조절, $d_{ff} = 4d_{model}$. 레이블 스무딩 10%, 드롭아웃 없음.

p.14 해설 — B.2 이미지 분류 설정

① **그림 13** — 폭/임베딩 차원에 따른 매개변수 수: (a) 5층 CNN (b) ResNet18 (c) 트랜스포머. 폭 k에 대해 대략 k^2**에 비례**(합성곱 가중치는 입력 채널 × 출력 채널). → ✍️ 폭을 2배로 하면 매개변수는 대략 몇 배? (약 4배)

② **손실·증강·정규화** — 교차 엔트로피. 증강 = RandomCrop(32, padding=4) + RandomHorizontalFlip. 잡음이 있을 때 같은 표본의 모든 증강본은 **같은 (잡음) 레이블**. 명시적 정규화(가중치 감쇠·드롭아웃) **없음**.

③ **최적화** ⭐

- **Adam**: 상수 학습률 10^{-4}, 나머지 PyTorch 기본값
- **SGD**: 역제곱근 스케줄, $\gamma_0 = 0.1$, 512스텝마다 갱신, **모멘텀 없음**
- 배치 크기 128, PyTorch 기본 초기화

④ **학습률 스케줄**

$$\text{역제곱근: } \gamma(t) = \frac{\gamma_0}{\sqrt{1 + \lfloor t/512 \rfloor}}$$

에폭이 아니라 **스텝** 기준 — 학습 집합 크기가 다른 실험끼리 비교하기 위해. **동적 감소**: 학습 손실이 'patience' 스텝 동안 정체·악화되면 'drop'배로 감소. → 🔎 역제곱근 공식에 밑줄 — Reddi 외(2018)의 $\alpha/\sqrt{t}$와 같은 계열!

⑤ **선택 이유** — (1) 최적화가 잘 되고 (2) 실험별 튜닝이 필요 없어 많은 실험에 같은 설정을 쓸 수 있음. 다른 자연스러운 선택에도 결과가 견고.

p.15 해설 — B.3 기계 번역 설정, B.4 세부 사항

① **번역에서의 분포** — 삼중쌍 (x, y, i): 원문 문장 x, 번역 y, 예측할 토큰 위치 i (균등분포).

② **자기회귀 분해** ⭐

$$p_M(y \mid x) = \prod_{i=1}^{|y|} p_M(y_i \mid y_{<i}, x)$$

학습 오차:

$$\mathrm{Error}_S(M) = \frac{1}{|S|} \sum_{(x,y,i)\in S} -\log p_M(y_i \mid y_{<i}, x)$$

→ 이것이 번역에서의 "학습 오차" — EMC 정의에 그대로 들어간다. → ai_life **04 자연어처리**: "다음 단어 예측"이 곧 확률의 곱이라는 점을 학생에게 보여 주기 좋은 식.

③ **실제 구성** — 독립 표본이 아니라 (x, y)를 뽑고 모든 $(x, y, 0..|y|)$를 포함.

④ **학습** — Vaswani 외 5.3절 재현: **워밍업**(선형 증가) 후 역제곱근 감소. BPE 전처리, fairseq.

⑤ **데이터셋** — IWSLT'14 독→영: **TED 강연**. WMT'14 영→불.

⑥ **B.4 그림별 세부** — 그림 1: Adam 0.0001, 4K 에폭, **5회 시행의 평균과 표준편차**. 그림 7: 5회. 그림 11a: SGD + 증강, 5회(무작위 초기화 + 무작위 부분 표본).

→ ✍️ 그림 1에 오차 막대(표준편차)가 있다는 것은 왜 중요한가? 정점이 "우연"이 아님을 보이는 근거.

p.16 해설 — 부록 C: 관련 연구 확장

① **Belkin 외 (2018)** ⭐ — 편향-분산과 딥러닝 실무의 모순을 **이중 하강 곡선**으로 화해: 보간점까지 U자, 그 너머에선 감소. MNIST, CIFAR-10, SVHN, TIMIT의 부분집합에서 완전연결망, ℓ_2 **손실**. 랜덤 특징 선형 회귀, **랜덤 포레스트**에서도 → 신경망만의 이상 현상이 아님. → 지난주 Belkin 해설과 나란히 놓고 "이 논문이 더한 것"을 적어 보자.

② **선형 최소제곱 이론들**

연구	내용
Advani & Saxe (2017), Hastie 외 (2019)	$N, D \to \infty$ 점근, **무작위 행렬 이론**. 오지정이면 학습 오차 최소가 과대 매개변수에서
Belkin 외 (2019)	가우시안·푸리에 두 데이터 모델의 유한 표본 분석
Bartlett 외 (2019)	최소 ℓ_2 노름 보간해의 일반화 경계
Muthukumar 외 (2019)	잡음 하 보간해의 근본 한계, 푸리에 해석
Mei & Montanari (2019)	랜덤 특징 위 릿지 회귀 점근

③ **물리학 관점** — Geiger 외: MNIST 완전연결망 + 힌지 손실에서 매개변수가 임계를 넘으면 **"막힘 전이"**. CIFAR-10 CNN, 임계 영역의 **앙상블** 행동 — 이 논문의 그림 28, 29와 일치.

④ **조기 종료** — Advani & Saxe, Geiger 외도 **최적 조기 종료**에선 이중 하강이 안 보인다고 지적.

p.17 해설 — 부록 D: 랜덤 특징 사례 연구

① **그림 14** ⭐ — **랜덤 푸리에 특징**(Rahimi & Recht 2008), Fashion-MNIST. = 활성화 e^{-ix}인 **2층 신경망**, 첫 층은 무작위 초기화 후 **고정**, 둘째 층만 **경사 흐름**으로 학습.

② **설정** — 첫 층 $\mathcal{N}(0, \frac{1}{d})$ 초기화 후 고정, 폭(임베딩 차원) d가 모델 크기. 둘째 층은 0으로 초기화, **MSE 손실**. → 지난주 Jacot(NTK)의 "선형화된 신경망"과 같은 계열 — 둘째 층만 배우면 **선형 회귀**!

③ **핵심** ⭐⭐ — 이 설정에선 **EMC =** d (임베딩 차원). 그래서 테스트 오차 정점이 정확히 $n = d$ **직선**을 따라간다. 격자를 **가로**로 가로지르면 모델 방향, **세로**로 가로지르면 표본 방향 이중 하강. → 🔎 *EMC = d* 와 *the peak follows the path of n = d* 에 밑줄.

④ **그림 15** — 표본 방향 단면 (특징 수 1,000개): 표본이 1,000 근처일 때 테스트 오차 **정점**.

⑤ **의의** — 모델·표본 방향 이중 하강은 **딥러닝만의 현상이 아니다**.

→ ✍️ ai_life **01 선형회귀**로 직접 재현해 보자: 무작위 특징 $\cos(w_j x + b_j)$ d개로 점 $n = 20$개를 최소제곱 적합(최소 노름 해)하고, $d = 5, 10, 20, 40, 100$에서 테스트 오차를 그리면 $d = 20$ 근처에서 정점이 보일 것이다.

p.18 해설 — 부록 E.1: 에폭 방향 이중 하강 추가 결과

① **엄밀한 평가** — ResNet18, CIFAR-10, 증강, 20% 잡음. 최적화기 3가지(**Adam, SGD, SGD+모멘텀 0.9**) × 학습률 스케줄 3가지(**상수, 역제곱근, 동적 감소**) × 여러 초기 학습률.

② **결과** ⭐ — 모든 최적화기·스케줄에서 이중 하강이 **확실히** 나타나고, 정점은 **보간점과 함께 이동**.

③ **그림 16** — Adam: (a) 상수 (b) 역제곱근 (c) 동적.

④ **실무 권고** ⭐⭐ — 테스트 오차가 오르기 시작할 때 학습을 멈추는 것이 **항상 최선은 아니다**. 최대치에 도달한 뒤 다시 감소해 **더 낮은 최종값**에 이를 수 있다. → 🔎 *stopping the training when the test error starts to increase may not always be the best strategy* 에 밑줄.

⑤ **그림 17** — SGD: (a) 상수 (b) 역제곱근 (c) 동적.

→ ✍️ 학습률이 클수록 정점이 더 빨리(더 이른 에폭에) 올까, 늦게 올까? 그림 16(a)의 여러 학습률 곡선에서 확인해 보자. (EMC가 빨리 커지면 정점도 일찍)

p.19 해설 — SGD+모멘텀, 깨끗한 설정의 모델 방향 이중 하강

① **그림 18** — SGD+모멘텀: (a) 상수 (b) 역제곱근 (c) 동적 학습률. 역시 에폭 방향 이중 하강.

② **E.2.1 깨끗한 설정 (잡음 없음)**

③ **그림 19** ⭐ — CIFAR-100, ResNet18, 잡음 **없음**, 증강, Adam 0.0001, 4K 에폭.

- 위: (모델 크기 × 에폭) 평면의 학습·테스트 성능
- 아래: 같은 모델들의 테스트 오차 동역학
- **최적 조기 종료를 해도 이중 하강이 나타나는** 설정! → 🔎 *even with optimal early stopping this setting exhibits double descent* 에 밑줄 — 본문 p.10의 근거.

→ ✍️ 그림 19 위쪽 평면에서 "학습 오차가 0이 되는 경계선"과 "테스트 오차가 높은 띠"를 같은 색으로 그려 겹치는지 확인하자. → ✍️ 최적 조기 종료로도 사라지지 않는다면, 실무에서 모델 크기를 고를 때 어떤 점을 조심해야 할까?

p.20 해설 — CIFAR-100 표준 CNN

① **그림 20** — 5층 CNN, CIFAR-100, 잡음 **없음**, 증강 **없음**, SGD 10^6 스텝 (본문 그림 7과 같은 실험).

- 위: (모델 크기 × 학습 스텝) 평면의 학습·테스트 성능
- 아래: 테스트 오차 동역학

② **관찰** — 잡음 없이도 모델 방향 정점. CIFAR-100은 클래스가 100개라 같은 크기 모델에 **더 어려운** 분포 → 본문 p.10의 "잡음 = 분포를 어렵게 만드는 대리"와 일치. → 🔎 *no label noise, no data-augmentation* 에 밑줄.

→ ✍️ CIFAR-10(10클래스)과 CIFAR-100(100클래스)에서 같은 CNN의 EMC는 어느 쪽이 더 작을까? 그래서 정점이 더 뚜렷한 쪽은? → ✍️ "모델 오지정"을 ai_life **02 물체인식** 예로 설명해 보자: 고양이/개 2종만 배운 모델에 100종을 구분하라고 하면?

p.21 해설 — E.2.2 가중치 감쇠에 따른 이중 하강

① **그림 21** — 5층 CNN, CIFAR-10, 10% 잡음, 증강, SGD 50만 스텝. 왼쪽: 가중치 감쇠 5×10^{-4} (아래) vs 없음 (위)의 테스트 오차 동역학. 오른쪽: 감쇠 양에 따른 테스트·학습 오차와 테스트 손실.

② **정규화를 축으로** ⭐ — ResNet18, CIFAR-10, 증강, 20% 잡음, 가중치 감쇠 $\lambda \in [0, 0.1]$, SGD + 역제곱근. 모델 방향과 **질적으로 매우 비슷한** 그림 — 여기선 "모델 복잡도"를 **정규화 계수**가 조절. → 정규화가 강할수록 EMC↓ (외우기 어려워짐). 가설이 **또 하나의 축**에서 확인됨. → 🔎 *"model complexity" is now controlled by the regularization parameter* 에 밑줄.

③ **그림 22** — (a) 테스트 오차 (b) 학습 손실, (가중치 감쇠 × 에폭) 평면. 모든 감쇠 값에 같은 초기 학습률을 써서 학습이 불안정 → 테스트 오차 그림에 약간의 잡음.

→ ✍️ ai_life **01 선형회귀**의 릿지 회귀에서 λ를 크게→작게 바꾸는 것은 EMC를 어떻게 바꾸는가? λ축 위에서 이중 하강 그림을 상상해 그려 보자.

p.22 해설 — E.2.3 언어 모델, 조기 종료

① 조기 종료는 이중 하강을 보이지 않는다 (언어 모델)

② 그림 23 ⭐ — 축소된 IWSLT'14, 왼쪽 4k 표본, 오른쪽 18k 표본의 모델 방향 테스트 오차 동역학. **최적 조기 종료를 하면 표본이 많을수록 항상 좋다**. → 🔎 *with optimal early-stopping, more samples is always better* 에 밑줄 — 본문 그림 3의 "더 많은 데이터가 해롭다"는 **끝까지 학습할 때**의 이야기!

③ 그림 24 — IWSLT'14 독→영 vs 축소(20만) WMT'14 영→불. 최적 조기 종료 시 테스트 오차가 훨씬 낮음.

④ 그림 25 — CNN, CIFAR-10, 10% 잡음, 증강, SGD 학습률 $\propto 1/\sqrt{T}$. (모델 크기 × 에폭) 평면과 동역학.

→ ✍️ "끝까지 학습" vs "최적 조기 종료" 두 경우를 표로 비교하자: 모델 방향 / 표본 방향 이중 하강이 각각 나타나는가? → ✍️ 실무에서 최적 조기 종료 시점을 알려면 무엇이 필요한가? (검증 집합) 그 비용은?

p.23 해설 — E.2.4 학습 절차: 적대적 학습

① **그림 26** ⭐ — **적대적 학습** ResNet18, CIFAR-10 (2만 5천 개로 축소), 잡음 **없음**. 반경 $\epsilon = 0.5$, $\epsilon = 1.0$의 L_2 **강건성**, **10단계 PGD**(Goodfellow 외 2014; Madry 외 2017). SGD 배치 128, 학습률 0.1로 400 에폭, 이후 0.01로 400 에폭. → 잡음이 없어도 **강건 테스트 오차**에 뚜렷한 모델 방향 정점.

② **해석** — 적대적 학습은 "각 점 주변 반경 ϵ 안의 모든 입력"을 맞춰야 하므로 사실상 과제가 **훨씬 어려워져** EMC가 작아진다 → 같은 모델 크기 범위에서 임계 영역이 드러남. → 🔎 *10-step PGD* 에 밑줄.

③ **그림 27** — 본문 그림 5(데이터 증강 효과)의 **더 큰 모델**까지 확장한 버전.

→ ✍️ 적대적 예제란? ai_life **02 물체인식** 수업에서 "사람 눈엔 같은데 AI는 다르게 보는 그림"을 예로 설명해 보자. → ✍️ $\epsilon = 1.0$과 0.5 중 어느 쪽의 정점이 더 큰 모델 쪽에 있을까? (더 어려운 과제 = 더 큰 모델이 필요)

p.24 해설 — E.3 앙상블, 전체 정리

① **그림 28** ⭐⭐ — ResNet18 5개의 **다수결 앙상블** vs 개별 모델, CIFAR-10, 15% 잡음(모델마다 **독립적으로** 잡음 샘플), Adam 4K 에폭 (그림 1과 같은 설정). 앙상블이 **임계 영역에서 가장 크게** 도움. → 🔎 *ensembling helps most around the critical regime* 에 밑줄 — 정점의 원인이 **분산**(잡음 민감성)이라는 증거 (본문 p.6 직관).

② **그림 29** — 5층 CNN, 잡음 없음, SGD, 증강 없음(그림 7 설정)에서도 앙상블 효과.

✍️ **논문 전체 정리 질문**

1. EMC를 정의하고, 모델 크기·학습 시간·데이터 증강·가중치 감쇠·레이블 잡음이 각각 EMC를 **올리는지 내리는지** 표로 정리하자.
2. 세 가지 이중 하강 중 **에폭 방향**이 왜 이 논문의 새로운 기여인가?
3. "더 많은 데이터가 해롭다"가 성립하는 조건 두 가지(끝까지 학습, 임계 크기 모델)를 써 보자.
4. 앙상블 실험(그림 28)이 "정점 = 분산 문제"라는 직관을 어떻게 뒷받침하는지 편향-분산 분해로 설명해 보자.
5. 지난주 Belkin(2019) → 이번 주 Nakkiran(2020) → (다음) Hastie 외(2022)로 이어지는 흐름을 한 문단으로. ai_life 학생에게 "외워도 잘 맞히는 AI"를 어떻게 설명할까?