Adam의 수렴에 대하여, 그리고 그 너머 (AMSGrad)

> 원제: *On the Convergence of Adam and Beyond*

항목	내용
저자	Sashank J. Reddi, Satyen Kale, Sanjiv Kumar (Google 뉴욕)
학회	ICLR 2018 (최우수 논문상)
분야	기계학습 · 최적화 이론 · 온라인 볼록 최적화
난이도	★★★★☆
링크	https://openreview.net/forum?id=ryQu7f-RZ · https://arxiv.org/abs/1904.09237
PDF 원문	arXiv PDF (무료) — 23쪽 (본문 8 + 참고문헌 1 + 부록 증명 14)
ai_life 연결 단원	01 선형회귀 심화(학습률), 03 CNN(학습에 쓰는 옵티마이저)

한 줄 요약

Adam·RMSProp은 과거 기울기 제곱의 '지수이동평균'으로 학습률을 조절하기 때문에, 드물게 오는 큰 기울기를 금방 잊어버려 아주 단순한 1차원 볼록 문제에서도 최악의 점으로 수렴할 수 있다. 과거 최댓값을 기억하는 AMSGrad로 고치면 수렴이 보장된다.

왜 중요한가

지난주 Kingma & Ba(2015)가 Adam의 수렴을 "증명"했지만, 이 논문은 그 증명에 **오류**가 있음을 보이고 구체적인 **반례**를 만들었습니다. "널리 쓰이는 알고리즘도 수학적으로 틀릴 수 있다", "이론적 증명은 꼼꼼히 검증해야 한다"는 교훈을 준 사건이자, 최적화 알고리즘 설계에서 **학습률이 증가하면 안 된다**($\Gamma \succcurlyeq 0$)는 원리를 명확히 했습니다. ICLR 2018 최우수 논문상.

핵심 내용

1. 일반 적응형 방법의 틀 (Algorithm 1)

$$\mathbf{x}_{t+1} = \Pi_{\mathcal{F},\sqrt{V_t}}\left(\mathbf{x}_t - \alpha_t\, \mathbf{m}_t / \sqrt{V_t}\right), \quad \mathbf{m}_t = \phi_t(\mathbf{g}_1..\mathbf{g}_t),\ V_t = \psi_t(\mathbf{g}_1..\mathbf{g}_t)$$

방법	ϕ_t (1차)	ψ_t (2차)
SGD	$\mathbf{g}_t$	I
AdaGrad	$\mathbf{g}_t$	$\mathrm{diag}(\sum_i \mathbf{g}_i^2)/t$ — **모든** 과거
Adam	$(1-\beta_1)\sum \beta_1^{t-i}\mathbf{g}_i$	$(1-\beta_2)\mathrm{diag}(\sum \beta_2^{t-i}\mathbf{g}_i^2)$ — **최근** 위주

2. 문제의 핵심량

$$\Gamma_{t+1} = \frac{\sqrt{V_{t+1}}}{\alpha_{t+1}} - \frac{\sqrt{V_t}}{\alpha_t}$$

= "학습률의 역수"의 변화. SGD·AdaGrad는 $\Gamma_t \succeq 0$ (학습률이 **증가하지 않음**). Adam은 Γ_t가 음수가 될 수 있다 — 원래 Adam 증명은 이를 양반정치로 **잘못 가정**.

3. 반례 (정리 1) ⭐

$\mathcal{F} = [-1, 1], C > 2$:

$$f_t(x) = \begin{cases} Cx, & t \bmod 3 = 1 \\ -x, & \text{그 외} \end{cases}$$

세 번에 한 번 큰 기울기 C(올바른 방향 $x \to -1$), 두 번은 -1(잘못된 방향). 최적해는 $x = -1$. 하지만 $\beta_1 = 0$, $\beta_2 = 1/(1+C^2)$인 Adam은 큰 기울기를 거의 C배로 **눌러 버려서** $x = +1$(최악의 점)로 간다. 3스텝마다 regret $\geq 2C - 4$ → 평균 regret이 0으로 가지 않음.

- 정리 2: $\beta_1 < \sqrt{\beta_2}$인 **어떤** 상수 β_1, β_2에도 반례 존재
- 정리 3: 확률적(stochastic) 설정에서도 반례
- 정리 6: 분모에 ϵ을 더해도 소용없음

4. 해결책: AMSGrad (Algorithm 2)

$$\hat{v}_t = \max(\hat{v}_{t-1}, v_t), \qquad \mathbf{x}_{t+1} = \Pi\big(\mathbf{x}_t - \alpha_t\, \mathbf{m}_t / \sqrt{\hat{v}_t}\big)$$

과거 v의 **최댓값**을 기억 → 학습률이 커지지 않음($\Gamma_t \succeq 0$), "장기 기억". 메모리·시간은 Adam과 같음. 정리 4: regret $O(\sqrt{T})$ (데이터 의존적으로는 AdaGrad처럼 더 좋을 수 있음).

5. 온라인 최적화와 regret

$$R_T = \sum_{t=1}^{T} f_t(\mathbf{x}_t) - \min_{\mathbf{x}\in\mathcal{F}} \sum_{t=1}^{T} f_t(\mathbf{x})$$

$R_T = o(T) \Leftrightarrow$ 평균 성능이 최적에 수렴. 온라인 경사하강의 기본 학습률은 $\alpha/\sqrt{t}$.

6. 실험

합성 문제(1010x / −10x)에서 Adam은 $x = 1$로, AMSGrad는 $x = -1$로. MNIST 로지스틱 회귀·1층 신경망(ReLU 100개), CIFAR-10(CIFARNET)에서 AMSGrad가 같거나 더 좋음.

읽는 순서 가이드

1. **p.1-2 초록·서론·기여** - "드물지만 큰 기울기를 빨리 잊는다" (15분)
2. **p.2-3 Algorithm 1과 표** - SGD/AdaGrad/Adam을 한 틀로 (30분)
3. **p.4 Γ와 반례** - 반례를 손으로 몇 스텝 시뮬레이션 ⭐ (40분)
4. **p.5 AMSGrad** - max 한 줄의 의미 (15분)
5. **p.6-8 정리 4·실험·결론** (20분)
6. **p.10-11 정리 1 증명** - 귀납법 구조만 (선택, 30분)

사전 지식 체크

- [ ] Kingma & Ba(2015) Adam (지난주)
- [ ] 이상구 외(2023) 경사하강법·SGD (이번 주)
- [ ] 지수이동평균 $m_t = \beta m_{t-1} + (1-\beta) g_t$
- [ ] 볼록함수, 사영(projection)
- [ ] regret, $O(\sqrt{T})$ 표기

생각해볼 질문

1. 반례에서 $C = 10$이면 $\beta_2 = 1/101$. 이 β_2는 실전 값 0.999와 매우 다르다. 그런데 정리 2는 왜 실전 값에서도 문제가 생길 수 있다고 말하는가?
2. AMSGrad의 "max"는 학습률을 **줄이기만** 한다. 그렇다면 왜 AdaGrad처럼 학습률이 너무 빨리 줄지 않는가?
3. 이 논문 이후 실무에선 여전히 Adam(AdamW)을 많이 쓴다. 이론과 실전 사이의 간극을 어떻게 이해할까?
4. "드물지만 정보가 많은 큰 기울기"는 실제 데이터의 어떤 상황에 해당할까? (힌트: 출력 공간이 큰 문제, 희귀 클래스)

용어 정리

영어	한국어
adaptive method	적응형 방법
exponential moving average (EMA)	지수이동평균
online convex optimization	온라인 볼록 최적화
regret	후회(누적 손실 차이)
projection	사영
positive semi-definite	양반정치
long-term memory	장기 기억
counterexample	반례

다음에 이어 읽을 논문

- Loshchilov & Hutter (2019), *Decoupled Weight Decay Regularization* (AdamW, ICLR 2019)
- Duchi, Hazan, Singer (2011), *Adaptive Subgradient Methods for Online Learning and Stochastic Optimization* (AdaGrad, JMLR)

✍️ 나의 메모