p.1 해설 — 초록과 서론: Adam이 수렴하지 않는 경우

① **초록** — RMSProp, Adam, AdaDelta, NAdam은 모두 **과거 기울기 제곱의 지수이동평균의 제곱근**으로 기울기를 나눈다. 출력 공간이 큰 학습 등에서 이들이 최적해(비볼록이면 임계점)로 **수렴하지 못하는** 현상이 관찰되었다. → 🔎 *exponential moving averages of squared past gradients* 에 밑줄.

② **원인 지목** ⭐ — 실패의 한 원인은 바로 **지수이동평균**. 단순한 **볼록** 문제에서 Adam이 최적해로 가지 않는 명시적 예 + 기존 Adam 분석의 정확한 문제점 제시.

③ **해결 방향** — 과거 기울기에 대한 **"장기 기억"** 을 주면 고쳐진다 → 새 Adam 변형(AMSGrad). → 🔎 *"long-term memory"* 에 밑줄.

④ **서론: 계보** — SGD → 좌표별로 학습률을 자동 조절하는 **AdaGrad**(Duchi 외 2011): 기울기가 **희소**할 때 SGD보다 훨씬 좋다.

⑤ **AdaGrad의 약점** — 비볼록·조밀한 기울기에선 **모든** 과거 기울기를 쓰므로 학습률이 너무 **빨리 감소**. 고차원 딥러닝에서 특히 심각.

⑥ **지수이동평균의 등장과 부작용** — RMSProp, Adam 등은 **최근 몇 개** 기울기에만 의존해 감소를 완화. 그런데 어떤 미니배치는 **드물게 큰** 기울기를 주는데, 그 정보가 지수평균 때문에 **빨리 사라져** 수렴이 나빠진다. → 🔎 *their influence dies out rather quickly* 에 밑줄.

→ ✍️ 지수이동평균 $v_t = 0.9v_{t-1} + 0.1g_t^2$ 에서 $t = 1$에 $g = 10$, 이후 계속 $g = 1$이면 v_t가 어떻게 변하는지 5스텝 계산해 보자.

p.2 해설 — 기여와 온라인 최적화 설정

① **기여 1** — RMSProp·Adam이 **증명 가능하게** 최적해로 가지 않는 단순 볼록 예. AdaDelta, NAdam, 그리고 사실상 **고정 크기 창**으로 기울기 제곱을 평균하는 모든 알고리즘에 확장된다.

② **기여 2** ⭐ — 수렴을 보장하려면 **장기 기억**이 필요. Kingma & Ba(2015)의 **수렴 증명의 문제**를 지적. Adam과 **같은 시간·메모리**로 구현되는 새 변형 + AdaGrad 같은 **데이터 의존 regret** 경계. → 🔎 *we point out a problem with the proof of convergence* 에 밑줄.

③ **기여 3** — 예비 실험: 비슷하거나 더 좋음.

④ **표기법** — $\mathcal{S}_+^d$: 양정치 $d \times d$ 행렬, $\sqrt{\mathbf{a}}$, $\mathbf{a}^2$, $\mathbf{a}/\mathbf{b}$, $\max(\mathbf{a}, \mathbf{b})$는 모두 **원소별**. 사영 $\Pi_{\mathcal{F},A}(\mathbf{y}) = \arg\min_{\mathbf{x}\in\mathcal{F}} \|A^{1/2}(\mathbf{x}-\mathbf{y})\|$. 지름 D_∞.

⑤ **온라인 최적화** ⭐ — 매 시각 t: 점 $\mathbf{x}_t$ 선택 → 손실 f_t 공개(= 다음 미니배치의 손실) → $f_t(\mathbf{x}_t)$ 만큼 손해.

$$R_T = \sum_{t=1}^{T} f_t(\mathbf{x}_t) - \min_{\mathbf{x}\in\mathcal{F}} \sum_{t=1}^{T} f_t(\mathbf{x})$$

목표 $R_T = o(T)$ = 평균적으로 최적 성능에 수렴.

⑥ **기본 알고리즘** — 온라인 경사하강(Zinkevich 2003): $\mathbf{x}_{t+1} = \Pi_{\mathcal{F}}(\mathbf{x}_t - \alpha_t \mathbf{g}_t)$, $\alpha_t = \alpha/\sqrt{t}$. 평균 regret이 사라지는 온라인 알고리즘 ⇒ **경험적 위험 최소화(ERM)** 의 확률적 알고리즘 → "온라인 GD = SGD"로 취급.

→ ✍️ regret을 "시험을 볼 때마다 점수를 매기는데, 처음부터 정답 하나를 알고 있던 사람과의 누적 점수 차"로 비유해 설명해 보자.

p.3 해설 — 적응형 방법의 공통 틀 (Algorithm 1)

① **Algorithm 1** ⭐

$$\mathbf{g}_t = \nabla f_t(\mathbf{x}_t),\ \ \mathbf{m}_t = \phi_t(\mathbf{g}_1..\mathbf{g}_t),\ \ V_t = \psi_t(\mathbf{g}_1..\mathbf{g}_t),\ \ \mathbf{x}_{t+1} = \Pi_{\mathcal{F},\sqrt{V_t}}(\mathbf{x}_t - \alpha_t \mathbf{m}_t/\sqrt{V_t})$$

α_t = **스텝 크기**, $\alpha_t V_t^{-1/2}$ = **학습률**. 대각 $V_t = \mathrm{diag}(\mathbf{v}_t)$만 고려.

② **SGD** — $\phi_t = \mathbf{g}_t$, $\psi_t = I$, $\alpha_t = \alpha/\sqrt{t}$. 감소 스텝은 수렴엔 필요하지만 실전 성능은 나쁨.

③ **AdaGrad** — $\psi_t = \mathrm{diag}(\sum_{i=1}^t \mathbf{g}_i^2)/t$, $\alpha_t = \alpha/\sqrt{t}$ → 실효 학습률 $\alpha/\sqrt{\sum_i g_{i,j}^2}$ (완만한 감소). 희소 기울기에서 큰 이득.

④ **Adam** ⭐

$$m_{t,i} = \beta_1 m_{t-1,i} + (1-\beta_1) g_{t,i}, \qquad v_{t,i} = \beta_2 v_{t-1,i} + (1-\beta_2) g_{t,i}^2 \quad (1)$$

추천값 $\beta_1 = 0.9$, $\beta_2 = 0.999$. $\mathcal{F} = \mathbb{R}^d$이면 사영은 항등 → 원래 Adam. **RMSProp** = $\beta_1 = 0$인 Adam. 딥러닝에선 $\beta_1 \neq 0$의 **모멘텀**이 성능을 크게 올림. → 🔎 식 (1)에 밑줄. 지난주 Kingma & Ba 해설의 식과 비교!

⑤ **각주 1** — 단순화를 위해 **편향 보정(debiasing)** 단계를 뺐지만, 논증은 보정판에도 적용된다.

→ ✍️ SGD / AdaGrad / Adam을 (ϕ_t, ψ_t) 표로 정리하고, "과거를 얼마나 기억하는가"로 순위를 매겨 보자.

p.4 해설 — Adam의 비수렴: Γ와 반례 ⭐⭐

① **핵심량**

$$\Gamma_{t+1} = \frac{\sqrt{V_{t+1}}}{\alpha_{t+1}} - \frac{\sqrt{V_t}}{\alpha_t} \quad (2)$$

학습률 **역수**의 시간 변화. SGD·AdaGrad는 $\Gamma_t \succeq 0$ (학습률 **비증가**). Adam·RMSProp은 Γ_t가 **부정부호**가 될 수 있다.
→ 🔎 식 (2)에 크게 밑줄.

② **반례** — $\mathcal{F} = [-1, 1]$, $C > 2$:

$$f_t(x) = \begin{cases} Cx & t \bmod 3 = 1 \\ -x & \text{그 외} \end{cases}$$

최소 regret은 $x = -1$. $\beta_1 = 0$, $\beta_2 = 1/(1 + C^2)$인 Adam은 $x = +1$ 로 수렴!

③ **직관** — 3스텝에 한 번 큰 기울기 C, 나머지 두 번은 -1(잘못된 방향). 큰 기울기가 $\sqrt{v}$로 나뉘어 거의 C**배 축소** → 잘못된 방향 두 번을 이기지 못함.

④ **정리 1** — Adam의 평균 regret이 0으로 가지 않는 온라인 볼록 문제가 존재.

⑤ **ε을 더하면?** — $\hat{\mathbf{x}}_{t+1} = \mathbf{x}_t - \alpha_t \mathbf{m}_t / \sqrt{V_t + \epsilon I}$ (3). 어떤 상수 $\epsilon > 0$에 대해서도 반례 존재 (정리 6, 부록 F).

⑥ **파국적** — 구간에서 **가장 나쁜 점**으로 수렴. 상수 스텝에서도 성립. SGD·AdaGrad는 이 문제 없음. 고차원, 기울기 **분산**이 클 때 악화. 큰 β_2가 권장되는 이유이기도 함.

⑦ **정리 2** — $\beta_1 < \sqrt{\beta_2}$인 **모든** 상수 β_1, β_2에 대해 반례 존재. (이 조건은 실전에서도, Kingma & Ba 증명에서도 가정됨)

→ ✍️ $C = 3$, $\beta_2 = 0.1$로 Adam($\beta_1 = 0$)을 $x_1 = 1$에서 6스텝 손으로 따라가 보자 (사영 포함).

p.5 해설 — AMSGrad 알고리즘

① **Algorithm 2 AMSGrad** ⭐⭐

$$m_t = \beta_{1t} m_{t-1} + (1-\beta_{1t}) g_t, \quad v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$
$$\hat{v}_t = \max(\hat{v}_{t-1}, v_t), \qquad x_{t+1} = \Pi_{\mathcal{F}, \sqrt{\hat{V}_t}} \left(x_t - \alpha_t m_t / \sqrt{\hat{v}_t} \right)$$

→ 🔎 `max` 한 줄에 크게 밑줄 — Adam과의 **유일한** 차이.

② **정리 3** — **확률적** 볼록 문제에서도 Adam이 최적해로 가지 않는 예가 있다.

③ **결과의 의미** — 피하려면 **문제마다** $\epsilon, \beta_1, \beta_2$를, 고차원이면 **차원마다** 다르게 튜닝해야 → 적응형 방법의 취지를 무너뜨림. 반례는 인위적이지만, 실제로 수렴을 **느리게** 할 수 있는 상황은 충분히 상상 가능.

④ β_1 **감소에 대해** — Kingma & Ba는 β_1을 시간에 따라 줄이지만, 핵심 변수는 β_2이므로 β_2가 1에서 떨어져 있으면 분석 그대로 성립.

⑤ **4절 설계 원리** — Adam의 원 증명은 Γ_t가 양반정치라고 **잘못 가정**(부록 D). 해결책 두 가지: (a) 알고리즘을 바꿔 제약 충족(AMSGrad), (b) β_1, β_2를 시간에 따라 바꾸기(AdamNC).

⑥ **세 알고리즘 비교** — $v_{t-1,i} > g_{t,i}^2 > 0$일 때: Adam은 학습률을 **공격적으로 키움**(해로움), AdaGrad는 **살짝 줄임**(장기 누적으로 너무 작아짐), AMSGrad는 **키우지도 줄이지도 않음**. → ✍️ 이 세 반응을 표로 정리해 보자.

p.6 해설 — 정리 4: AMSGrad의 regret 경계

① **그림 1** — 1차원 합성 문제: 왼쪽·가운데는 온라인, 오른쪽은 확률적 설정에서 Adam vs AMSGrad.

② **정리 4** ⭐ — $\alpha_t = \alpha/\sqrt{t}$, $\beta_{1t} \le \beta_1$, $\gamma = \beta_1/\sqrt{\beta_2} < 1$, 지름 D_∞, $\|\nabla f_t\|_\infty \le G_\infty$이면

$$R_T \le \frac{D_\infty^2 \sqrt{T}}{\alpha(1-\beta_1)} \sum_{i=1}^{d} \hat{v}_{T,i}^{1/2} + \frac{D_\infty^2}{(1-\beta_1)^2} \sum_{t=1}^{T} \sum_{i=1}^{d} \frac{\beta_{1t} \hat{v}_{t,i}^{1/2}}{\alpha_t} + \frac{\alpha\sqrt{1+\log T}}{(1-\beta_1)^2(1-\gamma)\sqrt{1-\beta_2}} \sum_{i=1}^{d} \|g_{1:T}$$

→ 세 항의 의미: (1) 초기 거리 × $\sqrt{T}$, (2) 모멘텀 비용, (3) 기울기 크기.

③ **따름정리 1** — $\beta_{1t} = \beta_1 \lambda^{t-1}$이면 둘째 항이 상수 $\frac{\beta_1 D_\infty^2 G_\infty}{(1-\beta_1)^2(1-\lambda)^2}$.

④ **해석** — $\sum_i \hat{v}_{T,i}^{1/2} \ll \sqrt{d}$, $\sum_i \|g_{1:T,i}\|_2 \ll \sqrt{dT}$ 이면 SGD의 $O(\sqrt{dT})$보다 **훨씬 좋다**(희소 기울기). $\beta_{1t} = \beta_1/t$로도 $O(\sqrt{T})$.

⑤ **대안** — max 대신 과거 v_t의 **단순 평균**을 쓰면 AdaGrad와 비슷한 알고리즘.

⑥ **5절 실험 시작** — 볼록(로지스틱 회귀)·비볼록(신경망) 다중 분류. 합성 문제:

$$f_t(x) = \begin{cases} 1010x & t \bmod 101 = 1 \\ -10x & \text{그 외} \end{cases}, \quad \mathcal{F} = [-1, 1],\ \beta_1 = 0.9,\ \beta_2 = 0.99$$

→ ✍️ 101스텝 동안의 기울기 합은? ($1010 - 100 \cdot 10 = 10 > 0$ → 최적해는 $x = -1$)

p.7 해설 — 실험: 합성·MNIST·CIFAR-10

① **그림 2** — 위: MNIST 로지스틱 회귀(학습/시험 손실), 1층 신경망. 아래: CIFARNET 학습·시험 손실.

② **합성 결과** ⭐ — Adam: 평균 regret이 0으로 안 감, $x_t \to 1$ (regret **최대** 점). AMSGrad: 평균 regret → 0, $x_t \to -1$ (최적). 확률적 버전: 확률 0.01로 $1010x$, 아니면 $-10x$ → 역시 Adam은 $x = 1$로. → 🔎 *converge to x = 1, which unfortunately has the largest regret* 에 밑줄.

③ **로지스틱 회귀 (볼록)** — MNIST 784차원 → 10클래스. $\alpha_t = \alpha/\sqrt{t}$ (이론과 일치), 미니배치 128, $\beta_1 = 0.9$, $\beta_2 \in \{0.99, 0.999\}$, 격자 탐색. AMSGrad가 학습·시험 손실 모두 우수, 하이퍼파라미터에 **더 견고**.

④ **신경망 (비볼록)** — 은닉층 1개(ReLU 100개), **상수** $\alpha_t = \alpha$ (딥러닝 관행).

⑤ **CIFAR-10 / CIFARNET** — 32×32 이미지 6만 장. 합성곱 2층(64채널, 6×6 커널) + 완전연결 384, 192. 2×2 맥스풀링, 국소 응답 정규화, 드롭아웃 0.5, 미니배치 128. → ai_life **03 CNN** 단원의 구조 그림과 비교해 보자.

→ ✍️ ai_life **01 선형회귀** 데모에 Adam/AMSGrad 토글을 넣는다면, 학생에게 어떤 데이터를 보여 줘야 차이가 드러날까?

p.8 해설 — AdamNC와 결론

① **CIFAR 결과** — AMSGrad가 학습 손실·정확도에서 상당히 우수, 시험 손실에도 이어짐.

② **5.1 AdamNC** — 구조는 Adam 그대로, β_2를 **증가** 스케줄로 (Algorithm 3, 부록).

③ **정리 5** — 조건 (1) v가 기울기 제곱합의 일정 비율 이상, (2) $v_{t,i}^{1/2}/\alpha_t \geq v_{t-1,i}^{1/2}/\alpha_{t-1}$ (= $\Gamma_t \succeq 0$)이면 AMSGrad와 비슷한 regret 경계.

④ **따름정리 2** ⭐ — $\beta_{2t} = 1 - 1/t$이면 $v_{t,i} = \sum_{j=1}^{t} g_{j,i}^2/t$ → **모멘텀 붙은 AdaGrad**! 데이터 의존 regret. → 🔎 $\beta_{2t} = 1 - 1/t$ 에 밑줄. "지수평균"을 "단순평균"으로 바꾸는 마법.

⑤ **6절 결론** ⭐ — 본질적으로 **고정 크기 창**의 과거 기울기로 스케일하는 모든 알고리즘은 이 문제를 겪는다. 장기 기억을 주는 작은 수정으로 해결, 실전 성능도 유지·개선. → 🔎 *any algorithm that relies on an essentially fixed sized window* 에 밑줄.

⑥ **메시지** — RMSProp·Adam은 크게 성공했으니 그 행동을 **엄밀히 이해**하고 **함정**을 알고 써야 한다.

→ ✍️ "고정 크기 창"의 비유: 최근 일주일 날씨만 보고 우산을 챙기는 사람과 1년 기록을 보는 사람 — 장마철 직후에는 누가 더 틀릴까?

p.9 해설 — 참고문헌

참고문헌 중 주목할 것

참고문헌	왜 볼까
Duchi, Hazan, Singer (2011)	**AdaGrad** — 적응형 방법의 출발점
Kingma & Ba (2015)	**Adam** — 지난주 읽은 논문, 이번 반례의 대상
Tieleman & Hinton (2012)	**RMSProp** — 코세라 강의 슬라이드가 출처
Zeiler (2012)	AdaDelta
Dozat (2016)	NAdam (네스테로프 + Adam)
Zinkevich (2003)	온라인 볼록 최적화와 온라인 경사하강
McMahan & Streeter (2010)	적응적 경계 최적화 (보조정리 4의 출처)
Auer & Gentile (2000)	보조정리 5의 출처
Krizhevsky 외 (2012)	AlexNet — CIFARNET 정규화의 출처

✍️ 본문 정리 질문 (부록 들어가기 전에)

1. Γ_t의 정의를 쓰고, SGD에서 $\Gamma_t \succeq 0$ 임을 보이자 ($\sqrt{V_t} = I$, $\alpha_t = \alpha/\sqrt{t}$).
2. Adam에서 Γ_t가 음수가 되는 구체적 상황을 한 줄로 (큰 g 뒤에 작은 g들이 이어질 때 v_t가 줄어든다).
3. AMSGrad의 max가 $\Gamma_t \succeq 0$을 보장하는 이유는? (상수 β_2, 감소하는 α_t와 함께)

p.10 해설 — 부록 A: 정리 1의 증명 (1)

① **설정** — f_t 선형, $\mathcal{F} = [-1, 1]$, $C \geq 2$, $x_1 = 1$ (좌표 평행이동으로 일반성 유지).

$$\beta_1 = 0, \quad \beta_2 = \frac{1}{1+C^2}, \quad \alpha_t = \frac{\alpha}{\sqrt{t}}, \quad \alpha < \sqrt{1-\beta_2}$$

Kingma & Ba의 조건(유계 기울기, 유계 지름, $\beta_1^2/\sqrt{\beta_2} < 1$) 모두 충족 — 즉 **원 논문의 가정 안에서** 반례. → 🔎 *the conditions on the parameters required for ADAM are satisfied* 에 밑줄.

② **주장** ⭐ — 모든 t에서 $x_t > 0$, 그리고 $x_{3t+1} = 1$. **수학적 귀납법**으로.

③ **기울기** — $\nabla f_i = C$ ($i \bmod 3 = 1$), 아니면 -1.

④ **(3t+1)번째 갱신**

$$\hat{x}_{3t+2} = 1 - \frac{\alpha C}{\sqrt{(3t+1)(\beta_2 v_{3t} + (1-\beta_2)C^2)}}$$

분모에서 $\beta_2 v_{3t} \geq 0$을 버리면

$$\frac{\alpha C}{\sqrt{(3t+1)(1-\beta_2)C^2}} = \frac{\alpha}{\sqrt{(3t+1)(1-\beta_2)}} < 1 \quad (4)$$

→ $0 < x_{3t+2} < 1$. **큰 기울기 C가 $\sqrt{C^2}$로 나뉘어 상쇄**되는 것이 핵심! → 🔎 식 (4)에 밑줄.

⑤ **다음 두 갱신** — 기울기 -1이므로 x가 **증가**: $\hat{x}_{3t+3} = x_{3t+2} + \frac{\alpha}{\sqrt{(3t+2)(\beta_2 v_{3t+1} + 1 - \beta_2)}}$, $\hat{x}_{3t+4}$도 마찬가지.

⑥ **목표** — $\hat{x}_{3t+4} \geq 1$을 보이면 사영으로 $x_{3t+4} = 1$.

→ ✍️ 왜 -1 기울기 때의 분모는 작고(따라서 이동량이 크고), C 기울기 때의 분모는 큰가? v에 C^2이 들어가는 시점을 표시해 보자.

p.11 해설 — 부록 A: 정리 1의 증명 (2)

① **경우 나누기** — $\hat{x}_{3t+3} \geq 1$이면 바로 $\hat{x}_{3t+4} > 1$. 아니면 다음을 보이면 충분:

$$T_1 = \frac{\alpha C}{\sqrt{(3t+1)(\beta_2 v_{3t} + (1-\beta_2)C^2)}} \leq T_2 = \frac{\alpha}{\sqrt{(3t+2)(\beta_2 v_{3t+1} + 1 - \beta_2)}} + \frac{}{\sqrt{(3t+3)}}$$

= "한 번 뒤로 간 거리 ≤ 두 번 앞으로 간 거리".

② T_1 **위로** — 식 (5): $T_1 \leq \dfrac{\alpha}{\sqrt{(3t+1)(1-\beta_2)}}$.

③ T_2 **아래로** — $v_t \leq C^2$ 사용, $\frac{1}{\sqrt{3t+2}} + \frac{1}{\sqrt{3t+3}} \geq \frac{\sqrt{2}}{\sqrt{3t+1}}$ 류의 부등식으로

$$T_2 \geq \frac{\sqrt{2}\,\alpha}{\sqrt{(3t+1)(\beta_2 C^2 + 1 - \beta_2)}} = \frac{\alpha}{\sqrt{(3t+1)(1-\beta_2)}} \geq T_1 \quad (6)$$

마지막 등호: $\beta_2 = 1/(1+C^2)$이면 $\dfrac{\beta_2 C^2 + (1-\beta_2)}{2} = 1 - \beta_2$. → ✍️ 이 등식을 직접 확인해 보자. ($\beta_2 C^2 + 1 - \beta_2 = \frac{C^2 + C^2}{1+C^2} = \frac{2C^2}{1+C^2}$, $1 - \beta_2 = \frac{C^2}{1+C^2}$)

④ **결론** ⭐ — 귀납법으로 모든 t에서 $x_{3t+1} = 1$. 3스텝마다 regret

$$\geq 2C - 4$$

(첫 스텝: $f(1) - f(-1) = C - (-C) = 2C$; 나머지 두 스텝: $-x - 1 \geq -2$ 씩, 합 ≥ -4). 따라서 $R_T \geq (2C-4)T/3$, $R_T/T \not\to 0$. → 🔎 *ADAM suffers a regret of at least 2C – 4* 에 밑줄.

→ ✍️ $C = 2$이면 $2C - 4 = 0$. 그래서 본문은 $C > 2$를 요구한다. 왜 $C = 2$는 반례가 안 되는지 생각해 보자.

p.12 해설 — 부록 B: 정리 2의 증명 (1)

① **일반화** — 이제 β_1, β_2가 **임의의 상수**($\beta_1 < \sqrt{\beta_2}$). 함수열:

$$f_t(x) = \begin{cases} Cx & t \bmod C = 1 \\ -x & \text{그 외} \end{cases}$$

C는 짝수 자연수, 식 (7)의 세 조건을 만족할 만큼 **큼** ($\gamma = \beta_1/\sqrt{\beta_2} < 1$). → 주기가 3에서 C로: 큰 기울기가 **더 드물게** 온다.

② **관찰:** $m_{kC} \le 0$ — 주기 끝에서 모멘텀이 항상 0 이하.

$$m_{kC+C} = -(1-\beta_1^{C-1}) + (1-\beta_1)\beta_1^{C-1}C + \beta_1^C m_{kC} \quad (9)$$

C가 크면 $\beta_1^{C-1}C$가 작아 귀납적으로 ≤ 0.

③ **전략** — T' 이후($t + C \le \tau^2 t, \tau \le 3/2$)만 분석. 그 전 regret은 상수라 평균엔 무관.

④ **주장 (10)** — $t = kC$에서 $x_{t+C} \ge \min\{x_t + c_t, 1\}$, $c_t > 0$. 즉 한 주기가 지나면 x가 **오른쪽(잘못된 쪽)으로** 순증가.

⑤ **이동량** δ — 첫 스텝 δ_t(기울기 C, 음수 이동), 나머지 δ_{t+i}(기울기 -1). 한 번 양수가 되면 계속 양수 → **보조정리 6**(1차원 사영 누적)으로 $x_{t+C} \ge \min\{1, x_t + \sum \delta_i\}$.

→ ✍️ 정리 1(주기 3)과 정리 2(주기 C)의 차이를 한 문장으로: 무엇을 크게 해서 임의의 β를 이기는가?

p.13 해설 — 부록 B: 정리 2의 증명 (2)

① **목표** — $\delta = \sum_{i=t}^{t+C-1} \delta_i > 0$.

② **기울기 -1 구간의 합을 아래로** — 정의에 m을 풀어 넣고, $m_t \le 0$, $t + C \le \tau^2 t$, $v_{t+i-1} \ge (1-\beta_2)\beta_2^{i-2}C^2$ 등을 차례로 사용.

③ **핵심 상계** ⭐ — 주기 후반($i' = C/2 \le i \le C$)에선 큰 기울기 C^2의 흔적이 $\beta_2^{i'-1}$배로 **거의 사라져**

$$v_{t+i-1} \le (1-\beta_2)\left(\beta_2^{i'-1}C^2\frac{1}{1-\beta_2^C} + \frac{1}{1-\beta_2}\right) \le 2$$

→ 🔎 이 부등식의 의미에 밑줄: "지수평균은 큰 기울기를 **잊는다**" — 서론의 직관이 수식이 된 곳.

④ **결과** — 후반 $C - i'$ 스텝 각각이 $\dfrac{\alpha}{\tau\sqrt{t}\sqrt{1+\beta_2}}$ 이상 오른쪽으로 → 합이 첫 스텝의 왼쪽 이동을 이긴다.

⑤ **사용된 부등식들** — 기하급수 합 $\sum \beta^j \le \frac{1}{1-\beta}$, γ에 대한 합 $\frac{\gamma(1-\gamma^{C-1})}{1-\gamma}$.

→ ✍️ $\beta_2 = 0.999$, $C = 10000$이면 $\beta_2^{C/2-1} \approx e^{-5} \approx 0.007$. 즉 5000스텝 전의 큰 기울기는 v에 0.7%만 남는다. 실전 β_2에서도 문제가 생길 수 있는 이유!

p.14 해설 — 정리 2 마무리, 부록 C: 확률적 반례

① λ — $\sum \delta_i \geq \lambda/\sqrt{t}$, $\lambda \geq 0$는 t와 무관. 따라서 $x_{t+C} \geq \min\{1, x_t + \lambda/\sqrt{t}\}$.

② **두 사실** — (1) $x_t = 1$이면 이후 주기 끝마다 1. (2) $\sum 1/\sqrt{t}$는 **발산**하므로 언젠가 $x = 1$ 도달.

③ **regret** — 그 이후 C스텝마다 regret $\geq 2C - 2(C-1) = 2 \rightarrow R_T \geq 2(T - T_1')/C$, 평균 regret이 0으로 안 감.

④ **부록 C: 정리 3** ⭐ — 매 시각 i.i.d.로

$$f_t(x) = \begin{cases} Cx & \text{확률 } p = \frac{1+\delta}{C+1} \\ -x & \text{확률 } 1-p \end{cases}$$

기댓값 함수 $F(x) = \delta x \rightarrow$ 최적점 $x^\star = -1. \rightarrow$ ✍️ $F(x) = pCx - (1-p)x$ 를 계산해 δx가 나오는지 확인하자.

⑤ **Adam의 스텝**

$$\Delta_t = -\alpha_t \frac{\beta_1 m_{t-1} + (1-\beta_1) g_t}{\sqrt{\beta_2 v_{t-1} + (1-\beta_2) g_t^2}}$$

⑥ **보조정리 1** — C가 충분히 크면 $\mathbb{E}[\Delta_t] \geq 0 \rightarrow$ Adam의 스텝이 **평균적으로 최적해에서 멀어진다**. → 🔎 *keep drifting away from the optimal solution* 에 밑줄.

p.15 해설 — 보조정리 1의 증명

① **기댓값 분해 (11)** — $-\mathbb{E}_t[\Delta_t]/\alpha_t = T_1 + T_2 + T_3$:

- T_1: 큰 기울기 C가 왔을 때의 (음의) 이동
- T_2: 모멘텀 $-\beta_1 m_{t-1}$ 의 기여
- T_3: 기울기 -1일 때의 (양의) 이동

② T_1 **아래로 (12)** — $-T_1 \geq -\dfrac{1}{\sqrt{1-\beta_2}}$ (분모에 C^2이 있어 C가 상쇄). 이 항에 확률 $p \approx 1/C$가 곱해지므로 작다.

③ T_2 **(13)** — $k = \lceil \log(C+1)/\log(1/\beta_1) \rceil$. 최근 k번 모두 -1인 사건 E (확률 $\geq 1-kp$)에서는 $m_{t-1} \leq 0 \to T_2 \geq 0$. 아니면 **코시-슈바르츠**로 $m_{t-1} \leq A\sqrt{v_{t-1}}$ 를 써서 $\mathbb{E}[T_2] \geq -\dfrac{\beta_1(1-\beta_1)kp}{\sqrt{(1-\beta_2)(\beta_2-\beta_1^2)}}$.

④ T_3 — **옌센 부등식** — $-1/\sqrt{x}$는 볼록 → $\mathbb{E}[T_3] \geq \dfrac{1-\beta_1}{\sqrt{\beta_2(1+\delta)C + (1-\beta_2)}}$.

⑤ **(14)** — $\mathbb{E}[v_{t-1}] = (1-\beta_2^{t-1})(C^2 p + 1 - p) \leq (1+\delta)C$.

→ ✍️ 크기 비교: T_1 기여 $\sim p \cdot 1 = O(1/C)$, T_2 기여 $\sim kp = O(\log C / C)$, T_3 기여 $\sim 1/\sqrt{C}$. $C \to \infty$에서 누가 이기나? ($1/\sqrt{C}$가 가장 천천히 줄어든다 → 양수!)

p.16 해설 — 정리 3 마무리, 부록 D: AMSGrad 수렴 증명 (1)

---

① **정리 3 결론** — 세 경계를 합치면 C가 크면 $\mathbb{E}[\Delta_t] \geq 0$. 사영 없는 Adam이면 $\mathbb{E}[x_{t+1}] \geq \mathbb{E}[x_t] \rightarrow x_1 \geq 0$에서 시작하면 $\mathbb{E}[F(x_t)] \geq 0$, 그런데 $F(-1) = -\delta$. **기대 최적성 격차가 항상** δ.

② **부록 D의 위치** ⭐ — Kingma & Ba 정리 4.1을 따라가되, 그 증명의 문제: (a) Γ_t가 양반정치라는 **잘못된 가정**, (b) 그들의 **보조정리 10.3, 10.4**의 문제. 이 증명이 그것을 고친다. → 🔎 *incorrect assumption that Γt ⋯ is positive semidefinite* 에 밑줄.

③ **출발점** — 사영의 **비확장성**(보조정리 4)으로

$$\|\hat{V}_t^{1/4}(x_{t+1} - x^*)\|^2 \leq \|\hat{V}_t^{1/4}(x_t - x^*)\|^2 + \alpha_t^2 \|\hat{V}_t^{-1/4} m_t\|^2 - 2\alpha_t \langle m_t, x_t - x^* \rangle$$

④ **정리 (15)** — $\langle g_t, x_t - x^* \rangle$ 를 "거리 감소량 + 스텝 크기 항 + 모멘텀 항"으로 상계. 코시-슈바르츠와 **영(Young) 부등식** 사용.

→ ✍️ 영 부등식 $ab \leq \frac{a^2}{2\epsilon} + \frac{\epsilon b^2}{2}$ 를 써서 $\langle m_{t-1}, x_t - x^* \rangle$ 같은 내적을 쪼개는 연습을 해 보자.

p.17 해설 — 부록 D (2): 볼록성과 보조정리 2

① 볼록성으로 regret 쪼개기 (16)

$$\sum_{t=1}^{T} f_t(x_t) - f_t(x^*) \leq \sum_{t=1}^{T} \langle g_t, x_t - x^* \rangle$$

(볼록함수는 접선 위에 있다: $f(x^*) \geq f(x_t) + \langle g_t, x^* - x_t \rangle$) → 이후 (15)를 대입. $\hat{v}_{t-1,i} \leq \hat{v}_{t,i}$ (**max 덕분**)를 사용. → 🔎 *the fact that* $\hat{v}_{t-1,i} \leq \hat{v}_{t,i}$ 에 밑줄 — Adam에선 이것이 성립하지 않는다!

② 보조정리 2 ⭐

$$\sum_{t=1}^{T} \alpha_t \|\hat{V}_t^{-1/4} m_t\|^2 \leq \frac{\alpha\sqrt{1+\log T}}{(1-\beta_1)(1-\gamma)\sqrt{1-\beta_2}} \sum_{i=1}^{d} \|g_{1:T,i}\|_2$$

③ 증명 시작 — 마지막 항을 떼어 내고, $\hat{v}_{T,i} \geq v_{T,i}$ 로 분모를 바꾼 뒤 m_T, v_T를 기울기 합으로 전개.

④ 코시-슈바르츠 (17) — 분자 $(\sum \beta_1^{T-j} g_j)^2 \leq (\sum \beta_1^{T-j})(\sum \beta_1^{T-j} g_j^2)$, $\sum \beta_1^{T-j} \leq \frac{1}{1-\beta_1}$ → 비 $\beta_1^{T-j}/\sqrt{\beta_2^{T-j}} = \gamma^{T-j}$ 등장.

→ ✍️ 왜 조건 $\gamma = \beta_1/\sqrt{\beta_2} < 1$ 이 필요한지 이 단계에서 확인하자 (기하급수 $\sum \gamma^j$ 수렴).

p.18 해설 — 부록 D (3): 망원 합

① **보조정리 2 마무리** — 합의 순서를 바꾸고 $\sum_{j\geq t}\gamma^{j-t}\leq\frac{1}{1-\gamma}$, 코시-슈바르츠, **조화급수** $\sum_{t=1}^{T}1/t\leq 1+\log T$. → 🔎 *harmonic sum* 에 밑줄 — $\sqrt{1+\log T}$의 출처.

② **정리 4로 복귀 (18)** — 보조정리 2를 (16)에 넣고, 첫 항을

$$\frac{\|\hat{V}_t^{1/4}(x_t-x^*)\|^2}{\alpha_t}-\frac{\|\hat{V}_{t-1}^{1/4}(x_t-x^*)\|^2}{\alpha_{t-1}}$$

꼴로 재배열 → 좌표별로 $(x_{t,i}-x_i^*)^2\left(\frac{\hat{v}_{t,i}^{1/2}}{\alpha_t}-\frac{\hat{v}_{t-1,i}^{1/2}}{\alpha_{t-1}}\right)$.

③ **바로 여기가 Γ** ⭐⭐ — 괄호 안이 Γ_t의 좌표 성분. AMSGrad에서는 **항상** ≥ 0 이라 $(x_{t,i}-x_i^*)^2\leq D_\infty^2$로 바꿔 **망원 합**(telescoping)이 가능. Adam에선 음수일 수 있어 이 단계가 **무너진다**. → ✍️ 괄호가 음수일 때 $(x-x^*)^2\leq D^2$로 바꾸면 왜 부등호 방향이 틀리는지 설명해 보자.

④ **각주 3** — 원 증명에 빠졌던 상수 인자 $\frac{2}{1-\beta_1}$을 이번에 바로잡았다.

p.19 해설 — 정리 4 완성, 부록 E: AdamNC

① **Algorithm 3 AdamNC** — Adam과 같은 구조, 단 (β_{1t}, β_{2t})가 시간에 따라 변함:

$$m_t = \beta_{1t} m_{t-1} + (1-\beta_{1t}) g_t, \quad v_t = \beta_{2t} v_{t-1} + (1-\beta_{2t}) g_t^2$$

② **망원 합 결과** —

$$\sum_t \left(\frac{\hat{v}_{t,i}^{1/2}}{\alpha_t} - \frac{\hat{v}_{t-1,i}^{1/2}}{\alpha_{t-1}} \right) D_\infty^2 = \frac{\hat{v}_{T,i}^{1/2}}{\alpha_T} D_\infty^2 - \cdots$$

→ 정리 4의 첫 항 $\frac{D_\infty^2 \sqrt{T}}{\alpha(1-\beta_1)} \sum_i \hat{v}_{T,i}^{1/2}$ 이 나온다.

③ **최악의 경우** — $\sum_t |g_{t,i}|/\sqrt{t} = O(G_\infty \sqrt{T})$ 이므로 AMSGrad의 regret은 $\min\{O(G_\infty \sqrt{T}),\ 정리\ 4\ 경계\}$ → T에 대한 최악 의존도는 $O(\sqrt{T})$. → 🔎 *the worst case dependence of regret on T in our case is O(√T)* 에 밑줄.

④ **부록 E: 정리 5 증명 시작** — 정리 4와 같은 방법으로 (19)까지. 차이는 $\hat{V}_t$ 대신 V_t.

→ ✍️ $O(\sqrt{T})$ regret이면 평균 regret은 $O(1/\sqrt{T})$. $T = 10^6$이면 평균 손해는 대략 몇 분의 1로 줄어드나?

p.20 해설 — 부록 E (2): 보조정리 3

① **(20)** — 볼록성 + 정리 5의 조건 2 ($v_{t,i}^{1/2}/\alpha_t \geq v_{t-1,i}^{1/2}/\alpha_{t-1}$, 즉 $\Gamma_t \succeq 0$**을 가정으로 요구**).

② **보조정리 3** —

$$\sum_{t=1}^{T} \alpha_t \|V_t^{-1/4} m_t\|^2 \leq \frac{2\zeta}{(1-\beta_1)^2} \sum_{i=1}^{d} \|g_{1:T,i}\|_2$$

③ **증명 (21)** — 코시-슈바르츠 → $\beta_{1k} \leq \beta_1$ → $\sum \beta_1^{T-j} \leq \frac{1}{1-\beta_1}$ → **조건 1**(분모가 기울기 제곱합의 $1/\zeta$배 이상)을 써서

$$\leq \frac{\zeta}{1-\beta_1} \sum_i \sum_j \frac{\beta_1^{T-j} g_{j,i}^2}{\sqrt{\sum_{k \leq j} g_{k,i}^2}}$$

→ 분모가 **누적합**(AdaGrad형)이 되는 것이 핵심.

→ ✍️ AMSGrad(정리 4)는 $\Gamma \succeq 0$을 **알고리즘이 보장**하고, AdamNC(정리 5)는 **가정으로 요구**한다. 실전에서 어느 쪽이 편할까?

p.21 해설 — 정리 5 마무리, 부록 F: ε으로도 안 된다

---

① **보조정리 3 마무리** — 보조정리 5(Auer & Gentile): $\sum_i \frac{y_i}{\sqrt{\sum_{j\le i} y_j}} \le 2\sqrt{\sum_i y_i}$ → $\frac{2\zeta}{(1-\beta_1)^2}\sum_i \|g_{1:T,i}\|_2$.

② **정리 5 완성 (22)** — 정리 4와 같은 망원 합으로

$$R_T \le \frac{D_\infty^2}{2\alpha_T(1-\beta_1)}\sum_i v_{T,i}^{1/2} + \frac{D_\infty^2}{(1-\beta_1)^2}\sum_{t,i}\frac{\beta_{1t}v_{t,i}^{1/2}}{\alpha_t} + \frac{2\zeta}{(1-\beta_1)^3}\sum_i \|g_{1:T,i}\|_2$$

③ **부록 F: 정리 6** ⭐ — 분모에 ϵ을 더한 수정판 Adam(식 3)도, Kingma & Ba의 모든 조건을 만족하면서 평균 regret이 0으로 가지 않는 볼록 문제가 있다. → 🔎 *For any ϵ > 0* 에 밑줄 — 실무에서 "ε을 키우면 되지 않나?"에 대한 답.

→ ✍️ 보조정리 5를 $y_i = 1$ (모두 1)로 확인해 보자: 좌변 $\sum 1/\sqrt{i} \approx 2\sqrt{t}$, 우변 $2\sqrt{t}$.

p.22 해설 — 부록 F: 정리 6의 증명

① **설정** — 먼저 $\epsilon = 1$ (실은 $\epsilon \le 1$ 모두). 정리 1과 **같은** 함수열(Cx / $-x$, 주기 3), $x_1 = 1$, 단

$$\beta_1 = 0, \quad \beta_2 = \frac{2}{(1+C^2)C^2}, \quad \alpha_t = \frac{\alpha}{\sqrt{t}}, \quad \alpha < \sqrt{1-\beta_2}$$

② **귀납법** — 정리 1과 동일한 구조: $x_{3t+2}, x_{3t+3} > 0$, $x_{3t+4} = 1$.

③ **차이점** — 모든 분모에 $+\epsilon$. 큰 기울기 스텝:

$$\hat{x}_{3t+2} = 1 - \frac{\alpha C}{\sqrt{(3t+1)(\beta_2 v_{3t} + (1-\beta_2)C^2 + \epsilon)}} \ge 0$$

④ **핵심 부등식 (23)** — 두 번의 앞 이동 ≥ 한 번의 뒤 이동. 이번엔 등식

$$\frac{\beta_2 C^2 + (1-\beta_2) + \epsilon}{2} \text{ 와 } (1-\beta_2) + \frac{\epsilon}{C^2}$$

의 관계를 β_2 선택으로 맞춘다 (원문 마지막 줄 참고).

⑤ **결론** — 다시 3스텝마다 regret $\ge 2C - 4$.

→ ✍️ ϵ이 분모에 들어가면 큰 기울기와 작은 기울기 중 누구의 스텝이 **상대적으로** 더 줄어드는가? 그래도 반례가 유지되는 이유를 직관적으로 설명해 보자.

p.23 해설 — 일반 ε과 보조정리들, 전체 정리

① **일반** ϵ — 함수열을 $\sqrt{\epsilon}$배로 **재조정**: $f_t = C\sqrt{\epsilon}x$ / $-\sqrt{\epsilon}x \to R_T \geq (2C-4)\sqrt{\epsilon}\,T/3$.

② **보조정리 4** (McMahan & Streeter) — 양정치 Q에 대한 사영은 **비확장**: $\|Q^{1/2}(u_1-u_2)\| \leq \|Q^{1/2}(z_1-z_2)\|$. **보조정리 5** (Auer & Gentile) — $\sum_i \frac{y_i}{\sqrt{\sum_{j\leq i} y_j}} \leq 2\sqrt{\sum_i y_i}$. **보조정리 6** — 1차원 구간 사영에서 이동량이 "음수 구간 → 양수 구간" 순이면 $y_{T+1} \geq \min\{b,\ y_1 + \sum \delta_j\}$.

✍️ **논문 전체 정리 질문**

1. 정리 1의 반례를 "3스텝 이야기"로 친구에게 설명하자: 누가 몇 번, 어느 방향으로, 얼마나 움직이나?
2. Adam 원 증명의 오류는 정확히 어느 단계였나? (p.18의 망원 합, $\Gamma_t \succeq 0$)
3. AMSGrad 코드는 Adam 코드에서 **몇 줄**을 바꾸면 되나? 직접 파이썬으로 써 보자.
4. 이상구 외(2023)의 경사하강법 → SGD → (지난주) Adam → AMSGrad 로 이어지는 "학습률 조절의 역사"를 한 장의 표로 정리하자.
5. "실험이 잘 되는 것"과 "수렴이 증명되는 것"은 어떻게 다른가? ai_life 학생들에게 이 논문을 어떤 이야기로 들려줄 수 있을까?