p.1 해설 — 초록과 서론: "깊을수록 학습이 어렵다"

① **초록** — 더 깊은 신경망은 학습이 어렵다는 문제에서 출발. 층이 입력 x를 기준으로 한 **잔차 함수**를 배우도록 바꾸면 최적화가 쉬워지고, 깊이를 늘릴수록 정확도가 오른다. 152층(VGG의 8배)으로 ImageNet 2015 1위, 앙상블 top-5 오류 3.57%. → 🔎 *reformulate the layers as learning residual functions* 에 밑줄.

② **서론 첫 문단** — 깊은 CNN은 저·중·고수준 특징을 층마다 쌓아 올린다. 최근 결과들은 **깊이가 결정적**이라는 것을 보여준다(16~30층).

③ **오른쪽 단: 두 가지 장애물**

- **기울기 소실/폭발** — 정규화된 초기화와 배치 정규화로 상당 부분 해결됨.
- **성능 저하(degradation)** — 층을 늘리면 정확도가 포화되다가 오히려 떨어짐. 그런데 이것은 **과적합이 아니다**: 훈련 오차 자체가 커지기 때문.

④ **Figure 1** — 20층 vs 56층 "plain" 망. 56층이 **훈련 오차와 테스트 오차 모두** 더 높음. → 🔎 그래프에서 *training error* 곡선을 꼭 확인. 이것이 논문 전체의 출발점.

⑤ **마지막 문단의 사고 실험** — 얕은 망 + 항등 사상 층들을 붙이면 깊은 망을 "구성"할 수 있으므로, 깊은 망은 *적어도* 얕은 망만큼은 좋아야 한다. 그런데 실제 최적화기는 그 해를 찾지 못한다.

용어	뜻
degradation	성능 저하 (깊을수록 훈련 오차↑)
vanishing gradient	기울기 소실
constructed solution	구성적 해 (항등 층 추가)

p.2 해설 — 핵심 아이디어: $F(x) + x$

① **Figure 2 (잔차 블록)** — 두 개의 가중치 층 $F(x)$ 옆으로 **지름길**이 x를 그대로 전달하고, 둘을 더한 뒤 ReLU.

② **핵심 문단** — 원하는 함수를 $H(x)$라 할 때, 층들이 H를 직접 배우게 하지 않고

$$F(x) := H(x) - x$$

를 배우게 한다. 원래 함수는 $F(x) + x$로 복원된다. → 🔎 *if an identity mapping were optimal, it would be easier to push the residual to zero* — 논문에서 가장 중요한 한 문장.

③ **지름길 연결(shortcut)** — 항등 지름길은 **추가 파라미터도, 계산량도 0**. 기존 SGD·역전파 그대로 학습 가능.

④ **실험 예고** — (1) 깊은 ResNet은 최적화가 쉽고 plain 망은 깊어질수록 훈련 오차↑, (2) ResNet은 깊이를 늘려 정확도 이득. CIFAR-10에서도 같은 현상 → 특정 데이터셋만의 문제가 아님.

⑤ **오른쪽 단: 관련 연구 (2절)**

- **잔차 표현**: 영상 검색의 VLAD, Fisher 벡터, 편미분방정식의 **멀티그리드** 방법 — 잔차를 다루면 최적화가 빨라진다는 오랜 지혜.
- **지름길 연결**: 오래된 아이디어. 동시대의 **Highway Network**는 게이트로 지름길을 열고 닫지만, ResNet의 지름길은 **항상 열려 있고** 파라미터가 없음.

p.3 해설 — 3.1 잔차 학습, 3.2 항등 지름길

① **3.1 첫 문단** — 비선형 층들이 복잡한 함수 $H(x)$를 근사할 수 있다면, $H(x) - x$도 근사할 수 있다(입출력 차원이 같다는 가정). 표현력은 같지만 **학습의 쉬움**이 다르다. → Cybenko 보편 근사 정리와 연결: "표현 가능성"과 "학습 가능성"은 다른 문제!

② **사전조건화(preconditioning)** — 실제로 항등 사상이 최적일 리는 없지만, 최적 함수가 **0보다 항등에 더 가깝다면** 항등을 기준으로 한 작은 수정(perturbation)을 찾는 편이 쉽다. Fig. 7에서 실제로 잔차 함수의 응답이 작다는 것을 보임. → 🔎 *precondition* 에 밑줄 — 수치해석 용어. 문제를 풀기 쉬운 형태로 바꾸는 것.

③ **3.2 식 (1)**

$$y = F(x, \{W_i\}) + x$$

2층 예시: $F = W_2\,\sigma(W_1 x)$, 덧셈 후 두 번째 비선형성 적용.

④ **식 (2): 차원이 다를 때**

$$y = F(x, \{W_i\}) + W_s x$$

W_s는 차원을 맞추는 선형 사영. 차원이 같을 땐 항등이 충분하고 경제적.

⑤ F가 층 하나뿐이면 $y = W_1 x + x$로 사실상 선형층 → 이점이 없음. 그래서 **2~3층**을 한 블록으로.

p.4 해설 — Figure 3: 세 가지 구조 비교

① Figure 3 (이 쪽의 대부분)

- **왼쪽**: VGG-19 (196억 FLOPs)
- **가운데**: 34층 plain 망 (36억 FLOPs)
- **오른쪽**: 34층 ResNet — plain과 똑같고 **지름길만 추가**. 점선 지름길 = 차원이 늘어나는 곳. → 🔎 세 그림을 나란히 보며 "ResNet = plain + 화살표"임을 확인.

② 3.3 네트워크 구조 (오른쪽 단)

- **plain 기준망**: VGG 철학 — 3×3 합성곱, 특징 맵 크기가 같으면 필터 수 같게, 크기가 절반이면 필터 수 2배(층당 계산량 유지). 끝에 전역 평균 풀링 + 1000-way 완전연결.
- **잔차망**: 차원이 늘어날 때 두 선택지 — **(A)** 0으로 채운 항등 지름길(파라미터 없음), **(B)** 1×1 합성곱 사영.

③ 3.4 구현 — 이미지 크기 조정·크롭·색 증강, 합성곱 뒤 **배치 정규화**, He 초기화, SGD(미니배치 256, 학습률 0.1에서 오차가 정체되면 1/10), 60만 반복, 가중치 감쇠 0.0001, 모멘텀 0.9, 드롭아웃 없음. → 이번 주 Adam 논문과 비교: ResNet은 Adam이 아닌 **SGD+모멘텀**으로 학습.

p.5 해설 — Table 1과 Figure 4: 결정적 실험

① **Table 1** — 18/34/50/101/152층 구조표. 50층부터는 3층짜리 **병목 블록**(1×1→3×3→1×1). FLOPs: 18층 1.8억 → 152층 113억.

② **Figure 4** ⭐ **가장 중요한 그림**

- **왼쪽(plain)**: 34층(빨강)이 18층보다 훈련 오차가 **높다** → 성능 저하.
- **오른쪽(ResNet)**: 34층이 18층보다 **낮다** → 깊이의 이득 회복. → 🔎 가는 선 = 훈련 오차, 굵은 선 = 검증 오차. 두 그래프의 빨강/파랑 순서가 **뒤바뀐 것**에 표시하기.

③ **4.1 plain 망 분석** — plain-34의 문제는 **기울기 소실 때문이 아니다**: 배치 정규화로 순전파 신호의 분산이 0이 아니고, 역전파 기울기 크기도 정상. 저자 추측: 깊은 plain 망은 **수렴 속도가 지수적으로 느릴** 수 있다. → 🔎 *unlikely to be caused by vanishing gradients* — 흔한 오해를 바로잡는 문장.

p.6 해설 — 표 2~5와 병목 블록

① **Table 2** — top-1 오류: plain-18 27.94 / plain-34 28.54 (더 나쁨!) vs ResNet-18 27.88 / ResNet-34 25.03 (3.5%p 개선).

② **세 가지 관찰 (본문)**

1. 잔차 학습으로 상황이 **역전**: 34층 ResNet이 18층보다 좋다.
2. 같은 34층끼리 비교하면 ResNet이 훨씬 좋다 → 깊은 망에서 잔차 학습의 효과 입증.
3. 18층에선 정확도가 비슷하지만 ResNet이 **더 빨리 수렴**.

③ **항등 vs 사영 지름길 (Table 3)** — (A) 0-채움, (B) 차원 늘 때만 사영, (C) 모든 지름길 사영. C > B > A 이지만 차이는 **작다** → 성능 저하 해결의 핵심은 사영이 아니라 **지름길 그 자체**. 메모리·계산 절약을 위해 이후 C는 쓰지 않음.

④ **Figure 5: 병목 설계** — 1×1(차원 축소, 256→64) → 3×3 → 1×1(복원, 64→256). 계산량은 2층 블록과 비슷. → 병목 블록에서는 **항등 지름길이 특히 중요**: 사영을 쓰면 고차원 양 끝을 연결하므로 비용이 2배.

⑤ **Table 4, 5** — 단일 모델 top-5 4.49%(152층), 앙상블 3.57% → ILSVRC 2015 1위.

p.7 해설 — 50/101/152층과 CIFAR-10

① **더 깊은 ResNet** — 34층의 2층 블록을 3층 병목 블록으로 교체 → 50층(38억 FLOPs). 101층·152층으로 확장해도 152층(113억)이 **VGG-16/19(153/196억)보다 가볍다**. → 🔎 "깊이 ≠ 계산량" — 깊지만 좁게 설계한 결과.

② **결과** — 50/101/152층 모두 34층보다 확연히 좋고 **성능 저하가 관찰되지 않음**.

③ **4.2 CIFAR-10 실험 설계** — 목적은 최고 성능이 아니라 **극단적으로 깊은 망의 행동** 관찰. 32×32 입력, 특징 맵 크기 {32, 16, 8}, 필터 {16, 32, 64}, 총 $6n+2$ 층. 지름길은 모두 항등(옵션 A) → 잔차망과 plain 망의 **파라미터 수가 완전히 같음**. → 공정한 비교를 위한 실험 설계에 주목.

④ **학습 설정** — 가중치 감쇠 0.0001, 모멘텀 0.9, 학습률 0.1에서 32k·48k 반복에 1/10, 64k에서 종료. $n = 3, 5, 7, 9$ → 20, 32, 44, 56층. 110층은 처음 학습률 0.01로 **워밍업** 후 0.1.

p.8 해설 — 층 응답 분석과 1000층 실험

① **Figure 6** — 왼쪽: plain은 깊을수록 오류↑ (plain-110은 60% 초과라 표시도 안 됨). 가운데: ResNet은 깊을수록 오류↓. 오른쪽: 110층과 **1202층**.

② **Table 6** — ResNet-110: 6.43% 오류(당시 최고 수준), 파라미터 170만.

③ **Figure 7: 층 응답 분석** ⭐ **이론적으로 중요** — 각 3×3 층 출력(BN 후, 덧셈 전)의 표준편차. ResNet의 응답이 plain보다 **전반적으로 작다** → 3.1절의 가설(잔차 함수는 0에 가깝다) 지지. 더 깊을수록 개별 층의 수정은 더 작아짐. → 🔎 *residual functions might be generally closer to zero* 에 밑줄. 이것이 "작은 수정을 쌓는다 = 미분방정식의 오일러 스텝" 관점의 근거.

④ **1000층 넘기** — 1202층도 최적화 어려움 없이 훈련 오차 0.1% 미만. 그러나 테스트 오차 7.93%로 110층보다 나쁨 → **과적합**(데이터가 작아서). 저자들은 맥스아웃·드롭아웃 같은 강한 정규화를 쓰지 않았음을 밝힘. → 성능 저하(최적화 문제)와 과적합(일반화 문제)의 **구분**이 다시 등장 — 이번 주 Zhang·Belkin 논문과 연결!

⑤ **4.3 PASCAL·COCO 검출** — VGG-16을 ResNet-101로 바꾸기만 해도 COCO mAP 28% 상대 개선 → **좋은 표현은 다른 과제로 일반화**된다.

p.9 해설 — 참고문헌 [1]~[50]

이 쪽은 참고문헌입니다. 다음 번호는 원리 공부에 특히 가치가 있으니 표시해 두세요.

번호	논문	왜 볼까
[1]	Bengio 외 (1994) 장기 의존성 학습의 어려움	기울기 소실 문제의 고전
[3]	Briggs 외, *A Multigrid Tutorial*	잔차로 푸는 수치해석 — ResNet의 수학적 뿌리
[9]	Glorot & Bengio (2010)	깊은 망 학습이 어려운 이유와 초기화
[13]	He 외 (2015) PReLU / He 초기화	이 논문이 쓰는 초기화
[16]	Ioffe & Szegedy (2015) 배치 정규화	기울기 소실 완화
[42], [43]	Srivastava 외 Highway Networks	게이트 지름길 — ResNet과 비교

→ 읽기 팁: 참고문헌 쪽은 건너뛰되, 본문에서 **[3] 멀티그리드**가 등장한 맥락(p.2)을 다시 떠올려 보세요.

p.10 해설 — 부록 A: 물체 검출 기준선

① **개요** — Faster R-CNN 검출기의 백본을 VGG-16에서 ResNet-50/101로 교체. ImageNet으로 사전학습 후 검출 데이터로 미세조정.

② **구조 처리** — ResNet에는 VGG의 은닉 완전연결층이 없으므로, conv1~conv4_x(91개 합성곱 층)를 공유 특징 추출기로, conv5_x를 영역별 분류기로 사용.

③ **배치 정규화 고정** — 사전학습 후 BN 통계를 고정해 미세조정 중에는 **선형 변환**처럼 동작. 메모리 절약 목적.

④ **PASCAL VOC (Table 7, 8)** — ResNet-101이 VGG-16 대비 mAP **3%p 이상** 향상. 저자 강조: 이 이득은 **오직 더 좋은 특징** 덕분.

⑤ **MS COCO** — 80개 범주. mAP@[.5, .95]에서 6%p 향상(상대 28%).

→ ai_life **02 컴퓨터비전 물체인식** 단원과 직접 연결: 물체 인식 시뮬레이터의 "특징 추출기"가 바로 이런 백본.

p.11 해설 — 부록 B: 검출 성능 개선 기법

① **Table 9 (COCO)** — 단계별 개선: VGG-16 기준 21.2 → ResNet-101 27.2 → +상자 정제 → +문맥 → +다중 스케일 테스트 → 앙상블 37.4 (mAP@[.5,.95]).

② **개선 기법들**

- **상자 정제(box refinement)**: 예측한 상자에서 다시 특징을 뽑아 위치를 한 번 더 보정.
- **전역 문맥(global context)**: 이미지 전체 특징을 함께 사용.
- **다중 스케일 테스트**: 여러 크기로 입력해 결과 결합.

③ **Table 10, 11 (PASCAL VOC 2007/2012)** — 20개 범주별 정확도. "baseline+++"는 위 기법 모두 적용.

④ **앙상블** — 3개 망으로 COCO 2015 검출 1위.

→ 읽기 팁: 표의 숫자를 다 볼 필요는 없습니다. **VGG-16 → ResNet-101 한 줄의 차이**만 확인하세요.

p.12 해설 — 부록 B·C: ImageNet 검출과 위치 추정

① **ImageNet 검출 (Table 12)** — 200개 범주. 단일 모델 58.8%, 3개 앙상블 62.1% mAP → ILSVRC 2015 1위, 2위와 **8.5%p 차이**.

② **부록 C: 위치 추정(localization)** — 분류기로 클래스를 먼저 예측하고, **클래스별 상자 회귀**(PCR)로 위치 예측. RPN을 클래스별로 바꿔 사용.

③ **Table 13, 14** — 위치 추정 top-5 오류: VGG 26.9% → ResNet 앙상블 **9.0%** (테스트). 큰 폭의 개선.

✍️ **논문 전체 정리 질문**

1. "성능 저하"와 "과적합"을 어떻게 구분했는가? (p.1 Fig 1 vs p.8 1202층)
2. 왜 지름길에 파라미터를 넣지 않는 것(항등)이 더 좋았을까?
3. $x_{t+1} = x_t + F(x_t)$를 미분방정식 $\dot{x} = F(x)$와 연결해 설명해 보자.