어텐션만 있으면 된다 (트랜스포머)

> 원제: *Attention Is All You Need*

항목	내용
저자	Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, Illia Polosukhin (Google Brain / Google Research / University of Toronto)
학회	NeurIPS 2017
분야	딥러닝 · 자연어처리 · 신경망 구조
난이도	★★★☆☆
링크	https://arxiv.org/abs/1706.03762
PDF 원문	arXiv PDF (무료)
ai_life 연결 단원	04 자연어처리·AI 에이전트

한 줄 요약

순환(RNN)이나 합성곱 없이 '어텐션' 연산만으로 문장을 처리하는 트랜스포머 구조를 제안 — GPT, BERT, Claude 등 현대 거대 언어모델의 출발점.

왜 중요한가

현대 AI의 거의 모든 모델이 이 구조를 씁니다. 수학적으로는 **행렬곱 + 소프트맥스**라는 단순한 연산으로, 토큰 사이의 관계를 *데이터에 따라 동적으로* 계산한다는 점이 핵심입니다.

핵심 내용

1. 스케일드 닷-프로덕트 어텐션

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

- Q(질의), K(키), V(값) = 입력 X에 학습 행렬 W^Q, W^K, W^V를 곱한 것
- $QK^\top$: 모든 토큰 쌍의 **유사도 행렬** ($n \times n$)
- softmax: 각 행을 확률분포(가중치)로 만듦
- V와 곱함: 관련 있는 토큰 정보의 **가중 평균**

2. 왜 $\sqrt{d_k}$로 나누는가? (수학적 이유 — 각주 4)

q, k의 각 성분이 평균 0, 분산 1인 독립 확률변수라면

$$\mathrm{Var}(q \cdot k) = \mathrm{Var}\Big(\sum_{i=1}^{d_k} q_i k_i\Big) = d_k$$

→ 차원이 클수록 내적 값이 커져 softmax가 한쪽으로 쏠리고(포화) 기울기가 사라짐. $\sqrt{d_k}$로 나눠 분산을 1로 맞춤.

3. 멀티-헤드 어텐션

$$\mathrm{MultiHead}(Q, K, V) = \mathrm{Concat}(\mathrm{head}_1, \ldots, \mathrm{head}_h) W^O$$

서로 다른 부분공간에서 여러 종류의 관계(문법, 의미, 위치 등)를 동시에 학습.

4. 위치 인코딩

어텐션은 순서를 모름(순열 등변성) → 사인/코사인으로 위치 정보 주입

$$PE_{(pos,2i)} = \sin\big(pos/10000^{2i/d}\big), \quad PE_{(pos,2i+1)} = \cos\big(pos/10000^{2i/d}\big)$$

→ 상대 위치 k만큼 이동은 **회전 행렬(선형변환)** 로 표현 가능.

5. 계산 복잡도 비교 (Table 1)

층 종류	층당 복잡도	최대 경로 길이
Self-Attention	$O(n^2 d)$	$O(1)$
RNN	$O(nd^2)$	$O(n)$
CNN	$O(knd^2)$	$O(\log_k n)$

읽는 순서 가이드

1. **Figure 1 (전체 구조도)** - 인코더/디코더 블록 파악 (15분)
2. **3.2절 어텐션** - 수식 1을 작은 행렬(3×2)로 손 계산 (40분)
3. **3.5절 위치 인코딩** - 회전 성질 직접 확인 (20분)
4. **4절 Why Self-Attention + Table 1** (15분)
5. **5-6절 학습/결과** - 가볍게

사전 지식 체크

- [ ] 행렬곱, 전치, 내적
- [ ] softmax 함수와 그 미분
- [ ] 확률변수 합의 분산
- [ ] 잔차 연결, 층 정규화 (ResNet 리뷰 참고)

생각해볼 질문

1. 어텐션 행렬을 "데이터에 따라 바뀌는 가중치 행렬"로 보면, 일반 완전연결층과 무엇이 다를까?
2. $O(n^2)$ 복잡도 때문에 긴 문서 처리에 한계가 있다. 이를 줄이는 수학적 아이디어는? (힌트: 저랭크 근사, 커널화 — Performer, Linformer)
3. 위치 인코딩을 회전으로 보는 관점이 RoPE(회전 위치 임베딩)로 어떻게 발전했을까?

용어 정리

영어	한국어
query / key / value	질의 / 키 / 값
self-attention	셀프 어텐션 (자기 주의)
multi-head	다중 헤드
positional encoding	위치 인코딩
permutation equivariant	순열 등변

다음에 이어 읽을 논문

- Devlin et al. (2019), *BERT*
- Su et al. (2021), *RoFormer: Enhanced Transformer with Rotary Position Embedding*

✍️ 나의 메모