잡음 제거 확산 확률 모델 (DDPM)

> 원제: *Denoising Diffusion Probabilistic Models*

항목	내용
저자	Jonathan Ho, Ajay Jain, Pieter Abbeel (UC 버클리)
학회	NeurIPS 2020
분야	딥러닝 · 생성 모델 · 변분 추론
난이도	★★★★☆
링크	https://arxiv.org/abs/2006.11239 · 코드 https://github.com/hojonathanho/diffusion
PDF 원문	arXiv PDF (무료) — 25쪽 (본문 9 + 참고문헌 3 + 부록·샘플 그림 13)
ai_life 연결 단원	02 컴퓨터비전(이미지 생성), 03 CNN(U-Net 구조)

한 줄 요약

사진에 가우시안 잡음을 1000단계에 걸쳐 조금씩 더해 완전한 잡음으로 만든 뒤, 신경망이 '각 단계에서 더해진 잡음 ϵ'을 맞히도록 학습하면, 순수한 잡음에서 거꾸로 걸어 나와 고품질 이미지를 생성할 수 있다 — 손실은 놀랍게도 $\|\epsilon - \epsilon_\theta\|^2$ 하나.

왜 중요한가

지난주 VAE(Kingma & Welling 2014)의 ELBO를 **수천 단계짜리 사슬**로 확장한 모델로, Stable Diffusion·DALL·E 2·Sora 같은 오늘날 이미지·영상 생성 AI의 직접적 조상입니다. 수학적으로는 (1) **변분 추론**, (2) **잡음 제거 점수 매칭** (score matching), (3) **랑주뱅 동역학**, (4) **자기회귀 모델**을 하나로 잇는 다리이며, 결과적으로 "잡음을 예측하는 회귀 문제"라는 아주 단순한 학습 목표에 도달합니다. CIFAR-10 비조건부 FID **3.17**로 당시 최고.

핵심 내용

1. 정방향(확산) 과정: 잡음 더하기 — 학습할 것 없음

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) = \mathcal{N}\left(\mathbf{x}_t; \sqrt{1-\beta_t}\,\mathbf{x}_{t-1},\ \beta_t I\right)$$

$\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s \le t} \alpha_s$ 로 두면 **한 번에** 점프 가능:

$$q(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}\left(\sqrt{\bar{\alpha}_t}\,\mathbf{x}_0,\ (1-\bar{\alpha}_t) I\right) \quad \Longleftrightarrow \quad \mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$$

$T = 1000$, $\beta_1 = 10^{-4} \to \beta_T = 0.02$ 선형.

2. 역방향 과정: 잡음 빼기 — 신경망이 학습

$$p_\theta(\mathbf{x}_{t-1} \mid \mathbf{x}_t) = \mathcal{N}\big(\boldsymbol{\mu}_\theta(\mathbf{x}_t, t),\ \sigma_t^2 I\big), \quad p(\mathbf{x}_T) = \mathcal{N}(\mathbf{0}, I)$$

3. 변분 경계 (VAE의 ELBO와 같은 구조)

$$L = \mathbb{E}_q\Big[\underbrace{D_{KL}(q(\mathbf{x}_T|\mathbf{x}_0)\|p(\mathbf{x}_T))}_{L_T} + \sum_{t>1}\underbrace{D_{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t,\mathbf{x}_0)\|p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{L_{t-1}} \underbrace{-\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)}_{L_0}\Big]$$

모든 KL이 **가우시안 대 가우시안** → 닫힌 식으로 계산.

4. 핵심 발견: ε을 예측하라 ⭐

$$\boldsymbol{\mu}_\theta(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}}\Big(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\Big)$$

로 매개변수화하면 각 L_{t-1}은 가중치 붙은 $\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta\|^2$ = **여러 잡음 수준의 잡음 제거 점수 매칭**과 같아지고, 샘플링은 **랑주뱅 동역학**을 닮는다. 가중치를 버린 단순화 손실:

$$L_{\text{simple}} = \mathbb{E}_{t,\mathbf{x}_0,\boldsymbol{\epsilon}}\Big[\big\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon},\ t)\big\|^2\Big]$$

5. 두 알고리즘 (각 5줄!)

학습	샘플링
$\mathbf{x}_0$ 뽑기, $t \sim U\{1..T\}$, $\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$	$\mathbf{x}_T \sim \mathcal{N}(0, I)$
$\nabla_\theta\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\|^2$ 로 경사하강	$t = T..1$: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}}(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta) + \sigma_t\mathbf{z}$

6. 결과와 해석

- CIFAR-10: IS 9.46, FID **3.17**. LSUN 256×256에서 ProgressiveGAN급.
- 로그 가능도는 경쟁력이 낮음(≤3.75 bits/dim) — 비트의 절반 이상이 **눈에 안 보이는 세부**에 쓰임 → 훌륭한 **손실 압축기**.
- 역과정 중간 예측 $\hat{\mathbf{x}}_0$: **큰 구조가 먼저, 세부가 나중** (점진적 생성).
- 확산 = 일반화된 비트 순서를 갖는 **자기회귀 모델**.

읽는 순서 가이드

1. **p.1-2 초록·서론·그림 2** - 마르코프 사슬 그림 (15분)
2. **p.2 식 (1)-(4)** - 정방향 과정, $q(\mathbf{x}_t|\mathbf{x}_0)$ 유도 ⭐ (40분)
3. **p.3-4 식 (5)-(12)** - ε 매개변수화 (40분)
4. **p.4 알고리즘 1·2** - 직접 의사코드로 옮기기 (20분)
5. **p.5-7 실험·점진적 생성** - 그림 6, 7 (20분)
6. **p.13-14 부록 A 유도** - 식 (5)를 직접 따라가기 (선택, 40분)

사전 지식 체크

- [ ] Kingma & Welling (2014) VAE, ELBO, 재매개변수화 (지난주)
- [ ] 가우시안 분포, 두 가우시안의 KL 발산
- [ ] 마르코프 사슬, 베이즈 정리
- [ ] U-Net, 합성곱, 잔차 블록 (지난주 ResNet)
- [ ] 트랜스포머의 사인파 위치 임베딩 (지난주)

생각해볼 질문

1. $\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}$ 에서 $\bar{\alpha}_T \approx 0$이면 $\mathbf{x}_T$는 무엇이 되나? 왜 정방향에 $\sqrt{1-\beta_t}$ 축소가 필요한가?
2. VAE는 인코더를 **학습**하지만 확산 모델은 인코더(정방향 과정)가 **고정**이다. 장단점은?
3. 손실이 "잡음 예측 MSE"라면, ai_life **01 선형회귀**의 MSE와 무엇이 같고 무엇이 다른가?
4. 1000단계 샘플링은 느리다. 단계를 줄이려면 어떤 아이디어가 필요할까? (힌트: DDIM)

용어 정리

영어	한국어
diffusion model	확산 모델
forward / reverse process	정방향 / 역방향 과정
Markov chain	마르코프 사슬
variance schedule	분산 스케줄
variational bound (ELBO)	변분 경계
KL divergence	KL 발산
denoising score matching	잡음 제거 점수 매칭
Langevin dynamics	랑주뱅 동역학
rate-distortion	전송률-왜곡
FID / Inception Score	프레셰 인셉션 거리 / 인셉션 점수

다음에 이어 읽을 논문

- Song, Meng, Ermon (2021), *Denoising Diffusion Implicit Models* (DDIM, ICLR 2021) — 샘플링 가속
- Song 외 (2021), *Score-Based Generative Modeling through Stochastic Differential Equations* (ICLR 2021) — 연속 시간(SDE)으로 통합

✍️ 나의 메모