p.1 해설 — 초록과 서론: 확산 모델로 고품질 이미지를

① **초록** ⭐ — **확산 확률 모델**로 고품질 이미지 합성. 확산 모델 = **비평형 열역학**에서 영감을 받은 **잠재 변수 모델**. 최고 결과는 확산 모델과 **잡음 제거 점수 매칭 + 랑주뱅 동역학** 사이의 새로운 연결로 설계한 **가중 변분 경계**로 학습해서 얻었다. → 🔎 *weighted variational bound* 와 *denoising score matching with Langevin dynamics* 에 밑줄.

② **덤으로** — 점진적 **손실 압축 해제** 방식을 자연스럽게 허용 = **자기회귀 디코딩의 일반화**.

③ **성적** — 비조건부 CIFAR-10: **Inception 점수 9.46**, **FID 3.17** (당시 최고). LSUN 256×256: ProgressiveGAN과 비슷한 품질. → ✍️ FID는 낮을수록 좋다. 생성 이미지와 실제 이미지의 **특징 분포 사이 거리**라는 뜻을 메모해 두자.

④ **서론** — GAN, 자기회귀 모델, 흐름(flow), **VAE**(지난주!) 모두 놀라운 이미지·음성 샘플을 만들었다. 에너지 기반 모델과 **점수 매칭**도 GAN급 이미지를 냄.

⑤ **그림 1** — CelebA-HQ 256×256 얼굴(왼쪽), 비조건부 CIFAR-10(오른쪽) 생성 샘플.

⑥ **학회** — NeurIPS 2020, 밴쿠버.

→ ✍️ 지금까지 배운 생성 모델(VAE, GAN, 자기회귀=트랜스포머 언어모델)을 표로 정리하고, 확산 모델이 들어갈 칸을 비워 두자. 이 논문을 다 읽으면 채울 수 있다.

p.2 해설 — 그래프 모형과 배경: 정방향·역방향 과정

① **그림 2** ⭐ — $\mathbf{x}_T \to \cdots \to \mathbf{x}_t \to \mathbf{x}_{t-1} \to \cdots \to \mathbf{x}_0$ (역방향 p_θ, 생성) / 반대 방향 $q(\mathbf{x}_t|\mathbf{x}_{t-1})$ (정방향, 잡음 추가). → ✍️ 이 그림을 노트에 크게 그리고, 왼쪽 끝에 "순수 잡음", 오른쪽 끝에 "사진"이라 적자.

② **확산 모델이란** — 변분 추론으로 학습된 **매개변수화된 마르코프 사슬**. 사슬의 전이는 **확산 과정**(신호가 사라질 때까지 잡음을 조금씩 더하는 사슬)을 **거꾸로** 되돌리도록 학습. 잡음이 작은 가우시안이면 역방향도 **조건부 가우시안**으로 충분.

③ **기여** — 확산 모델이 고품질 샘플을 낼 수 있음을 **처음** 보임 + 특정 매개변수화가 **잡음 제거 점수 매칭**(학습) 및 **어닐링된 랑주뱅 동역학**(샘플링)과 동치임을 밝힘. 로그 가능도는 경쟁력이 낮음.

④ **식 (1) 역방향 과정**

$$p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T)\prod_{t=1}^{T} p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t), \quad p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\boldsymbol{\mu}_\theta(\mathbf{x}_t,t), \Sigma_\theta(\mathbf{x}_t,t))$$

⑤ **식 (2) 정방향 과정** ⭐

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) := \mathcal{N}\left(\mathbf{x}_t; \sqrt{1-\beta_t}\,\mathbf{x}_{t-1}, \beta_t I\right)$$

VAE와의 차이: 근사 사후분포 q가 **고정**되어 있다 (학습하지 않음).

⑥ **식 (3)** — 음의 로그 가능도의 변분 경계 L (= VAE의 ELBO).

⑦ **식 (4) 닫힌 형식** ⭐⭐ — $\alpha_t = 1-\beta_t$, $\bar{\alpha}_t = \prod_{s=1}^{t}\alpha_s$:

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0, (1-\bar{\alpha}_t)I\right)$$

→ 🔎 크게 밑줄. 임의의 t로 **한 번에** 점프! → ✍️ $t=2$일 때 직접 유도: $\mathbf{x}_2 = \sqrt{\alpha_2}(\sqrt{\alpha_1}\mathbf{x}_0 + \sqrt{1-\alpha_1}\boldsymbol{\epsilon}_1) + \sqrt{1-\alpha_2}\boldsymbol{\epsilon}_2$ 의 분산은? ($\alpha_2(1-\alpha_1)+1-\alpha_2 = 1-\alpha_1\alpha_2$ ✓)

p.3 해설 — 분산 감소된 경계와 역방향 평균 (식 5-10)

① **식 (5)** ⭐ — L을 KL 발산들로 다시 쓰기:

$$L = \mathbb{E}_q\Big[\underbrace{D_{KL}(q(\mathbf{x}_T|\mathbf{x}_0)\|p(\mathbf{x}_T))}_{L_T} + \sum_{t>1}\underbrace{D_{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t,\mathbf{x}_0)\|p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))}_{L_{t-1}} \underbrace{-\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)}_{L_0}\Big]$$

② **식 (6)-(7) 정방향 사후분포** — $\mathbf{x}_0$을 알면 계산 가능한 가우시안:

$$\tilde{\boldsymbol{\mu}}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t}\mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\mathbf{x}_t, \qquad \tilde{\beta}_t = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$$

→ 모든 KL이 **가우시안 대 가우시안** → 몬테카를로 대신 **닫힌 식**(라오-블랙웰화).

③ **3.1** L_T — β_t를 상수로 고정 → q에 학습 매개변수 없음 → L_T는 **상수**, 무시.

④ **3.2 분산** — $\Sigma_\theta = \sigma_t^2 I$ 고정. $\sigma_t^2 = \beta_t$와 $\sigma_t^2 = \tilde{\beta}_t$ 결과 비슷 (데이터가 $\mathcal{N}(0,I)$일 때 / 한 점일 때 각각 최적인 두 극단).

⑤ **식 (8)**

$$L_{t-1} = \mathbb{E}_q\Big[\frac{1}{2\sigma_t^2}\|\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t,\mathbf{x}_0) - \boldsymbol{\mu}_\theta(\mathbf{x}_t,t)\|^2\Big] + C$$

→ 가장 단순한 선택: $\boldsymbol{\mu}_\theta$가 $\tilde{\boldsymbol{\mu}}_t$를 예측.

⑥ **식 (9)-(10) 재매개변수화** — $\mathbf{x}_t(\mathbf{x}_0,\boldsymbol{\epsilon}) = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}$ 대입:

$$\mathbb{E}\Big[\frac{1}{2\sigma_t^2}\Big\|\frac{1}{\sqrt{\alpha_t}}\Big(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}\Big) - \boldsymbol{\mu}_\theta(\mathbf{x}_t,t)\Big\|^2\Big]$$

→ 🔎 식 (10)에 밑줄 — 다음 쪽 "ε 예측"의 출발점. VAE의 재매개변수화 트릭과 같은 아이디어!

p.4 해설 — ε 예측과 두 알고리즘 ⭐⭐

① 알고리즘 1 (학습)

1. $\mathbf{x}_0 \sim q(\mathbf{x}_0)$ 2. $t \sim \text{Uniform}(\{1..T\})$ 3. $\boldsymbol{\epsilon} \sim \mathcal{N}(0, I)$
2. $\nabla_\theta \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}, t)\|^2$ 로 경사하강

② 알고리즘 2 (샘플링) — $\mathbf{x}_T \sim \mathcal{N}(0, I)$; $t = T..1$: $\mathbf{z} \sim \mathcal{N}(0, I)$ ($t = 1$이면 0),

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)\right) + \sigma_t \mathbf{z}$$

→ 🔎 두 알고리즘 상자 전체에 밑줄. 이 논문의 **전부**.

③ 식 (11) 매개변수화 — $\boldsymbol{\mu}_\theta = \frac{1}{\sqrt{\alpha_t}}(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t))$, $\boldsymbol{\epsilon}_\theta$ = $\mathbf{x}_t$에서 $\boldsymbol{\epsilon}$을 예측하는 신경망. 샘플링은 $\boldsymbol{\epsilon}_\theta$를 데이터 밀도의 **학습된 기울기**로 쓰는 **랑주뱅 동역학**을 닮음.

④ 식 (12) —

$$\mathbb{E}\left[\frac{\beta_t^2}{2\sigma_t^2\alpha_t(1-\bar{\alpha}_t)}\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\cdot, t)\|^2\right]$$

= **여러 잡음 수준의 잡음 제거 점수 매칭**. "점수 매칭을 닮은 목표 최적화 = 랑주뱅식 사슬을 변분 추론으로 맞추기".

⑤ 세 가지 선택지 — $\tilde{\boldsymbol{\mu}}$ 예측 / **ε 예측** / $\mathbf{x}_0$ 예측(초기 실험에서 품질 나쁨). 4절에서 비교.

⑥ 3.3 데이터·디코더 — 픽셀 $\{0..255\} \to [-1, 1]$. 마지막 단계는 이산 디코더(식 13): 가우시안을 픽셀 칸 $[x - \frac{1}{255}, x + \frac{1}{255}]$에서 적분 → 변분 경계가 **무손실 부호 길이**가 됨. → ✍️ 알고리즘 1을 파이썬 10줄로 써 보자 (신경망은 `eps_model(x_t, t)` 로 가정).

p.5 해설 — 단순화된 목표와 실험 설정

① **표 1 (CIFAR-10)** —

모델	IS	FID	NLL
StyleGAN2+ADA (조건부)	10.06	2.67	-
NCSN	8.87	25.32	-
Ours (L_{simple})	**9.46**	**3.17**	≤3.75
Ours (L, 고정 Σ)	7.67	13.51	≤3.70
→ 비조건부 중 최고, 조건부 모델들보다도 좋음.			

② **표 2 (절제 실험)** — $\tilde{\boldsymbol{\mu}}$ 예측은 진짜 경계 L에서만 작동, 단순 MSE로는 불안정. ε 예측 + L_{simple} = **9.46 / 3.17**.

③ **식 (14)** L_{simple} ⭐⭐

$$L_{\text{simple}}(\theta) := \mathbb{E}_{t,\mathbf{x}_0,\boldsymbol{\epsilon}}\left[\left\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}, t)\right\|^2\right]$$

→ 🔎 크게 밑줄. 식 (12)의 **가중치를 버린** 것.

④ **왜 가중치를 버리면 좋은가** — 작은 t(아주 약한 잡음 제거, 쉬운 일)의 가중치를 **낮추고**, 큰 t의 **어려운** 잡음 제거에 집중 → 샘플 품질 향상.

⑤ **4절 설정** ⭐ — $T = 1000$, β_t: $10^{-4} \to 0.02$ **선형**. $L_T = D_{KL}(q(\mathbf{x}_T|\mathbf{x}_0)\|\mathcal{N}(0,I)) \approx 10^{-5}$ bits/dim. 역방향 신경망 = **U-Net**(PixelCNN++ 계열) + 그룹 정규화, 시간 t는 **트랜스포머 사인파 위치 임베딩**으로 입력, 16×16 해상도에서 **셀프 어텐션**. → ai_life **03 CNN**: U-Net은 "줄였다가 다시 키우는" 합성곱망.

⑥ **4.1** — FID는 관례대로 학습 집합 기준 3.17, 시험 집합 기준 5.24.

→ ✍️ β_t 선형 스케줄에서 $\bar{\alpha}_{1000}$을 대략 계산해 보자: $\log \bar{\alpha}_T = \sum \log(1-\beta_t) \approx -\sum \beta_t \approx -1000 \times 0.01 = -10$, 즉 $\bar{\alpha}_T \approx e^{-10}$ — 신호가 사실상 0.

p.6 해설 — LSUN 샘플, 절제 실험, 점진적 부호화

① **그림 3·4** — LSUN 교회 (FID 7.89), LSUN 침실 (FID 4.90).

② **알고리즘 3·4 (전송/수신)** — $\mathbf{x}_T$부터 $\mathbf{x}_0$까지 차례로 "보내기". 수신자는 p_θ만 알고 있으면 됨. 총 기대 부호 길이 = 식 (5).

③ **4.2 절제** ⭐ — (a) $\tilde{\boldsymbol{\mu}}$ 예측은 진짜 변분 경계에서만 잘 됨. (b) 역방향 **분산을 학습**하면 불안정, 품질 나쁨 → 고정이 낫다. (c) ε 예측은 경계로 학습하면 $\tilde{\boldsymbol{\mu}}$와 비슷, L_{simple}로 학습하면 **훨씬 좋음**. → 🔎 *learning reverse process variances ⋯ leads to unstable training* 에 밑줄.

④ **4.3 점진적 부호화** — 학습/시험 부호 길이 차 ≤ 0.03 bits/dim → **과적합 아님**. 하지만 다른 가능도 기반 모델보다 부호 길이는 경쟁력 낮음.

⑤ **손실 압축기로서** ⭐ — $L_1 + \cdots + L_T$ = **전송률(rate)**, L_0 = **왜곡(distortion)**. 최고 품질 CIFAR-10 모델: 전송률 **1.78** bits/dim, 왜곡 **1.97** bits/dim (0-255 척도 RMSE **0.95**). 무손실 부호 길이의 **절반 이상**이 **눈에 안 보이는 왜곡**을 기술하는 데 쓰임. → 🔎 *More than half of the lossless codelength describes imperceptible distortions* 에 밑줄.

→ ✍️ RMSE 0.95 (0-255 척도)는 픽셀 밝기 1 정도의 차이다. 사람 눈에 보일까? 이 사실이 "가능도는 낮은데 샘플은 예쁜" 이유를 어떻게 설명하나?

p.7 해설 — 점진적 생성과 자기회귀와의 연결

① **중간 예측 (식 15)** ⭐ — 수신자는 어느 시점 t에서든

$$\hat{\mathbf{x}}_0 = \left(\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}_\theta(\mathbf{x}_t)\right)/\sqrt{\bar{\alpha}_t}$$

로 원본을 추정 (식 4를 $\mathbf{x}_0$에 대해 푼 것!). → ✍️ 식 (4)의 재매개변수화 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}$ 에서 식 (15)를 직접 유도하자.

② **그림 5** — 전송률-왜곡 곡선: 저전송률 구간에서 왜곡이 **가파르게** 감소 → 대부분의 비트가 눈에 안 보이는 왜곡에 할당됨.

③ **점진적 생성** ⭐ — 샘플링 도중 $\hat{\mathbf{x}}_0$를 보면 **큰 구조가 먼저, 세부가 나중**에 나타남 (그림 6). 그림 7: 같은 $\mathbf{x}_t$에서 여러 번 샘플 — t가 작으면 세부만 다르고, 크면 큰 구조만 공유. "개념적 압축"의 힌트. → 🔎 *Large scale image features appear first and details appear last* 에 밑줄. ai_life **03 CNN**에서 "얕은 층 = 윤곽, 깊은 층 = 세부"와 비교해 보자.

④ **자기회귀 디코딩과의 연결 (식 16)**

$$L = D_{KL}(q(\mathbf{x}_T)\|p(\mathbf{x}_T)) + \mathbb{E}_q\Big[\sum_{t\geq 1} D_{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t)\|p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))\Big] + H(\mathbf{x}_0)$$

사고 실험: T = 데이터 차원, 정방향이 t번째 좌표를 **가리는(mask)** 과정이라면…

p.8 해설 — 확산 = 일반화된 자기회귀, 보간, 관련 연구

① **자기회귀 결론** ⭐ — 그 설정에서 p_θ 학습 = 좌표 $t+1..T$는 그대로 복사, t번째 좌표를 예측 → **자기회귀 모델 학습**과 같다. 따라서 가우시안 확산 = 데이터 좌표 재배열로는 표현할 수 없는 **일반화된 비트 순서**의 자기회귀 모델. 가우시안 잡음이 가리기(masking)보다 이미지에 더 자연스러울 것. T는 데이터 차원과 무관(32×32×3보다 작은 1000). → 🔎 *a kind of autoregressive model with a generalized bit ordering* 에 밑줄. 지난주 트랜스포머(자기회귀)와 연결!

② **그림 8 / 4.4 보간** — 두 이미지 $\mathbf{x}_0, \mathbf{x}_0'$를 q로 $\mathbf{x}_t, \mathbf{x}_t'$로 부호화 → 선형 보간 $\bar{\mathbf{x}}_t = (1-\lambda)\mathbf{x}_t + \lambda\mathbf{x}_t'$ → 역과정으로 복원. 자세·피부톤·머리·표정·배경은 부드럽게 변하지만 **안경은 아님**. t가 크면 거칠고 다양한 보간, $t = 1000$이면 새 샘플. → ✍️ 원문은 $\bar{\mathbf{x}}_t = (1-\lambda)\mathbf{x}_0 + \lambda\mathbf{x}_0'$로 인쇄되어 있지만 문맥상 잠재변수 $\mathbf{x}_t, \mathbf{x}_t'$의 보간이다 — 그림 8 왼쪽 도식으로 확인해 보자.

③ **5절 관련 연구** — 흐름·VAE와 비슷해 보이지만, q에 매개변수가 없고 최상위 잠재 $\mathbf{x}_T$가 데이터와 **상호정보량 ≈ 0**. ε 예측 → 점수 매칭 + 어닐링된 랑주뱅(NCSN, Song & Ermon)과 연결. 하지만 확산 모델은 로그 가능도 계산이 쉽고, 샘플러를 **변분 추론으로 직접** 학습. 역방향 함의: 어떤 가중 점수 매칭 = 랑주뱅식 샘플러의 변분 추론.

p.9 해설 — 결론, 사회적 영향, 참고문헌 시작

① **6절 결론** ⭐ — 확산 모델로 고품질 샘플. 확산 모델 ↔ (1) 마르코프 사슬 학습용 **변분 추론**, (2) **잡음 제거 점수 매칭**과 어닐링된 **랑주뱅 동역학**(나아가 에너지 기반 모델), (3) **자기회귀 모델**, (4) **점진적 손실 압축** 사이의 연결. 이미지에 훌륭한 귀납적 편향 → 다른 데이터 양식으로 확장 기대. → ✍️ 이 네 가지 연결을 마인드맵으로 그리고, 지난주 VAE를 (1) 옆에 붙이자.

② **사회적 영향 (Broader Impact)** ⭐ — 악용: 정치 목적의 유명인 **가짜 이미지·영상**. 현재 CNN 생성 이미지는 미세한 결함으로 탐지 가능하지만 점점 어려워질 것. 학습 데이터의 **편향**을 반영 — 인터넷에서 자동 수집된 무표지 데이터는 편향 제거가 어렵고, 생성물이 퍼지면 편향이 **강화**. 긍정: 데이터 **압축**, 표현 학습, 예술·사진·음악. → 🔎 이 단락 전체에 밑줄. ai_life 수업의 **AI 윤리** 토론 자료로 바로 쓸 수 있다 (Touretzky의 Big Idea 5와 연결).

③ **지원** — ONR PECASE, NSF, 구글 TPU.

④ **참고문헌 [1]-[7]** — GSN [1], infusion training [2], **BigGAN** [3], GAN=에너지 모델 [4], **Neural ODE** [5], PixelSNAIL [6], **Sparse Transformer** [7].

p.10 해설 — 참고문헌 [8]-[28]

주목할 참고문헌

번호	참고문헌	왜 볼까
[11]	Du & Mordatch (2019)	에너지 기반 모델의 이미지 생성 (표 1의 EBM)
[14]	**Goodfellow 외 (2014)**	**GAN** — 생성 모델의 대표
[18]	Gregor 외 (2016)	"개념적 압축" (p.7 그림 7의 해석)
[21]	**Heusel 외 (2017)**	**FID** 점수의 원 논문 (TTUR)
[22]	Higgins 외 (2017)	**β-VAE** — 가중 변분 경계의 선례
[27]	**Karras 외 (2018)**	**ProgressiveGAN** — LSUN 비교 기준

→ ✍️ [21]의 FID 정의를 찾아 한 줄로 메모: 인셉션 신경망 특징의 두 가우시안(실제/생성) 사이 프레셰 거리

$$\|\mu_r - \mu_g\|^2 + \mathrm{Tr}\left(\Sigma_r + \Sigma_g - 2(\Sigma_r\Sigma_g)^{1/2}\right)$$

→ ✍️ [22] β-VAE는 지난주 VAE 리뷰의 "다음에 읽을 논문"이었다. "가중 변분 경계"라는 공통점을 적어 두자.

p.11 해설 — 참고문헌 [29]-[50]

주목할 참고문헌

번호	참고문헌	왜 볼까
[29]	Karras 외 (2020) StyleGAN2 + ADA	표 1의 최강 GAN
[31]	**Kingma & Ba (2015) Adam**	이 논문의 옵티마이저 (지난주)
[33]	**Kingma & Welling (2013/2014) VAE**	변분 경계, 재매개변수화 (지난주) ⭐
[38]	Menick & Kalchbrenner (2019)	부분 척도 픽셀망 — 순서의 귀납적 편향
[43]	PixelIQN	표 1 비교
[47]	Rezende, Mohamed, Wierstra (2014)	VAE와 같은 시기의 확률적 역전파
[48]	**Ronneberger 외 (2015) U-Net**	역방향 신경망의 뼈대 ⭐
[49]	Salimans & Kingma (2016)	가중치 정규화 (그룹 정규화로 대체)

→ ✍️ [48] U-Net은 원래 **의료 영상 분할**용이었다. 왜 "잡음 제거"에도 잘 맞을까? (입력과 출력이 같은 크기의 이미지, 여러 해상도의 정보를 건너뛰기 연결로 합침) → ai_life **03 CNN**에 U-Net 그림(인코더-디코더 + 건너뛰기 연결)을 추가하면 좋겠다.

p.12 해설 — 참고문헌 [51]-[72]

주목할 참고문헌

번호	참고문헌	왜 볼까
[51]	Salimans 외 (2016)	**Inception Score** 의 출처
[52]	**Salimans 외 (2017) PixelCNN++**	U-Net 백본, 이산 로지스틱 디코더
[53]	**Sohl-Dickstein 외 (2015)**	**확산 모델의 원조** — "비평형 열역학을 이용한 심층 비지도 학습" ⭐⭐
[55]	**Song & Ermon (2019) NCSN**	데이터 분포의 **기울기(점수)** 추정 — ε 예측과 동치 ⭐
[56]	Song & Ermon (2020) NCSNv2	점수 기반 모델 개선
[60]	**Vaswani 외 (2017)**	사인파 위치 임베딩으로 시간 t 입력 (지난주)
[62]	Wang 외 (2020)	CNN 생성 이미지 **탐지** (사회적 영향)
[66]	Wu & He (2018)	그룹 정규화
[71]	Yu 외 (2015)	LSUN 데이터셋

→ ✍️ [53]의 제목에 "열역학"이 들어간 이유를 추측해 보자: 잉크 한 방울이 물에 퍼지는 **확산**은 되돌릴 수 없어 보이지만, 아주 작은 단계로 나누면 되돌리는 과정도 가우시안으로 근사할 수 있다.

p.13 해설 — 추가 정보와 부록 A: 식 (5) 유도 (1)

① 표 3 (LSUN FID)

모델	침실	교회	고양이
ProgressiveGAN	8.34	6.42	37.52
StyleGAN	2.65	4.21	8.53
Ours (L_{simple})	6.36	7.89	19.75
Ours (대형)	**4.90**	-	-

② 점진적 압축은 개념 증명 — 알고리즘 3·4는 최소 무작위 부호화가 필요한데 고차원에서 계산 불가 → 실용 압축 시스템이 아니라 식 (5)의 **압축 해석**.

③ 표 4 (전송률-왜곡, 그림 5 수치) — 역과정 시간 1000: 전송률 1.776, RMSE 0.95 / 900: 0.120, 12.0 / 500: 0.007, 38.0 / 100: 0.000, 67.6. → ✍️ 이 표에서 "마지막 100단계(900→1000)에 전송률의 대부분이 쓰이지만 RMSE는 12 → 0.95로만 준다"는 것을 확인하자. 눈에 안 보이는 세부에 비트가 몰린다!

④ 부록 A 시작 (식 17-21) — Sohl-Dickstein 외 [53]의 유도를 완결성을 위해 수록.

- (18): 로그 비율을 시간별로 분해
- (19): $t = 1$ 항을 분리
- (20) ⭐ : **베이즈 정리** $q(\mathbf{x}_t|\mathbf{x}_{t-1}) = q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0) = \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)q(\mathbf{x}_t|\mathbf{x}_0)}{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}$
- (21): $\frac{q(\mathbf{x}_t|\mathbf{x}_0)}{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}$들이 **망원**처럼 상쇄되어 $q(\mathbf{x}_T|\mathbf{x}_0)$만 남음 → 🔎 (20)의 베이즈 정리 적용에 밑줄 — 유도의 핵심 한 수.

p.14 해설 — 부록 A (2)와 부록 B 실험 세부

① **식 (22)** — (21)을 KL 발산으로 묶으면 식 (5) 완성: $L_T + \sum_{t>1} L_{t-1} + L_0$.

② **식 (23)-(26) 다른 형태** — 계산은 못 하지만 4.3절 논의용: 베이즈로 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$($\mathbf{x}_0$ **조건 없음**)을 쓰면

$$L = D_{KL}(q(\mathbf{x}_T)\|p(\mathbf{x}_T)) + \mathbb{E}_q\Big[\sum_{t\geq 1} D_{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t)\|p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))\Big] + H(\mathbf{x}_0)$$

→ ✍️ 식 (5)와 (26)의 차이를 한 줄로: 하나는 $\mathbf{x}_0$을 아는 사후분포, 하나는 모르는 진짜 역과정과 비교.

③ **부록 B 구조** ⭐ — PixelCNN++의 **U-Net**(Wide ResNet 기반), 가중치 정규화 → **그룹 정규화**. 32×32 모델은 해상도 4단계(32→4), 256×256은 6단계. 해상도마다 잔차 블록 2개, 16×16에서 **셀프 어텐션**. 시간 t는 **사인파 위치 임베딩**을 각 잔차 블록에 더함. 매개변수: CIFAR-10 **3,570만**, LSUN·CelebA-HQ **1억 1,400만**, 대형 침실 약 **2억 5,600만**.

④ **계산 비용** — TPU v3-8. CIFAR: 배치 128에서 초당 21스텝, **80만 스텝 10.6시간**, 256장 샘플링 17초. 256^2 모델: 128장 샘플링 **300초**. → 🔎 *300 seconds* 에 밑줄 — 1000단계 샘플링의 느림 (→ DDIM의 동기).

⑤ **하이퍼파라미터** — β_t: 상수/선형/2차 중 **선형**($10^{-4} \to 0.02$, $T = 1000$ 탐색 없이). CIFAR 드롭아웃 0.1 (없으면 PixelCNN++식 과적합 흔적). 좌우 뒤집기. **Adam** 학습률 2×10^{-4} (256^2는 2×10^{-5}).

p.15 해설 — 부록 B·C·D: 세부, NCSN과의 차이, 잠재 구조

① **나머지 설정** — 배치 128(CIFAR)/64. 모델 매개변수의 **EMA**(감쇠 0.9999). 한 번 학습, 학습 중 **최소 FID** 시점 보고. 5만 샘플로 IS/FID. → ✍️ 매개변수 EMA는 Adam의 m_t와 같은 지수이동평균이다 (Reddi 외 해설 참고). 무엇을 평균하는지가 다를 뿐.

② **부록 C: NCSN과의 차이** ⭐

1. U-Net + 셀프 어텐션 (NCSN은 RefineNet), 모든 층에 t 입력
2. 정방향마다 $\sqrt{1-\beta_t}$로 **축소** → 분산이 커지지 않음 (NCSN은 생략)
3. 정방향이 신호를 **완전히 파괴**($D_{KL} \approx 0$) + β_t가 매우 작음 → 샘플링 시 **분포 이동 방지**
4. 랑주뱅식 샘플러의 계수(학습률·잡음 크기)가 β_t에서 **엄밀히 유도** → 샘플러를 변분 추론으로 **직접** 학습 (NCSN은 사후에 손으로 설정) → 🔎 4번에 밑줄.

③ **부록 D: 잠재 구조와 확률성** — 사전분포와 랑주뱅 모두 확률적. 같은 중간 잠재 $\mathbf{x}_t (t \in \{1000, 750, 500, 250\})$에서 사슬을 **분기**: $\mathbf{x}_{1000}$에서 분기하면 전혀 다른 샘플, 더 진행 후 분기하면 **성별·머리색·안경·채도·자세·표정**을 공유 → $\mathbf{x}_{750}$ 같은 중간 잠재가 눈에 안 보여도 이 속성들을 **부호화**하고 있음.

④ **거친→세밀한 보간 (그림 9 설명)** — 보간 전 확산 단계를 늘리면 원본 구조가 더 많이 파괴되고 모델이 역과정에서 채워 넣음.

p.16 해설 — 그림 9·10: 보간과 점진적 샘플링 품질

① **보간 마무리** — 확산 0단계: **픽셀 공간**에서 섞기(두 사진 겹치기). 1000단계: 원본 정보 소실 → 보간이 **새 샘플**.

② **그림 9** ⭐ — 행: 1000, 875, ⋯, 125, 0단계. 열: 원본 | 재구성 | $\lambda = 0.1..0.9$ | 재구성 | 원본. → ✍️ 0단계 행과 500단계 행의 $\lambda = 0.5$ 이미지를 비교해 보자. 왜 0단계는 "유령처럼 겹친" 사진이고 500단계는 "자연스러운 중간 얼굴"일까?

③ **그림 10** — 비조건부 CIFAR-10 점진적 샘플링 품질: 역과정 단계($T - t$)에 따라 **IS는 증가, FID는 감소**. 대부분의 개선이 **후반부**에 일어남 (표 4와 일치). → 🔎 FID 곡선이 꺾이는 지점에 표시.

④ **핵심 메시지** — 확산 단계 수 = "얼마나 추상적인 수준에서 섞을지"의 조절 손잡이.

→ ✍️ ai_life **02 물체인식** 수업 아이디어: "사진에 잡음을 점점 더하면 AI(그리고 사람)가 언제 고양이를 못 알아보는가?" → 정방향 과정 체험 활동.

p.17 해설 — 그림 11: CelebA-HQ 생성 샘플

① **그림 11** — CelebA-HQ 256×256 생성 얼굴들 (선별하지 않은 샘플).

② **관찰 포인트**

- 피부 질감, 머리카락, 배경 흐림 등 **세부**까지 자연스러움
- 다양한 자세·나이·성별·조명 → **모드 붕괴**(GAN의 고질병: 비슷한 것만 생성)가 적음
- 귀걸이·안경 테두리 등 작은 물체에서 가끔 어색함

→ ✍️ 이 그림에서 "사람이 아님"을 알아챌 수 있는 단서를 3개 찾아보자 (Broader Impact의 "미세한 결함으로 탐지 가능"과 연결). → ✍️ 이 얼굴들은 실제로 존재하지 않는 사람들이다. 이런 이미지가 수업 자료나 SNS에서 쓰일 때 어떤 **윤리적 표시**가 필요할까?

③ **다음 쪽 예고** — 이 얼굴들이 학습 데이터를 **베낀 것**은 아닌지 확인하는 최근접 이웃 실험.

p.18 해설 — 그림 12: 최근접 이웃 (CelebA-HQ)

① **그림 12** ⭐ — 생성 샘플(맨 왼쪽 열)과 학습 집합에서 가장 가까운 이미지들(나머지 열). 얼굴 주변 100×100 영역에서 계산.

- (a) **픽셀 공간** 최근접 이웃
- (b) **인셉션 특징 공간** 최근접 이웃

② **왜 이 실험을 하나** — 생성 모델이 학습 데이터를 **외워서 그대로 내놓는지**(암기·표절) 확인. 최근접 이웃이 생성 샘플과 **다르다면** 새 이미지를 만든 것. → 🔎 *nearest neighbors* 에 밑줄 — 본문 4.3의 "과적합 아님" 주장의 시각적 근거.

③ **두 거리의 차이** — 픽셀 거리는 밝기·배경색이 비슷한 이미지를, 인셉션 특징 거리는 **의미적으로** 비슷한(표정·자세) 이미지를 찾는다.

→ ✍️ 이번 주 Nakkiran(이중 하강)과 지난주 Zhang(외우기) 관점에서, "모델이 데이터를 외우는가?"를 생성 모델에선 어떻게 판정하는지 비교해 보자. → ✍️ 저작권 관점: 학습 데이터와 아주 비슷한 이미지가 생성된다면 어떤 문제가 생길까?

p.19 해설 — 그림 13: CIFAR-10 생성 샘플

① **그림 13** — 비조건부 CIFAR-10 생성 샘플 (32×32, 클래스 정보 없이 생성).

② **관찰 포인트**

- CIFAR-10의 10개 클래스(비행기·자동차·새·고양이·사슴·개·개구리·말·배·트럭)가 고루 나타나는지
- 32×32 저해상도에서도 물체의 **형태와 배경**이 일관됨
- 이 샘플들의 FID가 **3.17**

→ ✍️ 샘플 중 무작위로 20개를 골라 사람이 클래스를 맞혀 보자. 몇 개가 "무엇인지 알 수 없음"인가? 이것이 IS(인셉션 점수)가 재려는 것이다 — 분류기가 **확신 있게**, 그리고 **다양하게** 분류할수록 높다. → ai_life **02 물체인식**: 학생들이 직접 만든 분류기로 이 생성 이미지들을 분류해 보는 활동.

③ **IS 정의 메모**

$$\mathrm{IS} = \exp\left(\mathbb{E}_{\mathbf{x}}\left[D_{KL}(p(y|\mathbf{x}) \,\|\, p(y))\right]\right)$$

개별 이미지는 확신($p(y|\mathbf{x})$ 뾰족), 전체는 다양($p(y)$ 평평)할수록 큼.

p.20 해설 — 그림 14: CIFAR-10 점진적 생성

① **그림 14** ⭐ — 비조건부 CIFAR-10 **점진적 생성**: 각 행은 하나의 샘플, 왼쪽→오른쪽으로 역과정이 진행되며 중간 예측 $\hat{\mathbf{x}}_0$(식 15)를 표시.

② **관찰** — 처음엔 흐릿한 **색 덩어리**(전체 구도) → 중간에 **물체 윤곽** → 마지막에 **질감과 세부**. → 🔎 "큰 구조 먼저, 세부 나중"을 이 그림에서 직접 확인하고 몇 번째 열에서 물체를 알아볼 수 있는지 표시.

③ **연결** — 그림 10(IS/FID가 후반에 개선) + 표 4(후반에 전송률 집중)와 같은 이야기를 **눈으로** 보여 줌.

→ ✍️ 이 과정을 화가의 작업에 비유해 보자: 밑그림(구도) → 채색(형태) → 세부 묘사. 확산 모델이 "화가처럼" 그린다고 할 수 있을까? → ✍️ 반대로 정방향 과정(잡음 추가)에선 **무엇이 먼저 사라지는가**? 세부(고주파)가 먼저, 큰 구조(저주파)가 나중 — 역과정이 그 반대 순서인 이유를 설명해 보자.

p.21 해설 — 그림 15: 최근접 이웃 (CIFAR-10)

① **그림 15** — 비조건부 CIFAR-10 생성 샘플(맨 왼쪽 열)과 학습 집합 최근접 이웃.

- (a) **픽셀 공간**
- (b) **인셉션 특징 공간**

② **의미** — 생성 샘플이 학습 이미지의 **복사본이 아님**을 확인. CIFAR-10은 5만 장뿐이고 모델은 3,570만 매개변수 — 외우기에 충분한 용량인데도 새로운 이미지를 만든다. → 🔎 매개변수(3,570만) vs 데이터(5만 장 × 3,072 픽셀 ≈ 1.5억 값)의 규모를 비교해 메모.

→ ✍️ Nakkiran(이번 주)의 용어로: 이 확산 모델은 과대 매개변수 영역인가? 그런데도 일반화(새 샘플 생성)가 잘 되는 이유는? (힌트: 잡음을 더한 $\mathbf{x}_t$는 매번 달라서 사실상 무한한 학습 데이터, 드롭아웃 0.1) → ✍️ 학습/시험 부호 길이 차이 ≤ 0.03 bits/dim (p.6)과 이 그림을 함께 근거로 "과적합이 아니다"를 주장하는 문단을 써 보자.

p.22 해설 — 그림 16: LSUN 교회 샘플

① **그림 16** — LSUN 교회 256×256 생성 샘플, **FID 7.89**.

② **관찰 포인트**

- 첨탑·창문·지붕선 같은 **기하학적 구조**의 일관성
- 하늘·나무·잔디 등 배경의 자연스러움
- 비교: ProgressiveGAN 6.42, StyleGAN 4.21 (표 3) — 확산 모델이 이 데이터셋에선 GAN보다 다소 뒤짐

→ ✍️ 건물처럼 **직선과 대칭**이 많은 이미지는 생성 모델에게 왜 어려울까? 그림에서 휘어진 직선이나 비대칭 창문을 찾아보자. → ✍️ 같은 모델 구조(U-Net)로 얼굴·침실·교회·고양이를 모두 생성한다는 점은 Touretzky의 "AI는 데이터로부터 배운다"(Big Idea 3)를 어떻게 보여 주는가?

③ **한 줄 정리** — 확산 모델은 "얼굴"만이 아니라 복잡한 **장면**도 생성할 수 있다.

p.23 해설 — 그림 17: LSUN 침실 (대형 모델)

① **그림 17** — LSUN 침실 256×256, **대형 모델**(약 2억 5,600만 매개변수, 115만 스텝), **FID 4.90**.

② **관찰 포인트**

- 침대·창문·조명·커튼의 배치가 그럴듯함
- 빛과 그림자, 침구의 주름 같은 **질감**
- ProgressiveGAN(8.34)보다 좋고 StyleGAN(2.65)보다는 뒤짐

③ **모델 크기 효과** — 소형(1억 1,400만, FID 6.36, 다음 쪽) → 대형(2억 5,600만, FID 4.90): **필터 수만 늘려서** 개선. → 🔎 FID 4.90에 밑줄.

→ ✍️ 이번 주 Nakkiran의 "큰 모델이 좋다 / 나쁘다" 논의를 떠올리자. 이 실험은 어느 영역(과소/임계/과대)에서의 결과로 보이는가? → ✍️ 다음 쪽(소형 모델)과 같은 위치의 샘플을 비교하며 차이를 3가지 적어 보자.

p.24 해설 — 그림 18: LSUN 침실 (소형 모델)

① **그림 18** — LSUN 침실 256×256, **소형 모델**(1억 1,400만 매개변수, 240만 스텝), **FID 6.36**.

② 대형 모델과 비교

	소형	대형
매개변수	1억 1,400만	약 2억 5,600만
학습 스텝	240만	115만
FID	6.36	**4.90**
→ 더 적은 스텝으로도 큰 모델이 더 좋음.		

→ ✍️ "학습을 오래 하는 것"과 "모델을 키우는 것" 중 어느 쪽이 더 효율적이었나? 이 결과는 오늘날 **스케일링 법칙** 연구(모델·데이터·계산량의 관계)의 문제의식과 연결된다. → ✍️ 지난주 ResNet(He 외 2016)은 "깊게 쌓는 것"을 가능하게 했다. 이 U-Net에도 잔차 블록이 쓰인다(부록 B). 잔차 연결이 큰 모델 학습에 왜 중요할까?

p.25 해설 — 그림 19: LSUN 고양이, 전체 정리

① **그림 19** — LSUN 고양이 256×256, **FID 19.75** (StyleGAN2 6.93보다 크게 뒤짐). 자세·배경이 매우 다양한 데이터라 가장 어려움 — 다리 개수나 몸 형태가 어색한 샘플을 찾아보자.

✍️ 논문 전체 정리 질문

1. 정방향 과정 식 (2)에서 식 (4)를 유도하고, 재매개변수화 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\boldsymbol{\epsilon}$ 를 외우자.
2. 변분 경계 식 (5)의 세 항 L_T, L_{t-1}, L_0이 각각 무엇을 비교하는지, 왜 L_T는 무시할 수 있는지 설명하자.
3. "$\tilde{\boldsymbol{\mu}}$ 예측 → ε 예측 → 가중치 제거(L_{simple})"의 세 단계를 한 문장씩.
4. 알고리즘 1·2를 보지 않고 써 보자. 지난주 VAE의 학습 알고리즘과 무엇이 같고 다른가?
5. 확산 모델이 연결하는 네 가지(변분 추론, 점수 매칭·랑주뱅, 자기회귀, 손실 압축)를 마인드맵으로.
6. ai_life **02/03 단원**에 "잡음 더하기 ↔ 잡음 빼기" 체험 활동을 넣는다면, 고등학생에게 $\boldsymbol{\epsilon}$ 예측을 어떻게 설명할까?