KAN: 콜모고로프-아놀드 네트워크

> 원제: *KAN: Kolmogorov-Arnold Networks*

항목	내용
저자	Ziming Liu (MIT), Yixuan Wang (칼텍), Sachin Vaidya (MIT), Fabian Ruehle (노스이스턴대), James Halverson (노스이스턴대), Marin Soljačić (MIT), Thomas Y. Hou (칼텍), Max Tegmark (MIT) — NSF AI·기초상호작용연구소(IAIFI)
학회	ICLR 2025 (arXiv 2024.4 최초 공개, v5 2025.2)
분야	딥러닝 · 신경망 구조 · 근사 이론 · 해석 가능 AI · AI for Science
난이도	★★★☆☆ (본문) / ★★★★☆ (근사 이론)
링크	https://arxiv.org/abs/2404.19756 · 코드 https://github.com/KindXiaoming/pykan (`pip install pykan`)
PDF 원문	arXiv PDF (무료) — 50쪽 (본문 33 + 참고문헌 8 + 부록·그림 9)
ai_life 연결 단원	01 선형회귀(스플라인 = 구간별 다항식 회귀), 03 CNN(MLP 대안), 전 단원의 "AI가 찾은 공식" 활동

한 줄 요약

MLP는 '노드'에 고정된 활성화 함수를 두고 '엣지'의 선형 가중치를 학습하지만, KAN은 거꾸로 '엣지'마다 학습 가능한 1변수 함수(B-스플라인)를 두고 노드는 더하기만 한다 — 콜모고로프-아놀드 표현 정리에서 영감을 받은 이 구조는 작은 과학 문제에서 더 정확하고, 무엇보다 학습된 함수를 '눈으로 읽어' 수식을 찾을 수 있다.

왜 중요한가

지난주 Cybenko(1989), 이번 주 Hornik(1989)은 **보편 근사 정리(UAT)** 로 MLP를 정당화했습니다. Hornik 논문 서론이 "함수마다 다른 미지의 변환이 필요해 실용성이 없다"고 밀어냈던 **콜모고로프(1957) 중첩 정리**를, 35년 뒤 이 논문이 **깊이와 폭을 일반화**하고 **역전파로 학습**하여 되살렸습니다. 공개 직후 수백 편의 후속 연구를 낳은 최근 논문으로, (1) 근사 이론(차원의 저주를 피하는 스케일링 $\ell \propto N^{-4}$), (2) 해석 가능성(학습된 활성화 함수 → 기호 수식), (3) AI-과학자 협업(매듭 이론·앤더슨 국소화 재발견)을 한 번에 보여 줍니다. 수학을 좋아하는 학생에게 "AI가 공식을 찾아 준다"는 체험을 줄 수 있는 좋은 소재입니다.

핵심 내용

1. 두 정리의 대비 (그림 0.1)

	MLP	KAN
정리	보편 근사 정리	콜모고로프-아놀드 표현 정리
얕은 식	$f(\mathbf{x}) \approx \sum_{i=1}^{N(\epsilon)} a_i \sigma(\mathbf{w}_i \cdot \mathbf{x} + b_i)$	$f(\mathbf{x}) = \sum_{q=1}^{2n+1} \Phi_q\big(\sum_{p=1}^{n} \phi_{q,p}(x_p)\big)$
노드	고정 활성화 σ	더하기만
엣지	학습 가능한 **수(가중치)**	학습 가능한 **함수**
깊은 식	$W_3 \circ \sigma \circ W_2 \circ \sigma \circ W_1$	$\Phi_3 \circ \Phi_2 \circ \Phi_1$

2. 콜모고로프-아놀드 정리 (식 2.1)

$[0,1]^n$ 위의 연속함수는 **1변수 연속함수들과 덧셈**만으로 정확히 표현된다 — "진짜 다변수 함수는 덧셈뿐". 하지만 내부 함수가 **매끄럽지 않거나 프랙털**일 수 있어 기계학습에선 "이론적으로만 옳고 실용성 없다"고 여겨졌다.

3. KAN 층과 깊은 KAN (식 2.2-2.7)

KAN 층 = **1변수 함수의 행렬** $\Phi = \{\phi_{q,p}\}$. 원래 정리는 $[n, 2n+1, 1]$ 모양의 2층 KAN. 층을 쌓으면 깊은 KAN:

$$x_{l+1,j} = \sum_{i=1}^{n_l} \phi_{l,j,i}(x_{l,i}), \qquad \mathrm{KAN}(\mathbf{x}) = (\Phi_{L-1} \circ \cdots \circ \Phi_0)\mathbf{x}$$

각 활성화: $\phi(x) = w_b\,\mathrm{silu}(x) + w_s \sum_i c_i B_i(x)$ (잔차 기저 + B-스플라인).

4. 근사 이론 (정리 2.1, KAT) ⭐

f가 매끄러운 KA 표현을 가지면, 격자 크기 G의 k차 B-스플라인으로

$$\|f - (\Phi_{L-1}^{G} \circ \cdots \circ \Phi_0^{G})\mathbf{x}\|_{C^m} \le C\, G^{-k-1+m}$$

→ 오차율이 **입력 차원과 무관** = 차원의 저주를 피함. 스케일링 지수 $\alpha = k+1 = 4$ (3차 스플라인) — 기존 이론($\alpha = (k+1)/d$ 등)보다 크다.

5. 정확도와 해석 가능성의 도구

- **격자 확장**: 작은 KAN을 학습한 뒤 스플라인 격자만 촘촘히 → 처음부터 재학습 없이 키우기 (계단식 손실 곡선)
- **희소화**(L1 + 엔트로피) → **가지치기** → **기호화**(`fix_symbolic`) → 수식 출력. 예: $\exp(\sin(\pi x) + y^2)$ 를 데이터만으로 복원
- 외부 자유도(연결 구조, MLP처럼) + 내부 자유도(1변수 함수, 스플라인처럼)

6. 결과

- 장난감·특수함수·파인만 방정식·편미분방정식에서 같은 매개변수 수 대비 더 낮은 오차 (파레토 프런티어)

- 포아송 방정식: 2층 폭 10 KAN이 4층 폭 100 MLP보다 **100배 정확**, **100배 적은 매개변수**
- 스플라인의 **국소성** → 연속 학습에서 파국적 망각 회피 (장난감 예)
- 매듭 이론: DeepMind의 $[3 \times 10^5]$ 매개변수 MLP(78%) 대신 ≈ 200개 매개변수 KAN(81.6%)
- 앤더슨 국소화의 이동도 경계(mobility edge) 공식 재발견

7. 한계 (저자 스스로)

같은 매개변수 수에서 **학습이 약 10배 느림**, 대규모(언어 모델 등)에서의 효과는 미검증, 깊은 KA 표현의 수학적 이론은 미완. "빨리 학습해야 하면 MLP, 해석 가능성·정확도가 중요하고 작은 과학 문제면 KAN" (그림 6.1).

읽는 순서 가이드

1. **p.1-3 초록·그림 0.1·서론** - MLP vs KAN 표 만들기 (20분)
2. **p.3-6 2.1-2.2절** - 정리 2.1, KAN 층 정의 ⭐ (40분)
3. **p.7-8 정리 2.1(KAT)·스케일링 법칙** (30분)
4. **p.9-13 격자 확장·단순화·Alice 예제** - pykan으로 직접 따라 하기 (40분)
5. **p.14-19 3절 실험** - 그림 3.1만 꼼꼼히, 나머지는 훑기 (20분)
6. **p.20-30 4절 과학 응용** - 4.1(그림 4.1)과 4.3(매듭) 중심 (30분)
7. **p.31-33 토론·그림 6.1** (15분)

사전 지식 체크

- [ ] Cybenko(1989)·Hornik(1989) 보편 근사 정리
- [ ] 스플라인, B-스플라인 기저 (구간별 다항식)
- [ ] 함수 합성, MLP 구조
- [ ] L1 정규화, 엔트로피
- [ ] 차원의 저주, 스케일링 법칙 $\ell \propto N^{-\alpha}$

생각해볼 질문

1. Hornik 논문은 콜모고로프 정리를 "함수마다 다른 미지의 변환이 필요하다"는 이유로 실용적이지 않다고 했다. KAN은 이 비판에 어떻게 답하는가?
2. $xy = \frac{(x+y)^2-(x-y)^2}{4}$ 를 이용해 곱셈을 $[2, 2, 1]$ KAN으로 손으로 그려 보자. 각 엣지에는 어떤 1변수 함수가 놓이나?
3. 상대론적 속도 합성 $\frac{u+v}{1+uv} = \tanh(\operatorname{arctanh} u + \operatorname{arctanh} v)$ 가 왜 **2층** KAN으로 충분한가? KAN이 "rapidity" 개념을 스스로 발견할 수 있다는 것은 과학 교육에 어떤 의미가 있을까?
4. 학습이 10배 느린데도 쓸 가치가 있는 상황은? ai_life 수업에서는?

용어 정리

영어	한국어
Kolmogorov-Arnold representation theorem	콜모고로프-아놀드 표현 정리
universal approximation theorem (UAT)	보편 근사 정리
learnable activation on edges	엣지 위의 학습 가능한 활성화
B-spline	B-스플라인
grid extension	격자 확장
curse of dimensionality (COD)	차원의 저주
neural scaling law	신경망 스케일링 법칙
sparsification / pruning	희소화 / 가지치기
symbolic regression	기호 회귀
catastrophic forgetting	파국적 망각
interpretability	해석 가능성

다음에 이어 읽을 논문

- Liu 외 (2024), *KAN 2.0: Kolmogorov-Arnold Networks Meet Science* (arXiv 2408.10205) — 같은 팀의 후속
- Schmidt-Hieber (2021), *The Kolmogorov-Arnold representation theorem revisited* (Neural Networks) — 정리의 현대적 재검토

✍️ 나의 메모