p.1 해설 — 초록과 그림 0.1: MLP를 뒤집다

① **초록** ⭐ — **콜모고로프-아놀드 표현 정리**에서 영감을 받은 **KAN**을 MLP의 대안으로 제안. MLP는 **노드**("뉴런")에 **고정** 활성화, KAN은 **엣지**("가중치")에 **학습 가능한** 활성화. KAN엔 **선형 가중치가 전혀 없다** — 모든 가중치가 **스플라인**으로 매개변수화된 1변수 함수로 대체. → 🔎 *learnable activation functions on edges* 와 *no linear weights at all* 에 밑줄.

② **주장** — 작은 규모 AI+과학 과제에서 **정확도**와 **해석 가능성** 모두 MLP보다 우수. 작은 KAN이 큰 MLP와 비슷하거나 더 정확, 더 빠른 **신경 스케일링 법칙**. 수학·물리의 두 예에서 과학자의 "협력자"로 법칙을 (재)발견.

③ **그림 0.1** ⭐⭐

	MLP	KAN
정리	보편 근사 정리	콜모고로프-아놀드 정리
얕은 식	$\sum_{i=1}^{N(\epsilon)} a_i \sigma(\mathbf{w}_i \cdot \mathbf{x} + b_i)$	$\sum_{q=1}^{2n+1} \Phi_q\left(\sum_{p=1}^{n} \phi_{q,p}(x_p)\right)$
깊은 식	$(W_3 \circ \sigma_2 \circ W_2 \circ \sigma_1 \circ W_1)(\mathbf{x})$	$(\Phi_3 \circ \Phi_2 \circ \Phi_1)(\mathbf{x})$
→ ✍️ 왼쪽 식은 지난주 Cybenko 식 (1)과 같다! 오른쪽과 나란히 노트에 옮겨 적자.		

④ **소속·학회** — MIT, 칼텍, 노스이스턴대, NSF IAIFI. **ICLR 2025** 채택.

p.2 해설 — 서론: MLP는 최선인가?

① **MLP의 지위** — 보편 근사 정리 덕분에 비선형 함수 근사의 기본 모델. 하지만 **트랜스포머**에서 MLP가 임베딩 외 매개변수의 거의 전부를 차지하면서 (어텐션보다) **해석하기 어렵다**.

② **KAN의 아이디어** — MLP처럼 완전연결 구조. 차이: 활성화가 **엣지**에, 학습 가능, 스플라인. 노드는 들어온 신호를 **더하기만**. "비싸지 않을까?" → 보통 KAN은 **훨씬 작은** 계산 그래프로 충분.

③ **선행 연구** — 콜모고로프 정리로 신경망을 만드는 연구는 있었지만 대부분 **깊이 2, 폭** $2n+1$ 에 머물렀고 역전파 같은 현대 기법을 못 썼다. 이 논문의 기여: **임의의 폭과 깊이**로 일반화 + 현대 딥러닝 맥락에서 부활 + AI+과학 실험.

④ **핵심 직관** ⭐ — KAN = **스플라인과 MLP의 결합**.

	장점	약점
스플라인	저차원에서 정확, 국소 조정, 해상도 전환	**차원의 저주** (합성 구조 활용 불가)
MLP	특징 학습으로 차원의 저주 완화	1변수 함수 최적화가 부정확
KAN은 "**바깥은 MLP, 안은 스플라인**" → 합성 구조(외부 자유도)와 1변수 함수(내부 자유도)를 모두 학습.		
→ 🔎 *MLPs on the outside and splines on the inside* 에 밑줄.		

⑤ **예 (식 1.1)** — $f = \exp\left(\frac{1}{N}\sum_{i=1}^{N}\sin^2(x_i)\right)$. → ✍️ 이 함수를 "1변수 함수 + 덧셈 + 1변수 함수"로 분해해 보자: 안쪽 $\sin^2(x_i)$, 덧셈, 바깥 $\exp(\cdot/N)$.

p.3 해설 — 논문 구성과 콜모고로프-아놀드 정리

① **그림 2.1** — 두 위대한 수학자 **안드레이 콜모고로프**와 **블라디미르 아놀드**에게 헌정. "수학적으로 탄탄, 정확, 해석 가능".

② **식 1.1의 교훈** — 스플라인은 N이 크면 차원의 저주로 실패, ReLU MLP는 지수·사인 근사가 비효율적, KAN은 둘 다 잘 함 (그림 3.1).

③ **구성** — 2절: 구조·수학적 기초·단순화·격자 확장 / 3절: 정확도(데이터 적합, 스케일링, 편미분방정식) / 4절: 해석 가능성과 과학적 발견(매듭 이론, 앤더슨 국소화) / 5절: 관련 연구 / 6절: 토론. 코드: `pip install pykan`. → ✍️ 집에서 pykan을 설치하고 README의 첫 예제를 돌려 보자.

④ **2절 도입** — MLP는 보편 근사 정리, KAN은 **콜모고로프-아놀드 정리**에서 출발. 2.1 정리 복습 → 2.2 구조 → 2.3 표현력·스케일링 → 2.4 격자 확장 → 2.5 단순화.

⑤ **2.1 정리 시작** ⭐ — 아놀드와 콜모고로프: 유계 영역 위의 다변수 연속함수 f는 **1변수 연속함수들의 유한 합성**과 **덧셈**이라는 이항 연산으로 쓸 수 있다. → 🔎 이 문장에 밑줄 — 힐베르트 13번째 문제의 해결 (지난주 Cybenko 해설 p.304 참고).

p.4 해설 — 정리의 내용과 "사형 선고", 그리고 낙관

① **그림 2.2** — 왼쪽: 신경망을 흐르는 활성화의 기호. 오른쪽: 활성화 함수를 **B-스플라인**으로 매개변수화 → 거친 격자 ↔ 촘촘한 격자 전환.

② **식 (2.1)** ⭐⭐ — 매끄러운 $f : [0,1]^n \to \mathbb{R}$에 대해

$$f(\mathbf{x}) = f(x_1, \ldots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \Big(\sum_{p=1}^{n} \phi_{q,p}(x_p) \Big)$$

$\phi_{q,p} : [0,1] \to \mathbb{R}$, $\Phi_q : \mathbb{R} \to \mathbb{R}$. "**진짜 다변수 함수는 덧셈뿐**". → 🔎 크게 밑줄. $n = 2$이면 안쪽 함수 $2 \times 5 = 10$개, 바깥 함수 5개.

③ **사형 선고** — 고차원 함수 학습 = 다항식 개수의 1D 함수 학습? 하지만 이 1D 함수들이 **매끄럽지 않거나 프랙털**일 수 있어 실제로 학습 불가 → "이론적으로 옳지만 실용적으로 쓸모없다"(Poggio, Girosi).

④ **저자들의 낙관** ⭐ — (1) 원래 식의 2층·$2n+1$에 얽매일 필요 없음 → **임의 폭·깊이**로 일반화. (2) 과학과 일상의 함수는 대개 **매끄럽고 희소한 합성 구조**를 가진다. 최악보다 **전형적** 경우를 보는 물리학자의 사고방식.

⑤ **2.2 KAN 구조** — 식 (2.1)을 명시적으로 매개변수화한 신경망. 각 1D 함수를 **B-스플라인 곡선**(국소 기저함수의 학습 가능한 계수)으로 → 2층, 중간 폭 $2n+1$, 활성화가 엣지에, 노드는 덧셈.

p.5 해설 — KAN 층의 정의와 깊은 KAN

① **원형의 한계** — 2층 KAN은 매끄러운 스플라인으로 임의 함수를 근사하기엔 **너무 단순**. 더 넓고 깊게! 그런데 깊은 KA 정리의 "일반화판"은 (저자들이 아는 한) 아직 없다.

② **돌파구: MLP와의 유비** ⭐ — MLP는 층(선형 변환 + 비선형)을 정의하면 쌓을 수 있다. 그렇다면 "**KAN 층이란 무엇인가?**" → 1D 함수의 행렬:

$$\Phi = \{\phi_{q,p}\}, \quad p = 1..n_{in},\ q = 1..n_{out} \qquad (2.2)$$

원래 정리 = 안쪽 층($n \to 2n+1$) + 바깥 층($2n+1 \to 1$)의 **합성**. 더 깊게 = 그냥 **KAN 층을 더 쌓기**! → 🔎 *simply stack more KAN layers!* 에 밑줄.

③ **기호** — 모양 $[n_0, n_1, \ldots, n_L]$ (2.3). 층 l과 $l+1$ 사이에 $n_l n_{l+1}$개의 활성화 $\phi_{l,j,i}$ (2.4).

④ **순전파 (2.5)** ⭐

$$x_{l+1,j} = \sum_{i=1}^{n_l} \tilde{x}_{l,j,i} = \sum_{i=1}^{n_l} \phi_{l,j,i}(x_{l,i})$$

⑤ **행렬 형태 (2.6)-(2.7)** — $\mathbf{x}_{l+1} = \Phi_l \mathbf{x}_l$ (함수 행렬을 "곱한다"는 것은 각 성분에 함수를 적용 후 행별로 더하기). $\mathrm{KAN}(\mathbf{x}) = (\Phi_{L-1} \circ \cdots \circ \Phi_0)\mathbf{x}$. → ✍️ $[2,3,1]$ KAN을 그리고 엣지 6+3=9개에 ϕ 이름을 붙여 보자. MLP $[2,3,1]$의 가중치 9개와 같은 자리!

p.6 해설 — 구현 요령: 잔차 활성화, 초기화, 격자 갱신

① **식 (2.8)** — 출력이 1차원일 때 펼쳐 쓴 식 (중첩 합 L겹) — 번거로우므로 층 추상화가 더 깔끔. 원래 정리 = $[n, 2n+1, 1]$ 모양의 2층 KAN. 모든 연산이 **미분 가능** → 역전파로 학습.

② **MLP 비교 (2.9)** — $\mathrm{MLP}(\mathbf{x}) = (W_{L-1} \circ \sigma \circ \cdots \circ \sigma \circ W_0)\mathbf{x}$. MLP는 선형 W와 비선형 σ를 **분리**, KAN은 Φ 하나로 **합침**. → 🔎 이 대비 문장에 밑줄.

③ **요령 1: 잔차 활성화** ⭐

$$\phi(x) = w_b\, b(x) + w_s\, \mathrm{spline}(x), \quad b(x) = \mathrm{silu}(x) = \frac{x}{1+e^{-x}}, \quad \mathrm{spline}(x) = \sum_i c_i B_i(x)$$

$b(x)$는 ResNet의 **잔차 연결**과 비슷한 역할. w_b, w_s는 중복이지만 크기 조절용.

④ **요령 2: 초기화** — $w_s = 1$, $\mathrm{spline} \approx 0$ ($c_i \sim \mathcal{N}(0, 0.1^2)$), w_b는 **자비에 초기화**.

⑤ **요령 3: 격자 갱신** — 스플라인은 유계 구간에서만 정의되는데 학습 중 활성화 값이 밖으로 나갈 수 있음 → 입력 활성화에 맞춰 격자를 **즉석 갱신**.

→ ✍️ silu를 그려 보자. ReLU와 무엇이 다른가? (매끄럽고, 음수에서 살짝 내려갔다 0으로) → ai_life **01 선형회귀**: $\sum c_i B_i(x)$ 는 "기저함수들의 선형결합" — 다항식 회귀 $\sum a_i x^i$ 와 같은 구조!

p.7 해설 — 매개변수 수와 근사 이론 (정리 2.1)

① **매개변수 수** ⭐ — 깊이 L, 폭 N, k차 스플라인($k=3$), 격자 G구간:

$$\text{KAN: } O(N^2L(G+k)) \sim O(N^2LG), \qquad \text{MLP: } O(N^2L)$$

KAN이 더 비싸 보이지만 보통 **훨씬 작은** N 으로 충분 → 매개변수 절약 + 일반화 + 해석. 1D 문제에서 $N=L=1$ KAN = 그냥 스플라인 근사.

② **2.3 매끄러움과 깊이** — 2층 $2n+1$ 표현은 매끄럽지 않을 수 있지만 **깊은** 표현은 매끄러울 수 있다. 예:

$$f(x_1,x_2,x_3,x_4)=\exp\left(\sin(x_1^2+x_2^2)+\sin(x_3^2+x_4^2)\right) \quad (2.13)$$

→ $[4,2,1,1]$ (3층) KAN으로 매끄럽게 표현, 2층으로는 아닐 수도. → ✍️ 각 층에 어떤 1D 함수가 놓이는지 적어 보자: 1층 x_i^2, 2층 $\sin$, 3층 $\exp$.

③ **정리 2.1 (KAT)** ⭐⭐ — $f=(\Phi_{L-1}\circ\cdots\circ\Phi_0)\mathbf{x}$ 이고 각 $\Phi_{l,i,j}$가 $(k+1)$번 연속 미분 가능하면, k차 B-스플라인 $\Phi_{l,i,j}^G$가 존재하여 $0\le m\le k$에 대해

$$\|f-(\Phi_{L-1}^G\circ\cdots\circ\Phi_0^G)\mathbf{x}\|_{C^m}\le C\,G^{-k-1+m} \quad (2.15)$$

$\|g\|_{C^m}$ = m계까지 도함수 크기의 최댓값. → 🔎 (2.15)에 크게 밑줄.

④ **증명 시작** — 고전 1D B-스플라인 이론(de Boor) + 유계 영역에서 연속함수의 균등 유계성 → 각 층을 하나씩 스플라인으로 바꿀 때 오차 $\le CG^{-k-1+m}$. 잔차 R_l 정의.

p.8 해설 — 차원의 저주를 피하다, 스케일링 법칙 비교

① **증명 완성** — $f - (\Phi^G$들의 합성$) = R_{L-1} + \cdots + R_0$ (**망원 합**), 각 $\|R_l\| \le CG^{-k-1+m}$ → (2.15).

② **의미** ⭐ — 오차율이 **입력 차원과 무관** → **차원의 저주를 이긴다**! 1D 함수만 스플라인으로 근사하므로 당연. $m = 0$이면 L^∞ 정확도 → RMSE 스케일링 지수 $k + 1$. 단 상수 C는 표현(따라서 차원)에 의존 — 미래 과제.

③ **신경 스케일링 법칙** — $\ell \propto N^{-\alpha}$ (ℓ: 테스트 RMSE, N: 매개변수 수).

이론	α
Sharma & Kaplan (고유 차원 d)	$(k+1)/d$ — 차원의 저주
Michaud 외 (최대 인자 수 2)	$(k+1)/2$
Poggio 외 (합성 희소성)	$m/2$
KAN (매끄러운 KA 표현)	$k + 1 = 4$ (3차 스플라인)
→ 🔎 *α = 4 which is the largest and best scaling exponent* 에 밑줄.	

④ **KAT vs UAT** ⭐ — UAT: 오차 ϵ을 위해 뉴런 $N(\epsilon)$개면 된다지만 $N(\epsilon)$이 어떻게 커지는지 **보장 없음**, 경우에 따라 d에 대해 **지수적**. (지난주 Cybenko 마지막 쪽 "천문학적인 수의 항", Hornik p.364 "남은 과제"와 연결!) → ✍️
$\alpha = 4$이면 매개변수를 2배로 할 때 오차는 몇 분의 1? ($2^{-4} = 1/16$) MLP의 $\alpha = 1$이면? ($1/2$)

p.9 해설 — 격자 확장 (그림 2.3)

① **그림 2.3** ⭐ — $f(x, y) = \exp(\sin(\pi x) + y^2)$ 적합.

- 위 왼쪽 $[2, 5, 1]$ / 위 오른쪽 $[2, 1, 1]$ KAN의 학습 동역학: 격자를 늘릴 때마다 손실이 **뚝 떨어졌다가 정체** → **계단** 모양
- 아래 왼쪽: 테스트 RMSE가 격자 크기 G에 대해 **스케일링 법칙**
- 아래 오른쪽: 학습 시간이 G에 대해 완만히 증가 → 🔎 "interpolation threshold" 표시선에 주목 — 이번 주 Nakkiran의 **보간 임계점**과 같은 개념!

② **KAT와 UAT의 차이의 원인** — KAN은 함수의 **본질적으로 저차원인 표현**을 활용, MLP는 아님. 소볼레프·베소프 같은 일반 함수공간에선 비선형 n-폭 이론상 차원의 저주를 **절대** 못 이김 → 그래서 **합성 구조**를 가진 "착한" 함수에 집중.

③ **2.4 격자 확장 (정확도를 위해)** — 스플라인은 격자를 촘촘히 할수록 임의로 정확. MLP엔 "세밀화" 개념이 없다 — 폭·깊이를 키우면 좋아지지만 스케일링이 **느리고**, 크기마다 **따로 학습**해야 해서 비쌈. KAN은 작은 것을 학습한 뒤 **격자만 촘촘히** → 처음부터 재학습 불필요. → ✍️ 사진 해상도 올리기에 비유해 보자: 저해상도 그림을 먼저 그리고 픽셀을 쪼개 세부를 다듬기.

p.10 해설 — 격자 확장의 방법과 장난감 예

① **방법** ⭐ — 구간 $[a,b]$, k차 B-스플라인. 거친 격자 G_1구간: 격자점 $\{t_0=a,\ldots,t_{G_1}=b\}$ + 양쪽으로 k개씩 확장. 기저 G_1+k개, i번째 B_i는 $[t_{-k+i},t_{i+1}]$에서만 0이 아님 (**국소성**).

$$f_{coarse}=\sum_{i=0}^{G_1+k-1}c_iB_i(x),\qquad f_{fine}=\sum_{j=0}^{G_2+k-1}c_j'B_j'(x)$$

c_j'는 f_{fine}과 f_{coarse}의 거리를 최소화 → **최소제곱**으로. → ai_life **01 선형회귀**의 최소제곱이 여기서도!

② **계단 손실** — $[2,5,1]$, 격자 3에서 시작해 LBFGS 200스텝마다 늘려 1000까지. 세밀화 때마다 학습 손실이 더 빨리 감소 (1000에선 최적화 실패). 테스트 손실은 **U자** — 편향-분산 절충.

③ **보간 임계점 예측** ⭐ — 학습 표본 1000개, $[2,5,1]$의 매개변수 $15G$ → 임계점 $G=1000/15\approx 67$, 실험값 $G\sim 50$과 대략 일치. → ✍ $15G$는 어디서? 엣지 $2\times5+5\times1=15$개 × 격자당 계수 약 G개.

④ **작은 KAN이 더 잘 일반화** — 과제가 $[2,1,1]$로 정확히 표현되므로 $[2,1,1]$을 학습 → 더 낮은 테스트 손실, 더 뚜렷한 계단, 임계점이 더 큰 G로 이동. "구조를 모르면 최소 모양을 어떻게 찾나?" → 2.5절.

⑤ **스케일링** — $[2,1,1]$의 테스트 RMSE $\propto G^{-3}$ (이론 G^{-4}). 경계 효과로 일부 표본 오차가 큼 → **중앙값**으로 보면 G^{-4}에 가까움.

p.11 해설 — 외부·내부 자유도, 희소화 정규화

① **외부 vs 내부 자유도** ⭐ — 노드 연결의 **계산 그래프** = 외부 자유도(MLP엔 있고 스플라인엔 없음): 다변수 **합성 구조** 학습. 활성화 함수 안의 **격자점** = 내부 자유도(스플라인엔 있고 MLP엔 없음): **1변수 함수** 학습. KAN은 둘 다. → 🔎 *external versus internal degrees of freedom* 에 밑줄.

② **2.5 해석 가능성** — 데이터 구조에 맞는 KAN 모양을 모른다 → 충분히 큰 KAN에서 시작해 **희소화 정규화** 학습 후 **가지치기**.

③ **희소화** ⭐ — MLP의 L1 정규화를 두 가지로 수정: (1) 선형 가중치가 없으니 **활성화 함수의 L1 노름**을 정의, (2) L1만으론 부족 → **엔트로피** 정규화 추가.

$$|\phi|_1 \equiv \frac{1}{N_p}\sum_{s=1}^{N_p}|\phi(x^{(s)})| \quad (2.17), \qquad |\Phi|_1 \equiv \sum_{i,j}|\phi_{i,j}|_1 \quad (2.18)$$

$$S(\Phi) \equiv -\sum_{i,j}\frac{|\phi_{i,j}|_1}{|\Phi|_1}\log\frac{|\phi_{i,j}|_1}{|\Phi|_1} \quad (2.19)$$

$$\ell_{total} = \ell_{pred} + \lambda\left(\mu_1\sum_l|\Phi_l|_1 + \mu_2\sum_l S(\Phi_l)\right) \quad (2.20),\ \ \mu_1 = \mu_2 = 1$$

→ ✍️ 엔트로피를 줄이면 왜 희소해지나? (크기가 몇 개 엣지에 **몰려야** 엔트로피가 작다 — 균등하면 최대)

p.12 해설 — 시각화, 가지치기, 기호화

① **그림 2.4** — KAN으로 기호 회귀하는 과정: 학습 → 가지치기 → 기호 설정 → 재학습 → 수식 출력.

② **시각화** — 활성화 $\phi_{l,i,j}$의 투명도를 $\tanh(\beta A_{l,i,j})$ ($\beta = 3$)에 비례 → 크기가 작은 함수는 **흐려져서** 중요한 것에 집중.

③ **가지치기** ⭐ **(식 2.21)** — **노드** 단위로. l층 i번째 노드의

$$I_{l,i} = \max_k |\phi_{l-1,i,k}|_1 \text{ (들어오는 점수)}, \qquad O_{l,i} = \max_j |\phi_{l+1,j,i}|_1 \text{ (나가는 점수)}$$

둘 다 임계값 $\theta = 10^{-2}$보다 크면 중요, 아니면 제거.

④ **기호화** ⭐ — 어떤 활성화가 $\cos$, $\log$ 같은 기호 함수라고 의심되면 `fix_symbolic(l,i,j,f)`. 입출력에 이동·배율이 있으므로 표본에서 아핀 매개변수를 맞춤:

$$y \approx c\, f(ax + b) + d$$

(a, b는 격자 탐색, c, d는 선형 회귀) → 🔎 $y \approx cf(ax+b)+d$ 에 밑줄.

⑤ **2.5.2 사람과 KAN의 상호작용** — 단순화 기법들을 **누를 수 있는 버튼**으로 보자. 회귀 과제 $f(x, y) = \exp(\sin(\pi x) + y^2)$ (2.22).

→ ✍️ 학생 활동: KAN 그림을 보여 주고 "이 엣지의 곡선은 어떤 함수 같나요?"를 맞히게 하면 함수 그래프 학습이 된다.

p.13 해설 — Alice의 5단계와 "왜 기호 회귀가 아닌가"

① Alice의 5단계 ⭐⭐

1. **희소화 학습**: $[2, 5, 1]$ → 은닉 뉴런 5개 중 4개가 쓸모없어 보임
2. **가지치기**: 자동으로 $[2, 1, 1]$만 남음, 활성화가 익숙한 함수처럼 보임
3. **기호 설정**: `fix_symbolic(0,0,0,'sin')`, `fix_symbolic(0,1,0,'x^2')`, `fix_symbolic(1,0,0,'exp')` (모르면 `suggest_symbolic`)
4. **추가 학습**: 남은 아핀 매개변수만 학습 → 손실이 **기계 정밀도**까지 떨어지면 정답
5. **수식 출력**: SymPy로 $1.0e^{1.0y^2+1.0\sin(3.14x)}$ — 정답! → 🔎 5단계 전체에 밑줄. pykan 튜토리얼에서 그대로 따라 할 수 있다.

② 왜 기호 회귀(SR)가 아닌가 ⭐ — SR은 깨지기 쉽고 디버깅이 어렵다(성공/실패만, 중간 결과 없음). KAN은 경사하강으로 함수 공간에서 **연속적** 탐색 → 견고. KAN을 시각화하는 것은 KAN의 **"뇌"를 보여 주는 것**, 사용자는 "수술"(디버깅) 가능. 목표가 기호가 아니어도(예: 베셀 함수) 스플라인으로 수치 근사.

③ 3절 도입: KAN은 정확하다 — 공정한 비교 = 정확도(손실) **와** 복잡도(매개변수 수) → **파레토 프런티어**. 3.5절: 파국적 망각 없는 연속 학습.

→ ✍️ ai_life 수업 아이디어: 학생이 만든 데이터(예: 공의 낙하 높이-시간)로 KAN을 학습시켜 $h = \frac{1}{2}gt^2$ 를 "발견"하게 하기.

p.14 해설 — 3.1 장난감 데이터: α=4를 거의 달성

① **그림 3.1**⭐ — 다섯 장난감 예에서 KAN vs MLP. KAN은 이론의 가장 빠른 스케일링($\alpha = 4$, 빨간 점선)을 **거의 포화**, MLP는 느리게 줄다가 **금방 정체**. → 🔎 고차원 예(100차원)에서 차이가 가장 크다는 점에 표시.

② **다섯 예 (매끄러운 KA 표현이 있는 것)**

예	KAN 모양
$J_0(20x)$ (베셀 함수)	$[1, 1]$ (그냥 스플라인)
$\exp(\sin(\pi x) + y^2)$	$[2, 1, 1]$
xy	$[2, 2, 1]$
$\exp(\frac{1}{100}\sum_{i=1}^{100}\sin^2(\frac{\pi x_i}{2}))$	$[100, 1, 1]$
$\exp(\frac{1}{2}(\sin(\pi(x_1^2 + x_2^2)) + \sin(\pi(x_3^2 + x_4^2))))$	$[4, 4, 2, 1]$

③ **설정** — 격자를 200스텝마다 $\{3, 5, 10, 20, 50, 100, 200, 500, 1000\}$. MLP는 여러 깊이·폭. 둘 다 LBFGS 1800스텝. 빨간 점선 $\alpha = k + 1 = 4$, 검은 점선(Sharma & Kaplan) $\alpha = 4/d$.

④ **깊이의 힘** — 마지막 예에서 2층 $[4, 9, 1]$은 3층 $[4, 2, 2, 1]$보다 **훨씬** 나쁨 → 깊은 KAN의 표현력. (MLP도 마찬가지)

⑤ **주의** — "진짜" KAN 모양을 안다고 가정. 실제로는 KA 표현의 존재도 모양도 모름 — 특히 다변수 **특수함수**(3.2절).

p.15 해설 — 3.2 특수함수, 3.3 파인만 데이터셋

① **그림 3.2** — 특수함수 15개에서 (매개변수 수, RMSE) 평면의 파레토 프런티어: **모든** 특수함수에서 KAN이 MLP보다 우수.

② **두 발견** — (1) 특수함수의 (근사적) **콤팩트한 KA 표현**을 찾을 수 있다 → 특수함수의 새로운 수학적 성질? (2) KAN이 MLP보다 효율적·정확.

③ **설정** — MLP: 폭 5 또는 100, 깊이 $\{2..6\}$. KAN(가지치기 없음): 폭 5, 깊이 $\{2..6\}$. KAN(가지치기): $\lambda = 10^{-2}$ 또는 10^{-3}로 희소화 후 가지치기. 격자 $G = 3 \to 200$.

④ **실용적 함의** ⭐ — 콤팩트한 표현 = 고차원 **조회표**(lookup table)를 여러 개의 **1D 조회표**로 분해 → 메모리 절약, 추론 시 몇 번의 덧셈만 추가. → 🔎 *breaking down a high-dimensional lookup table into several 1D lookup tables* 에 밑줄.

⑤ **3.3 파인만 데이터셋** — 3.1(모양을 앎)과 3.2(모름)의 중간: 데이터 구조를 알아 손으로 KAN을 만들 수 있지만 최적인지는 모름 → **사람이 만든 KAN** vs **자동 발견 KAN** 비교. 파인만 교과서의 물리 방정식들 (Udrescu & Tegmark, AI Feynman).

→ ✍️ "파레토 프런티어"를 정의해 보자: 더 단순하면서 동시에 더 정확한 다른 모델이 없는 모델들의 집합.

p.16 해설 — 표 1·2: 특수함수와 파인만 방정식

① **표 1 (특수함수)** — 열: 이름 | 오차 $< 10^{-2}$인 최소 KAN 모양 | 그 RMSE | 최고 KAN 모양 | 최고 RMSE | MLP RMSE.

- 야코비 타원함수 `ellipj`: 최소 $[2, 2, 1]$, 최고 1.33×10^{-4} vs MLP 6.48×10^{-4}
- 르장드르 함수 ($m = 0$) `lpmv`: $[2, 2, 1]$, 5.25×10^{-5} vs MLP 1.74×10^{-2} (**300배 이상**)
- 구면조화 $(0, 1)$ `sph_harm`: $[2, 1, 1]$, 2.21×10^{-7} vs MLP 1.25×10^{-6} → 🔎 르장드르 함수 행에 동그라미 — 가장 큰 차이.

② **표 2 (파인만)** — 열: 방정식 번호 | 원래 식 | **무차원** 식 | 변수 | 사람이 만든 KAN | 가지친 KAN(최소/최고) | 오차들 | MLP.

- 예: I.37.4 간섭 $I^* = I_1 + I_2 + 2\sqrt{I_1 I_2}\cos\delta$ → 무차원 $1 + a + 2\sqrt{a}\cos\delta$, 사람 $[2, 3, 2, 1]$ vs 자동 $[2, 2, 1]$
- 예: I.26.2 굴절 $\arcsin(n \sin\theta_2)$: 사람 $[2, 2, 2, 1, 1]$ vs 자동 $[2, 2, 1]$

→ ✍️ 표 2에서 "사람이 만든 KAN"보다 "자동 발견 KAN"이 더 작은 행이 몇 개인지 세어 보자. (다음 쪽의 결론) → ✍️ 왜 식을 **무차원**으로 바꿔서 학습할까? (단위에 따른 크기 차이를 없애고 변수 수를 줄이기 위해)

p.17 해설 — 파인만 비교 방법과 "rapidity의 재발견"

① 네 가지 신경망

1. **사람이 만든 KAN**: 기호 식을 KA 표현으로 재작성. 예: $xy = \frac{(x+y)^2-(x-y)^2}{4} \to [2,2,1]$
2. 가지치기 없는 KAN: 폭 5, 깊이 $\{2..6\}$
3. 가지친 KAN: (2)에서 희소화·가지치기
4. MLP: 폭 5, 깊이 $\{2..6\}$, 여러 활성화 → ✍️ 곱셈 항등식을 확인하고 $[2,2,1]$ KAN을 그려 보자: 1층 엣지에 $\pm x$, $\pm y$(선형), 2층 엣지에 $\pm\frac{1}{4}(\cdot)^2$.

② 결과 — MLP와 KAN이 **평균적으로 비슷**. 파인만 데이터는 변수 의존이 매끄럽거나 단조라 너무 쉬운 듯 (특수함수와 대조).

③ 자동 발견 KAN이 더 작다 ⭐ — 최소/최고 가지친 모양이 대개 사람이 만든 것보다 작음 → KA 표현이 생각보다 **효율적**. 하지만 정보가 작은 공간에 압축돼 해석이 미묘해질 수도.

④ 상대론적 속도 합성 ⭐⭐ — $f(u,v) = \frac{u+v}{1+uv}$. 사람은 곱셈 2층 + 역수 1층 + 곱셈 2층 = **5층**이라 생각. 자동 발견은 **2층**! 돌이켜보면 **rapidity** $a = \operatorname{arctanh} u$, $b = \operatorname{arctanh} v$:

$$\frac{u+v}{1+uv} = \tanh(\operatorname{arctanh} u + \operatorname{arctanh} v)$$

→ 물리 개념을 모르는 척해도 KAN에서 **직접 발견**할 수 있다. → 🔎 이 식에 크게 밑줄. ✍️ $\tanh$의 덧셈정리 $\tanh(a+b) = \frac{\tanh a+\tanh b}{1+\tanh a\tanh b}$ 로 직접 확인하자.

p.18 해설 — 3.4 편미분방정식, 3.5 연속 학습

① **그림 3.3** — 포아송 방정식: 예측 해와 참 해 사이의 L^2 제곱 오차, H^1 제곱 오차. 1·2번째: 학습 동역학, 3·4번째: 매개변수 수에 대한 스케일링. KAN이 더 빨리 수렴, 더 낮은 손실, 더 가파른 스케일링.

② **3.4 포아송 방정식** ⭐ $-\Omega = [-1,1]^2$에서 $u_{xx} + u_{yy} = f$, 경계에서 $u = 0$. $f = -\pi^2(1 + 4y^2)\sin(\pi x)\sin(\pi y^2) + 2\pi\sin(\pi x)\cos(\pi y^2)$ → 참 해 $u = \sin(\pi x)\sin(\pi y^2)$. **PINN** 손실: $\text{loss}_{pde} = \alpha\,\text{loss}_i + \text{loss}_b$ (내부 점 $n_i = 10000$, 경계 점 $n_b = 800$, $\alpha = 0.01$).

③ **결과** ⭐ — 2층 폭 10 KAN이 4층 폭 100 MLP보다 **100배 정확**(10^{-7} vs 10^{-5} MSE)하고 **100배 적은 매개변수**(10^2 vs 10^4). → 🔎 이 문장에 밑줄. 단서: KAN 학습이 **약 10배 느림**, 참 해가 기호 식이라 KAN에 유리한 비교일 수 있음.

④ **3.5 연속 학습** — **파국적 망각**: 신경망이 과제 1 다음 과제 2를 배우면 과제 1을 금방 잊는다. 사람은 그렇지 않다 — 뇌는 공간적으로 국소화된 **기능 모듈**…

→ ✍️ 직접 확인: $u = \sin(\pi x)\sin(\pi y^2)$ 를 두 번 미분해 $u_{xx} + u_{yy}$가 위의 f가 되는지 검산해 보자 (연쇄법칙 연습!).

p.19 해설 — 국소성으로 망각을 피하다

---

① **그림 3.4** ⭐ — 1D 회귀, **가우시안 봉우리 5개**. 각 봉우리 주변 데이터를 **차례로** 제시. KAN(가운데 줄)은 망각 없음, MLP(아래 줄)는 심한 망각. → 🔎 MLP 마지막 칸에서 앞의 봉우리들이 사라진 것을 확인하자.

② **뇌의 국소성** — 새 과제를 배우면 관련 영역만 재조직, 나머지는 그대로. MLP엔 이런 **국소성**이 없다.

③ **KAN의 국소 가소성** ⭐ — 스플라인 기저는 **국소적** → 표본 하나는 근처 몇 개 계수에만 영향, 먼 계수(이미 정보를 저장)는 그대로. MLP는 ReLU/Tanh/SiLU 같은 **전역** 활성화라 국소 변화가 먼 영역까지 퍼짐. → ✍️ p.10의 "B_i는 $[t_{-k+i}, t_{i+1}]$에서만 0이 아님"이 바로 이 국소성의 수학적 근거다.

④ **한계** — 아주 단순한 예의 예비 결과. 고차원에서 "국소성"을 어떻게 정의할지 불분명.

⑤ **4절 도입: KAN은 해석 가능하다** — 장난감(4.1, 4.2) + 실제 과학(4.3 매듭 이론, 4.4 응집물질물리의 상전이 경계).

→ ai_life 연결: 학생이 여러 단원을 차례로 배워도 앞 단원을 잊지 않는 것처럼, AI도 그럴 수 있을까? — 수업 토론거리.

p.20 해설 — 4.1 지도학습 장난감: 구조를 드러내다

① **그림 4.1** ⭐ — 간단한 기호 과제에서 KAN은 해석 가능.

② **여섯 예 (1)**

예	결과
(a) 곱셈 xy	$[2,5,1] \to [2,2,1]$, 활성화는 **선형과 2차** — $xy = \frac{(x+y)^2-(x-y)^2}{4}$ 를 이용
(b) 나눗셈 x/y (양수)	$[2,5,1] \to [2,1,1]$, **로그와 지수** — $x/y = \exp(\log x - \log y)$
(c) 수치→범주	$[0,1]$의 실수 → 첫 소수 자리(원-핫). 활성화가 각 자리 주변의 **뾰족한 스파이크**
(d) 특수함수 $\exp(J_0(20x)+y^2)$	SR은 베셀 함수를 미리 주지 않으면 못 찾지만 KAN은 구불구불한 $J_0(20x)$를 수치로 학습
(e) 상전이	$\tanh$로 상전이 모사, 질서 매개변수 = x_1, x_2, x_3의 4차항 조합
→ 🔎 (b)의 $x/y = \exp(\log x - \log y)$ 에 밑줄 — KAN이 로그 계산자의 원리를 스스로 찾음!	

→ ✍️ (c)에서 $0.314 \to [0,0,0,1,0,\dots]$ 인 이유는? (첫 소수 자리 3 → 4번째 칸, 0부터 세므로)

p.21 해설 — 깊은 합성, 4.2 비지도 발견

① **(e) 계속** — 학습 후 4차 의존성과 $\tanh$ 의존성이 모두 나타남. 4.4절 국소화 상전이의 단순판.

② **(f) 깊은 합성** — $f = \sqrt{(x_1 - x_2)^2 + (x_3 - x_4)^2}$: 항등·제곱·제곱근이 필요해 최소 3층. $[4, 3, 3, 1] \to [4, 2, 1, 1]$로 자동 가지치기 = 기대한 계산 그래프 그대로.

③ **4.2 비지도 학습** ⭐ — 과학적 발견은 보통 지도학습($y \approx f(\mathbf{x})$)이지만, 변수들 사이의 **구조적 관계** $f(x_1, \ldots, x_d) \approx 0$ 을 찾는 비지도 형태도 있다. 예: $x_3 = \exp(\sin(\pi x_1) + x_2^2) \to f = \sin(\pi x_1) + x_2^2 - \log x_3 = 0$ → 점들이 3D가 아니라 **2D 부분다양체** 위에.

④ **왜 비지도인가** — 지도학습은 입력/출력 분할이 필요: 가능한 분할 $2^d - 2$가지! DeepMind 매듭 연구는 signature를 **손으로** 목표로 골랐다. → ✍️ $d = 18$이면 분할 방법은 몇 가지? ($2^{18} - 2 = 262{,}142$)

⑤ **방법** ⭐ — **대조 학습**처럼: 양성 표본 = 실제 데이터, 음성 표본 = 각 특징을 학습 집합 전체에서 **무작위 섞기**(분포 유지). $g(\mathbf{x}_{real}) = 1$, $g(\mathbf{x}_{fake}) = 0$ 학습. $g = \sigma \circ f$, $\sigma(x) = \exp(-\frac{x^2}{2w^2})$ (폭 좁은 가우시안) → $f(\mathbf{x}_{real}) \approx 0$. 마지막 활성화를 가우시안으로 고정한 $[\ldots, 1, 1]$ KAN.

p.22 해설 — 비지도 장난감 결과, 4.3 매듭 이론

① **그림 4.2** — 6차원 데이터: (x_1, x_2, x_3) 종속($x_3 = \exp(\sin x_1 + x_2^2)$), (x_4, x_5) 종속($x_5 = x_4^3$), x_6 독립. 시드 0 → x_1, x_2, x_3 관계 발견, 시드 2024 → x_4, x_5 관계 발견. 현재는 **무작위성**(시드)에 의존 — 체계적 방법은 미래 과제.

② **4.3 매듭 이론** ⭐ — 저차원 위상수학. **매듭** K = S^1을 S^3에 매장. 주변 공간의 변형으로 바꿀 수 있으면 위상적으로 동치 $[K] = [K']$. **위상 불변량** f: $f(K) \neq f(K')$이면 $[K] \neq [K']$.

- 기하적 불변량: 쌍곡 매듭의 **쌍곡 부피**
- 대수적 불변량: **존스 다항식** → 🔎 *topological invariants* 에 밑줄.

③ **기계학습과 매듭** — 강화학습으로 리본성 확인[46], 지도학습 + 수학자로 대수적·기하적 불변량을 잇는 **새 정리** (DeepMind, Davies 외 2021, *Nature*)[45].

④ **DeepMind의 결과** — (1) 신경망 기여도 분석: signature σ는 주로 meridinal distance μ(실수 μ_r, 허수 μ_i)와 longitudinal distance λ에 의존. (2) 수학자들이 기울기(slope) $\mathrm{Re}(\lambda/\mu)$와의 상관을 찾아 정리를 증명.

→ ✍️ 신발 끈 매듭과 고리 매듭을 그려 보고, "끊지 않고 하나를 다른 것으로 바꿀 수 있는가"가 위상 동치라는 뜻임을 설명해 보자.

p.23 해설 — 매듭 지도학습: 200개 매개변수로 DeepMind 넘기

① **그림 4.3** — 매듭 데이터 지도 모드: signature가 주로 μ(실수·허수)에 의존한다는 DeepMind 결과를 재발견.

② **표 3** ⭐

방법	구조	매개변수	정확도
DeepMind MLP	4층 폭 300	3×10^5	78.0%
KAN	2층 $[17, 1, 14]$ ($G = 3, k = 3$)	2×10^2	**81.6%**
→ 🔎 매개변수가 **1500분의 1**인데 더 정확. (각주: 이후 조지아텍 Shi 연구실은 매개변수 60개 MLP로 80% — "AI+과학 과제는 생각보다 계산이 덜 필요할지도")			

③ **설정** — 매듭 불변량 17개 입력, signature(짝수) 원-핫, 교차 엔트로피.

④ **해석** ⭐ — 투명도로 중요한 입력이 바로 보임: signature는 주로 μ_r, 약간 μ_i와 λ. $[3, 1, 14]$ KAN으로 78.2%. **DeepMind와의 차이**: 그들은 μ_i가 주 요인이라 했고 KAN은 μ_r. 절제 실험: μ_r만 65.0%, μ_i만 43.8%. 표 4의 기호식 F는 μ_r와 λ만으로 77.8%. → ✍️ 이 차이는 "AI의 해석이 서로 다를 때 무엇을 믿어야 하나?"라는 좋은 토론거리다. 절제 실험이 왜 강력한 증거인가?

p.24 해설 — 표 4: signature의 기호식들, 비지도 매듭

① **표 4** ⭐ — signature를 μ_r, μ_i, λ의 함수로:

- **A**: DeepMind 수학자들이 신경망 기여도에서 영감받아 찾은 식
- **B-D**: KAN 자동 발견 ($[3,1]$, $[3,1,1]$, $[3,2,1]$) — 클수록 정확하지만 복잡 → **단순함-정확도의 파레토 프런티어**
- **E**: 다변수 **파데 표현**(테일러 급수의 비) 귀납 편향을 넣어 A와 비슷한 식
- **F**: 분자·분모를 각각 KAN으로 학습해 나눔 → μ_r와 **λ만** 사용, 77.8% → 🔎 *a whole Pareto frontier of formulas* 에 밑줄.

② **재발견 정리** — 기여도 분석 대신 KAN **시각화를 바라보는 것**만으로, 자동 기호 회귀로 쉽게.

③ **새 패러다임: 비지도 "AI for Math"** — signature를 포함한 **18개 변수 모두** 입력으로 동등하게. 매듭 데이터 = 양성, 특징 섞기 = 음성. $[18,1,1]$ KAN, 둘째 층 활성화를 0 중심 가우시안으로 고정 → 양성 표본은 $\sum_{i=1}^{18} g_i(x_i) \approx 0$ 이라는 **관계**를 암묵적으로 표현.

→ ✍️ 단순한 식(B)과 정확한 식(D) 중 과학자는 어느 쪽을 원할까? 상황에 따라 다르다는 점을 예로 들어 설명해 보자.

p.25 해설 — 비지도로 찾은 세 관계

① **그림 4.4** — 매듭 데이터 비지도 모드: 세 수학적 관계 재발견. $\lambda \in \{10^{-2}, 10^{-3}\}$, 여러 시드 → 세 군집.

② **세 관계** ⭐

1. **signature, μ_r, λ** (+ 3번으로 제거 가능한 두 변수) — 지도 모드에서 본 signature 의존성을 비지도로 **다시** 발견!
2. **첨점 부피 V, μ_r, λ** — 활성화가 모두 **로그**처럼 보임 → $-\log V + \log \mu_r + \log \lambda = 0$, 즉 $V = \mu_r \lambda$ (정의상 참). 사전 지식 없이 발견한 것이 고무적.
3. **짧은 측지선의 실수부 g_r와 단사 반지름** — 활성화가 같은 모양에 부호만 반대 → 선형 상관 추측 → 산점도로 확인: $2r$이 g_r의 **상한**. → 🔎 2번의 $\log$ 합 = 곱의 관계에 밑줄. (곱셈 관계 → 로그 활성화 — p.20의 나눗셈 예와 같은 원리)

③ **솔직한 평가** — 좋은 소식: KAN의 발견은 아마 **믿을 만하다**. 나쁜 소식: 아직 **새로운 것**은 발견하지 못함. 깊은 KAN이면 더 복잡한 관계를 찾을 수도. → 🔎 *we have not discovered anything new yet* 에 밑줄 — 과학 논문의 정직함.

→ ✍️ $V = \mu_r \lambda$ 를 로그로 바꾸면 왜 "덧셈 관계"가 되는지, 그래서 왜 KAN(노드는 덧셈)이 찾기 쉬운지 설명하자.

p.26 해설 — 4.4 앤더슨 국소화와 이동도 경계

① **앤더슨 국소화** ⭐ — 양자계의 **무질서**가 전자 파동함수를 **국소화**시켜 수송을 멈추는 현상. 1·2차원에선 무한소의 무질서로도 모든 고유상태가 지수적으로 국소화. 3차원에선 임계 에너지(**이동도 경계, mobility edge**)가 확장 상태와 국소 상태를 가름 → 고체의 **금속-부도체 전이**, 광소자의 빛 국소화 이해에 중요.

② **준주기 모형** — 저차원에서 무작위 대신 **준주기성**을 넣어도 이동도 경계 생김 → 해석적 이동도 경계 연구가 활발.

③ **세 모형**

모형	KAN의 역할
모자이크 모형 (MM)	이동도 경계를 에너지의 1D 함수로 정확히 추출
일반화 오브리-앙드레 (GAAM)	KAN 공식이 참 식과 가까움
수정 오브리-앙드레 (MAAM)	사람이 가설을 주고 KAN이 빠르게 검증하는 **협업**

④ **국소화의 척도** — 역참여비 $\mathrm{IPR}_k = \frac{\sum_n |\psi_n^{(k)}|^4}{(\sum_n |\psi_n^{(k)}|^2)^2}$, 그리고 **프랙탈 차원** $D_k = -\frac{\log \mathrm{IPR}_k}{\log N}$. $D_k = 0$: 국소, $D_k = 1$: 확장. → ✍️ 파동함수가 한 칸에만 있으면 IPR은? (1 → $D = 0$, 국소) N칸에 고르게 퍼지면? ($1/N$ → $D = 1$, 확장)

p.27 해설 — 모자이크 모형: 박사과정생 Alice

① **그림 4.5** — 위: 상도표. 가운데·아래: KAN이 정량적 결과(가운데)와 정성적 직관(아래)을 모두 제공. $\phi = \frac{1+\sqrt{5}}{2}$ (황금비).

② **모형** — 최근접 이웃 결합 t, 생성·소멸 연산자. 준주기성: b를 **무리수**(황금비)로, 준주기 퍼텐셜이 간격 κ로. 매우 강한 퍼텐셜에서도 이동도 경계가 있음(항상 확장 상태 존재)이 특징.

③ **질서 매개변수** — 이동도 경계 $g(\lambda, E) \equiv \lambda - |f_\kappa(E)| = 0$. $g > 0$: 국소, $g < 0$: 확장. 이동도 경계 학습 = "질서 매개변수" g 학습.

④ **Alice의 두 가지 영리한 선택** ⭐

1. 분류 과제이므로 둘째 층 활성화를 `fix_symbolic`으로 **시그모이드**
2. 결국 $\lambda = \lambda(E)$만 필요 → $g(\lambda, E) = \lambda - h(E)$ 로 가정, λ의 활성화를 **선형**으로 고정 → $[2, 1]$ KAN 학습만으로 이동도 경계를 얻음. → 🔎 사람의 **귀납 편향**을 KAN에 쉽게 넣을 수 있다는 점에 밑줄.

→ ✍️ 이상구 외(2023)의 "모델링 관점: 무엇을 손실함수로? 제약조건은?" 제언과 Alice의 선택을 비교해 보자.

p.28 해설 — 표 5와 GAAM

① **표 5** — GAAM·MAAM의 참 식과 KAN 발견 식들. GAAM 참: $\alpha E + 2(\lambda - 1) = 0$. MAAM은 자동 모드(긴 식, $\sin{\cdot}\arctan{\cdot}\exp$ 범벅)에서 수동 단계(3, 4A, 4B)로 갈수록 **짧아짐**. → 🔎 MAAM-KAN auto 행과 step 4B 행의 길이를 비교하자.

② **GAAM** — 준주기 퍼텐셜 $V_n = 2\lambda \frac{\cos(2\pi n b + \phi)}{1 - \alpha\cos(2\pi n b + \phi)}$ ($\alpha \in (-1, 1)$), b = 황금비. 이동도 경계 닫힌 식: $\alpha E = 2(1 - \lambda)$.

③ **데이터** — ϕ, α, λ 무작위 표본($t = 1$), 고유값과 프랙탈 차원 계산. 질서 매개변수 $g(\alpha, E, \lambda, \phi) = \alpha E + 2(\lambda - 1)$.

④ **Alice의 진행** ⭐ — $[4, 2, 1, 1]$ KAN (자동 가지치기로든 추측으로든). 마지막 활성화를 시그모이드로, 희소화 학습 → **98.7%** (그림 4.6(a) 1단계). 관찰: ϕ가 **전혀 쓰이지 않음** → 이동도 경계는 ϕ와 무관 (식 4.8과 일치). 나머지 활성화는 거의 선형 또는 2차…

→ ✍️ KAN이 "어떤 입력을 안 쓰는지" 보여 주는 것만으로도 과학적 정보가 된다. 이것을 Touretzky의 "투명성(transparency)"과 연결해 보자.

p.29 해설 — GAAM 마무리, MAAM: 사람의 지혜가 더 필요할 때

① **GAAM 마무리** — 자동 기호 맞춤(라이브러리를 선형·2차로 제한) → 이미 기호적인 신경망, **98.9%**(오히려 약간 향상). `symbolic_formula`로 g의 식 획득 → 작은 항을 지우고 계수를 정수로 맞추면 참 식에 가까워짐.

② **기호 회귀였다면** ⭐ — 운 좋으면 정답, 대부분은 쓸모없는 결과, 과정을 "디버깅"할 수 없고, 기호 항 라이브러리를 **미리** 줘야 함. KAN은 사전 정보 없이 먼저 **단서**를 보고, 그다음 사람이 가설을 세워 구현. "바로 정답을 주진 않아도 **항상 쓸모 있는 것**을 돌려준다". → 🔎 *KANs will always return something useful* 에 밑줄.

③ **MAAM** — 지수적으로 감소하는 결합 t, 퍼텐셜 $V_n = \lambda\cos(2\pi nb + \phi)$, 이동도 경계 닫힌 식 $\lambda\cosh p = E + t = E + t_1 e^p$ ($t_1 \equiv te^{-p} = 1$).

④ **Alice의 진행** — $[4,2,1,1]$로 75%(불충분) → $[4,3,1,1]$로 **98.4%**. ϕ 무시됨 (식 4.11과 일치). 자동 기호 회귀(큰 라이브러리) → 복잡한 식, 97.1%. 단순한 식을 원하면 **수동 모드**: $[4,3,1,1] \to [4,2,1,1]$ 가지치기(97.7%), p 외 활성화를 선형·2차로 고정(97.7%). 이후 두 갈래:

- 4A: p 의존이 $\cosh$라고 추측 → 96.9%
- 4B: 모른다면 단순하게 2차로…

p.30 해설 — 그림 4.6, 단순함-정확도의 손잡이, 관련 연구

① **그림 4.6** — GAAM·MAAM 이동도 경계를 찾는 사람-KAN 협업. 게으르게(자동 모드) 또는 적극적으로(수동 모드).

② **4B 결과** — 2차로 가정 → **95.4%**. 둘 다 해 보면: $\cosh$가 정확도에 유리, 2차가 단순함에 유리. 수동 조작을 많이 할수록 식이 단순(정확도는 약간 희생). → 🔎 KAN의 **"손잡이(knob)"**: 단순함과 정확도 사이를 사용자가 조절 — 때로는 단순함이 정확도까지 높음.

③ **5절 관련 연구: KA 정리와 신경망** — 연결 자체는 새롭지 않지만[66, 67, 9-14, …], 내부 함수의 병적 행동 때문에 비관적이었고 대부분 원래의 2층 $2n+1$에 머물렀으며 **역전파 이전**의 것도 많음. 일반화 가법 모형(GAM), 그래프 신경망, 커널 기계와도 연결.

④ **기여 재확인** — 콜모고로프 신경망을 **임의 폭·깊이**로 일반화, 현대 딥러닝 흐름 속에 부활, AI+과학의 **기초 모델** 가능성.

⑤ **신경 스케일링 법칙** — 테스트 손실이 모델 크기·데이터·계산량에 대해 **거듭제곱 법칙** (Kaplan 외 [73] 등).

→ ✍️ ai_life 활동 아이디어: 같은 데이터에 "정확하지만 긴 식"과 "단순하지만 덜 정확한 식"을 보여 주고 학생에게 고르게 하기 — 오컴의 면도날(Saltzer 결론!)과 연결.

p.31 해설 — 관련 연구: 스케일링, 해석, 활성화, 기호 회귀, PINN

① **스케일링 법칙의 기원** — 고유 차원, 과제 양자화, 자원 이론, **랜덤 특징**(Bahri 외, 이번 주 Lee 2019의 저자들!), 합성 희소성, 최대 인자 수. 이 논문의 기여: 매끄러운 KA 표현이 있으면 고차원 함수가 **1D 함수처럼** 스케일링(최선의 경우). 언어 모델 같은 복잡한 과제에도 성립할까? — 열린 질문.

② **기계적 해석 가능성(MI)** — **수동적** MI: 이미 학습된 신경망 이해. **능동적** MI: 본질적으로 해석 가능한 구조·학습법 설계. KAN은 **능동적**.

③ **학습 가능한 활성화** — 다항식, 스플라인, SiLU, 신경망 등으로 매개변수화한 선행 연구. KAN은 B-스플라인. (부록 B: LAN)

④ **기호 회귀** — 유전 알고리즘(Eureqa, GPLearn, PySR), 신경망 기반(EQL, OccamNet), 물리 영감(AI Feynman), 강화학습. KAN은 신경망 기반과 가장 비슷하지만, 기호로 고정하기 **전에** 활성화를 **연속적으로** 학습한다는 점이 다름.

⑤ **PINN·PINO** — 3.4절처럼 편미분방정식 손실에서 MLP를 KAN으로 대체 가능. Deep Ritz, PINN, FNO, DeepONet.

⑥ **AI for Math** — 풀린 매듭 판별, 리본 매듭, 불변량 예측과 관계 발견.

→ ✍️ "수동적 vs 능동적 해석 가능성"을 자동차에 비유해 보자: 엔진을 뜯어 분석하기 vs 처음부터 투명한 엔진 만들기.

p.32 해설 — 6절 토론: 수학·알고리즘·응용의 과제

① **수학적 측면** ⭐ — 정리 2.1은 예비 분석일 뿐, 이해는 매우 제한적. KA 정리는 $[n, 2n+1, 1]$이라는 **아주 제한된** 부분집합에 해당. 깊은 KAN의 경험적 성공이 수학적으로 무언가 근본적인 것을 뜻할까? "**더 깊은**" KA 표현의 일반화 정리, 활성화의 매끄러움과 깊이의 관계, "**콜모고로프-아놀드 깊이**"로 함수 부류를 분류할 수 있을까? → 🔎 *"Kolmogorov-Arnold depth"* 에 밑줄 — 수학 연구 주제!

② **알고리즘 측면**

1. **정확도**: 스플라인 대신 방사 기저 함수 등, 적응적 격자
2. **효율**: 활성화가 모두 달라 **배치 계산**을 못 씀 → 그룹으로 묶는 "다중 헤드"로 MLP와 KAN 사이 보간
3. **혼합**: KAN의 두 차이 (i) 엣지 위 활성화, (ii) 학습 가능 활성화 — 어느 쪽이 핵심? (부록 B의 LAN은 (ii)만)
4. **적응성**: 스플라인의 국소성으로 다중격자·다중척도 방법

③ **응용 측면** — 나비에-스토크스, 밀도범함수 이론 등. 트랜스포머의 MLP를 KAN으로 바꾼 **"칸스포머(kansformer)"**.

④ **AI+과학의 "언어 모델"로서 KAN** ⭐ — LLM이 혁명적인 이유: 자연어를 쓰는 누구에게나 유용. **과학의 언어는 함수**. KAN은 해석 가능한 함수로 이루어져 있어 KAN을 보는 것은 **함수라는 언어로 대화하는 것**. → 🔎 *The language of science is functions* 에 밑줄.

p.33 해설 — AI 과학자인가, 과학자를 돕는 AI인가 (그림 6.1)

① **패러다임 질문** ⭐ — "**AI 과학자**를 원하는가, **과학자를 돕는 AI**를 원하는가?" 완전 자동 AI 과학자의 본질적 어려움: 인간의 선호를 정량화하기 어렵다 — 분야마다 "단순하다", "해석 가능하다"의 기준이 다름. 그래서 과학의 언어(함수)로 말하고 개별 과학자의 귀납 편향과 쉽게 상호작용하는 AI가 바람직. → 🔎 *Do we want AI scientists, or do we want AI that helps scientists?* 에 크게 밑줄 — ai_life 수업의 마무리 토론 질문으로 최고.

② **최대 병목: 느린 학습** — 같은 매개변수 수에서 MLP보다 **약 10배 느림**. 효율 최적화를 열심히 하지 않았으므로 근본적 한계보다는 **공학적 문제**로 봄.

③ **그림 6.1: KAN을 쓸까 MLP를 쓸까?** ⭐ — 빨리 학습해야 하면 **MLP**. 해석 가능성·정확도가 중요하고 느린 학습이 큰 문제가 아니면 **KAN**을 시도 — 적어도 작은 규모 AI+과학 문제에서. → ✍️ 그림 6.1의 결정 트리를 노트에 옮겨 그리자.

④ **감사의 글** — Tomaso Poggio 등, NSF IAIFI 지원.

→ ✍️ 이번 주 Touretzky의 Big Idea 5(사회적 영향)와 연결: "AI가 과학자를 대체"와 "AI가 과학자를 돕는다" 중 학생들은 어떤 미래를 원하는지 토론해 보자.

p.34 해설 — 참고문헌 [1]-[16]: 뿌리들

주목할 참고문헌

번호	참고문헌	왜 볼까
[1]	Haykin (1994)	신경망 교과서
[2]	**Cybenko (1989)**	지난주 읽은 보편 근사 정리 ⭐
[3]	**Hornik, Stinchcombe, White (1989)**	이번 주 읽은 논문 ⭐
[4]	Vaswani 외 (2017)	트랜스포머 — MLP가 매개변수 대부분
[6]	**Kolmogorov (1956)**	다변수 연속함수를 적은 변수의 함수로 표현
[7]	**Kolmogorov (1957)**	1변수 함수의 중첩과 덧셈으로 표현 — 정리의 원 논문 ⭐
[8]	Braun & Griebel (2009)	콜모고로프 정리의 **구성적** 증명
[12]	Lai & Shen	콜모고로프 정리가 차원의 저주를 깰 수 있음
[14]	Fakhoury 외 ExSpliNet	해석 가능한 스플라인 신경망

→ ✍️ [2], [3], [7] 세 논문을 한 줄씩 비교하자: Cybenko(한-바나흐), Hornik(스톤-바이어슈트라스), Kolmogorov(정확한 표현). 이번 주와 지난주가 한 장에 모인다!

p.35 해설 — 참고문헌 [17]-[36]: 근사 이론과 스케일링

번호	참고문헌	왜 볼까
[17]-[18]	He, Xu 외	ReLU 신경망 = **유한요소** (스플라인과의 연결)
[19]	Poggio, Banburski, Liao (2020)	KA 정리를 "실용성 없다"고 본 대표 비판
[20]	Girosi & Poggio (1989)	"콜모고로프 정리는 무관하다" (같은 해 Cybenko·Hornik!)
[21]	Lin, Tegmark, Rolnick (2017)	왜 깊고 싼 학습이 잘 되나 — 물리 법칙의 구조
[23]	**de Boor (1978)** *A practical guide to splines*	B-스플라인 교과서, 정리 2.1 증명의 근거
[24]	Sharma & Kaplan (2020)	데이터 다양체 차원과 스케일링 지수
[25]	Michaud, Liu, Tegmark (2023)	정밀 기계학습, $\alpha = (k+1)/2$
[28]	Schmidt-Hieber (2020)	ReLU 신경망 비모수 회귀
[32]	Yarotsky (2017)	깊은 ReLU 신경망의 근사 오차 한계
[36]	Udrescu & Tegmark (2020) **AI Feynman**	물리 영감 기호 회귀, 파인만 데이터셋

→ ✍️ [20] Girosi & Poggio(1989)와 이 논문(2024)의 입장 차이를 한 문장씩. 35년 사이 무엇이 바뀌었나? (역전파, 깊은 구조, 계산력, "전형적 함수" 관점)

p.36 해설 — 참고문헌 [37]-[53]: PINN, 망각, 매듭, 국소화

번호	참고문헌	왜 볼까
[37]	Udrescu 외 (2020) AI Feynman 2.0	파레토 최적 기호 회귀
[38]	**Raissi, Perdikaris, Karniadakis (2019)**	**PINN** — 3.4절의 틀 ⭐
[39]	Karniadakis 외 (2021)	물리 정보 기계학습 리뷰
[40]	Kemker 외	파국적 망각 측정
[41]-[42]	Kolb & Whishaw / Meunier 외	뇌 가소성, 모듈식 뇌 — 3.5절 비유의 근거
[43]	Kirkpatrick 외 (2017)	EWC — 망각 극복의 대표 방법
[45]	**Davies 외 (2021, *Nature*)**	DeepMind의 AI로 수학 발견 — 4.3절의 비교 대상 ⭐
[46]	Gukov 외	강화학습으로 리본 매듭 탐색
[48]	**Anderson (1958)** *Absence of diffusion…*	앤더슨 국소화의 원 논문 (노벨상)
[49]-[50]	Thouless / Abrahams 외	국소화의 척도 이론

→ ✍️ [45]는 "AI가 수학자를 도와 새 정리를 증명"한 유명한 사례다. KAN이 같은 결과를 1500분의 1 매개변수로 재현했다는 점의 의미를 생각해 보자.

p.37 해설 — 참고문헌 [54]-[69]: 준주기 모형과 KA 신경망

번호	참고문헌	왜 볼까
[54]-[56]	John / Lahini 외 / Vaidya 외	빛의 국소화 (공저자 Vaidya의 연구)
[57]-[58]	De Roeck 외 / Li 외	상호작용계의 다체 국소화 논쟁
[60]	**Biddle & Das Sarma**	MAAM 이동도 경계 예측
[62]	**Ganeshan, Pixley, Das Sarma**	GAAM 이동도 경계 닫힌 식
[63]	Wang 외	모자이크 모형
[66]	**Poggio (2022)**	깊은 희소 신경망이 차원의 저주를 피하는 법
[67]	**Schmidt-Hieber (2021)** *KA representation theorem revisited*	정리의 현대적 재검토 ⭐
[68]-[69]	Ismayilova & Ismailov / Poluektov & Polar	콜모고로프 신경망의 최근 연구

→ ✍️ 4.4절에서 KAN은 [60], [62]가 이미 유도한 닫힌 식을 **데이터만으로** 다시 찾았다. "재발견"이 과학적으로 어떤 가치가 있는지 (검증, 방법론의 신뢰성) 정리해 보자. → [67]은 이번 주 리뷰의 "다음에 읽을 논문"이다.

p.38 해설 — 참고문헌 [70]-[84]: 스케일링 법칙과 기계적 해석

번호	참고문헌	왜 볼까
[70]	Agarwal 외 (2021)	**신경 가법 모형(NAM)** — KAN과 가까운 친척
[71]	Zaheer 외	Deep Sets
[73]	**Kaplan 외 (2020)**	언어 모델 **스케일링 법칙** ⭐
[74]-[76]	Henighan / Gordon / Hestness 외	생성 모델·번역·딥러닝 스케일링
[77]	**Bahri, Dyer, Kaplan, Lee, Sharma**	스케일링 법칙 설명 — **Jaehoon Lee**(이번 주 Lee 2019 1저자) 공저
[78]	Michaud 외	스케일링의 양자화 모형
[80]	Olsson 외	인덕션 헤드 (트랜스포머 해석)
[81]	Meng 외 (ROME)	사실 지식의 위치 찾기·편집
[83]	Elhage 외	중첩(superposition)의 장난감 모형
[84]	Nanda 외	그로킹의 진척 척도

→ ✍️ [70] NAM은 $f(\mathbf{x}) = \sum_i f_i(x_i)$ (1층 덧셈). KAN의 $[n, 1]$ 층과 같다. KAN은 여기에 무엇을 더한 것인가? (합성 = 깊이)

p.39 해설 — 참고문헌 [85]-[99]: 해석, 활성화, 기호 회귀

번호	참고문헌	왜 볼까
[85]	Zhong, Liu, Tegmark, Andreas	"시계와 피자" — 모듈러 덧셈의 두 가지 기계적 설명
[86]	Liu, Gan, Tegmark	뇌 영감 모듈식 학습 — 능동적 MI
[88]	Goyal 외	활성화 함수 학습
[89]	**Ramachandran, Zoph, Le (2017)**	활성화 탐색 → **Swish/SiLU** (KAN의 $b(x)$) ⭐
[92]-[93]	Bohra / Aziznejad & Unser	학습 가능한 스플라인 활성화
[94]	Eureqa	유전 프로그래밍 기호 회귀
[96]	**Cranmer — PySR**	대표적 오픈소스 기호 회귀
[97]	Martius & Lampert — EQL	방정식 학습 신경망
[99]	Mundhenk 외	강화학습 기호 회귀

→ ✍️ [89]에서 SiLU $x\sigma(x)$ 는 자동 **탐색**으로 찾은 활성화다. 그렇다면 KAN은 "활성화를 탐색하는 대신 데이터마다 **학습**한다"고 요약할 수 있다. 장단점은?

p.40 해설 — 참고문헌 [100]-[116]: 편미분방정식과 수학

번호	참고문헌	왜 볼까
[100]	E & Yu — **Deep Ritz**	변분 문제의 딥러닝 수치해법
[101]	Cho, Nam, Yang, Yun, Hong, Park — **분리형 PINN**	한국 연구자들이 주도한 PINN 가속 연구 (소속은 원 논문에서 확인)
[102]	Li 외 — **푸리에 신경 연산자(FNO)**	연산자 학습
[106]	Lu 외 — **DeepONet**	연산자 학습
[107]	Gukov 외 *Learning to Unknot*	풀린 매듭 판별
[109]	Hughes	매듭 불변량 예측 신경망
[112]	Ruehle (2020)	끈 이론의 데이터 과학 (공저자)
[114]	Gukov, Halverson, Ruehle	기계학습에서 엄밀한 결과 얻기
[115]-[116]	Zhang 외 / Xu & Zikatanov	다중척도·대수적 다중격자 — 적응적 KAN 아이디어

→ ✍️ [101]의 저자 목록을 보고, 국내 대학의 AI 수학 연구자들이 세계적 연구와 어떻게 이어지는지 찾아보자 (이번 주 성균관대 이상구 외 2023 논문과 함께 읽으면 좋다). → 🔎 "AI for Math"가 하나의 연구 분야로 자리 잡았다는 점에 밑줄.

p.41 해설 — 참고문헌 [117]-[118]과 부록 A: KAN 기능

① **[117]** Chen, Hou, Wang — 지수 수렴 다중척도 유한요소법 (공저자 Hou·Wang). ② **[118] Sitzmann 외** — **SIREN** (주기 활성화를 쓰는 암시적 신경 표현) — 부록 B.3의 비교 대상.

③ **부록 A: KAN 기능들** — pykan의 주요 함수 (표 6은 다음 쪽).

④ 이 쪽에서 정리할 것: pykan 실습 순서

```
model = KAN(width=[2,5,1], grid=5, k=3)
model.train(dataset, lamb=0.01)   # 희소화 학습
model = model.prune()             # 가지치기
model.auto_symbolic()             # 자동 기호화
model.symbolic_formula()          # 수식 출력
```

(정확한 인자 이름은 설치한 pykan 버전의 문서에서 확인하자 — 버전마다 조금씩 다르다.)

→ ✍️ 위 순서를 p.13 Alice의 5단계와 짝지어 보자. → ✍️ ai_life 사이트에 "KAN으로 공식 찾기" 페이지를 만든다면 어떤 데이터(예: 진자의 주기 $T = 2\pi\sqrt{L/g}$)가 좋을까?

p.42 해설 — 표 6과 부록 B: LAN

① 표 6: KAN 기능 ⭐

함수	기능
`model.train(dataset)`	학습
`model.plot()`	시각화
`model.prune()`	가지치기
`model.fix_symbolic(l,i,j,fun)`	활성화 $\phi_{l,i,j}$를 기호 함수로 고정
`model.suggest_symbolic(l,i,j)`	맞는 기호 함수 후보 제안
`model.auto_symbolic()`	1순위 후보로 자동 고정
`model.symbolic_formula()`	기호 수식 반환

② 부록 B: 학습 가능한 활성화 신경망(LAN) — KAN의 두 변화 (1) 활성화가 **학습 가능**, (2) 활성화가 **엣지에** — 를 분리하기 위해, (1)만 가진 LAN(거의 MLP, 노드의 활성화만 스플라인) 제안.

③ LAN 매개변수 — $N^2L + NLG$ ($G \ll N$이므로 MLP 대비 오버헤드 작음). 사전학습된 MLP에서 초기화 후 활성화를 미세조정 가능.

④ 장단점 ⭐

LAN의 장점	LAN의 단점
개념이 더 단순 (MLP에서 활성화만 학습)	덜 해석 가능 (가중치 행렬은 MLP처럼 읽기 어려움)
더 잘 확장 (활성화 매개변수 N vs KAN N^2)	KAN보다 덜 정확 (MLP보단 정확)
→ 🔎 장단점 표에 밑줄.	

p.43 해설 — LAN의 해석 가능성, B.3 이미지 적합

① **그림 B.1** — LAN을 $f(x,y) = \exp(\sin(\pi x) + y^2)$에 학습. **그림 B.2** — 그림 4.1의 합성 예들에 LAN: KAN은 완벽히 해석 가능했던 예들이 LAN에선 **훨씬 덜** 해석 가능.

② **왜?** ⭐ — (1) 가중치 행렬은 학습 가능한 활성화보다 해석하기 어렵다. (2) 가중치 행렬이 **너무 많은 자유도**를 줘서 활성화가 지나치게 제약 없음. → 선형 가중치 행렬을 **없애는 것**(엣지 위 활성화, KAN처럼)이 해석 가능성에 필요한 듯. → 🔎 *getting rid of linear weight matrices ⋯ is necessary* 에 밑줄. p.32의 "어느 변화가 핵심인가?"에 대한 예비 답.

③ **B.3 이미지 적합 (LAN)** — **암시적 신경 표현**: 이미지를 2D 함수 $f(x,y)$ (픽셀 값 = 좌표의 함수)로. 신경망 f로 이미지를 압축. **SIREN**: 주기(사인) 활성화 MLP. LAN은 초기 활성화가 매끄러워서 SIREN이 요구하는 고주파 특징을 바로 못 냄 → $\phi(x) = b(x) + \text{spline}(x)$ 에서 $b(x)$를 **사인**으로⋯

→ ✍️ ai_life **02 컴퓨터비전**: "이미지 = 좌표를 넣으면 색을 내는 함수"라는 관점을 학생에게 소개해 보자. 해상도와 무관하게 확대할 수 있다는 장점!

p.44 해설 — 그림 B.3, 부록 C: 하이퍼파라미터, D: 파인만

① **그림 B.3** ⭐ — SIREN(고정 사인 활성화)을 LAN(학습 가능 활성화)으로 바꾸면 이미지 표현 향상. MLP·LAN 모두 $[2, 128, 128, 128, 128, 128, 1]$, Adam, 배치 4096, 학습률 10^{-3}로 5000스텝 + 10^{-4}로 5000스텝. LAN(주황)이 MLP(파랑)보다 높은 **PSNR**, MLP에서 초기화해 미세조정한 LAN(초록)도 향상. $G = 5$ → 매개변수 증가 약 $G/N = 5/128 \approx 4\%$. → 🔎 4%의 추가 비용으로 화질 향상에 밑줄.

② **부록 C: 하이퍼파라미터의 영향** ($f = \exp(\sin(\pi x) + y^2)$, 그림 C.1)

1. **엔트로피 벌점**이 활성 함수 수를 줄이는 데 필요
2. **시드**에 따라 결과가 달라짐 (운 나쁘면 가지친 신경망이 필요 이상으로 큼)
3. 전체 벌점 강도 λ가 희소성을 조절
4. 격자 수 G: 너무 작으면 각 활성화의 표현력이 낮아 **앙상블**처럼 여러 개를 씀
5. 스플라인 차수 k: 해석 가능성에 미묘한 영향만

③ **부록 D: 파인만 KAN** — 그림 D.1(파레토 프런티어), D.2(최고 KAN), D.3(최소 KAN, 테스트 RMSE $< 10^{-2}$).

→ ✍️ 2번(시드 의존성)은 Nakkiran이 그림 1에서 5회 시행 평균을 낸 이유와 같다. 과학적 주장에서 **반복 실험**이 왜 필요한지 정리하자.

p.45 해설 — 그림 C.1, 부록 E·F

① **그림 C.1** — 하이퍼파라미터(엔트로피 벌점 유무, λ, 시드, G, k)에 따른 해석 가능성 결과의 격자. 이상적으로는 $[2, 1, 1]$ 모양으로 가지쳐져야 한다. → ✍️ 그림에서 $[2, 1, 1]$을 정확히 찾은 칸에 동그라미를 치고, 그 칸들의 공통 설정을 찾아보자.

② **부록 E: 격자 크기에 대한 주의** ⭐ — 편미분방정식·회귀 모두, 학습 데이터를 **균일 격자**에서 뽑으면, 스플라인 격자 크기가 한 방향의 학습점 수와 비슷한 수준으로 커질 때 학습 손실이 **갑자기 증가**(성능 급락). 고차원 B-스플라인 구현 문제일 수도 — 추가 연구 필요. → 🔎 이 현상에 밑줄 — p.10의 "보간 임계점"과 연결해 생각해 보자 (스플라인 격자 = 데이터 간격이 되면?).

③ **부록 F: 특수함수 KAN** — 그림 F.2(최소 KAN, RMSE $< 10^{-2}$), F.1(최고 KAN).

→ ✍️ 부록 E 현상을 1D로 상상해 보자: 학습점이 0.1 간격인데 스플라인 매듭도 0.1 간격이면, 각 스플라인 조각이 점 하나만 보게 된다. 무슨 일이 생길까?

p.46 해설 — 그림 D.1: 파인만 데이터셋의 파레토 프런티어

① **그림 D.1** — 파인만 방정식마다 (매개변수 수, RMSE) 평면에서 KAN과 MLP의 파레토 프런티어.

② **읽는 법**

- 왼쪽 아래로 갈수록 좋다 (적은 매개변수, 낮은 오차)
- KAN 곡선이 MLP 곡선보다 왼쪽 아래에 있으면 KAN 우세

③ **관찰** — 본문 p.17의 결론처럼, 파인만 데이터에선 KAN과 MLP가 **비슷**한 경우가 많다. 변수 의존이 매끄럽고 단조라 MLP도 쉽게 잘 맞춘다. → 🔎 KAN이 확실히 우세한 칸과 MLP가 우세한 칸을 하나씩 찾아 표시해 보자.

→ ✍️ "모든 문제에서 KAN이 이긴다"가 아니라는 점이 중요하다. 이 그림을 근거로, 어떤 종류의 함수에서 KAN의 이점이 큰지 한 문장으로 정리해 보자 (힌트: 특수함수처럼 **구불구불하거나 복잡한** 1변수 성분이 있을 때).

p.47 해설 — 그림 D.2: 최고 파인만 KAN

① **그림 D.2** — 각 파인만 방정식에 대해 **테스트 RMSE가 가장 낮은** 가지친 KAN의 시각화.

② **보는 포인트**

- 각 엣지의 작은 그래프가 학습된 1변수 함수 — 선형, 2차, 사인, 로그처럼 보이는 것들을 찾아보자
- 흐린 엣지 = 크기가 작아 중요도가 낮음
- 최고 KAN은 최소 KAN보다 대체로 **크다** (정확도를 위해 자유도를 더 씀)

→ ✍️ 간섭 공식(I.37.4, $1 + a + 2\sqrt{a}\cos\delta$)의 KAN을 찾아, $\sqrt{a}$와 $\cos\delta$에 해당하는 엣지를 표시해 보자. → ✍️ 상대론적 속도 합성(I.16.6) KAN에서 $\operatorname{arctanh}$와 $\tanh$ 모양의 활성화를 찾을 수 있는가? (p.17의 "rapidity")

p.48 해설 — 그림 D.3: 최소 파인만 KAN

① **그림 D.3** — 테스트 RMSE $< 10^{-2}$를 만족하는 **가장 작은** 가지친 KAN.

② **최고 vs 최소** — 최소 KAN은 "충분히 좋은" 정확도에서 가장 단순한 구조 → **해석**에 유리. 최고 KAN은 가장 정확하지만 더 복잡. → 🔎 같은 방정식의 D.2와 D.3을 나란히 놓고 노드·엣지 수를 비교하자.

③ **본문과의 연결** — 표 2의 "자동 발견 KAN이 사람이 만든 것보다 작다"(p.17)를 그림으로 확인하는 쪽.

→ ✍️ 오컴의 면도날(Saltzer 결론): "같은 일을 하면 단순한 것이 낫다". 과학에서 최소 KAN이 왜 더 가치 있을 수 있는지 설명해 보자. → ✍️ 반대로, 공학(예: 정밀 시뮬레이션)에서는 최고 KAN이 더 필요할 수 있다. 목적에 따라 모델 선택이 달라지는 예를 들어 보자.

p.49 해설 — 그림 F.1: 최고 특수함수 KAN

① **그림 F.1** — 15개 특수함수(타원함수·타원적분·베셀·르장드르·구면조화)마다 **테스트 RMSE가 가장 낮은** KAN.

② **보는 포인트** — 특수함수는 기초함수로 닫힌 식이 없는 경우가 많다. 그런데도 KAN은 $[2,2,1]$, $[2,3,2,1]$ 같은 **작은** 구조로 근사 → 2변수 특수함수를 "1변수 함수 몇 개 + 덧셈"으로 분해한 셈 (p.15의 "1D 조회표" 아이디어). → 🔎 구면조화 $(m=0, n=1)$의 $[2,1,1]$ KAN — 가장 단순한 것 중 하나 — 을 찾아 표시하자.

→ ✍️ 구면조화 $Y_1^0 \propto \cos\theta$ 는 한 변수만의 함수다. 그런데 왜 입력이 2개인 $[2,1,1]$이 필요할까? (데이터의 두 입력 중 하나만 쓰이고 나머지는 거의 0인 엣지가 될 것 — 그림에서 확인!) → ✍️ 베셀 함수 $J_\nu(x)$는 진동하며 감쇠한다. KAN 엣지 중 이런 모양의 활성화를 찾아보자.

p.50 해설 — 그림 F.2: 최소 특수함수 KAN, 전체 정리

① **그림 F.2** — RMSE $< 10^{-2}$를 만족하는 **가장 작은** 특수함수 KAN들. 특수함수의 새로운 **수학적 성질**을 암시할 수도 있는 콤팩트한 표현 (p.15).

✍️ 논문 전체 정리 질문

1. 그림 0.1의 MLP vs KAN 표를 보지 않고 다시 그려 보자 (정리, 얕은 식, 깊은 식, 노드, 엣지).
2. 콜모고로프-아놀드 정리 (2.1)을 쓰고, "진짜 다변수 함수는 덧셈뿐"이라는 말의 뜻을 설명하자. 왜 오랫동안 "실용성 없다"고 여겨졌나?
3. 정리 2.1(KAT)의 오차 CG^{-k-1+m} 이 입력 차원과 무관하다는 것이 왜 "차원의 저주를 이긴다"는 뜻인지, 그리고 그 대가(가정)는 무엇인지 쓰자.
4. Alice의 5단계로 $f = \exp(\sin(\pi x) + y^2)$ 를 찾는 과정을 친구에게 설명하자.
5. **Cybenko(1989) → Hornik(1989) → KAN(2024)** 을 잇는 "보편 근사의 35년" 연표를 만들자. 각 논문이 무엇을 증명/제안했고, 무엇을 남겼나?
6. "AI 과학자 vs 과학자를 돕는 AI" — ai_life 학생들과 나눌 토론 질문 3개를 만들어 보자.